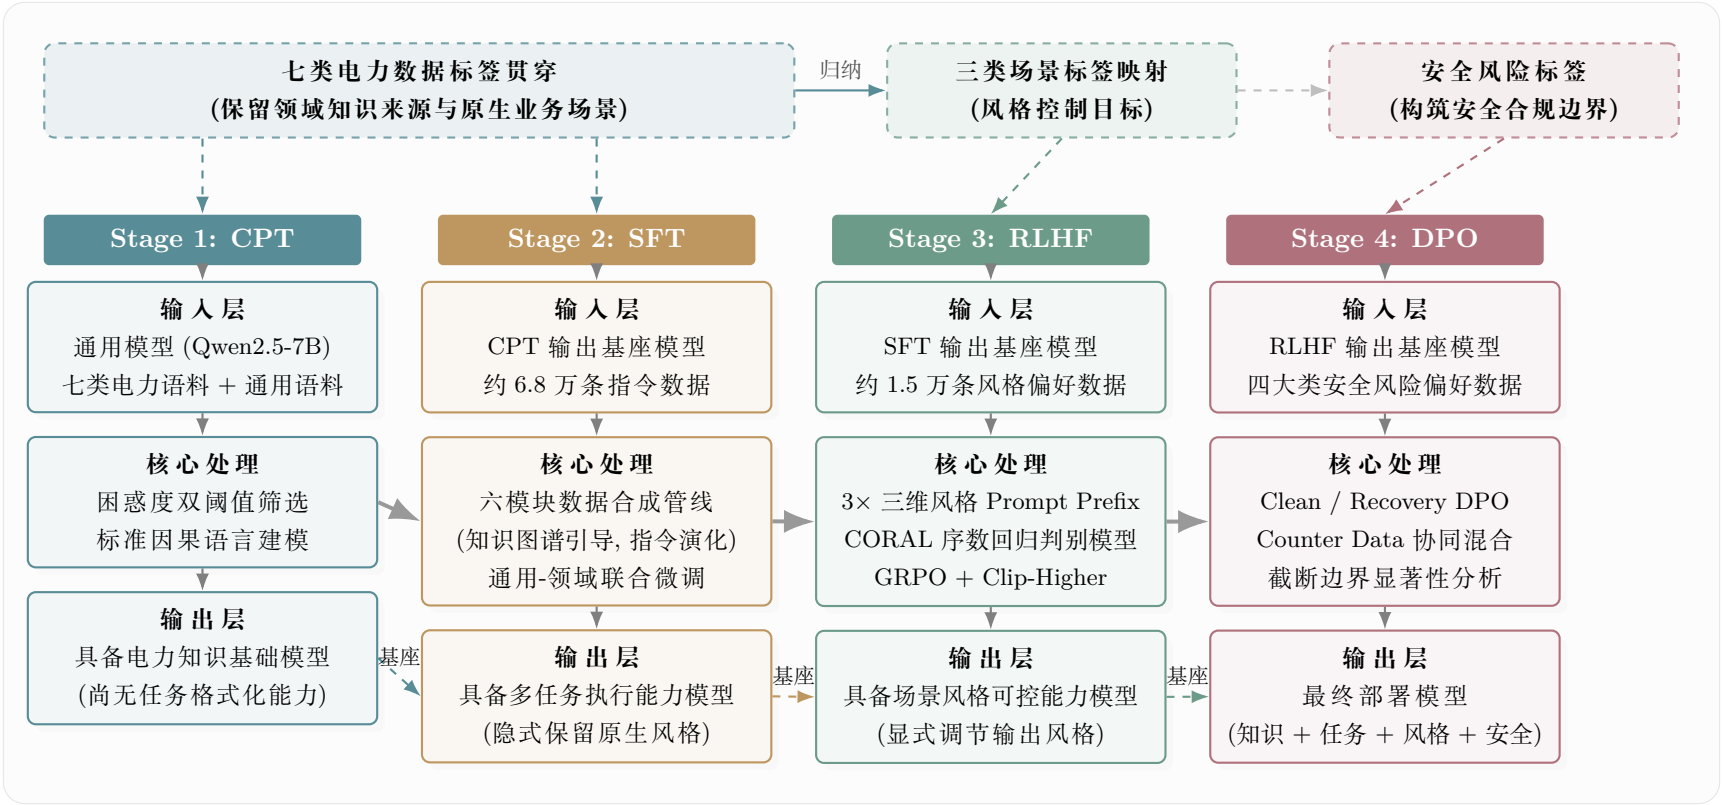

七类电力数据标签贯穿
(保留领域知识来源与原生业务场景)
归纳
三类场景标签映射
(风格控制目标)
安全风险标签
(构筑安全合规边界)
Stage 1: CPT
Stage 2: SFT
Stage 3: RLHF
Stage 4: DPO
输入层
通用模型 (Qwen2.5-7B)
七类电力语料 + 通用语料
核心处理
困惑度双阈值筛选
标准因果语言建模
输出层
具备电力知识基础模型
(尚无任务格式化能力)
基座
输入层
CPT 输出基座模型
约 6.8 万条指令数据
核心处理
六模块数据合成管线
(知识图谱引导, 指令演化)
通用-领域联合微调
输出层
具备多任务执行能力模型
(隐式保留原生风格)
基座
输入层
SFT 输出基座模型
约 1.5 万条风格偏好数据
核心处理
3× 三维风格 Prompt Prefix
CORAL 序数回归判别模型
GRPO + Clip-Higher
输出层
具备场景风格可控能力模型
(显式调节输出风格)
基座
输入层
RLHF 输出基座模型
四大类安全风险偏好数据
核心处理
Clean / Recovery DPO
Counter Data 协同混合
截断边界显著性分析
输出层
最终部署模型
(知识 + 任务 + 风格 + 安全)