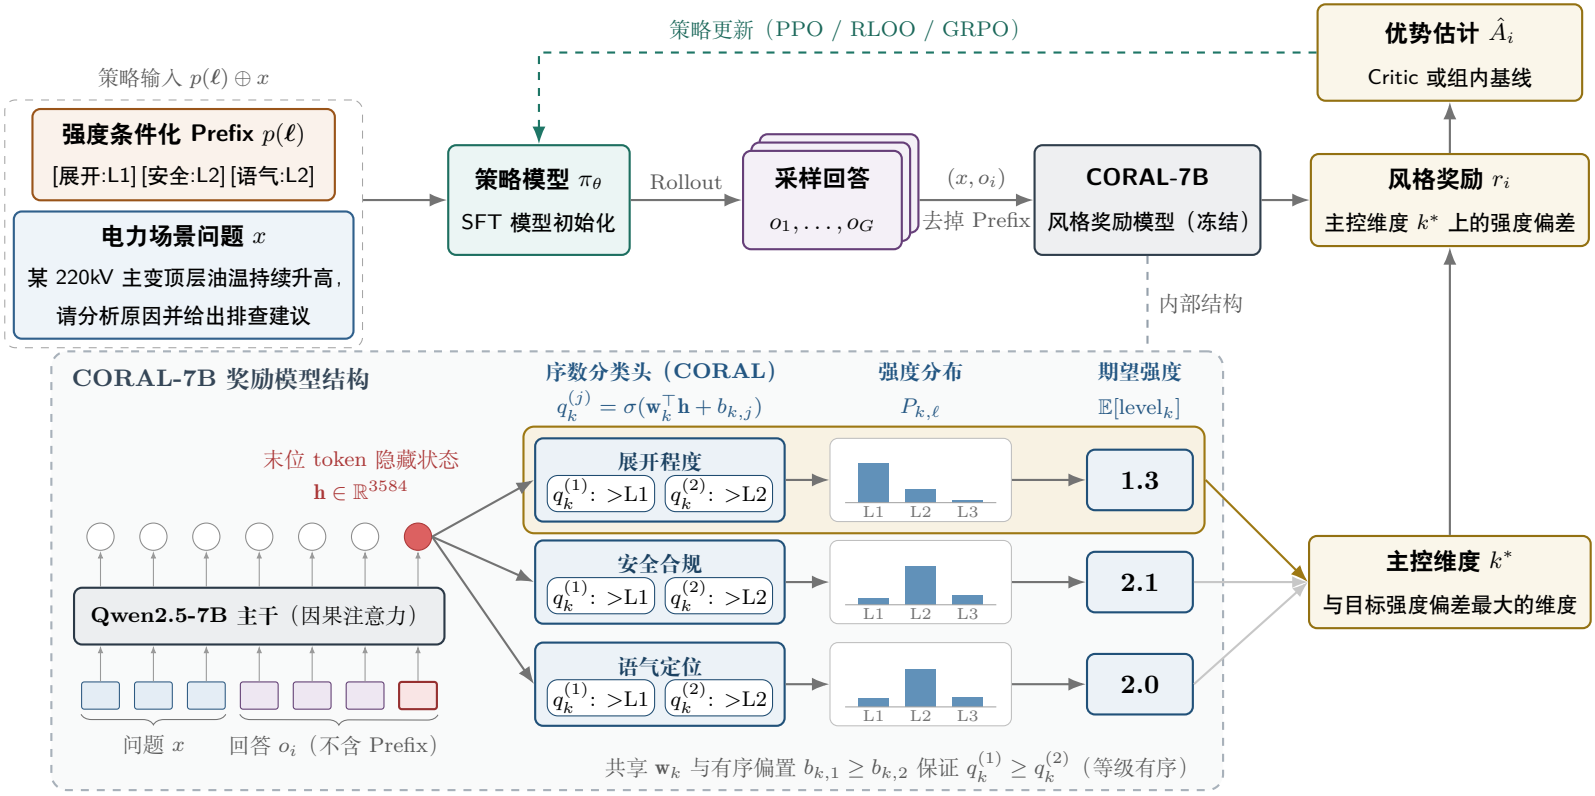

策略更新（PPO / RLOO / GRPO）
优势估计 $\hat{A}_i$
Critic 或组内基线
策略输入 $p(\ell) \oplus x$
强度条件化 Prefix $p(\ell)$
[展开:L1] [安全:L2] [语气:L2]
电力场景问题 x
某 220kV 主变顶层油温持续升高，请分析原因并给出排查建议
策略模型 π_θ
SFT 模型初始化
Rollout
采样回答
$o_1, \ldots, o_G$
(x, o_i)
去掉 Prefix
CORAL-7B
风格奖励模型（冻结）
风格奖励 r_i
主控维度 k^* 上的强度偏差
内部结构
CORAL-7B 奖励模型结构
序数分类头（CORAL）
$q_k^{(j)} = \sigma(\mathbf{w}_k^\top \mathbf{h} + b_{k,j})$
强度分布
$P_{k,\ell}$
期望强度
$\mathbb{E}[\text{level}_k]$
末位 token 隐藏状态
$\mathbf{h} \in \mathbb{R}^{3584}$
Qwen2.5-7B 主干（因果注意力）
问题 x
回答 o_i（不含 Prefix）
展开程度
$q_k^{(1)}$: >L1
$q_k^{(2)}$: >L2
L1 L2 L3
1.3
安全合规
$q_k^{(1)}$: >L1
$q_k^{(2)}$: >L2
L1 L2 L3
2.1
语气定位
$q_k^{(1)}$: >L1
$q_k^{(2)}$: >L2
L1 L2 L3
2.0
主控维度 k^*
与目标强度偏差最大的维度
共享 $\mathbf{w}_k$ 与有序偏置 $b_{k,1} \geq b_{k,2}$ 保证 $q_k^{(1)} \geq q_k^{(2)}$（等级有序）