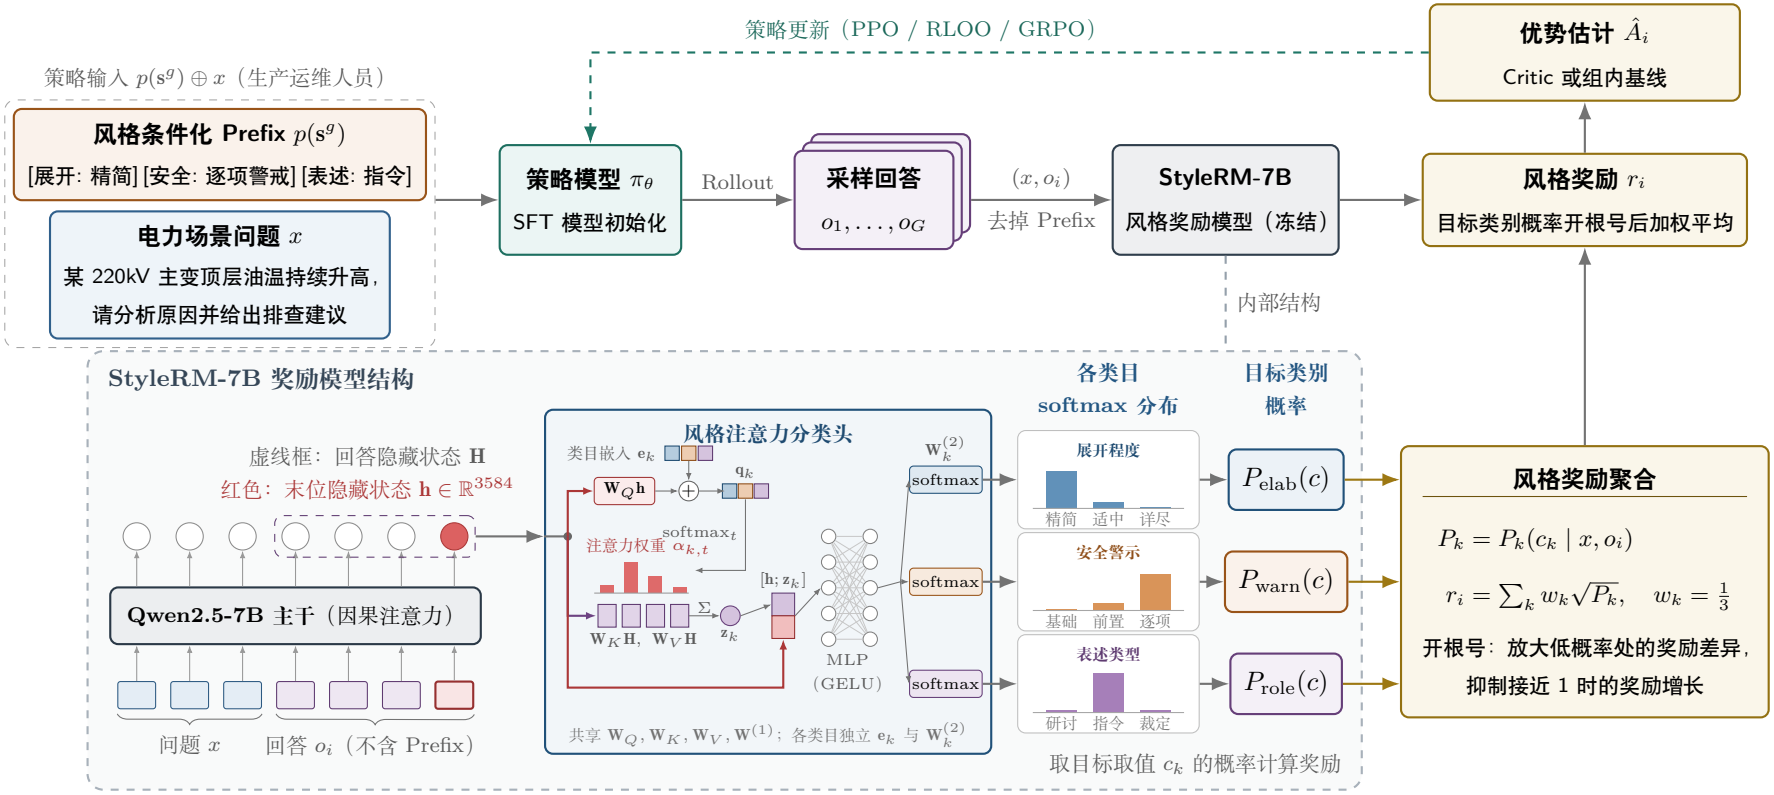

策略更新（PPO / RLOO / GRPO）
优势估计 $\hat{A}_i$
Critic 或组内基线
策略输入 $p(\mathbf{s}^g) \oplus x$（生产运维人员）
风格条件化 Prefix $p(\mathbf{s}^g)$
[展开: 精简] [安全: 逐项警戒] [表述: 指令]
电力场景问题 x
某 220kV 主变顶层油温持续升高，请分析原因并给出排查建议
策略模型 π_θ
SFT 模型初始化
Rollout
采样回答
$o_1, \ldots, o_G$
(x, o_i)
去掉 Prefix
StyleRM-7B
风格奖励模型（冻结）
风格奖励 r_i
目标类别概率开根号后加权平均
内部结构
StyleRM-7B 奖励模型结构
虚线框：回答隐藏状态 H
红色：末位隐藏状态 $\mathbf{h} \in \mathbb{R}^{3584}$
Qwen2.5-7B 主干（因果注意力）
问题 x
回答 o_i（不含 Prefix）
风格注意力分类头
类目嵌入 $\mathbf{e}_k$
$\mathbf{W}_Q\mathbf{h}$
$\mathbf{q}_k$
注意力权重 $\alpha_{k,t}$
softmax_t
$\mathbf{W}_K\mathbf{H}$, $\mathbf{W}_V\mathbf{H}$
Σ
$\mathbf{z}_k$
$[\mathbf{h}; \mathbf{z}_k]$
MLP (GELU)
$\mathbf{W}_k^{(2)}$
softmax
softmax
softmax
共享 $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V, \mathbf{W}^{(1)}$；各类目独立 $\mathbf{e}_k$ 与 $\mathbf{W}_k^{(2)}$
各类目 softmax 分布
展开程度
精简 适中 详尽
安全警示
基础 前置 逐项
表述类型
研讨 指令 裁定
目标类别概率
$P_{\text{elab}}(c)$
$P_{\text{warn}}(c)$
$P_{\text{role}}(c)$
取目标取值 c_k 的概率计算奖励
风格奖励聚合
$P_k = P_k(c_k \mid x, o_i)$
$r_i = \sum_k w_k \sqrt{P_k}, \quad w_k = \frac{1}{3}$
开根号：放大低概率处的奖励差异，抑制接近 1 时的奖励增长