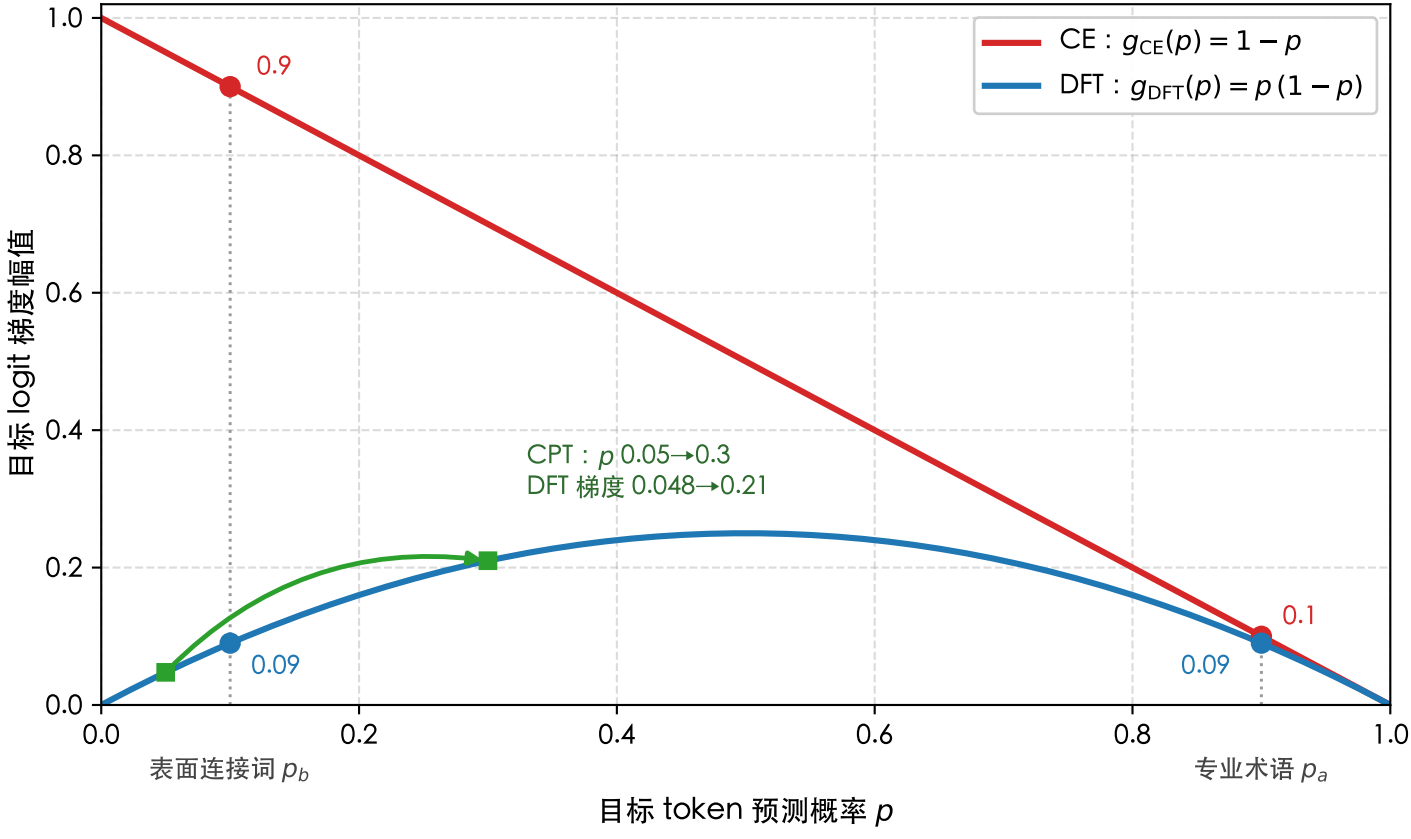
CE：$g_{CE}(p) = 1 - p$
DFT：$g_{DFT}(p) = p(1-p)$
0.9
0.1
0.09
0.09
CPT：p 0.05→0.3
DFT 梯度 0.048→0.21
目标 logit 梯度幅值
目标 token 预测概率 p
表面连接词 p_b
专业术语 p_a
0.0
0.2
0.4
0.6
0.8
1.0