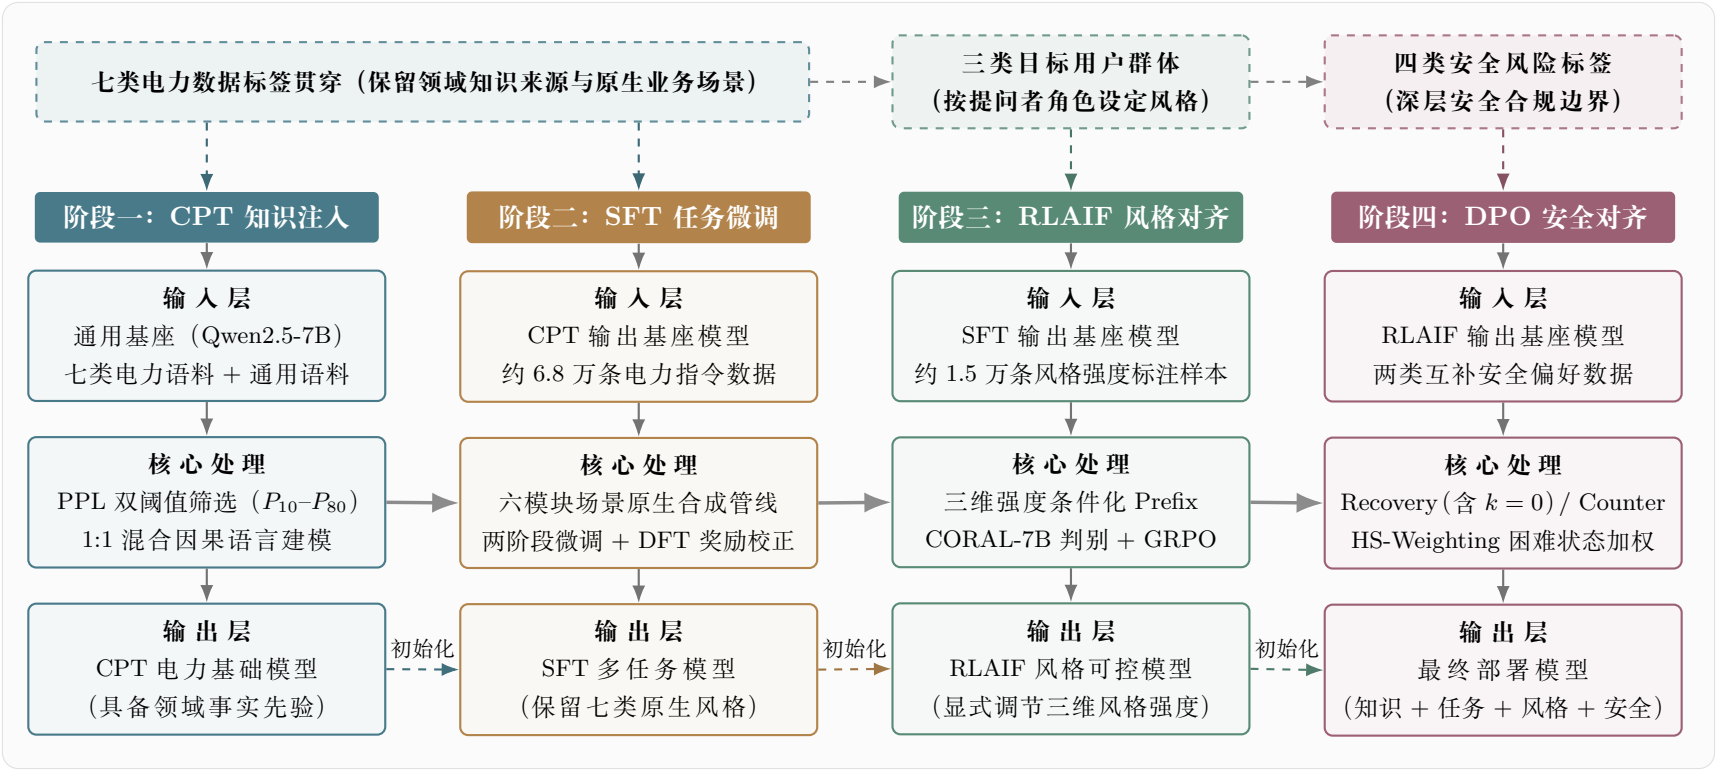

七类电力数据标签贯穿（保留领域知识来源与原生业务场景）
三类目标用户群体
（按提问者角色设定风格）
四类安全风险标签
（深层安全合规边界）
阶段一：CPT 知识注入
阶段二：SFT 任务微调
阶段三：RLAIF 风格对齐
阶段四：DPO 安全对齐
输 入 层
通用基座（Qwen2.5-7B）
七类电力语料 + 通用语料
输 入 层
CPT 输出基座模型
约 6.8 万条电力指令数据
输 入 层
SFT 输出基座模型
约 1.5 万条风格强度标注样本
输 入 层
RLAIF 输出基座模型
两类互补安全偏好数据
核 心 处 理
PPL 双阈值筛选（P_{10}–P_{80}）
1:1 混合因果语言建模
核 心 处 理
六模块场景原生合成管线
两阶段微调 + DFT 奖励校正
核 心 处 理
三维强度条件化 Prefix
CORAL-7B 判别 + GRPO
核 心 处 理
Recovery（含 $k = 0$）/ Counter
HS-Weighting 困难状态加权
输 出 层
CPT 电力基础模型
（具备领域事实先验）
初始化
输 出 层
SFT 多任务模型
（保留七类原生风格）
初始化
输 出 层
RLAIF 风格可控模型
（显式调节三维风格强度）
初始化
输 出 层
最终部署模型
（知识 + 任务 + 风格 + 安全）