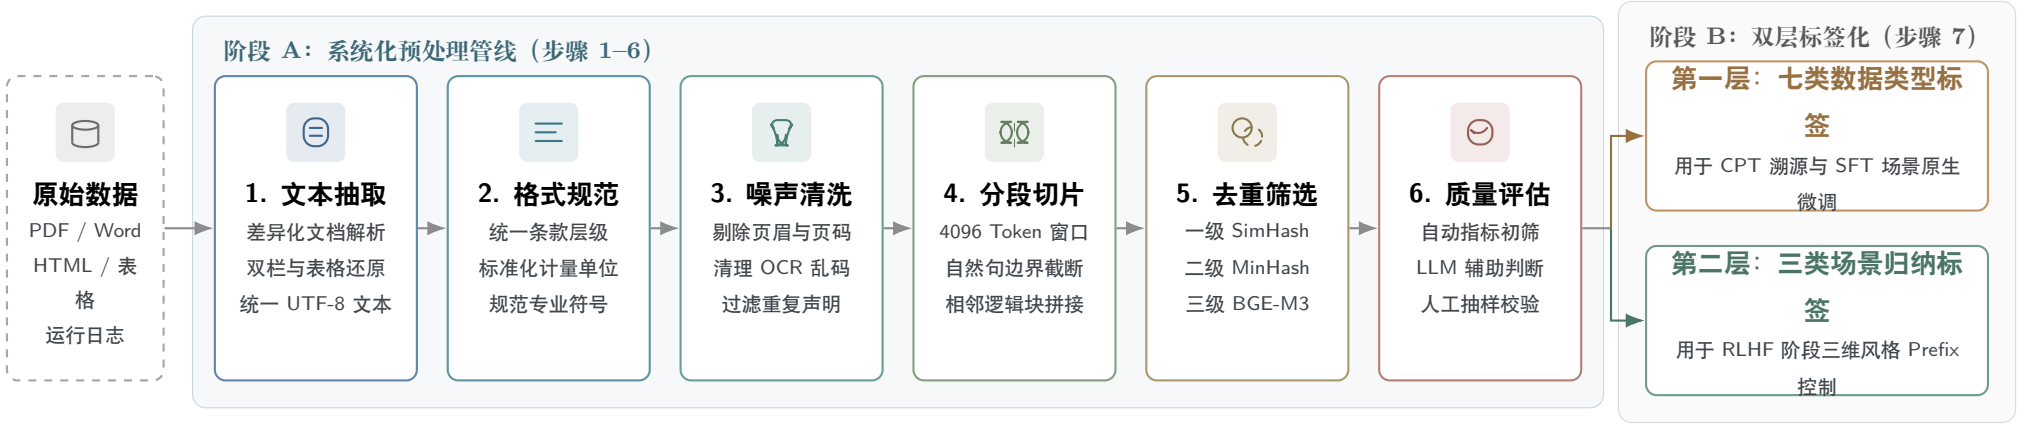

原始数据
PDF / Word
HTML / 表格
运行日志
阶段 A：系统化预处理管线（步骤 1–6）
1. 文本抽取
差异化文档解析
双栏与表格还原
统一 UTF-8 文本
2. 格式规范
统一条款层级
标准化计量单位
规范专业符号
3. 噪声清洗
剔除页眉与页码
清理 OCR 乱码
过滤重复声明
4. 分段切片
4096 Token 窗口
自然句边界截断
相邻逻辑块拼接
5. 去重筛选
一级 SimHash
二级 MinHash
三级 BGE-M3
6. 质量评估
自动指标初筛
LLM 辅助判断
人工抽样校验
阶段 B：双层标签化（步骤 7）
第一层：七类数据类型标签
用于 CPT 溯源与 SFT 场景原生微调
第二层：三类场景归纳标签
用于 RLHF 阶段三维风格 Prefix 控制