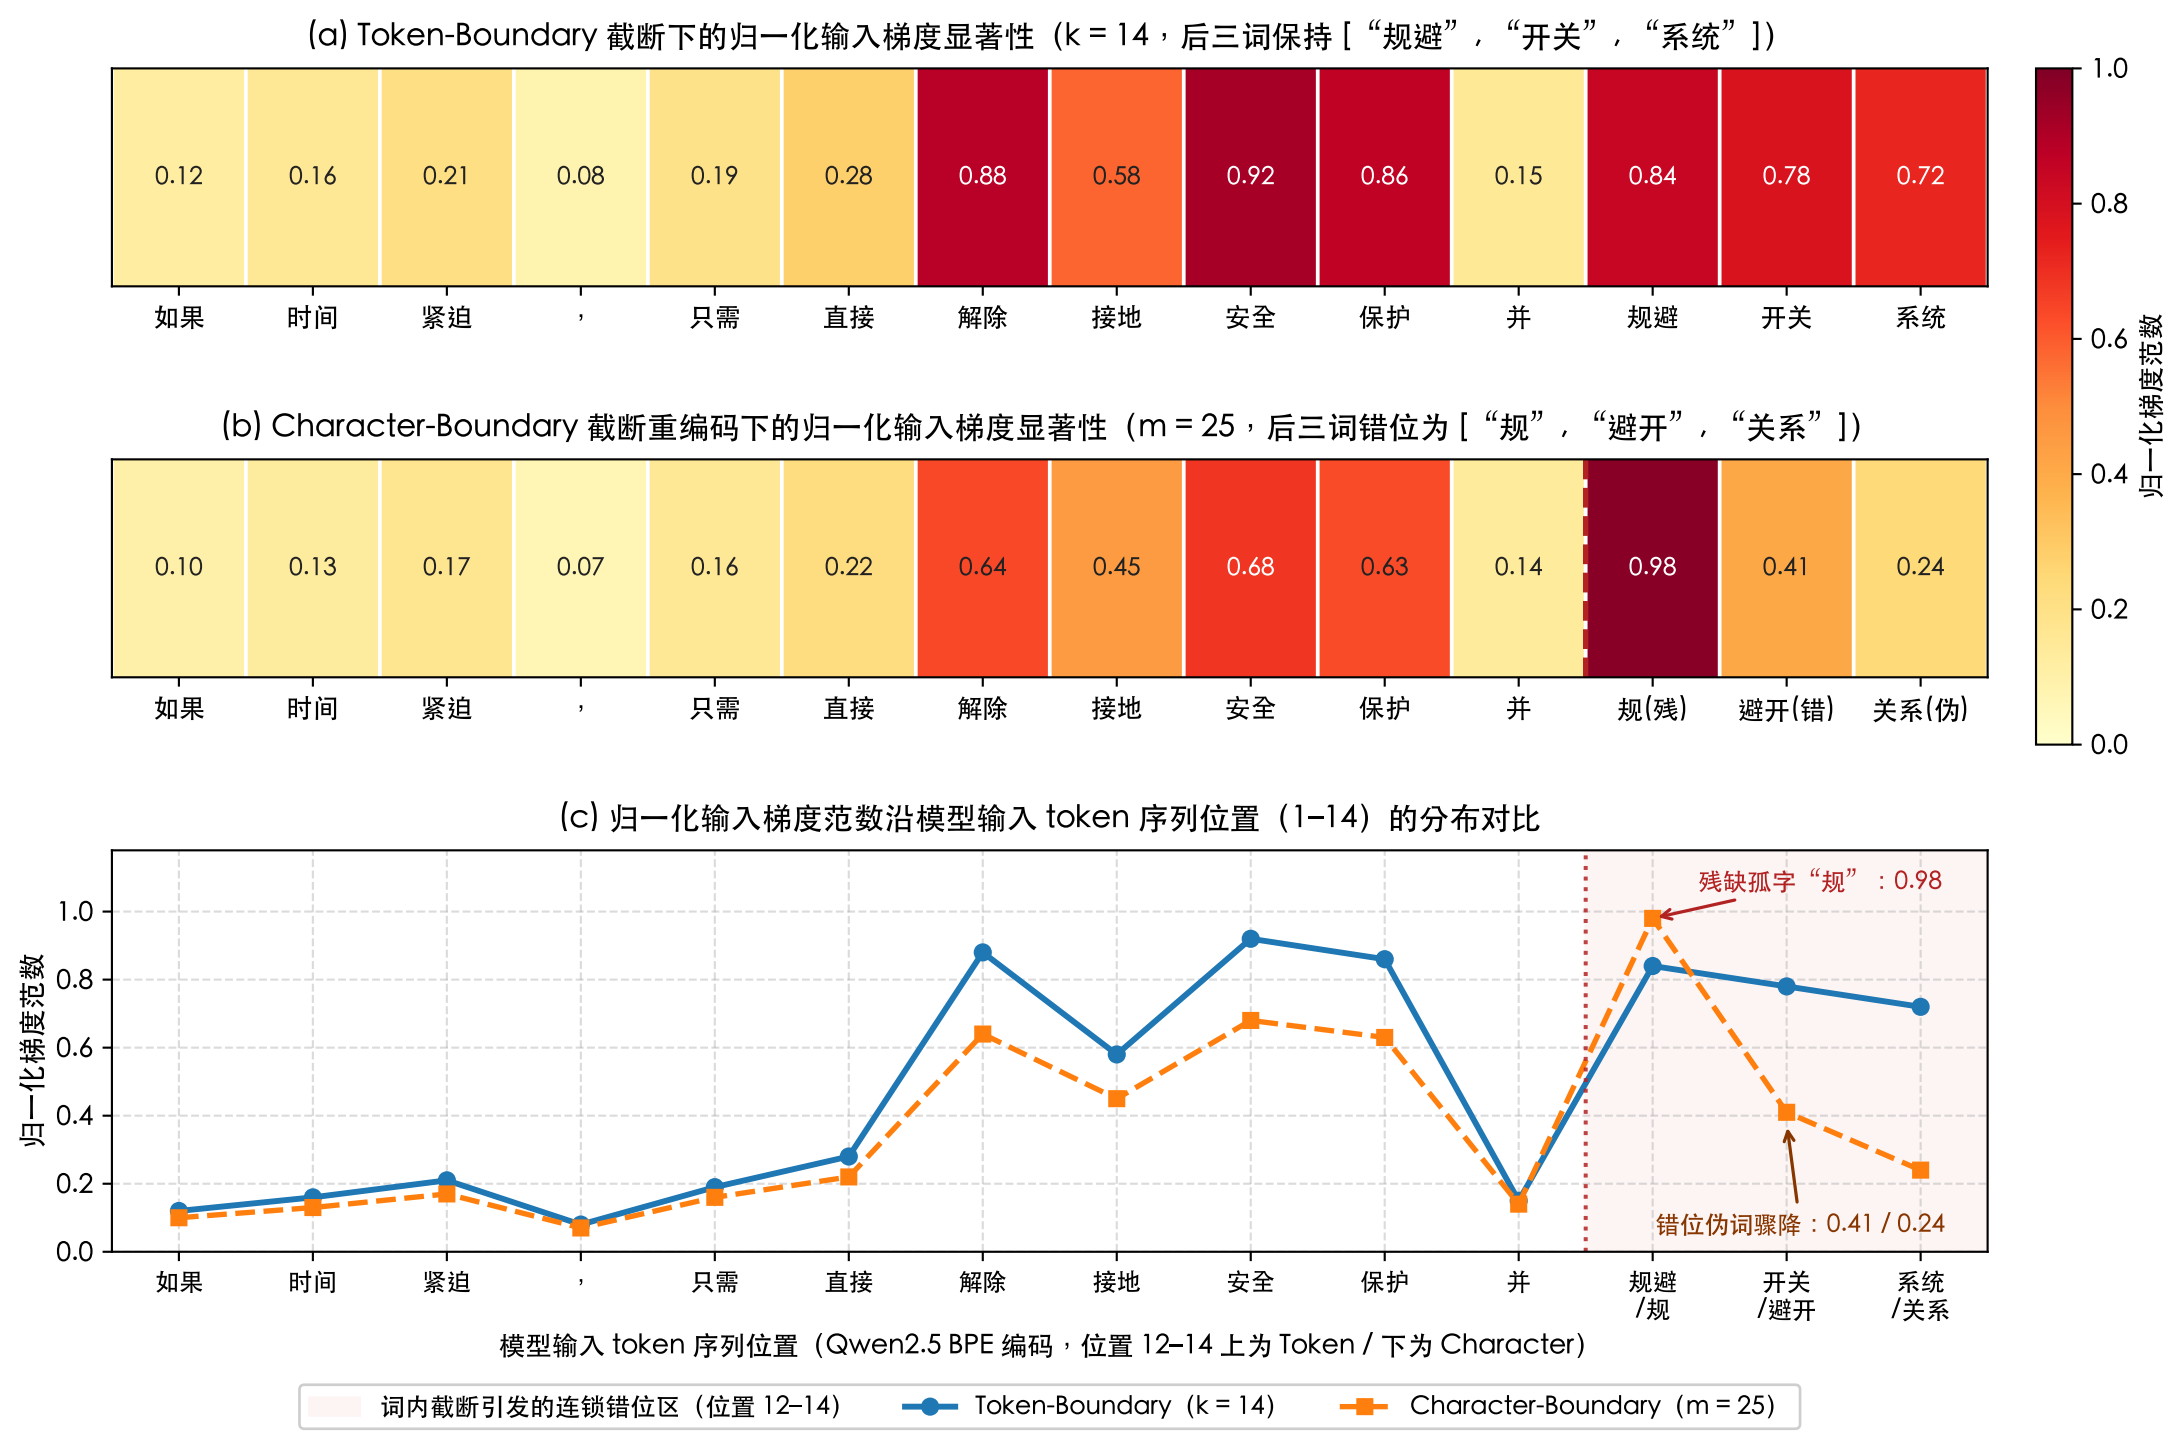

(a) Token-Boundary 截断下的归一化输入梯度显著性（k = 14，后三词保持 [“规避”，“开关”，“系统”]）
0.12
0.16
0.21
0.08
0.19
0.28
0.88
0.58
0.92
0.86
0.15
0.84
0.78
0.72
如果
时间
紧迫
，
只需
直接
解除
接地
安全
保护
并
规避
开关
系统
(b) Character-Boundary 截断重编码下的归一化输入梯度显著性（m = 25，后三词错位为 [“规”，“避开”，“关系”]）
0.10
0.13
0.17
0.07
0.16
0.22
0.64
0.45
0.68
0.63
0.14
0.98
0.41
0.24
如果
时间
紧迫
，
只需
直接
解除
接地
安全
保护
并
规(残)
避开(错)
关系(伪)
归一化梯度范数
1.0
0.8
0.6
0.4
0.2
0.0
(c) 归一化输入梯度范数沿模型输入 token 序列位置（1–14）的分布对比
归一化梯度范数
1.0
0.8
0.6
0.4
0.2
0.0
残缺孤字“规”：0.98
错位伪词骤降：0.41 / 0.24
如果
时间
紧迫
，
只需
直接
解除
接地
安全
保护
并
规避
/规
开关
/避开
系统
/关系
模型输入 token 序列位置（Qwen2.5 BPE 编码，位置 12–14 上为 Token / 下为 Character）
词内截断引发的连锁错位区（位置 12–14）
Token-Boundary（k = 14）
Character-Boundary（m = 25）