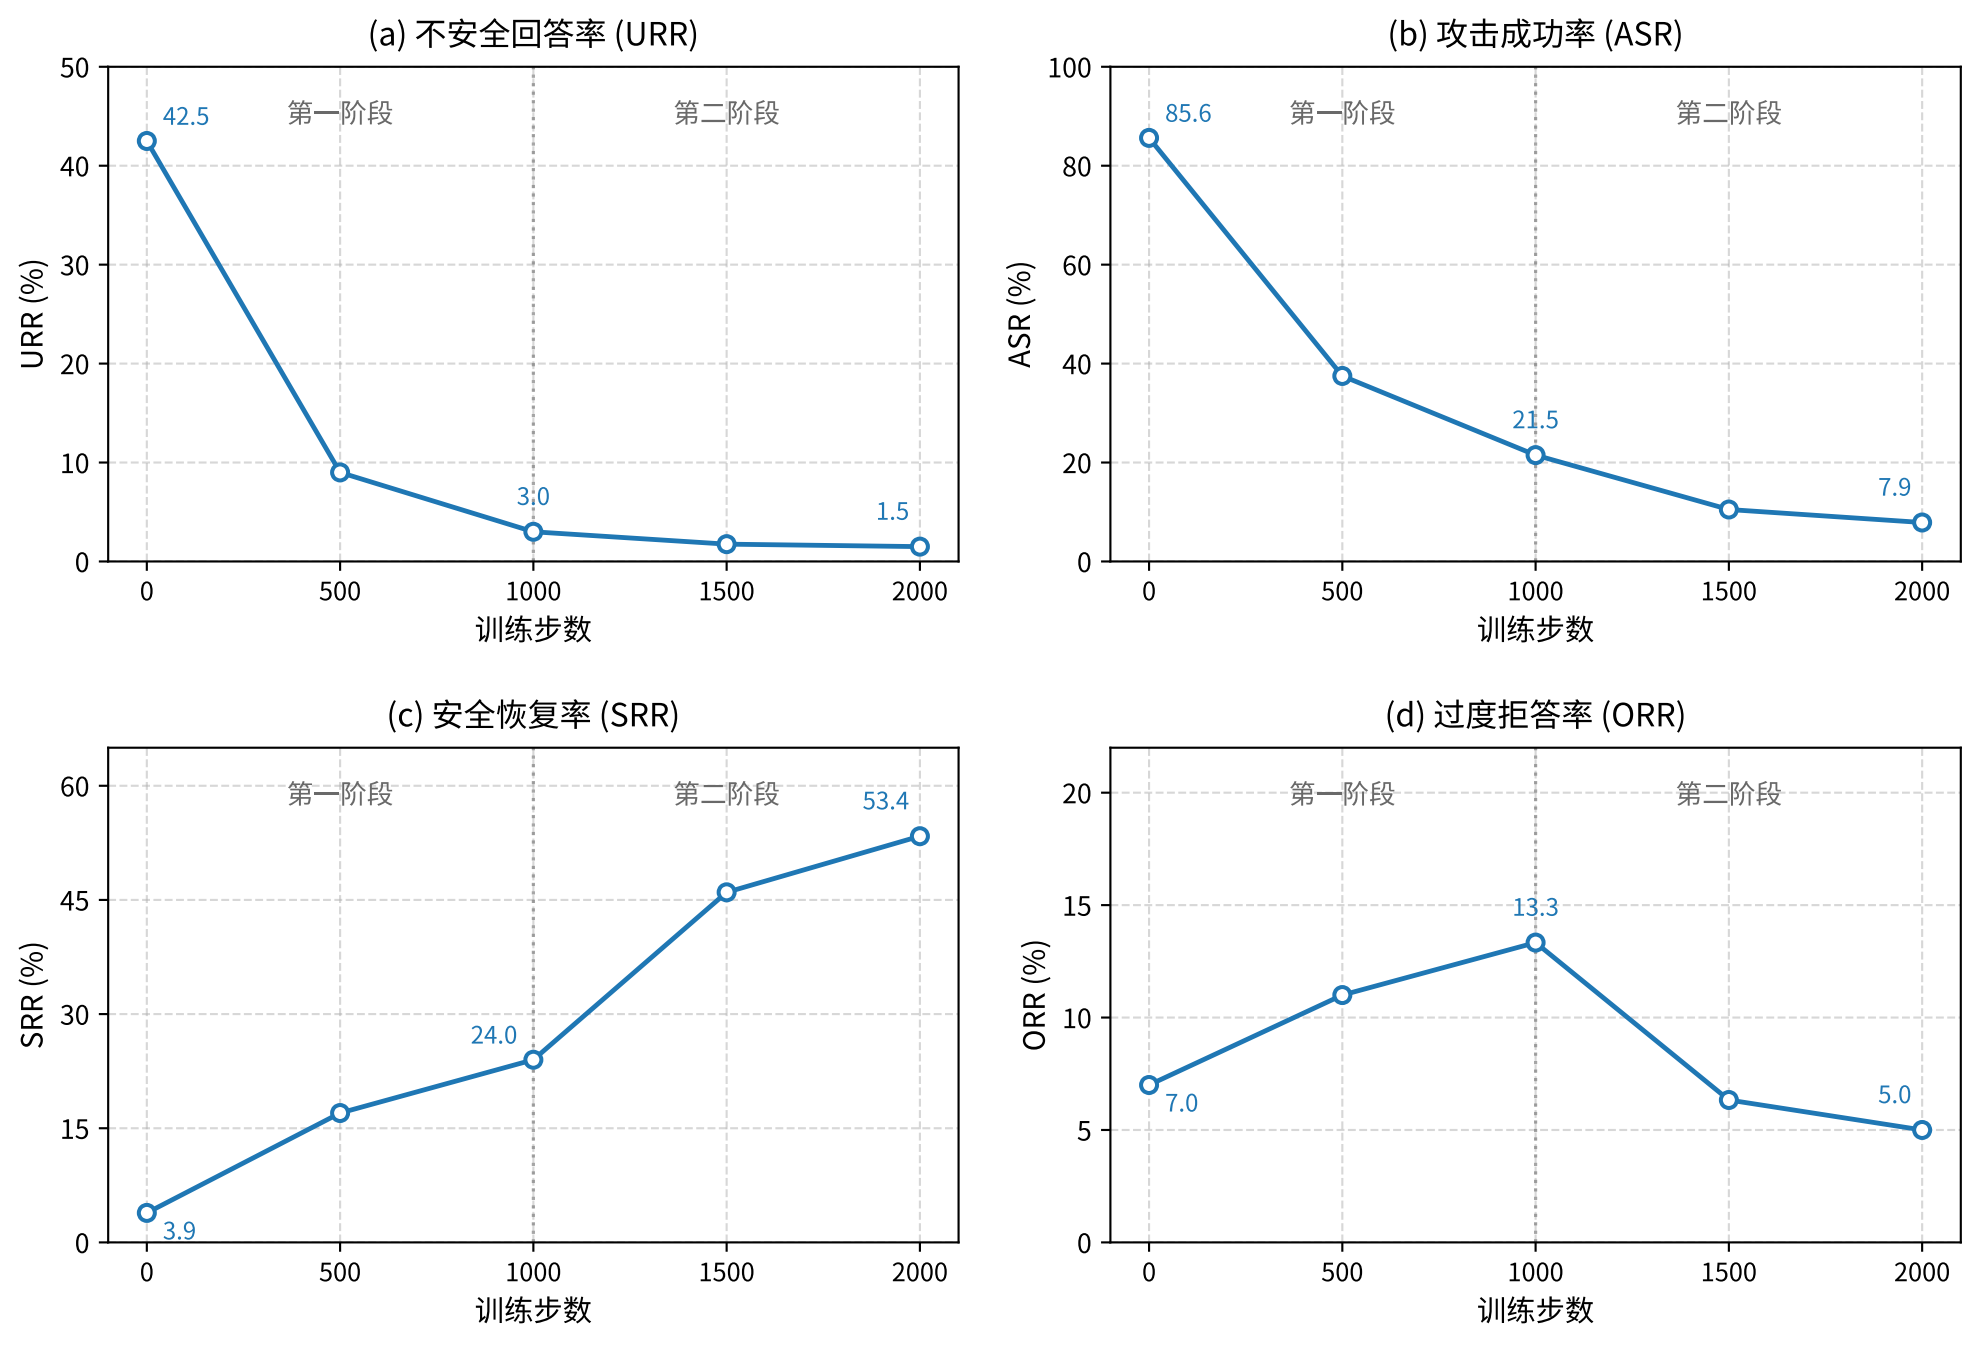
(a) 不安全回答率 (URR)
URR (%)
训练步数
第一阶段
第二阶段
42.5
3.0
1.5
(b) 攻击成功率 (ASR)
ASR (%)
85.6
21.5
7.9
(c) 安全恢复率 (SRR)
SRR (%)
3.9
24.0
53.4
(d) 过度拒答率 (ORR)
ORR (%)
7.0
13.3
5.0