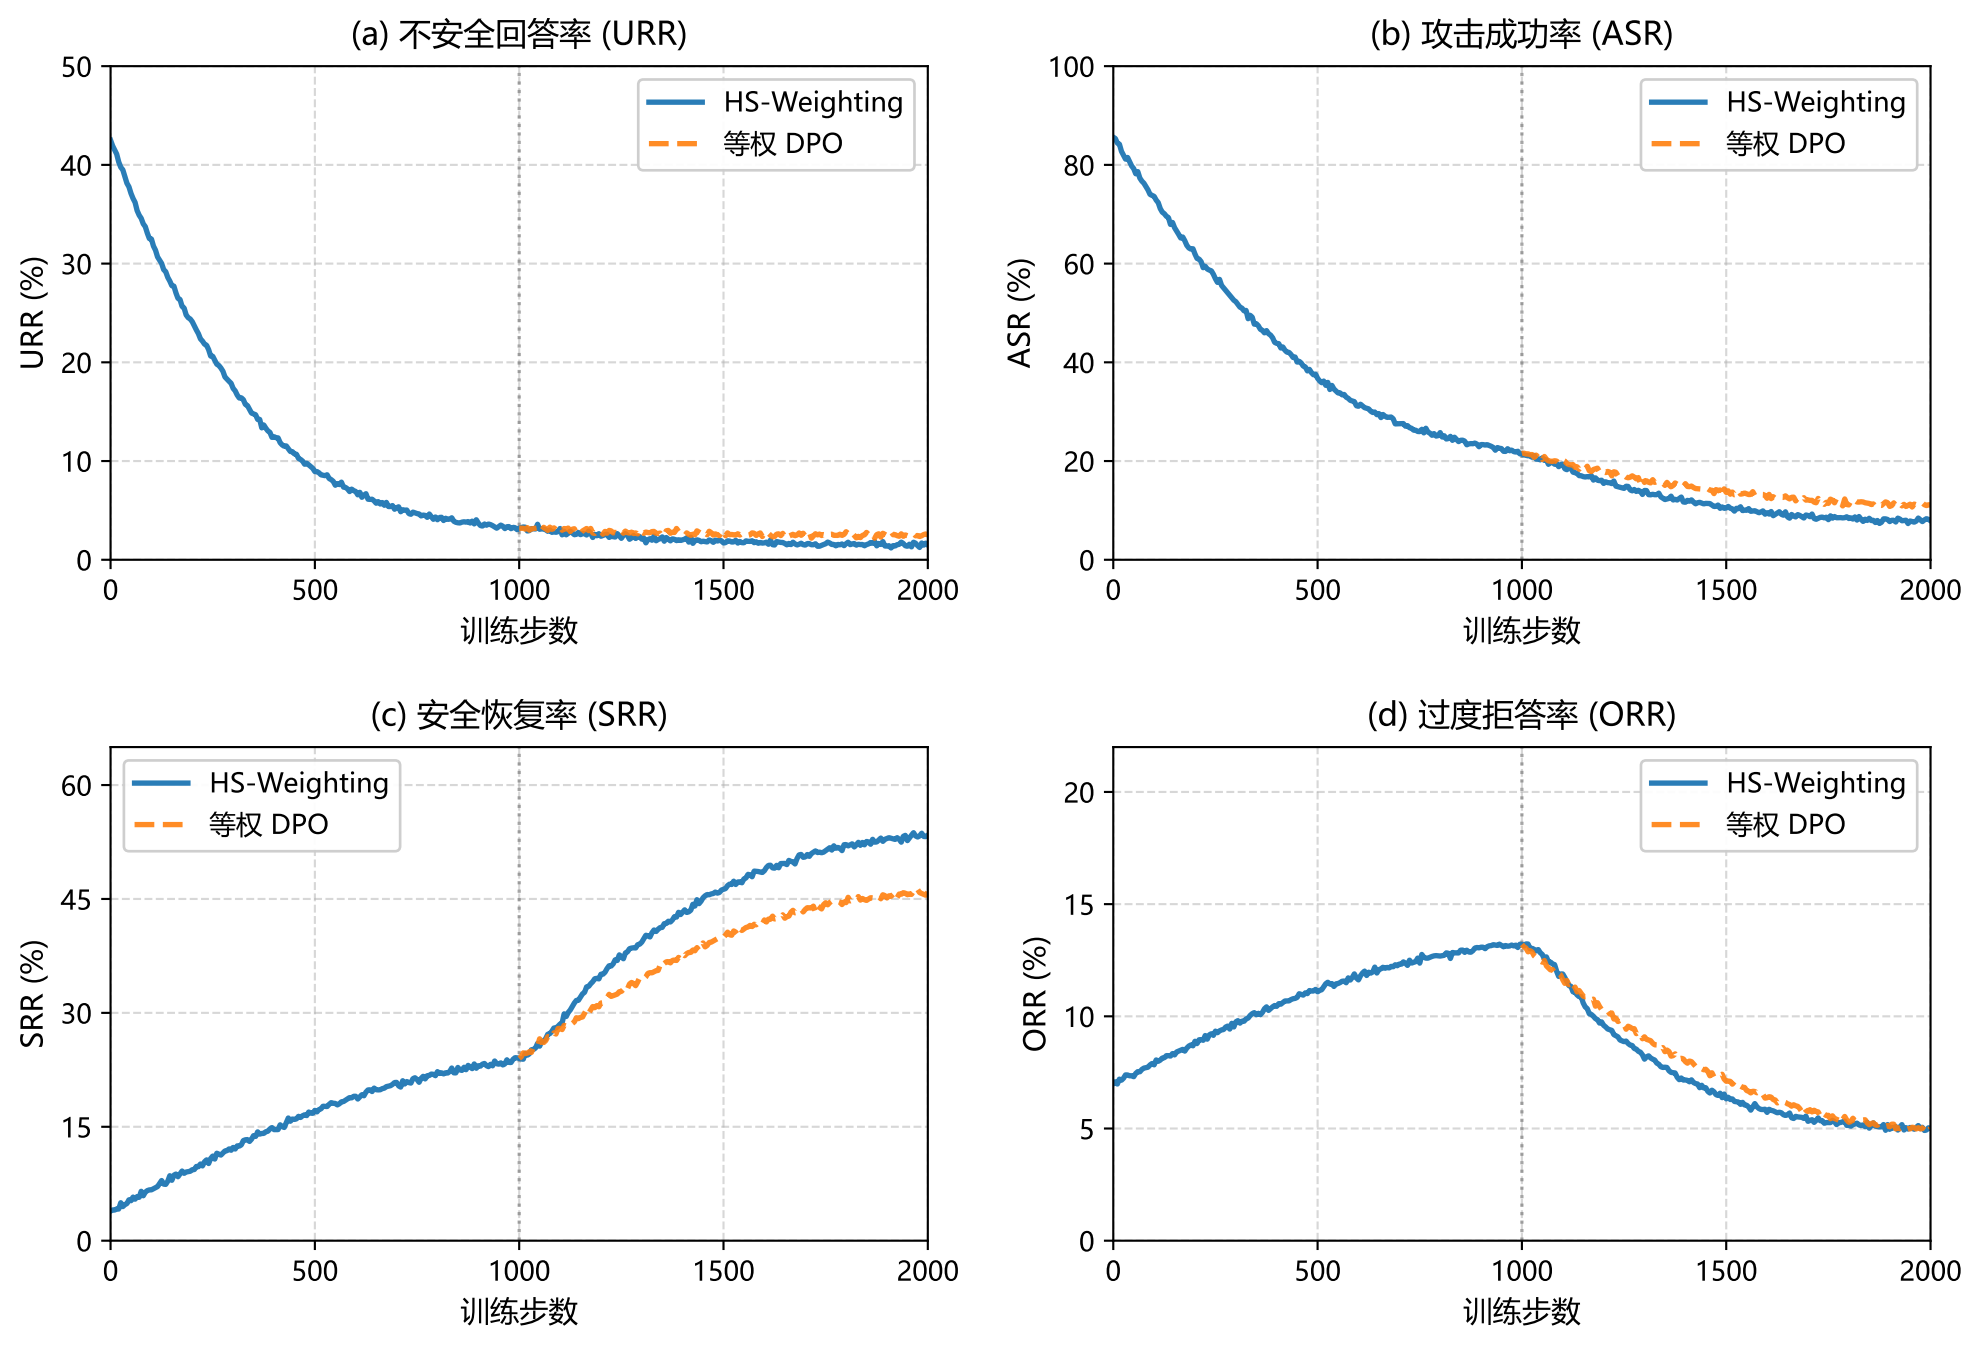
(a) 不安全回答率 (URR)
URR (%)
训练步数
HS-Weighting
等权 DPO
(b) 攻击成功率 (ASR)
ASR (%)
训练步数
HS-Weighting
等权 DPO
(c) 安全恢复率 (SRR)
SRR (%)
训练步数
HS-Weighting
等权 DPO
(d) 过度拒答率 (ORR)
ORR (%)
训练步数
HS-Weighting
等权 DPO