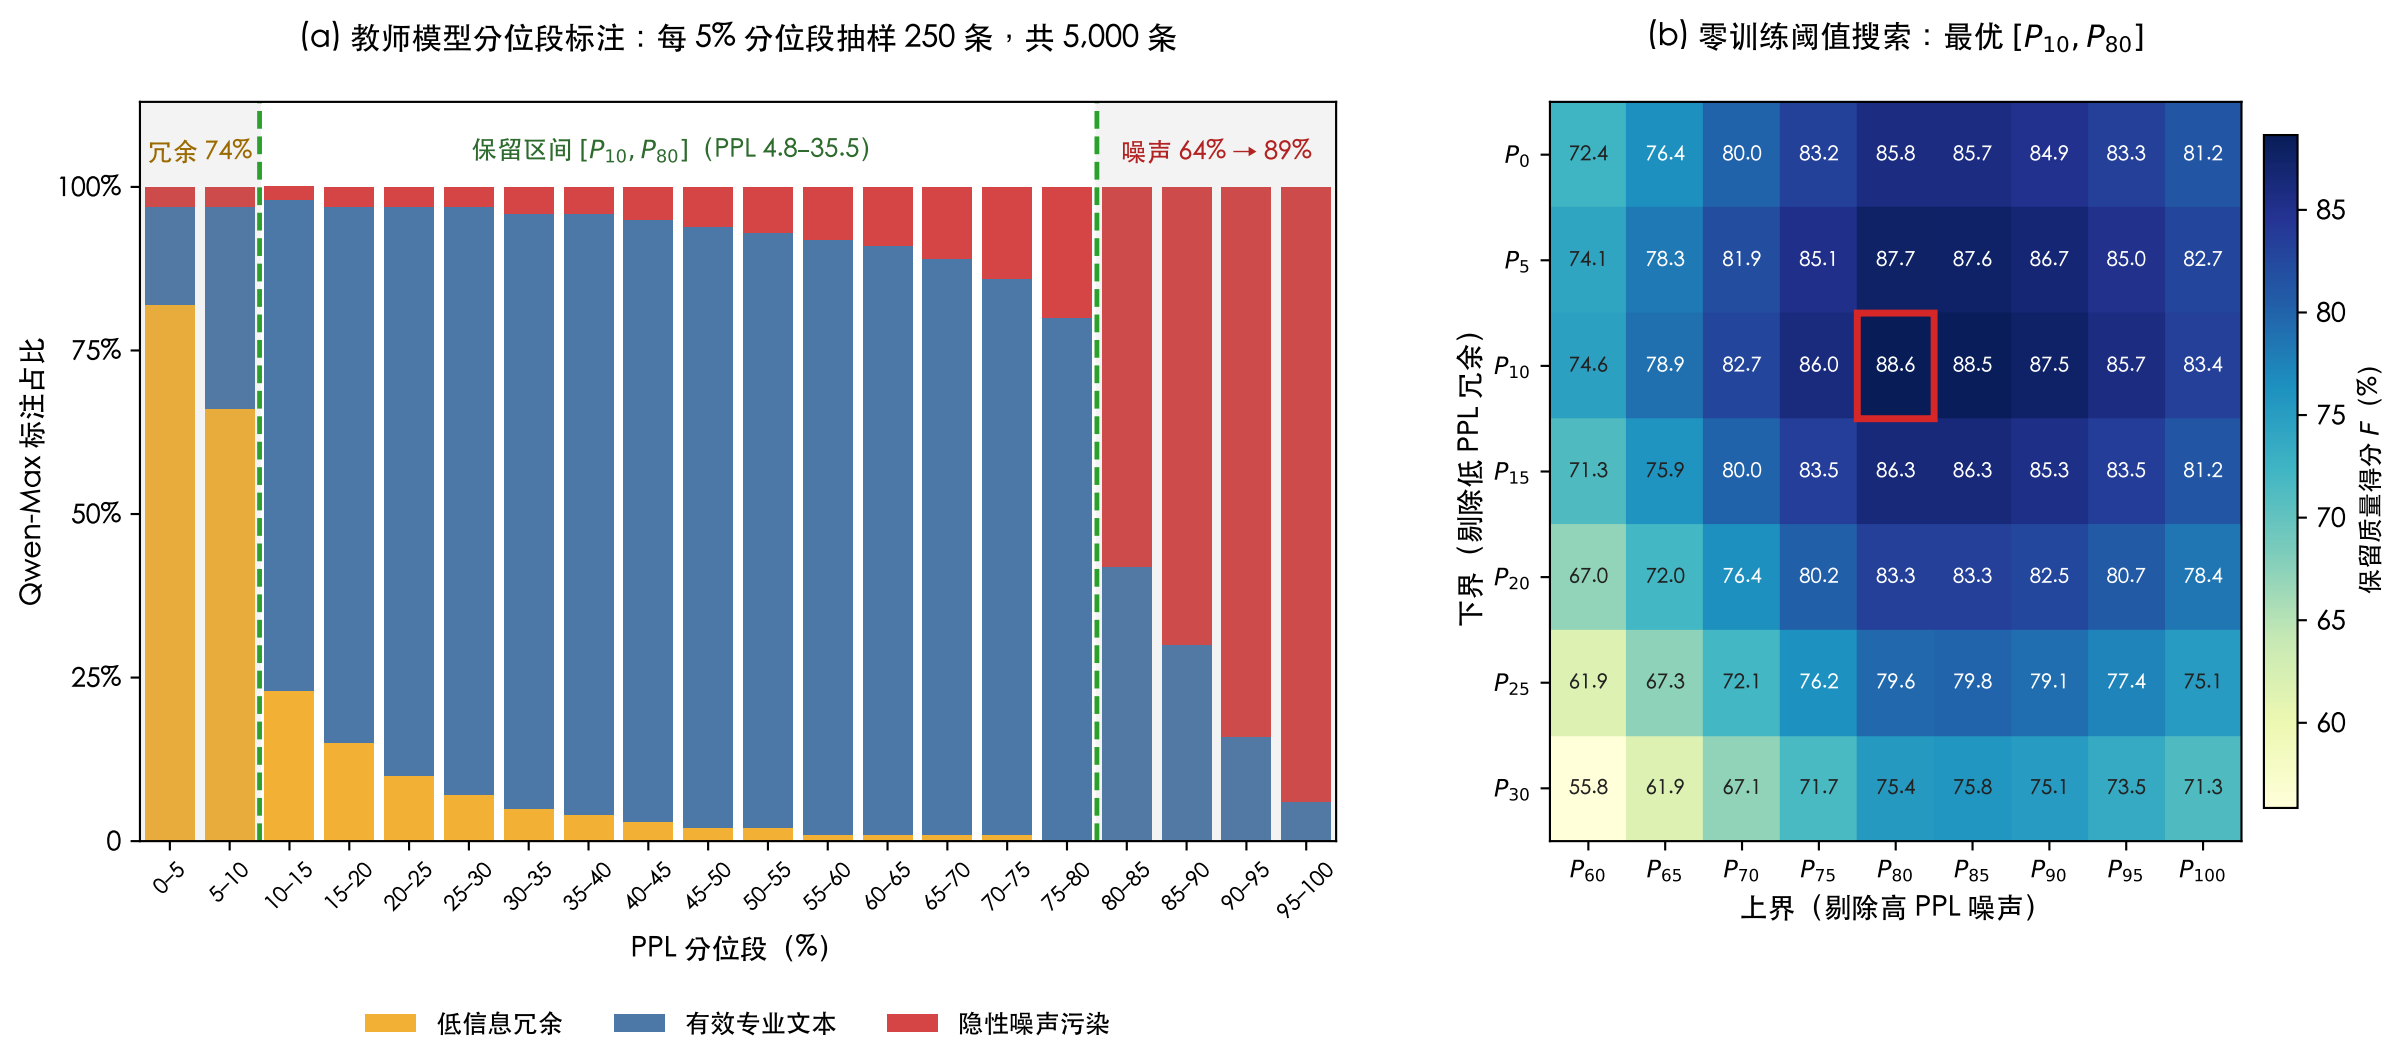

(a) 教师模型分位段标注：每 5% 分位段抽样 250 条，共 5,000 条
冗余 74%
保留区间 [P_{10}, P_{80}]（PPL 4.8–35.5）
噪声 64% → 89%
Qwen-Max 标注占比
100%
75%
50%
25%
0
0–5
5–10
10–15
15–20
20–25
25–30
30–35
35–40
40–45
45–50
50–55
55–60
60–65
65–70
70–75
75–80
80–85
85–90
90–95
95–100
PPL 分位段（%）
低信息冗余
有效专业文本
隐性噪声污染
(b) 零训练阈值搜索：最优 [P_{10}, P_{80}]
下界（剔除低 PPL 冗余）
P_0 72.4 76.4 80.0 83.2 85.8 85.7 84.9 83.3 81.2
P_5 74.1 78.3 81.9 85.1 87.7 87.6 86.7 85.0 82.7
P_{10} 74.6 78.9 82.7 86.0 88.6 88.5 87.5 85.7 83.4
P_{15} 71.3 75.9 80.0 83.5 86.3 86.3 85.3 83.5 81.2
P_{20} 67.0 72.0 76.4 80.2 83.3 83.3 82.5 80.7 78.4
P_{25} 61.9 67.3 72.1 76.2 79.6 79.8 79.1 77.4 75.1
P_{30} 55.8 61.9 67.1 71.7 75.4 75.8 75.1 73.5 71.3
P_{60} P_{65} P_{70} P_{75} P_{80} P_{85} P_{90} P_{95} P_{100}
上界（剔除高 PPL 噪声）
保留质量得分 F（%）
85
80
75
70
65
60