
原始数据
PDF / Word
HTML
纯文本日志
阶段 A：系统化预处理管线
1. 文本抽取
差异化解析
版式精准还原
→ 统一纯文本
2. 格式规范
统一层级编号
规范专业符号
消除形式噪声
3. 噪声清洗
过滤规则乱码
人工校验确认
剔除免责模板
4. 分段切片
4096 Token 切片
完整句边界截断
逻辑实体拼接
5. 去重筛选
一级 SimHash
二级 MinHash
三级语义向量
6. 质量评估
自动化初次筛选
LLM 辅助判断
人工多维抽验
阶段 B：双层分流（第 7 步）
第一层：七类数据
面向 SFT 阶段：保留原生业务风格
第二层：三类场景
面向 RLHF 阶段：Prefix 风格可控