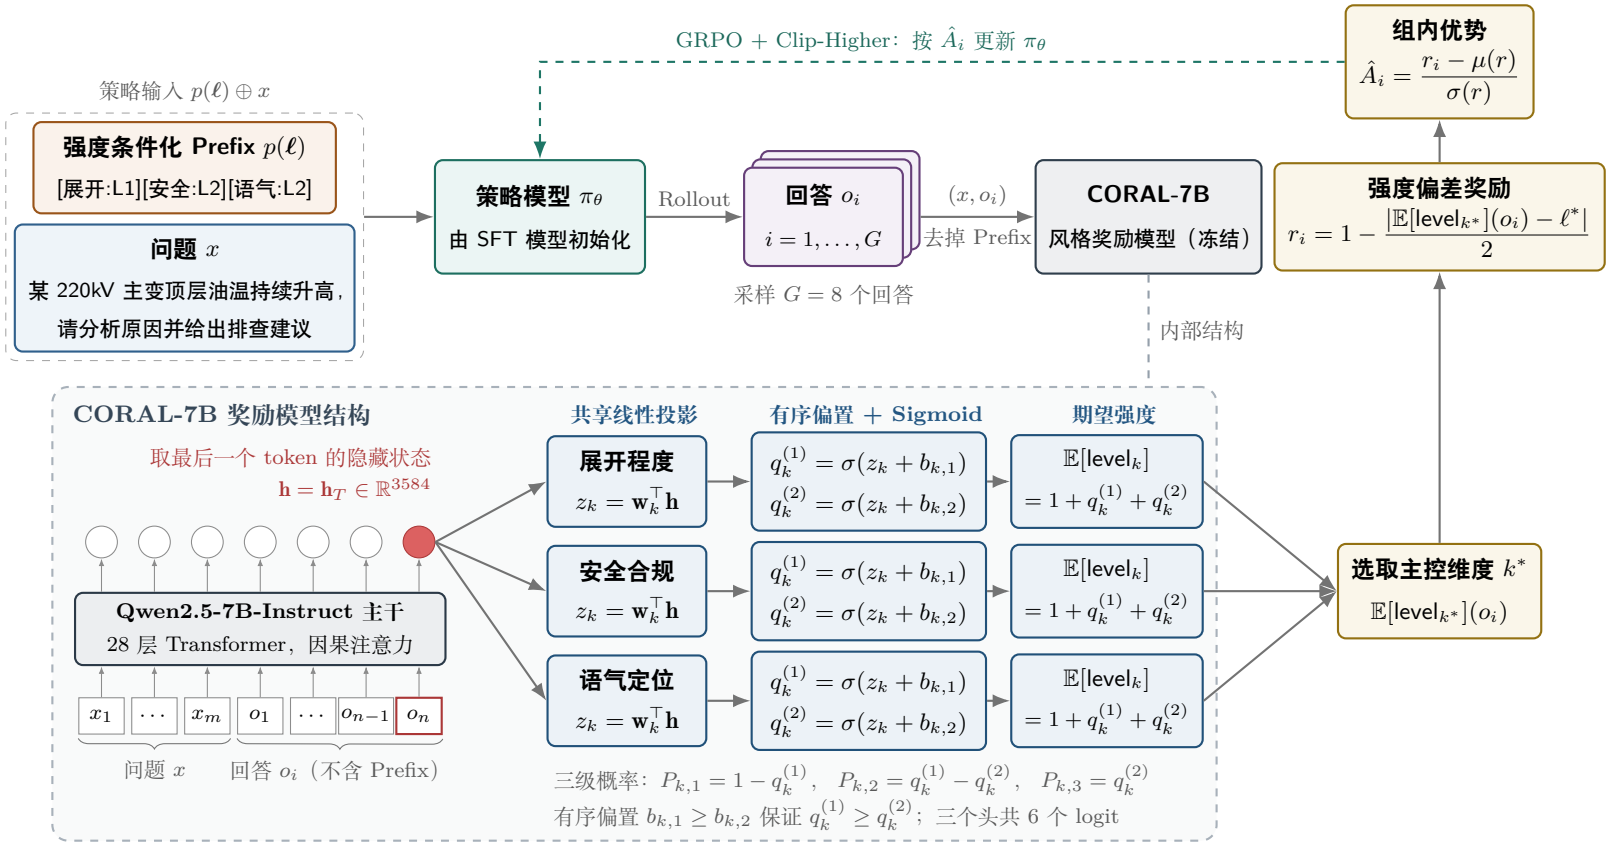

GRPO + Clip-Higher：按 $\hat{A}_i$ 更新 π_θ
组内优势
$\hat{A}_i = \frac{r_i - \mu(r)}{\sigma(r)}$
策略输入 $p(\ell) \oplus x$
强度条件化 Prefix $p(\ell)$
[展开:L1][安全:L2][语气:L2]
问题 x
某 220kV 主变顶层油温持续升高，请分析原因并给出排查建议
策略模型 π_θ
由 SFT 模型初始化
Rollout
回答 o_i
$i = 1, \ldots, G$
采样 $G = 8$ 个回答
(x, o_i)
去掉 Prefix
CORAL-7B
风格奖励模型（冻结）
强度偏差奖励
$r_i = 1 - \frac{|\mathbb{E}[\text{level}_{k^*}](o_i) - \ell^*|}{2}$
内部结构
CORAL-7B 奖励模型结构
取最后一个 token 的隐藏状态
$\mathbf{h} = \mathbf{h}_T \in \mathbb{R}^{3584}$
Qwen2.5-7B-Instruct 主干
28 层 Transformer，因果注意力
x_1 ⋯ x_m o_1 ⋯ o_{n-1} o_n
问题 x
回答 o_i（不含 Prefix）
共享线性投影
有序偏置 + Sigmoid
期望强度
展开程度
$z_k = \mathbf{w}_k^\top \mathbf{h}$
$q_k^{(1)} = \sigma(z_k + b_{k,1})$
$q_k^{(2)} = \sigma(z_k + b_{k,2})$
$\mathbb{E}[\text{level}_k] = 1 + q_k^{(1)} + q_k^{(2)}$
安全合规
$z_k = \mathbf{w}_k^\top \mathbf{h}$
$q_k^{(1)} = \sigma(z_k + b_{k,1})$
$q_k^{(2)} = \sigma(z_k + b_{k,2})$
$\mathbb{E}[\text{level}_k] = 1 + q_k^{(1)} + q_k^{(2)}$
语气定位
$z_k = \mathbf{w}_k^\top \mathbf{h}$
$q_k^{(1)} = \sigma(z_k + b_{k,1})$
$q_k^{(2)} = \sigma(z_k + b_{k,2})$
$\mathbb{E}[\text{level}_k] = 1 + q_k^{(1)} + q_k^{(2)}$
选取主控维度 k^*
$\mathbb{E}[\text{level}_{k^*}](o_i)$
三级概率：$P_{k,1} = 1 - q_k^{(1)}$，$P_{k,2} = q_k^{(1)} - q_k^{(2)}$，$P_{k,3} = q_k^{(2)}$
有序偏置 $b_{k,1} \geq b_{k,2}$ 保证 $q_k^{(1)} \geq q_k^{(2)}$；三个头共 6 个 logit