硕士学位论文

(学术学位论文)

基于指令微调与安全对齐的数字电网大语言模型应用研究

RESEARCH ON THE APPLICATION OF LARGE LANGUAGE MODELS FOR DIGITAL POWER GRIDS BASED ON INSTRUCTION TUNING AND SAFETY ALIGNMENT

赵乐森

哈尔滨工业大学

20XX 年 XX 月

国内图书分类号：TP391.1　　学校代码：10213
国际图书分类号：004.8　　密级：公开

硕士学位论文

基于指令微调与安全对齐的数字电网大语言模型应用研究

硕士研究生：赵乐森

导　　师：许鋆

申请学位：工学硕士

学　　科：控制科学与工程

所在单位：智能科学与工程学院

答辩日期：20XX 年 XX 月

授予学位单位：哈尔滨工业大学

Classified Index: TP391.1
U.D.C: 004.8

Dissertation for the Master Degree

RESEARCH ON THE APPLICATION OF LARGE LANGUAGE MODELS FOR DIGITAL POWER GRIDS BASED ON INSTRUCTION TUNING AND SAFETY ALIGNMENT

Candidate:	Zhao Lesen
Supervisor:	Xu Jun
Academic Degree Applied for:	Master of Engineering
Specialty:	Control Science and Engineering
Affiliation:	School of Intelligent Science and Engineering
Date of Defense:	XXXX, 20XX
Degree-Conferring-Institution:	Harbin Institute of Technology

摘 要

近年来，大语言模型在通用自然语言处理任务中取得了显著进展，但在数字电网知识服务场景中的应用仍面临领域知识不足、专业术语理解不稳定、故障诊断推理能力有限、制度问答依据性不足以及安全合规边界不清晰等问题。电力领域具有知识体系复杂、规程约束严格、业务风险较高等特点，因此需要针对电力知识问答、故障诊断、制度问答和技术方案分析等任务构建专门的领域大语言模型训练与对齐方法。针对上述问题，本文提出一种面向数字电网知识服务的领域大语言模型多阶段训练框架，包括持续预训练（CPT）、监督微调（SFT）、基于人类反馈的强化学习对齐（RLHF）以及基于直接偏好优化的安全对齐（DPO）四个阶段。首先，本文利用电力领域七类数据的专业语料进行持续预训练，以增强模型对电力术语、知识结构和业务表达的掌握能力。其次，在监督微调阶段，本文设计了“专家种子构建—设计逻辑提取—知识图谱构建—图遍历指令生成—指令演化—自动化质量筛选”六模块数据合成管线，在七类电力数据各自的业务场景中直接构建高质量指令数据，保留各数据类型的原生风格特征。进一步地，在 RLHF 阶段，本文将七类数据归纳为研发与演进、生产与运行、合规与管理三类风格控制场景，通过 Prompt Prefix 实现模型回答风格的系统化可控调节。最后，针对电力场景的安全合规要求，本文基于浅层安全对齐理论构建 Clean DPO、Recovery DPO 和 Counter Data 三类数据，并引入 RT-Weighting 风险 Token 加权与风险密度感知采样，通过分阶段混合训练提升安全拒答与 harmful prefix 鲁棒性，同时降低过度拒答率。实验结果表明：CPT 阶段通过 1:1 领域—通用数据混合策略将电力领域综合得分从 43.5% 提升至 68.2%；SFT 阶段将 PowerQA 综合得分提升至 82.3%，制度问答依据正确性提升至 78%；RLHF 阶段通过风格条件化 Prefix 机制，细粒度强度控制率（IHR）达 76.7%；DPO 阶段通过三类数据协同与 RT-Weighting，不安全回答率（URR）降至 1.5%，攻击成功率（ASR）降至 7.9%，安全恢复率（SRR）提升至 53.4%，过度拒答率（ORR）控制在 5.0%。上述结果表明，本文提出的多阶段训练与对齐框架能够在增强电力领域能力的同时，提高模型输出的专业性、可控性、安全性和实用性。

关键词：电力大语言模型；知识服务；指令数据；风格可控生成；安全对齐

Abstract

Recent years have witnessed significant progress of large language models (LLMs) in general natural language processing tasks. However, their application in digital power grid knowledge services still faces problems such as insufficient domain knowledge, unstable understanding of professional terminology, limited reasoning capability for fault diagnosis, inadequate evidential grounding in regulation question answering, and unclear safety and compliance boundaries. The power domain is characterized by a complex knowledge system, strict procedural constraints, and high business risks. It is therefore necessary to develop dedicated domain-specific training and alignment methods for tasks including power knowledge question answering, fault diagnosis, regulation question answering, and technical scheme analysis.

To address these problems, this thesis proposes a multi-stage training framework for domain LLMs oriented to digital power grid knowledge services, consisting of four stages: continual pre-training (CPT), supervised fine-tuning (SFT), reinforcement learning from human feedback (RLHF) alignment, and safety alignment based on direct preference optimization (DPO). First, professional corpora covering seven categories of power data are used for continual pre-training to enhance the model's mastery of power terminology, knowledge structure, and business expressions. Second, in the SFT stage, a six-module data synthesis pipeline is designed, comprising expert seed construction, design-logic extraction, knowledge-graph construction, graph-traversal instruction generation, instruction evolution, and automated quality filtering. High-quality instruction data are constructed directly within the native business scenarios of the seven power data categories, preserving the native stylistic characteristics of each data type. Furthermore, in the RLHF stage, the seven data categories are grouped into three style-control scenarios—research and evolution, production and operation, and compliance and management—and a Prompt Prefix mechanism is employed to achieve systematic and controllable adjustment of answer styles. Finally, to meet the high safety and compliance requirements of power scenarios, three types of deep safety alignment data—Clean DPO, Recovery DPO with safety-recovery data augmentation, and Counter Data—are constructed based on shallow safety alignment theory, and RT-Weighting risk-token weighting and risk-density-aware

sampling are introduced. A staged mixed training strategy improves the model's safety refusal capability and robustness against harmful-prefix attacks while reducing the over-refusal rate on normal business questions.

Experimental results show that: in the CPT stage, a 1:1 domain-general data mixing strategy raises the comprehensive power-domain score from 43.5% to 68.2%; in the SFT stage, the six-module pipeline improves the PowerQA comprehensive score to 82.3% and the correctness of regulatory evidence to 78%; in the RLHF stage, the style-conditioned Prefix mechanism achieves a fine-grained intensity control rate (IHR) of 76.7%; in the DPO stage, the three-type collaborative deep safety alignment scheme reduces the unsafe response rate (URR) to 1.5% and the attack success rate (ASR) to 7.9%, raises the safety recovery rate (SRR) to 53.4%, while keeping the over-refusal rate (ORR) at 5.0%. These results demonstrate that the proposed multi-stage training and alignment framework can enhance the model's professionalism, controllability, safety, and practicality in the power domain.

Keywords: power large language model,knowledge service,instruction data,controllable style generation,safety alignment

目 录

摘 要 I
Abstract II

第 1 章 绪论 1
1.1 研究背景与意义 1
1.1.1 行业背景与应用价值 1
1.1.2 电力领域大语言模型面临的特殊挑战 1
1.1.3 理论意义与实际意义 2
1.2 国内外研究现状 3
1.2.1 垂直领域大语言模型 3
1.2.2 指令数据构建与合成 5
1.2.3 RLHF 与风格可控生成 6
1.2.4 DPO 与安全对齐 7
1.2.5 现有研究不足 8
1.3 研究内容与方法 9
1.3.1 理论分析框架 9
1.3.2 核心研究问题 10
1.3.3 研究内容 11
1.3.4 技术路线 12
1.4 主要创新点 12
1.5 论文组织结构 13
第 2 章 面向数字电网知识服务的大语言模型总体框架 15
2.1 任务定义 15
2.2 整体框架设计 17
2.3 电力领域数据来源、类型与场景映射 20
2.3.1 数据来源与七类数据类型 21
2.3.2 SFT 阶段：七类数据业务场景中的指令数据生成 23
2.3.3 RLHF 阶段：七类数据到三类场景的归纳映射 24
2.4 电力数据预处理与标签化流程 25

2.5 持续预训练设计 31
2.5.1 训练数据构成 31
2.5.2 基于困惑度的数据筛选 31
2.5.3 领域数据与通用数据的配比设计 33
2.5.4 训练目标与实施细节 35
2.5.5 与 SFT 阶段的衔接 37
第 3 章 面向七类电力数据业务场景的指令数据构建与监督微调 38
3.1 研究动机 38
3.2 SFT 任务体系的形式化定义 38
3.3 专家种子问题构建 39
3.4 基于设计逻辑与知识图谱的指令生成 40
3.4.1 设计逻辑提取 41
3.4.2 知识图谱构建 43
3.4.3 图遍历指令生成 44
3.5 基于指令演化的复杂任务扩展 45
3.5.1 演化操作的定义与示例 46
3.5.2 自动化演化流程与质量保障 47
3.6 自动化质量筛选与多维评估 48
3.6.1 多维筛选标准 49
3.6.2 质量保障体系架构 50
3.7 SFT 训练策略与实验结果 50
3.7.1 两阶段训练策略 51
3.7.2 训练配置与优化 53
3.7.3 主要结果 53
3.7.4 消融分析 54
第 4 章 基于 Prompt Prefix 的电力场景回答风格强化学习对齐 56
4.1 研究动机 56
4.2 三类风格 Prefix 定义 57
4.2.1 展开程度风格（elaboration） 57
4.2.2 安全合规风格（cautious） 58
4.2.3 语气/角色定位风格（tone/role） 58
4.2.4 风格强度等级划分 58
4.2.5 场景—强度映射 60

4.2.6 强度条件化 Prefix 设计 60
4.3 风格偏好数据构建与质量筛选 61
4.3.1 基于 SFT 数据的场景适配改写 61
4.3.2 LLM-as-Judge 风格强度评分 62
4.3.3 三轮质量筛选 63
4.4 基于 Qwen2.5-7B 的风格判别模型训练 65
4.4.1 风格判别模型的功能定位与输入输出 65
4.4.2 模型架构设计 65
4.4.3 训练目标与优化配置 67
4.4.4 实验结果与分析 68
4.5 基于强化学习的风格对齐训练 69
4.5.1 数据准备与奖励映射 70
4.5.2 PPO 风格对齐与 Dual-Clip 改进 72
4.5.3 GRPO 风格对齐与 Clip-Higher 改进 73
4.5.4 Online DPO 风格对齐对比 76
4.6 风格评测与实验结果 78
4.6.1 自动评测：RM 与 LLM-as-Judge 的融合框架 79
4.6.2 人工抽检校准 80
4.6.3 综合评测指标 80
4.6.4 主要实验结果 81
第 5 章 面向电力安全合规的深层 DPO 对齐方法 83
5.1 研究动机 83
5.2 电力安全风险类型划分 84
5.3 浅层安全对齐的局限性与深层对齐需求 85
5.4 基于 Token-Boundary 与 Character-Boundary 截断的 Harmful Prefix 初步分析 86
5.4.1 实验设计动机 86
5.4.2 实验设计 88
5.4.3 初步分析结果 89
5.5 基于梯度显著性的安全触发机制可视化分析 91
5.5.1 可视化方法设计 91
5.5.2 分析维度 93
5.5.3 可视化结果分析 93

5.6 面向深层安全对齐的 DPO 数据构建 95
5.6.1 Clean DPO——基础安全边界数据 96
5.6.2 Recovery DPO——安全恢复增强数据 97
5.6.3 Counter Data——反偏保守数据 99
5.7 深层 DPO 训练策略 102
5.7.1 分阶段训练组织 102
5.7.2 安全性与有用性平衡机制 104
5.7.3 风险 Token 加权（RT-Weighting） 104
5.8 DPO 训练与实验结果 106
5.8.1 训练配置 107
5.8.2 安全拒答与攻击鲁棒性 107
5.8.3 过度拒答控制 108
5.8.4 DPO 数据类别消融分析 108
5.8.5 Token-Boundary 与 Character-Boundary 截断的消融对比 110
5.8.6 Counter Data 比例的影响分析 113
5.8.7 四类安全风险的细分性能分析 114
5.8.8 与基线方法的安全性对比 114
5.8.9 RT-Weighting 与风险密度采样消融 115
5.8.10 通用安全能力与通用-领域混合训练 116
5.8.11 综合讨论 116
结 论 119
参考文献 122
攻读硕士学位期间取得创新性成果 130
哈尔滨工业大学学位论文原创性声明和使用权限 131
致 谢 132

第 1 章 绪论

1.1 研究背景与意义

1.1.1 行业背景与应用价值

电力行业长期积累了大量专业知识资产，包括技术标准、运行规程、设备手册、检修记录、故障案例、仿真报告和制度文件等。这些知识分散在不同业务系统和文档形态中，具有术语密集、结构复杂、因果链条长和制度约束强等特点。以 Transformer 为代表的预训练生成模型奠定了当前大语言模型的基本架构基础[1]，GPT-3、GPT-4 等模型进一步展现出少样本学习、复杂指令遵循和通用推理能力[2-3]。在电力领域，已有研究开始讨论基础模型和大语言模型在电网运行、知识检索、调度辅助和安全关键决策支持中的应用潜力[4-5]。因此，大语言模型（Large Language Model, LLM）为数字电网知识服务提供了新的技术路径：模型不仅可以承担电力知识问答，还可辅助故障现象归因、检修步骤组织、制度条款解释和技术方案比较，从而提升专业知识获取与业务辅助决策效率。

1.1.2 电力领域大语言模型面临的特殊挑战

然而，电力场景不同于一般知识问答场景，其对领域大语言模型提出了三个层面的特殊挑战。

首先，**知识层面**：电力知识体系涵盖发电、输电、变电、配电、调度、检修、运维等业务环节，涉及多源异构的技术标准、设备手册、运行规程和仿真报告。模型需要理解设备原理、运行状态、保护逻辑和制度条款之间的关联，简单的文本检索或通用语言生成难以满足复杂推理要求。

其次，**任务层面**：电力业务问题不仅包括事实型知识查询，还包括故障现象的因果归因、检修步骤的依规生成、制度条款的适用边界判断和技术方案的跨维度比较。不同任务在输入信息类型、推理链条深度和输出结构方面存在显著差异——故障诊断要求结论先行和步骤化排查，制度问答要求条款引用和边界界定，技术方案分析要求多维度权衡和不确定性说明。

再次，**安全层面**：电力系统属于安全关键基础设施，相关基础模型研究也强调，面向电网的智能模型不仅要关注预测或生成效果，还必须考虑复杂物理系统约束、运行可靠性、验证机制和部署风险[4-5]。模型输出一旦被用户参考，错

误的操作建议、遗漏的安全前置条件或越权的制度解释都可能带来设备损坏、人身风险或系统运行风险。更为特殊的是，电力场景中的危险请求往往“语言上像正常技术咨询、工程上却具有危险后果”——例如，以“提高工作效率”为借口的违章操作诱导、伪装成学术讨论的参数越限建议等，这类请求比通用有害内容更隐蔽、更难以通过简单的关键词匹配进行识别。

在实际数字电网知识服务中，上述不足并非只表现为回答质量下降，而可能直接转化为业务风险。例如，在故障诊断场景中，模型若只给出笼统原因而缺少排查顺序和安全前置条件，可能误导现场人员执行不合规操作；在制度问答场景中，模型若无法区分条款适用边界，可能给出越权或过时的流程建议；在技术方案分析场景中，模型若缺乏对仿真假设、设备参数和系统稳定约束的理解，可能形成看似完整但实际不可采纳的方案结论。因此，面向电力领域的大语言模型不仅需要掌握专业知识，还需要具备结构化任务执行能力、面向业务场景的风格可控能力以及稳定的安全合规边界。

单一训练阶段难以同时满足上述要求。仅进行持续预训练可以提升领域知识覆盖，但无法保证模型按电力业务任务格式回答；仅进行监督微调可以提升任务执行能力，但回答风格主要由训练样本隐式决定，难以按业务角色显式切换；仅进行通用安全对齐又难以覆盖电力场景中特有的“语言上正常但工程上危险”的请求。因此，本文采用 CPT、SFT、RLHF 和 DPO 逐级递进的多阶段训练框架，分别对应知识注入、任务能力培养、风格可控对齐和安全合规边界优化。

1.1.3 理论意义与实际意义

从理论意义而言，本文的研究涉及垂直领域大语言模型训练中的四个递进式核心问题——领域知识注入与通用能力保持的平衡、多类型业务场景下指令数据的系统化构建、回答风格的细粒度可控调节、以及安全合规边界的深层对齐——这些问题是当前领域大语言模型从通用基座走向关键业务部署过程中具有共性的理论挑战。本文以电力领域为具体场景，提出的多阶段训练框架、场景原生指令数据构建策略、Prompt Prefix 风格控制机制和深层安全对齐方法，可为其他具有类似特征的垂直领域（如医疗、法律、工业制造等）提供方法论参考。

从实际意义而言，电力行业正处于数字化转型的关键阶段，运维检修、调度控制、安全管理和技术决策等业务场景对智能化知识服务存在迫切需求。构建具备专业知识、任务执行能力、风格可控性和安全合规保障的电力领域大语

言模型，有助于提升一线人员获取专业知识的效率、辅助故障诊断与处置决策、支撑制度合规性审查和技术方案论证，具有明确的工程应用价值。

1.2 国内外研究现状

本文研究面向数字电网知识服务的大语言模型多阶段训练与对齐方法，涉及垂直领域大语言模型、指令数据构建与合成、RLHF 与风格可控生成、DPO 与安全对齐四个方向。现有研究表明，大语言模型在通用自然语言处理任务中已具备较强的语言理解、知识表达和推理能力，但在医疗、法律、金融、电力等专业领域中仍存在领域知识覆盖不足、专业术语理解不稳定、事实依据不充分、回答风格难以按业务场景调节以及安全合规边界不清晰等问题。因此，有必要结合数字电网知识服务的业务特征，对相关研究进行系统梳理，并进一步明确本文的研究切入点。

1.2.1 垂直领域大语言模型

大语言模型向垂直领域迁移通常依赖两类技术路径：一类是通过持续预训练或领域自适应预训练将领域语料中的术语、表达方式和知识结构注入模型参数；另一类是通过检索增强生成、工具调用或知识库接入等方式，在推理阶段补充外部知识。Gururangan 等提出的领域自适应预训练（Domain-Adaptive Pretraining, DAPT）和任务自适应预训练（Task-Adaptive Pretraining, TAPT）表明，在通用预训练模型基础上继续使用领域语料进行训练，能够在生物医学、计算机科学、新闻和评论等领域取得稳定收益[6]。在早期预训练语言模型阶段，SciBERT[7]、BioBERT[8] 等工作已证明，专业语料能够显著改善模型对领域术语和专业文本结构的建模能力。进入大语言模型阶段后，Med-PaLM 通过医学问答基准和专家评测验证了大模型在医学知识问答中的潜力[9]；BloombergGPT 采用大规模金融语料与通用语料混合训练，在金融任务上获得提升且尽量保持通用能力[10]；FinGPT 从开源金融数据自动构建与轻量化适配角度探索了金融领域大模型的可行性[11]；LegalBench 和 ChatLaw 则分别从法律推理评测与中文法律知识库增强角度推动了法律领域大模型研究[12-13]。这些研究共同说明，垂直领域模型不能简单依赖通用基座模型的零样本能力，而需要围绕领域语料、任务数据、知识依据和评测体系进行系统设计。

除参数化知识注入外，检索增强生成（Retrieval-Augmented Generation, RAG）也成为领域知识服务的重要技术。Lewis 等提出的 RAG 将参数化语言模型与非

参数化外部知识库结合，使模型在知识密集型任务上生成更具体、更具事实性的回答[14]。近年来，知识图谱增强大语言模型、GraphRAG 等方法进一步尝试利用实体、关系和路径结构提升模型的多跳推理与事实一致性[15-16]。然而，RAG 和知识图谱增强方法主要解决推理阶段的知识可追溯问题，不能直接替代模型对领域术语、规程表达和业务推理模式的内化学习。因此，在电力等高专业度场景中，仅依赖检索增强往往难以保证模型在故障诊断、制度问答和技术方案分析中的结构化表达能力。

在电力领域，国内外研究仍处于起步和快速发展阶段。Huang 等讨论了基础模型在电力系统中的应用潜力，并在最优潮流、电动汽车调度、技术报告检索和态势感知等任务中验证了 GPT-4 等模型的能力[17]。Majumder 等从电力能源行业视角分析了大语言模型的能力边界，指出未来研究需要关注电力领域数据采集、模型微调、工具嵌入、RAG 知识池以及安全关键场景下的可靠性问题[4]。在工程应用方面，eGridGPT 面向电网控制室提出可信 AI 助手框架，强调网络安全、监管要求和数字孪生验证[18]；ChatGrid 将大语言模型接入电网可视化系统，使调度人员能够通过自然语言查询电网状态并获得文本与可视化反馈[19]。这些工作表明，大语言模型已开始进入电网运行、调度辅助和可视化分析场景，但多数研究仍以提示工程、外部工具接入或应用原型为主，尚未形成面向数字电网知识服务的多阶段训练体系。

国内研究方面，电力领域大语言模型评测和专用模型构建开始受到关注。Zhou 等提出的 ElecBench 面向电力调度构建了大语言模型评测基准，覆盖事实性、逻辑性、稳定性、安全性、公平性和表达性等维度[20]；Zhang 等进一步提出面向电力领域的 ElecBench 基准，包含 24 个数据集和 34030 条数据，覆盖通用电力知识及设备、调度、物资、营销等业务应用，并指出现有开源中文大模型仍需进一步领域优化[21]。Cheng 等提出 GAIA，用于电力调度场景的任务处理和人机协同[22]；Zhong 等提出 PowerGPT，面向电力巡检构建多模态指令数据和评测基准，验证了领域多模态模型在电力安全监督任务中的价值[23]。这些研究证明了电力领域大模型的应用前景，也揭示了现有模型在专业术语、业务流程、规程约束和场景化评测方面的不足。

总体来看，现有垂直领域大模型研究已证明持续预训练、领域数据构建、检索增强和专用评测的重要性，但在数字电网知识服务场景中仍存在三方面不足：第一，已有工作多关注单一任务或单一应用原型，缺乏从持续预训练、监督微调、偏好对齐到安全对齐的递进式训练框架；第二，电力领域多源数据具有显著的类型差异，现有研究较少讨论如何在训练过程中保留标准规程、故障案

例、设备手册、仿真报告和制度文件等不同数据类型的原生表达特征；第三，现有电力大模型工作对安全合规风险的讨论多停留在应用层面，尚缺乏针对“语言上像正常技术咨询、工程上具有危险后果”这类隐蔽风险的深层安全对齐方法。

1.2.2 指令数据构建与合成

监督微调阶段的核心在于构建高质量指令数据，使模型从“会生成文本”转变为“能够按照用户任务要求组织答案”。早期指令微调主要依赖人工标注或已有 NLP 任务模板，数据质量较高但成本较大，且难以覆盖复杂开放场景。Self-Instruct 提出从少量人工种子任务出发，由语言模型自动生成指令、输入和输出样本，并通过相似性过滤和质量筛选扩充指令数据[24]。Evol-Instruct 进一步提出通过逐步重写将简单指令演化为复杂指令，增强模型处理高复杂度任务的能力[25]。OSS-Instruct 利用开源代码片段引导大模型生成更真实、低偏差和可控的代码指令数据，说明“外部真实语料片段”可作为约束合成数据分布的重要锚点[26]。Orca 则强调利用 GPT-4 的复杂解释轨迹和逐步推理过程作为学习信号，帮助较小模型学习复杂推理方式[27]。这些方法推动了指令数据自动构建从“模板扩展”向“模型自举、复杂度演化、外部语料锚定和推理轨迹蒸馏”发展。

在专业领域，指令数据构建更强调事实正确性、专业可信度和专家审核。HuatuoGPT 将 ChatGPT 蒸馏数据与医生真实数据结合，并通过混合反馈强化学习提升医学问诊能力[28]；DISC-MedLLM 在医学咨询场景中结合医学知识图谱、真实对话重构和人工引导偏好改写，提升模型在多轮医疗问答中的准确性和真实性[29]；ChatLaw 通过外部法律知识库和法律数据构建缓解法律问答中的幻觉问题[13]。这些研究说明，专业领域指令数据不能仅依赖通用大模型自动生成，还需要引入专家知识、结构化知识约束和人工审核机制。尤其在电力领域，故障诊断、检修规程、制度条款和技术方案之间存在严格的因果链条、操作边界和责任约束，若指令数据缺少事实校验和业务语境，模型容易学习到表面流畅但工程上不可采纳的回答模式。

知识图谱和结构化知识也被用于提升指令构建和模型推理的可靠性。已有研究表明，将知识图谱路径、实体关系或结构化检索结果引入大语言模型，可以在一定程度上缓解幻觉并增强多跳推理能力[15-16]。但是，现有知识图谱增强方法多用于推理阶段的检索或路径选择，较少将其系统嵌入领域指令数据合成流程。对于数字电网知识服务而言，仅将技术标准或设备手册切分为问答对，难以显式表达“故障现象—可能原因—排查步骤—安全前置条件—制度依据”之

间的结构关系。因而，需要将知识图谱从“外部检索工具”进一步转化为“数据生成约束”，用于约束问题生成、答案组织、因果路径覆盖和事实一致性检查。

总体来看，现有指令数据构建研究仍存在三方面不足。第一，通用 Self-Instruct、Evol-Instruct 等方法强调数据规模和任务多样性，但缺少面向电力术语、设备状态、规程条款和故障因果链的领域约束；第二，领域指令数据构建常采用统一问答模板，将不同类型资料归约为相似的“问题—答案”形式，容易压缩设备手册、运行规程、仿真报告、故障案例和制度文件之间的原生风格差异；第三，已有方法对“少量专家种子如何系统扩展为大规模可信指令数据”的过程刻画不足，通常缺少设计逻辑抽取、知识图谱约束、图遍历指令生成、指令复杂度演化和自动化质量筛选之间的闭环。

1.2.3 RLHF 与风格可控生成

在人类偏好对齐方面，RLHF 已成为提升大语言模型可用性和可控性的重要技术路径。Christiano 等较早提出从人类偏好中学习奖励模型并进行强化学习优化[30]；Stiennon 等将人类反馈用于摘要任务，使模型生成更符合人类偏好的摘要[31]；Ouyang 等在 InstructGPT 中形成了“监督微调—奖励模型训练—PPO 强化学习”的典型流程，使较小参数规模模型在人工偏好评测中优于未对齐的大模型[32]。PPO 通过裁剪策略更新幅度提升强化学习训练稳定性[33]，但在大语言模型训练中仍面临奖励模型训练成本高、采样开销大、训练不稳定等问题。近年来，GRPO 在 PPO 基础上取消显式 critic 模型，通过组内相对奖励估计基线，降低强化学习训练资源消耗[34]；DAPO 进一步提出 Clip-Higher、动态采样、token-level policy gradient loss 等策略，以缓解大规模语言模型强化学习中的熵坍塌和有效梯度不足问题[35]。这些进展为基于强化学习的风格对齐训练提供了算法基础。

风格可控生成是可控文本生成的重要分支。CTRL 通过控制码（control code）对生成文本的领域、主题和任务形式进行条件化控制[36]；PPLM 通过属性分类器在生成过程中引导语言模型朝指定属性方向生成[37]；Prefix-Tuning 和 Prompt Tuning 则将前缀向量或软提示作为轻量化控制接口，在冻结大模型参数的情况下实现任务适配[38-39]。这些研究表明，Prompt 或 Prefix 可以作为模型行为控制的有效接口，既能降低全参数微调成本，也能在一定程度上实现多任务或多风格控制。

然而，现有风格控制研究主要面向情感、主题、文本体裁或开放域对话风格，较少关注电力业务场景中的“专业表达风格”。数字电网知识服务的风格

差异并不只是语气差异，而是与业务任务紧密耦合：研发与演进类任务通常需要说明假设条件、技术路线和不确定性；生产与运行类任务强调结论先行、安全前置条件和步骤化排查；合规与管理类任务要求条款依据、适用边界和责任约束。若仅为七类电力数据分别设计独立 Prefix，虽然可以保留细粒度差异，但控制接口复杂、训练样本分散，难以在实际部署中灵活切换；若过早将七类数据统一归纳为少数风格，又会在 SFT 阶段压缩不同数据类型的原生知识表达方式。

1.2.4 DPO 与安全对齐

DPO 是近年来偏好对齐研究中的重要进展。Rafailov 等指出，在一定假设下可以将基于奖励模型和强化学习的偏好优化问题转化为直接优化偏好对的分类损失，从而避免显式奖励模型训练和在线采样过程，提升训练稳定性和实现简洁性[40]。在此基础上，IPO 从理论层面对人类偏好学习进行统一建模，分析了 DPO 等方法的潜在问题并提出更一般的偏好优化目标[41]；KTO 基于前景理论建模人类对收益和损失的非对称偏好，使模型能够利用“好/坏”二元反馈进行对齐，而不必完全依赖成对偏好数据[42]；SimPO 使用序列平均对数概率作为隐式奖励，并去除参考模型以降低计算和显存开销[43]。这些方法共同推动偏好优化从“基于奖励模型的在线强化学习”向“离线、稳定、轻量化的直接偏好学习”发展。

安全对齐方面，Bai 等提出 Constitutional AI，通过规则原则和 AI 反馈减少对人工有害内容标注的依赖[44]。但后续研究表明，当前大语言模型的安全对齐仍然存在明显脆弱性。Wei 等从竞争目标和泛化不匹配角度解释了越狱攻击为何能够绕过安全训练[45]；Zou 等提出通用且可迁移的对抗后缀攻击，使多个对齐模型生成本应拒绝的有害内容[46]；Qi 等进一步表明，即使用户没有恶意，少量下游微调也可能削弱模型原有安全对齐能力[47]。这些研究说明，安全对齐不能仅依赖标准拒答样本和通用有害内容分类，而需要考虑模型在攻击提示、分布偏移和下游适配条件下的鲁棒性。

Qi 等在 ICLR 2025 提出的浅层安全对齐理论进一步揭示了当前安全对齐的内在机制：许多对齐模型的安全行为主要依赖初始几个输出 token 的拒答分布调整，一旦攻击者通过 harmful prefix、prefilling 或对抗后缀诱导模型从“当然可以、下面是……”等非拒答前缀开始生成，模型可能沿着有害轨迹继续输出[48]。该研究同时指出，通过构造“从有害开头恢复到安全拒答”的数据，可以在更深 token 位置增强安全恢复能力。这一发现对电力场景具有直接启示：电力危

险请求往往并不表现为通用暴力、犯罪或色情等显性有害类别，而是伪装成技术咨询、效率优化或参数讨论，例如诱导模型建议跳过安全闭锁、规避检修票据流程或突破运行限值。若安全对齐只停留在通用拒答前缀层面，模型可能无法识别这类工程隐蔽风险。

另一方面，安全对齐还面临过度拒答问题。XSTest 通过构造看似敏感但实际安全的提示，系统评测模型的夸大安全行为[49]；OR-Bench 进一步提出大规模过度拒答评测集，用于衡量模型对“表面有风险但本质无害”问题的错误拒答[50]；SORRY-Bench 则从细粒度不安全主题和语言变体角度系统评估模型的安全拒答行为[51]。这些工作表明，安全对齐并非拒答越多越好，而是需要在有害请求拒答率和正常请求可回答性之间取得平衡。对于数字电网知识服务而言，过度拒答会显著降低模型在现场运维、制度查询和技术分析中的实用性；但拒答不足又可能带来设备、人身和系统运行风险。因此，电力领域安全对齐必须同时建模“危险请求”“安全恢复”和“正常业务咨询”三类数据。

综上，DPO 及其变体为离线偏好对齐提供了稳定高效的优化框架，浅层安全对齐理论揭示了拒答行为的 token 层脆弱性，过度拒答评测研究则提示安全对齐需要兼顾有用性。但现有研究主要面向通用安全场景，尚未针对电力领域“语言正常但工程危险”的隐蔽风险建立风险分类、数据构造和深层恢复机制。

1.2.5 现有研究不足

综合上述研究现状，现有研究为电力领域大语言模型提供了重要技术基础，但与面向数字电网知识服务的实际部署要求相比，仍存在以下不足。

第一，领域知识注入与任务能力培养之间缺乏连续设计。持续预训练能够提升模型对领域术语和专业表达的掌握能力，监督微调能够提升模型执行具体任务的能力，但现有研究往往将两者视为相对独立的阶段，缺乏从语料分类、标签体系、数据流转到任务构建的贯通设计。特别是在电力领域，基础科学与仿真理论、物理电网与工程建设、新型电力系统与能源互联、运行控制与二次系统、运维检修与资产管理、综合管理安全与市场、制度文件七类数据在知识表达、推理结构和回答风格方面存在显著差异。若在 CPT 阶段仅进行无差别语料混合，在 SFT 阶段又使用统一模板构建问答数据，则难以保证模型能力提升路径可追溯，也难以保留不同数据类型的原生特征。

第二，领域指令数据构建缺乏“场景原生”设计。Self-Instruct、Evol-Instruct、OSS-Instruct 等方法证明了自动指令生成和复杂度演化的有效性，但这些方法主要面向开放域或代码领域，生成过程缺少电力专业知识约束。医疗、法律等领

域研究表明，专家数据、知识图谱和人工审核对保证事实正确性具有重要作用，但在电力领域，如何从少量专家种子出发，结合设计逻辑、知识图谱和质量筛选机制，系统生成覆盖七类业务场景的大规模高质量指令数据，仍缺乏成熟方法。现有统一模板式数据构建会在训练前压缩各类电力资料的原生表达习惯，导致模型难以学习故障案例的因果排查风格、制度文件的条款依据风格和技术方案的多维权衡风格。

第三，风格可控性与原生风格多样性之间存在矛盾。可控生成和 Prompt/Prefix 方法证明了通过控制码、属性分类器或前缀向量调节输出风格的可行性，但现有方法多控制情感、主题或文本体裁，缺少面向电力业务角色和任务场景的风格语义建模。若直接为七类电力数据分别设计 Prefix，会造成控制粒度过细、样本分散和部署复杂；若在 SFT 阶段过早将七类数据合并为少数风格，又会损失原生表达差异。因此，需要一种“先保留、后归纳”的风格控制路径：先在 SFT 阶段学习七类数据的原生任务风格，再在 RLHF 阶段归纳为少数具有明确业务语义的场景 Prefix，并进一步实现风格强度可调。

第四，安全对齐缺乏电力领域深层风险建模。通用安全对齐研究主要关注暴力、违法、仇恨、色情、自伤等显性风险，但电力领域的危险请求常以正常技术咨询形式出现，其风险来自工程语境、操作边界和规程约束，而非表面词汇本身。浅层安全对齐理论表明，模型安全行为可能主要依赖初始拒答 token，一旦被 harmful prefix 诱导进入非拒答轨迹，模型可能输出危险建议。现有安全恢复、防越狱和过度拒答缓解方法尚未结合电力安全规程、调度约束和检修边界进行适配，难以同时满足高风险拒答、深层安全恢复和正常业务咨询可回答的要求。

第五，安全性与有用性的平衡缺乏领域化数据支撑。XSTest、OR-Bench 和 SORRY-Bench 等评测表明，过度拒答是安全对齐的重要副作用。对于数字电网知识服务系统，过度拒答会削弱模型在制度查询、检修辅助、故障分析和技术方案论证中的实用价值；拒答不足则可能诱发违规操作或错误决策。因此，电力领域安全对齐不仅需要有害样本，还需要能够刻画正常业务边界的 Counter Data，使模型学会区分“危险操作建议”和“合规技术解释”。

1.3 研究内容与方法

1.3.1 理论分析框架

本文的核心理论出发点为：从通用基座模型到可安全部署的电力领域大语

言模型，需要依次跨越三个递进式能力缺口。

能力缺口一（知识 → 任务）：CPT 注入的领域知识以语言模型参数的形式存储，但模型尚未建立知识与任务格式之间的映射。SFT 的作用是在领域知识的基础上构建任务执行能力——通过结构化指令数据使模型学会按业务要求的形式组织和输出知识。本文将七类数据标签从 CPT 贯穿至 SFT，确保任务能力的培养可追溯至明确的领域知识来源。

能力缺口二（任务 → 风格）：SFT 使模型能够完成业务任务，但回答风格主要由训练数据的隐式模式驱动，缺乏显式的风格控制接口。本文在 SFT 阶段保留七类数据的原生风格多样性（场景原生策略），在 RLHF 阶段进行场景归纳和风格控制——通过将七类数据归纳为三类业务场景，采用强度条件化 Prompt Prefix 作为控制接口，将风格控制从隐式学习转变为显式可控。

能力缺口三（风格 → 安全）：RLHF 使模型具备风格可控能力，但安全对齐仍停留在通用层面，缺乏面向电力四类安全风险的专门化安全边界。DPO 阶段通过三类协同数据（Clean DPO、Recovery DPO、Counter Data）建立“安全拒答—深层恢复—过度拒答控制”的三层安全机制，并引入 RT-Weighting 与风险密度感知采样增强深层恢复精度。

上述四个能力缺口的递进式跨越，构成本文“知识注入 → 任务能力 → 风格控制 → 安全合规”的四阶段理论分析框架。该框架的核心约束为：（1）每个阶段以前一阶段的产出为基座，能力逐级累积；（2）三类标签体系（七类数据标签、三类场景标签、安全风险标签）分别在不同阶段引入，形成可追溯的数据流链路；（3）风格归纳操作后置于知识获取和任务能力培养，避免信息过早压缩。

1.3.2 核心研究问题

基于上述理论分析框架，本文围绕以下四个核心研究问题展开工作：

（1）知识注入：如何将七类电力语料中的领域知识有效注入通用基座模型，在显著提升电力领域知识覆盖的同时保持通用语言能力？

（2）指令数据构建：如何从少量专家种子出发，构建覆盖七类电力业务场景的大规模高质量指令数据，使得模型在各类数据的原生业务场景中习得差异化的任务响应模式？

（3）风格可控对齐：如何在不压缩七类原生任务风格的前提下，将风格控制归纳为三类业务场景，并通过 Prompt Prefix 机制实现细粒度的回答风格强度可控调节？

(4) 深层安全对齐：如何在电力安全高风险场景中增强模型对 harmful prefix 诱导攻击的鲁棒性，同时避免在正常业务问题上的过度拒答?

1.3.3 研究内容

针对上述四个研究问题，本文将提出 CPT-SFT-RLHF-DPO 四阶段递进训练框架。电力领域包含七类数据类型——基础科学与仿真理论、物理电网与工程建设、新型电力系统与能源互联、运行控制与二次系统、运维检修与资产管理、综合管理安全与市场、制度文件——本文将在 SFT 阶段直接在七类数据各自的业务场景中构建指令数据，保留原生知识表达特征；在 RLHF 阶段将七类数据归纳为三类风格控制场景，通过 Prompt Prefix 实现风格的系统化可控调节。具体研究内容如下。

(1) 电力领域持续预训练与知识注入。将利用七类电力领域语料对通用基座模型进行持续预训练，通过困惑度双阈值筛选选取高质量训练切片，以 1:1 领域-通用数据混合比例平衡领域知识注入与通用能力保持。

(2) 面向七类数据业务场景的 SFT 指令数据构建。将设计“专家种子构建—设计逻辑提取—知识图谱构建—图遍历指令生成—指令演化—自动化质量筛选”六模块数据合成管线，以少量专家种子为起点，在七类电力数据各自的业务场景中构建高质量指令数据，保留各类型的原生风格特征。

(3) 基于 Prompt Prefix 的场景风格强化学习对齐。将七类数据归纳为三类业务场景，通过强度条件化 Prompt Prefix 显式指定展开程度、安全合规和语气/角色定位三个风格维度的目标等级，训练风格判别模型并采用强化学习策略实现细粒度风格强度可控调节。

(4) 面向电力安全合规的深层 DPO 对齐。将基于浅层安全对齐理论建立四类电力安全风险分类体系，通过 token-boundary 截断分析和梯度可视化探究安全触发的粒度依赖特性，构建 Clean DPO、Recovery DPO 和 Counter Data 三类协同的深层安全对齐数据体系，并引入 RT-Weighting 风险 Token 加权与风险密度感知采样，在安全性与可用性之间取得平衡。

其中，CPT 阶段的领域适应思想来源于领域自适应预训练和持续预训练研究[6,52]；SFT 阶段的数据合成借鉴了 Self-Instruct、Evol-Instruct 以及设计逻辑驱动的数据合成思路[24-25,53-54]；RLHF 阶段的风格对齐建立在偏好学习、PPO/GRPO 以及 Prompt/Prefix 可控生成研究基础上[30-39]；DPO 阶段则结合直接偏好优化、安全对齐和浅层安全对齐分析方法构建电力安全合规边界[40,44-48]。

1.3.4 技术路线

综上，本文技术路线将遵循“领域知识注入—任务能力构建—场景风格控制—安全合规对齐”的递进逻辑，整体流程如图 1-1 所示。第 2 章将从整体框架角度说明四阶段训练系统及其数据流转关系；第 3 章、第 4 章和第 5 章将分别展开 SFT 指令数据构建、风格强化学习对齐和深层 DPO 安全对齐方法。四个阶段依次递进，前一阶段的产出为后一阶段的输入，三类标签体系贯穿全链路，形成可追溯的能力累积路径。

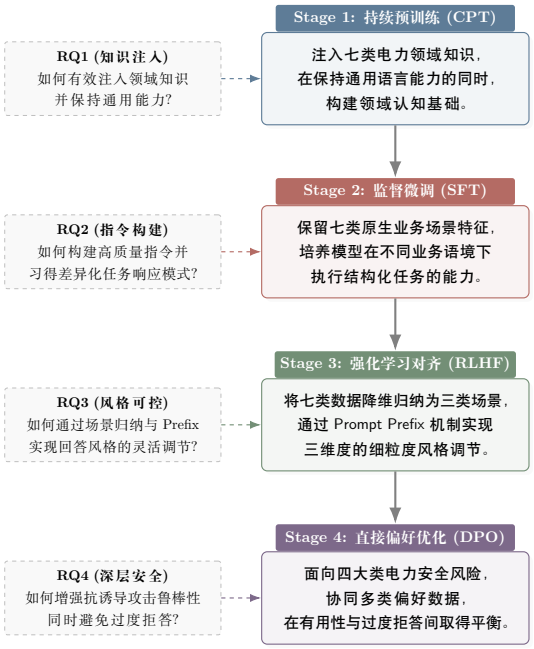


图 1-1 本文总体技术路线图

1.4 主要创新点

创新点一：面向七类电力数据业务场景的 SFT 指令数据构建方法。现有领域 SFT 方法通常采用统一问答模板对多类数据进行风格归约，导致各数据类型的原生知识表达特征在训练前即被压缩。本文提出“场景原生”策略——在 SFT 阶段直接在七类数据的业务场景中构建指令数据，保留各类型的知识表达习惯和推理风格；将风格归纳操作后移至 RLHF 阶段，避免了过早归纳导致的信息损失，解决了七类数据原生风格保留与风格控制可行性之间的矛盾。

创新点二：融合专家种子、设计逻辑与知识图谱的六模块数据合成管线。现有领域指令数据构建方法通常依赖大量人工标注或直接由 LLM 生成，前者成本高昂，后者存在事实性错误和知识覆盖偏差。本文设计了“专家种子构建—设

计逻辑提取—知识图谱构建—图遍历指令生成—指令演化—自动化质量筛选”六模块管线，以少量专家种子（约 600 条）为起点，通过设计逻辑编码推理模式、知识图谱约束生成空间和指令演化扩展复杂度，解决了从少量高质量种子向大规模可信电力指令数据（约 6.8 万条）的系统性转化问题。

创新点三：基于七类到三类场景归纳的 Prompt Prefix 风格可控对齐。现有 Prompt-based 风格控制方法通常为每种风格设计独立 Prefix，在电力多数据类型场景下面临控制粒度过细和 Prefix 设计复杂度过高的问题。本文在 SFT 阶段保留七类数据原生风格多样性的基础上，在 RLHF 阶段将七类归纳为三类业务场景，并进一步提出三维风格强度条件化 Prefix 机制——将场景映射为展开程度、安全合规和语气/角色定位三个风格维度的默认强度组合，使 Prefix 同时编码风格类别与强度等级，在降低控制复杂度的同时实现了细粒度的风格强度可调节。

创新点四：基于浅层安全对齐理论的电力深层 DPO 安全对齐方法。现有安全对齐方法主要面向通用有害内容，在电力场景中难以识别“语言上像技术咨询、工程上具有危险后果”的隐蔽风险请求，且容易在正常业务问题上产生过度拒答。本文建立了面向电力领域的四类递进式安全风险分类体系，通过 token-boundary 截断分析和梯度可视化探究了安全触发的粒度依赖特性，构建了 Clean DPO（基础安全边界）、Recovery DPO（含深层安全恢复增强）和 Counter Data（反偏保守）三类功能协同的深层安全对齐数据体系，并引入 RT-Weighting 风险 Token 加权与风险密度感知采样，在提升安全拒答和深层安全恢复能力的同时通过反偏保守机制抑制过度拒答。

1.5 论文组织结构

本文共分为六章，各章的内容安排如下。

第 1 章绪论。阐述本文的研究背景与意义，综述国内外相关研究现状，明确现有研究的不足与本文切入点，介绍本文的研究内容、方法、技术路线和主要创新点。

第 2 章面向数字电网知识服务的大语言模型总体框架。对数字电网知识服务四类核心任务进行形式化定义，给出面向数字电网知识服务的多阶段训练总体框架设计，介绍电力领域七类数据来源、类型与场景映射关系，阐述数据预处理与标签化流程和持续预训练设计。

第 3 章面向七类电力数据业务场景的指令数据构建与监督微调。给出 SFT 任务体系的形式化定义，阐述专家种子构建、基于设计逻辑与知识图谱的指令

生成、指令演化复杂任务扩展和自动化质量筛选方法，报告 SFT 训练策略与实验结果。

第 4 章基于 Prompt Prefix 的电力场景回答风格强化学习对齐。定义三类风格 Prefix 及其强度等级体系，阐述风格偏好数据构建与质量筛选流程、风格判别模型训练方法、基于强化学习的风格对齐训练策略，报告风格评测实验结果。

第 5 章面向电力安全合规的深层 DPO 对齐方法。划分电力安全风险类型，分析浅层安全对齐的局限性与深层对齐需求，通过 token-boundary 分析和梯度可视化探究安全触发机制，阐述深层 DPO 数据构建与训练策略，报告安全对齐实验结果。

第 6 章总结与展望。总结本文的主要工作和创新成果，指出研究的局限性，展望未来研究方向。

第 2 章 面向数字电网知识服务的大语言模型总体框架

2.1 任务定义

本文面向数字电网知识服务场景，围绕四类核心任务展开研究：电力知识问答、故障诊断、制度问答和技术方案分析。四类任务在输入形式、输出要求和关联的数据类型方面具有不同特征，覆盖了电力领域从知识获取、运行维护到合规管理的完整业务链路。本节对四类任务分别进行形式化定义，并说明各任务在 SFT 阶段关联的七类数据类型和在 RLHF 阶段对应的三类归纳场景。

（1）电力知识问答

电力知识问答任务面向电力领域的专业概念、设备原理、系统结构和技术资料等信息查询需求，要求模型根据用户提出的电力专业问题，给出准确、完整、结构清晰的解释性回答。

输入形式：用户以自然语言形式提出电力领域的事实型或解释型问题，典型输入包括“什么是电力系统暂态稳定”“变压器差动保护的原理是什么”“柔性直流输电的基本结构和工作方式”等。输入可能涉及单一的电力概念或原理，也可能涉及多个关联概念之间的比较和辨析。

输出要求：回答需准确阐述相关的电力概念或原理，对涉及的技术术语给出必要解释，回答结构层次分明，便于用户理解。对于较为复杂的问题，回答应适当补充应用场景或工程实例以帮助用户建立直观认识，但不需要过度展开故障诊断或制度合规判断。

SFT 阶段关联的七类数据类型：该任务主要关联基础科学与仿真理论、物理电网与工程建设、新型电力系统与能源互联、运行控制与二次系统四类数据。前两类数据提供电力基础理论和设备原理的知识来源，第三类提供新能源和系统演进相关知识，第四类提供运行控制和二次系统相关技术知识。

RLHF 阶段归纳场景：主要对应研发与演进场景（research_evolution），要求分析充分、逻辑严谨、重视机理阐述。

（2）故障诊断

故障诊断任务面向电力设备异常、系统故障和运行告警等场景，要求模型根据给定的故障现象、告警信息、设备状态和运行日志等条件，分析可能的故

障原因，给出排查步骤和处置建议，并提供明确的风险提示。

输入形式：用户描述故障的直观现象（如“变压器油温异常升高”“线路跳闸重合不成功”“保护装置发出差动告警”），同时提供可获取的辅助信息，包括相关告警信号、设备运行方式、近期操作记录或巡检记录等。输入的完整度和详细程度因实际场景而异，模型需在信息不完全的情况下尽可能给出合理的分析。

输出要求：回答应采用结论先行的结构，先给出最可能的故障原因判断，再展开具体的排查步骤。排查步骤需具备可执行性，按照从易到难、从外到内、从非破坏性检查到深入检测的顺序排列。每个步骤需说明操作目的和判断依据。回答末尾必须包含明确的风险提示，说明在排查和处置过程中需要遵守的安全注意事项和禁止性操作。当信息不足以确定唯一原因时，应列出多种可能原因及其区分方法。

SFT 阶段关联的七类数据类型：该任务主要关联运维检修与资产管理、运行控制与二次系统两类数据。前者提供故障现象、检修步骤和资产状态相关知识，后者提供运行方式、控制逻辑和保护配置等背景知识。

RLHF 阶段归纳场景：主要对应生产与运行场景（production_operation），要求结论先行、步骤清晰、风险优先、可执行。部分涉及新型电力系统设备故障的问题也可根据数据来源关联研发与演进场景。

（3）制度问答

制度问答任务面向电力行业的制度条款、规程要求、管理流程和安全规范等查询与解释需求，要求模型根据用户提出的制度相关问题，给出措辞正式、依据明确、边界清晰的规范回答。

输入形式：用户以自然语言形式提出与电力制度、规程或管理要求相关的问题，典型输入包括“高压设备检修需要办理哪些票证”“外来人员进入变电站的安全要求是什么”“调度操作票的填写规范和审批流程”等。输入可能涉及单一制度条款的查询，也可能涉及多个制度条款之间的交叉判断和适用性分析。

输出要求：回答需以正式、规范的措辞进行表述，不得使用口语化或推测性表达。回答应明确指出所依据的制度、规程或条款来源，便于用户追溯核实。对于涉及适用边界的问题（如“某类人员在某种情况下是否需要执行某流程”），回答需清晰界定制度的适用范围和例外情况。回答不得越权建议用户绕过制度流程，也不得在制度未明确规定的问题上给出主观性判断，而应建议用户咨询相关主管部门。

SFT 阶段关联的七类数据类型：该任务主要关联制度文件、综合管理安全

与市场两类数据。前者提供具体的制度条款、规程要求和审批流程，后者提供安全管理、市场规则和应急处置等管理类知识。

RLHF 阶段归纳场景：主要对应合规与管理场景（compliance_management），要求正式规范、依据明确、边界清晰、避免越权建议。

（4）技术方案分析

技术方案分析任务面向电力系统规划、工程建设、仿真评估和新能源接入等需要技术推演和方案比较的场景，要求模型在给定技术条件和约束下，对多种可行方案进行比较分析，给出具有技术深度的推演过程和权衡建议。

输入形式：用户描述一个技术分析需求或方案比较需求，典型输入包括“比较两种新能源并网方案在电压稳定性方面的优劣”“在给定负荷增长预期下评估某区域电网的扩容方案”“分析储能配置比例对新能源消纳率的影响”等。输入通常包含一定的技术参数、边界条件和评价指标，模型需在此基础上展开分析。

输出要求：回答应包含充分的背景分析和技术原理阐述，对涉及的计算方法、仿真模型和评价指标给出必要的解释。方案比较时需从多个维度（技术性能、经济性、可靠性、实施难度等）进行系统分析，明确各方案的适用条件和局限性，给出综合性的权衡建议，而非简单的优劣排序。技术推演需逻辑严谨、因果链条清晰，结论部分需明确推演的前提假设和不确定性因素。

SFT 阶段关联的七类数据类型：该任务主要关联基础科学与仿真理论、物理电网与工程建设、新型电力系统与能源互联三类数据，分别提供仿真分析、工程方案和系统演进方面的知识支撑。

RLHF 阶段归纳场景：主要对应研发与演进场景（research_evolution），要求分析充分、逻辑严谨、重视机理和方案比较。

四类任务的上述定义明确了各自的输入输出边界和场景归属，为本文后续的数据构建、SFT 训练、RLHF 风格对齐和评测体系设计提供了任务层面的规范基础。表 2-1 对四类任务进行了汇总对比。

2.2 整体框架设计

第 1 章已经从研究内容与技术路线角度概述了本文的四阶段方法，本节进一步从模型训练系统的角度说明各阶段的输入数据、核心处理、阶段输出及其衔接关系。框架的总体结构如图 2-1 所示。

从数据流角度看，三类标签体系贯穿多阶段训练全链路：七类电力数据标签贯穿 CPT 与 SFT 阶段，负责保留领域知识来源和原生业务场景；三类场景

表 2-1 数字电网知识服务核心任务定义汇总

任务类型	主要输入	输出要求
电力知识问答	电力专业概念、设备原理、系统结构等事实型或解释型自然语言问题	准确阐述概念或原理，术语解释清晰，结构层次分明；复杂问题适当补充应用场景
故障诊断	故障现象描述、告警信号、设备运行状态、巡检记录等多源信息	结论先行：先给最可能原因，再展开排查步骤（从易到难）；每步附操作目的与判断依据；末尾含风险提示与禁止性操作说明
制度问答	制度条款、规程要求、管理流程的查询或适用性判断问题	措辞正式规范，明确引用制度条款来源；清晰界定适用范围与例外；不越权建议，不确定时建议咨询主管部门
技术方案分析	技术分析或方案比较需求，含技术参数、边界条件和评价指标	充分的背景分析与原理阐述；多维度系统比较（技术性能、经济性、可靠性等）；明确前提假设与不确定性；给出权衡建议而非简单排序

标签主要在 RLHF 阶段发挥作用，负责将多样化业务场景归纳为可控的风格目标；安全风险标签主要服务于 DPO 阶段，负责构造安全拒答、深层恢复和反偏保守三类偏好数据。三类标签分别对应“知识来源—风格控制—安全边界”三个层面的训练需求。以下按训练阶段逐一说明各阶段的系统架构。

（1）CPT 阶段：电力领域知识注入

输入：通用基座模型（Qwen2.5-7B）。Qwen2.5 系列模型在技术报告中系统扩展了预训练数据规模，并结合监督微调与多阶段强化学习提升指令遵循、长文本生成和结构化数据分析能力[55]，因此适合作为本文电力领域多阶段训练的开源基座模型。经过预处理和质量筛选的全量七类电力领域语料（基础科学与仿真理论、物理电网与工程建设、新型电力系统与能源互联、运行控制与二次系统、运维检修与资产管理、综合管理安全与市场、制度文件），辅以通用语料用于能力保持。所有数据以原始文本形式使用，不对数据进行风格层面的区分或标注。

核心处理：采用标准因果语言建模损失进行持续预训练，通过困惑度双阈值筛选选取高质量训练切片，以 1:1 领域-通用数据混合比例平衡领域知识注入与通用能力保持。

阶段输出：具备电力领域知识基础的 CPT 模型。该模型对电力术语、知识结构和语言表达习惯有了初步掌握，但尚不具备按业务任务格式回答的能力。

衔接信号： CPT 模型作为 SFT 阶段的基座模型，注入的电力领域知识为 SFT 阶段的任务能力训练提供知识支撑。七类数据标签从本阶段开始贯穿，为后续训练提供领域知识来源的可追溯性。

（2）SFT 阶段：面向七类数据业务场景的任务能力培养

输入： CPT 模型；以“指令—回答”对形式构造的高质量 SFT 指令数据（约 6.8 万条），每条数据来源于七类数据类型中的某一类，在各类数据的原生业务场景中生成，保留其知识结构、推理逻辑和表达习惯。

核心处理： 采用第 3 章所述的六模块数据合成管线（专家种子构建—设计逻辑提取—知识图谱构建—图遍历指令生成—指令演化—自动化质量筛选），从约 600 条专家种子出发构建覆盖七类数据场景的指令数据；通过两阶段 SFT 训练策略（通用指令微调 + 联合微调）和 1:2 的通用-领域数据配比，使模型在获得指令遵循能力的同时掌握电力领域的任务执行模式。训练数据不添加场景 Prefix，模型通过不同数据类型的业务语境隐式建立差异化的任务响应模式。

阶段输出： 具备多任务执行能力的 SFT 模型，能够在电力知识问答、故障诊断、制度问答和技术方案分析等四类任务上按业务场景给出结构化回答。

衔接信号： SFT 模型作为 RLHF 阶段的基座模型。SFT 阶段保留了七类数据的原生风格多样性（未进行跨类型风格归纳），RLHF 阶段将在其基础上进行场景归纳和风格可控对齐。七类数据标签在 SFT 输出中仍然保留，为 RLHF 阶段的场景归纳映射提供依据。

（3）RLHF 阶段：七类到三类场景归纳与风格可控对齐

输入： SFT 模型；七类数据标签及其对应的指令数据；三类场景归纳映射（研发与演进、生产与运行、合规与管理）；风格强度标注数据（约 1.5 万条）。

核心处理： 首先将七类电力数据类型按照回答风格共性归纳为三类风格控制场景：研发与演进场景（research_evolution），覆盖基础科学与仿真理论、物理电网与工程建设、新型电力系统与能源互联；生产与运行场景（production_operation），覆盖运行控制与二次系统、运维检修与资产管理；合规与管理场景（compliance_management），覆盖综合管理安全与市场、制度文件。为每类场景设定默认的三维风格强度组合（展开程度、安全合规、语气/角色定位），通过强度条件化 Prompt Prefix（格式为 `[展开:Lx][安全:Ly][语气:Lz]`）显式指定目标等级。训练基于 Qwen2.5-7B-Instruct 的风格判别模型，以多维奖励信号驱动 GRPO + Clip-Higher 策略优化，使模型根据 Prefix 稳定切换回答风格。

阶段输出： 具备场景风格可控能力的 RLHF 模型，能够根据强度条件化 Prefix 显式调节输出风格。

衔接信号： RLHF 模型作为 DPO 阶段的基座模型。RLHF 阶段主要关注风格控制，对安全边界的优化不充分，DPO 阶段将在其基础上进行安全合规边界的系统性优化。

（4）DPO 阶段：电力安全合规边界优化

输入：RLHF 模型；四类电力安全风险分类体系（仿真失真与数据造假、设备损毁与参数越限、违章操作与人身风险、系统失稳与大面积停电）；基于安全风险标签构造的三类偏好数据。

核心处理：基于浅层安全对齐理论（Qi et al., ICLR 2025），构建 Clean DPO（基础安全边界）、Recovery DPO（含安全恢复数据增强，构造 $(x, h_{\leq k}, r)$ 三元组，除 $k = 0$ 的基础安全样本外，其余 recovery 样本的截取深度 k 从 Uniform$[1, C]$ 中采样，基础截取上限 $C_0 = 100$ token，实际 C 按风险类型差异化设定）和 Counter Data（反偏保守）三类协同的深层安全对齐数据体系。通过 token-boundary 截断分析和梯度可视化探究安全触发机制，引入 RT-Weighting 风险 Token 加权与风险密度感知采样，采用分阶段混合训练策略，在安全拒答、深层安全恢复和过度拒答控制之间寻求平衡。

阶段输出：最终模型，具备电力知识能力、任务执行能力、场景风格可控能力和安全合规能力四项核心能力。

衔接关系：DPO 阶段是四阶段训练链路的末端，其产出即为本文最终部署模型。

（5）四阶段能力累积与数据流总结

上述四个阶段按照“知识 → 任务 → 风格 → 安全”的逻辑逐级递进。从能力累积角度看：CPT 赋予模型电力领域知识（知识能力），SFT 使模型能够按业务任务格式执行四类核心任务（任务能力），RLHF 使模型能够按场景风格要求调节输出风格（风格控制能力），DPO 使模型在保持可用性的前提下建立深层安全合规边界（安全合规能力）。从数据流角度看：七类电力数据标签从 CPT 到 SFT 持续贯穿，确保领域知识来源的可追溯性；三类场景标签在 RLHF 阶段引入，将多样化业务场景归纳为可控风格目标；安全风险标签在 DPO 阶段引入，为安全偏好数据构造提供分类依据。三类标签分别对应“知识来源—风格控制—安全边界”三个层面的训练需求，使整个多阶段训练系统中的数据流转、标签传递和能力累积构成一个可追溯的完整链路，如图 2-1 所示。

2.3 电力领域数据来源、类型与场景映射

电力领域的数据体系庞大且复杂，涵盖从基础理论研究到现场运维操作、从工程建设规划到制度合规管理的多个业务层次。不同来源和类型的数据在知识形态、推理模式和表达习惯方面存在显著差异，这种差异直接决定了 SFT 阶

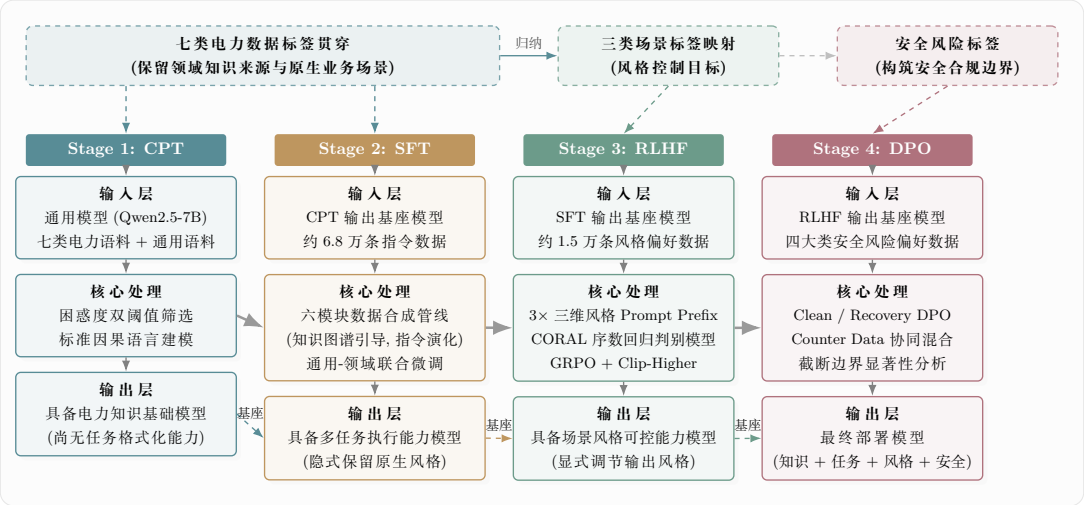


图 2-1 面向数字电网知识服务的多阶段训练总体框架

段指令数据的生成方式以及 RLHF 阶段的场景归纳逻辑。本节首先梳理电力领域的数据来源与七类数据类型，然后阐述 SFT 阶段如何在各类数据的业务场景中生成指令数据，最后分析 RLHF 阶段七类数据到三类场景的归纳逻辑及其对风格控制的作用。

2.3.1 数据来源与七类数据类型

本文使用的电力领域数据主要来源于公开发布的技术标准与规程文件、设备厂商手册与运行说明书、公开故障案例与仿真生成样本、电力市场与安全管理文档、学术论文与技术报告等渠道。真实电力企业故障案例库、调度运行日志和检修工单等数据因其安全和商业保密性质，难以大规模获取；本文仅在少量脱敏案例中引用此类数据作为补充参考，不作为大规模训练数据来源。依据数据的内容特征、知识形态和应用场景，本文将电力领域数据划分为以下七类：

（1）基础科学与仿真理论

该类数据涵盖电力系统分析的基础理论和仿真研究方法，主要包括电力系统稳态与暂态分析理论、电磁场理论、电力电子技术原理、电力系统稳定性分析、短路电流计算、潮流计算方法以及各类仿真模型（如机电暂态仿真、电磁暂态仿真）的建模理论等。数据形式以学术论文、专业教材、技术报告和仿真软件文档为主。该类数据的知识特征为理论性强、数学表达密集、概念抽象度高，回答时需要充分阐释机理、推导逻辑和适用条件。

（2）物理电网与工程建设

该类数据涵盖物理电网的规划、设计、建设和改造相关工程知识，主要包

括输配电网架规划原则、变电站设计规范、输电线路选线与施工标准、设备选型与容量配置、工程验收规范以及建设过程中的技术经济分析等。数据形式以工程设计规范、规划报告、建设标准和工程案例为主。该类数据的知识特征为工程导向、参数具体、约束多元，回答时需要综合考虑技术可行性和经济合理性，给出方案权衡和工程适用性分析。

(3) 新型电力系统与能源互联

该类数据涵盖以新能源为主体的新型电力系统相关技术和能源互联领域的前沿知识，主要包括新能源发电技术（风电、光伏等）、储能系统配置与控制、源网荷储协同优化、微电网与综合能源系统、氢能与多能互补、电力市场与碳交易机制等。数据形式以学术论文、技术白皮书、政策文件和行业报告为主。该类数据的知识特征为前沿性强、系统视角突出、涉及多学科交叉，回答时需要从系统层面进行演进趋势分析和技术路线比较。

(4) 运行控制与二次系统

该类数据涵盖电力系统实时运行控制和二次系统相关的专业知识，主要包括电力系统调度运行规程、电压与频率控制策略、继电保护配置与整定原则、安全稳定控制装置原理、SCADA/EMS 等自动化系统功能说明、二次回路设计与调试规范以及典型运行方式安排等。数据形式以调度规程、运行规定、保护定值单、自动化系统技术文档和运行分析报告为主。该类数据的知识特征为实时性强、逻辑严密、操作规范严格，回答时需要结论清晰、注重运行状态和控制逻辑的准确性。

(5) 运维检修与资产管理

该类数据涵盖电力一次和二次设备的运行维护、检修试验和资产管理相关知识，主要包括设备巡检规范、预防性试验规程、故障诊断方法、检修工艺流程、设备状态评估技术、资产全寿命周期管理方法以及典型故障案例分析等。数据形式以检修规程、试验标准、故障分析报告、设备技术台账和培训材料为主。该类数据的知识特征为操作导向、步骤化程度高、安全风险突出，回答时需要步骤清晰、可执行性强，并且必须包含明确的风险提示。

(6) 综合管理安全与市场

该类数据涵盖电力企业综合管理、安全管理体系和电力市场运营相关领域的知识，主要包括电力安全生产法规、安全标准化管理要求、应急管理预案、电力市场交易规则、需求侧管理方法以及电力可靠性管理等。数据形式以行政法规、部门规章、管理标准和市场运营规则为主。该类数据的知识特征为政策性强、管理流程明确、涉及合规判断，回答时需要规范表述、明确管理边界和适

用条件。

(7) 制度文件

该类数据涵盖电力行业各级各类的制度文件、操作规程和管理规定，主要包括国家和行业技术标准、企业操作规程、票证管理制度、调度纪律规定、安全作业规定、人员资质管理和培训考核制度等。数据形式以标准文件、规程文本和制度汇编为主。该类数据的知识特征为条款化程度高、适用边界明确、具有强制性，回答时需要严格依据条款原文、清晰界定适用范围和例外情况，不得越权解释。

2.3.2 SFT 阶段：七类数据业务场景中的指令数据生成

在 SFT 阶段，指令数据的生成直接面向上述七类数据各自的业务场景，各类数据保留其原生的知识结构、推理逻辑和表达习惯，不进行跨类型的风格归纳或统一化处理。

具体而言，面向基础科学与仿真理论类数据，SFT 指令的答案倾向于机理阐释、公式推导和参数论证，回答结构通常为“背景说明 → 原理分析 → 数学推导 → 结论”；面向物理电网与工程建设类数据，答案倾向于工程方案描述、技术经济比较和适用条件分析，结构为“需求分析 → 方案设计 → 技术经济比较 → 推荐方案”；面向新型电力系统与能源互联类数据，答案倾向于系统层面分析、技术路线推演和多方案权衡，结构为“趋势分析 → 技术路线 → 方案比较 → 演进建议”。上述三类数据虽然在目标回答结构上有所差异，但共同特点是需要充分的分析论证过程。

面向运行控制与二次系统类数据，答案倾向于运行状态判断、控制逻辑说明和风险优先提示，结构为“现象判断 → 可能原因 → 处置建议 → 风险提示”；面向运维检修与资产管理类数据，答案倾向于步骤化排查、可执行操作指导和安全禁忌说明，结构为“结论先行 → 排查步骤 → 每步依据 → 风险注意事项”。上述两类数据共同强调结论的清晰性、步骤的可执行性和风险的明确表达。

面向综合管理安全与市场类数据，答案倾向于管理流程说明、合规判断和边界界定，结构为“问题分析 → 适用规定 → 合规判断 → 管理建议”；面向制度文件类数据，答案倾向于条款原文引用、适用范围界定和流程解释，结构为“结论 → 依据条款 → 适用条件 → 合规提醒”。上述两类数据共同强调表述的规范性、依据的明确性和边界的清晰性。

七类数据在 SFT 输入格式中均为标准的“指令—回答”对，模型在微调过程中通过不同数据类型场景下的指令内容和回答风格学习差异化的任务响应模

式。这种“场景原生”的数据构建策略确保了模型在 SFT 阶段习得的回答风格与数据本身的业务特征高度一致，避免了因过早风格归纳导致的信息混杂和风格漂移。

2.3.3 RLHF 阶段：七类数据到三类场景的归纳映射

虽然 SFT 阶段保留七类数据各自的原生风格有利于保护数据多样性，但从风格控制的角度来看，为七类数据分别设计七种 Prompt Prefix 会导致控制粒度过细、训练成本过高以及部分相近场景 Prefix 之间的混淆风险。因此，本文在 RLHF 阶段将七类数据类型按照回答风格的共性归纳为三种风格控制场景。

归纳逻辑如下：基础科学与仿真理论、物理电网与工程建设、新型电力系统与能源互联三类数据，虽然分别侧重理论分析、工程方案和系统演进，但它们的共同特征是均要求回答具有充分的分析论证过程——需要展开技术原理、进行逻辑推演、比较多种方案并给出综合性判断，在目标回答风格上高度一致。因此，本文将这三类归纳为研发与演进场景（research_evolution），目标回答风格为分析充分、逻辑严谨、重视机理阐述和方案比较，推荐答案结构为“背景说明 → 原理分析 → 方案比较 → 结论与建议”。

运行控制与二次系统、运维检修与资产管理两类数据，虽然分别侧重实时运行控制和设备检修维护，但它们的共同特征是均要求回答面向现场操作——需要结论先行、步骤清晰、风险明确、可执行性强，直接服务于实际的运行处置和检修作业。因此，本文将这两类归纳为生产与运行场景（production_operation），目标回答风格为结论先行、步骤清晰、风险优先、可执行，推荐答案结构为“现象判断 → 可能原因 → 排查步骤 → 风险提示”。

综合管理安全与市场、制度文件两类数据，虽然分别侧重管理合规和制度条款解释，但它们的共同特征是均要求回答具备正式规范性和依据性——需要措辞正式、引用明确依据、界定适用边界、避免主观推测或越权建议。因此，本文将这两类归纳为合规与管理场景（compliance_management），目标回答风格为正式规范、依据明确、边界清晰、避免越权，推荐答案结构为“结论 → 依据/条款 → 适用条件 → 合规提醒”。

上述归纳映射的设计遵循了两个原则。第一是“风格相似性原则”——将回答风格要求高度一致的数据类型归入同一场景，确保同一 Prefix 训练下模型能够学习到稳定且一致的风格模式。第二是“控制粒度适中性原则”——将风格控制场景数量从七种压缩为三种，在保持风格区分度的同时降低了 Prefix 设计复杂度和 RLHF 训练难度。三种场景分别对应电力行业中三个典型的业务角色需

求（技术研究人员、生产运维人员、管理人员），具有明确的业务语义。

需要强调的是，七类到三类的归纳仅作用于 RLHF 阶段，不影响 SFT 阶段的数据构建。SFT 阶段在七类数据场景中保留了完整的原生风格多样性，为模型提供了丰富的表达基础；RLHF 阶段在此基础上通过归纳后的 Prefix 引导模型在不同场景间进行风格切换，实现系统化的风格可控调节。表 2-2 汇总了七类数据类型与三类场景的归纳映射关系。

表 2-2 电力领域七类数据类型与三类场景归纳映射

数据类型	**SFT 阶段业务特征**	**RLHF 归纳场景**
基础科学与仿真理论	理论分析、仿真推演、参数研究	研发与演进
物理电网与工程建设	工程规划、建设方案、系统设计	
新型电力系统与能源互联	新能源消纳、源网荷储协同、系统演进	
运行控制与二次系统	运行方式、控制策略、保护配置	生产与运行
运维检修与资产管理	故障诊断、检修步骤、状态评估	
综合管理安全与市场	安全管理、市场规则、应急处置	合规与管理
制度文件	制度条款、流程要求、适用边界	

2.4 电力数据预处理与标签化流程

电力领域原始数据来源多样、格式不一、质量参差不齐，在进入 CPT 和 SFT 阶段之前必须经过系统化的预处理和标签化，将其转化为高质量、结构化、可训练的语料和指令数据素材。本文的预处理与标签化流程包括七个步骤：文本抽取、格式规范、噪声清洗、分段切片、去重筛选、质量评估和双层标签化。流程如图 2-2 所示，各步骤具体说明如下。大规模预训练语料的质量会显著影响语言模型的泛化能力和生成稳定性，现有语料构建研究通常结合网页文本清洗、重复数据去除、语言模型评分和质量筛选等机制来提高训练语料有效性[56-58]。

（1）文本抽取

电力领域数据以多种文件格式存在，主要包括 PDF 格式的制度文件和设备手册、Word 格式的规程文档和检修报告、HTML 网页格式的技术资料和公告

文件、纯文本格式的运行日志和故障记录，以及 Excel 表格形式的设备台账和试验数据等。本文针对不同格式采用差异化的抽取策略：对于 PDF 文件，使用 PyMuPDF 和 pdfplumber 等工具提取文本，并对双栏排版、表格嵌入和公式混排等情况进行版式还原处理；对于 Word 文件，使用 python-docx 提取段落和表格文本；对于网页文件，使用 HTML 解析器提取正文内容并去除导航栏、广告和页脚等非正文元素；对于表格数据，将结构化字段转换为自然语言描述以适配语言模型的输入格式；对于运行日志和故障记录，保留其时序关系和字段关联信息。所有抽取出的文本统一转换为 UTF-8 编码的纯文本格式，便于后续步骤进行处理。

（2）格式规范

不同来源的文本在标题层级、条款编号、表格呈现、计量单位和符号表达方面缺乏统一性，直接影响后续的分段切片和知识提取效果。本文的格式规范步骤包括：统一标题编号层级，将“一、”“1.”“1.1”“第 1 条”等多种编号方式转换为统一的层级结构标记；统一条款引用格式，将“第 X 条”“X.X 条款”等格式统一为标准表达，便于制度问答任务中的条款追溯；统一计量单位表达，将中文单位（如“千伏”）、英文缩写（如“kV”）和混合表达进行标准化；统一电力专业符号，将特殊字符、下标、希腊字母等统一为可被分词器正确识别的形式；规范化表格内容，将复杂表格转换为带表头标注的结构化文本段落。格式规范的目的是降低文本的形式噪声，使模型在训练时聚焦于知识内容本身而非格式差异。

（3）噪声清洗

原始文本中包含大量与电力知识无关的噪声内容，需要在预处理阶段予以清除。噪声清洗的内容包括：去除页眉页脚和页码信息；去除文档目录页和索引页（目录结构信息在元数据中已保留）；去除乱码字符、不可见字符和因 OCR 识别错误产生的无意义符号；去除重复出现的免责声明、版权声明和文档修订记录等模板性文本；去除孤立的图表编号（如图号“图 3-2”后无对应图表内容）和无实体的引用标记。噪声清洗采用规则匹配与人工校验相结合的方式，规则负责批量过滤已知模式的噪声，人工校验负责确认边界情况和调整规则阈值。

（4）分段切片

经过清洗的连续文本需要按照合理的粒度切分为 CPT 训练可用的文本块。考虑到 CPT 阶段的训练效率和对完整上下文的需求，本文将切片的目标长度设定为约 4096 个 token，与主流基座模型的预训练窗口大小相匹配。切片时按照数据类型的不同采用差异化的组织策略。对于基础科学和仿真理论类文本，按

知识单元进行组织，将相邻的概念定义、原理阐述和推导过程拼接为一个切片，确保知识链条的完整性。对于制度文件类文本，按条款单元进行组织，将同一章节下相邻的若干完整条款（包括其子条款和附则说明）拼接为一个切片，保留条款之间的层级隶属关系。对于故障案例和检修记录类文本，按案例单元进行组织，每个切片包含一个或多个完整的故障案例（涵盖故障现象、分析过程、处置措施和结论）。对于运行日志类文本，按时间段或事件批次进行组织，保留时序上的连续性和关联性。

为满足 4K token 的目标长度并避免过度填充（padding）导致的计算浪费，切片时采用“完整句边界截断 + 相邻短文本拼接”策略。首先沿自然句边界将文本断开，然后将相邻的短文本块按所属数据类型的逻辑关系进行拼接，直至接近 4K token 的上限。拼接时优先合并在知识内容上紧密关联的相邻块（如同一章节下的连续条款、同一故障案例的多个分析段落），确保合并后的切片在语义上连贯一致。对于最后剩余不足 4K token 的尾部文本，将其合并到前一切片中而非独立填充，以最大限度地减少 padding token 的比例，提高 CPT 阶段的计算利用率。

（5）去重筛选

电力领域的不同数据源之间存在大量重复或高度相似的内容——同一技术标准被多个文档引用，同一故障案例在不同报告中出现，同一制度条款在各级文件中被逐级转录。这些冗余数据不仅浪费训练计算资源，还会导致模型对高频重复片段过拟合，损害泛化能力。训练语料去重已被证明能够提升语言模型训练质量，并减少模型对重复片段的记忆与过拟合风险[57]。本文设计了一个三级递进式去重管道，从句面精确匹配到语义级过滤，逐步提升去重的精度和覆盖率。

第一级：精确匹配与规则去重。基于 SimHash 对全量文本切片进行快速指纹索引。SimHash 可将高维文本特征压缩为二值签名，并通过汉明距离近似衡量文本相似度，常用于大规模近重复网页检测[59-60]。记文本切片 d 的 SimHash 签名为 $h(d) \in \{0,1\}^B$（本文取 $B = 64$），两个切片的汉明距离为：

$$d_H(d_i, d_j) = \| h(d_i) \oplus h(d_j) \|_0 \tag{2-1}$$

其中 $\oplus$ 为按位异或，$\| \cdot \|_0$ 为 ℓ_0 范数。对 $d_H = 0$（完全同指纹）的切片对进行精确文本比对，若文本完全相同则保留一份、删除其余重复副本。同时，利用正则表达式匹配技术标准编号、规程条款号和设备型号等结构化字段，识别因格式差异导致 SimHash 指纹不同的内容重复（如同一标准条款在不同文档中被重

新编号引用）。

第二级：MinHash 近似去重。精确匹配无法处理局部修改后的近似重复——如同一个故障案例在不同报告中被改写或摘录。本文采用 MinHash 进行 n-gram 级别的近似去重。MinHash 可对集合 Jaccard 相似度进行无偏估计，是文档相似性估计和近重复检测中的经典方法[61]。对于文本切片 d，首先抽取其字符级 n-gram 集合 $\mathcal{N}_n(d) = \{g_1, g_2, \ldots, g_{|d|-n+1}\}$（取 $n = 3$），然后通过 K 个独立的哈希函数 $\{\pi_k\}_{k=1}^{K}$ 生成 MinHash 签名：

$$\mathcal{M}(d) = \left(\min_{g \in \mathcal{N}_n(d)} \pi_1(g),\ \min_{g \in \mathcal{N}_n(d)} \pi_2(g),\ \ldots,\ \min_{g \in \mathcal{N}_n(d)} \pi_K(g) \right) \tag{2-2}$$

其中每个 π_k 将 n-gram 映射到 $[0, M-1]$ 的整数空间（M 为哈希表大小）。两个切片 d_i 和 d_j 的 Jaccard 相似度可通过其 MinHash 签名无偏估计：

$$\hat{J}(d_i, d_j) = \frac{1}{K} \sum_{k=1}^{K} \mathbb{1}\left[\mathcal{M}_k(d_i) = \mathcal{M}_k(d_j)\right] \tag{2-3}$$

该估计的方差为 $\mathrm{Var}[\hat{J}] = J(1-J)/K$，其中 J 为真实 Jaccard 相似度。本文取 $K = 128$ 以将估计标准差控制在 < 0.05。对所有 $\hat{J}(d_i, d_j) > \tau_J$ 的切片对（$\tau_J = 0.85$），保留文本质量评分较高的一条，丢弃另一条。

MinHash 的优势在于其局部敏感性：两个文本的 Jaccard 相似度越高，其 MinHash 签名碰撞概率越大，且计算复杂度为 $O(K \cdot |\mathcal{N}_n(d)|)$，显著低于逐对计算完整 n-gram 集合相似度的 $O(|\mathcal{D}|^2 \cdot |\mathcal{N}|)$。实际实现中，采用 LSH（Locality-Sensitive Hashing）桶分组策略进一步加速。LSH 通过局部敏感哈希函数将相似样本以更高概率映射到同一桶中，从而降低大规模近邻搜索的复杂度[62]。将 K 个哈希值分为 B 个 band，每个 band 包含 $r = K/B$ 个哈希值，仅在同一 band 内所有哈希值均相等的切片对之间计算 Jaccard 相似度。设 s 为真实 Jaccard 相似度，则两个切片在同一 band 内碰撞的概率为 $1 - (1 - s^r)^B$，该 S 曲线在 $s \approx (1/B)^{1/r}$ 处陡升，通过调节 (r, B) 可以精确控制去重的灵敏度阈值。

第三级：语义嵌入去重。MinHash 依赖字符级 n-gram 重叠，对表述不同但语义相同的文本（如“变压器油温异常升高”和“主变顶层油温超限”）无效。本文使用通用文本嵌入模型 BGE-M3（BAAI/bge-m3）作为嵌入模型，取每个切片的嵌入向量经 ℓ_2 归一化后作为切片嵌入向量 $\mathbf{v}_d \in \mathbb{R}^D$（$D = 3584$）。两个切片的语义相似度通过余弦相似度度量：

$$\cos(d_i, d_j) = \frac{\mathbf{v}_{d_i}^{\top} \mathbf{v}_{d_j}}{\|\mathbf{v}_{d_i}\|_2 \cdot \|\mathbf{v}_{d_j}\|_2} \tag{2-4}$$

对 $\cos(d_i, d_j) > \tau_{\cos}$（$\tau_{\cos} = 0.92$）的切片对，判定为语义重复，保留信息密度较高的一条（以单位 token 数的有效实体提及量衡量）。为降低计算复杂度，使用 FAISS 库构建 IVF-PQ 索引，在近似近邻搜索中实现高效查询；FAISS 已被广泛用于 GPU 加速的大规模向量相似度检索[63]。

三级去重的协同设计。三级去重从前到后依次提高检测精度和计算成本：第一级规则去重以 $O(|\mathcal{D}|)$ 成本快速剔除精确重复，实际去除 18.6% 的切片；第二级 MinHash 以 $O(K \cdot |\mathcal{D}| \cdot \bar{n})$ 成本去除近似字符重叠的切片，再去除 12.3%；第三级语义去重以前两级过滤后的较小候选集为输入，以 $O(|\mathcal{D}'| \cdot D)$ 的成本去除字符差异大但语义相同的切片，再去除 7.2%。按逐级累积口径计算，三级去重后的最终累积保留率为 66.2%，对应累计去重率约为 33.8%，其中三个阶段的阶段去除率分别为 18.6%、12.3% 和 7.2%，体现了从规则重复、字符近似重复到语义重复的递进式过滤效果。表 2-3 汇总了三级去重管道的配置参数和实验统计。

表 2-3 三级去重管道配置参数与实验结果

去重级别	核心算法	关键参数	去除率	累积保留率
第一级	SimHash + 规则匹配	$B = 64$，精确文本匹配 + 正则结构化去重	18.6%	81.4%
第二级	MinHash + LSH 桶分组	$K = 128$，$n = 3$，$\tau_J = 0.85$，LSH band $B = 16$，$r = 8$	12.3%	71.4%
第三级	语义嵌入 + FAISS 索引	$\tau_{\cos} = 0.92$，$D = 3584$	7.2%	66.2%
三级合计		—	**33.8%**	**66.2%**

(6) 质量评估

去重后的文本切片需要经过多维度的质量评估，以筛选出适合用于训练的高质量数据。本文的质量评估维度包括：领域相关性，判断文本内容是否属于电力领域，排除泛行业管理类文本和与电力无关的通用内容；事实完整性，检查知识类切片是否包含完整的概念定义或原理阐述，避免因切片不当导致的半截知识点；条款完整性，检查制度类切片是否包含完整的条款内容及其必要的上下文（如所属章节或上位条款）；风险表达检查，对涉及操作和故障的文本，检查是否包含必要的安全警告和风险说明，对缺少风险表达的文本进行标注提醒；可训练性评估，综合判断文本的语言流畅性、逻辑连贯性和内容信息密度，排除过于碎片化或信息量过低的切片。质量评估采用“自动指标初筛 + LLM 辅助判断 + 人工抽样校验”的三级机制，在效率和准确性之间取得平衡。

（7）双层标签化

经过上述步骤后得到的高质量文本切片进入标签化阶段。本文的标签化包含两个层次，分别服务于 SFT 阶段和 RLHF 阶段。

第一层：七类数据类型标签（用于 SFT 阶段）。根据文本的来源和内容特征，为每条文本切片分配七类数据类型标签之一：基础科学与仿真理论、物理电网与工程建设、新型电力系统与能源互联、运行控制与二次系统、运维检修与资产管理、综合管理安全与市场、制度文件。数据类型标签的分配依据是该文本的核心知识内容而非其文件来源——例如，一份制度文件中引用的技术标准段落可能被标注为对应的技术类数据类型而非制度文件类。数据类型标签决定了该文本切片在 SFT 阶段所属的数据场景，指导后续的指令数据生成风格和质量筛选标准。

第二层：三类场景归纳标签（用于 RLHF 阶段）。在 SFT 数据构建完成后，按照 2.3 节所述的归纳逻辑，将七类数据类型标签映射为三类场景归纳标签：基础科学与仿真理论、物理电网与工程建设、新型电力系统与能源互联映射为 research_evolution；运行控制与二次系统、运维检修与资产管理映射为 production_operation；综合管理安全与市场、制度文件映射为 compliance_management。场景归纳标签不参与 SFT 阶段的数据构建和训练，而是在 RLHF 阶段作为 Prompt Prefix 的设计依据和风格偏好数据的组织框架。三条 Prefix 与三类场景归纳标签一一对应，RLHF 训练时通过 Prefix 激活对应场景的风格模式。

双层标签的设计是本文方法的重要组成部分。第一层标签（七类）服务于数据多样性的保留——SFT 阶段在七类数据的原生场景中分别构建指令数据，保持了各类型独有的知识表达风格。第二层标签（三类）服务于风格控制的可行性——RLHF 阶段将风格控制的数量从七种压缩为三种，在保持风格区分度显著性的同时降低了训练难度。两层标签之间通过 2.3 节定义的归纳映射规则进行显式关联，确保 SFT 阶段的多样性输入与 RLHF 阶段的归约控制之间具有清晰可追溯的衔接关系。



图 2-2 电力数据预处理与双层标签化流程

2.5 持续预训练设计

持续预训练（CPT）是本文多阶段训练框架的第一阶段，其核心目标是将电力领域专业知识有效注入通用基座模型，使模型在电力术语理解、知识结构掌握和领域语言表达等方面获得显著增强，为后续 SFT 阶段在七类数据业务场景中的任务能力训练提供知识底座。

2.5.1 训练数据构成

CPT 阶段所使用的数据为 2.4 节经过预处理和双层标签化的七类电力领域文本切片，涵盖基础科学与仿真理论、物理电网与工程建设、新型电力系统与能源互联、运行控制与二次系统、运维检修与资产管理、综合管理安全与市场、制度文件全部七类数据。每类数据以约 4096 token 长度的切片形式组织，经过去重和质量筛选后构成 CPT 的初始候选语料库。

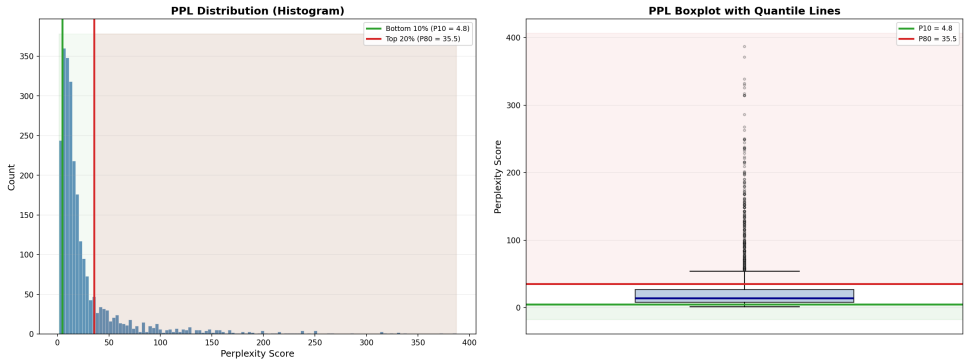
2.5.2 基于困惑度的数据筛选

在实际 CPT 训练中，本文观察到尽管经过了 2.4 节所述的多级去重和质量筛选，训练后的模型在生成文本时仍偶尔出现乱码、不连贯表达或与领域无关的碎片化输出。分析表明，原始语料中仍残留了部分难以通过规则和相似度方法检测的低质量数据——这些数据虽然表面形式正常，但内容逻辑混乱、知识事实错误或包含 OCR 等环节引入的隐性噪声，对 CPT 训练产生了负面影响。同时，语料中也存在大量高重复性的基础性表述，模型在训练早期即已充分学习，反复训练这些数据不仅效率低下，还可能加剧灾难性遗忘。

针对上述问题，本文借鉴数据剪枝与质量筛选研究中的相关思路。Marion 等在大规模预训练数据剪枝研究中比较了困惑度、EL2N 和记忆度等质量评分指标，发现困惑度能够作为一种简单有效的预训练数据质量估计方法[58]。据此，本文提出一种基于模型困惑度（Perplexity, PPL）的两阶段数据筛选方法。具体流程如下。

第一阶段：初始 CPT 与种子模型获取。从预处理后的语料中，按照七类数据的比例分布，人工选取一小批高质量数据（约占总量的 5%—10%），通过严格的逐条校验确保其内容准确、表达规范、无乱码和事实错误。使用这批精选数据对基座模型进行初步 CPT 训练，得到一个种子 CPT 模型。该种子模型虽仅在少量高质量数据上训练，但已初步具备了电力领域的语言分布知识，能够有效区分专业、规范的电力文本与低质量文本。

第二阶段：全量语料的困惑度评分与筛选。利用种子 CPT 模型对整个剩余候选语料库（约 90%—95%）进行推理，逐切片计算困惑度（PPL）分数。困惑度反映了模型对一段文本的“熟悉程度”——对于模型已充分学习的常见模式文本，困惑度较低；对于模型感到陌生或难以拟合的文本，困惑度较高。本文在分析困惑度分布后，设定了高、低两个筛选阈值：去除困惑度最高的 20% 切片。这部分切片困惑度过高，模型在给定上下文后难以有效预测其 token 序列，表明其内容可能包含逻辑矛盾、事实错误、格式乱码或 OCR 噪声等隐性质量问题，属于模型“难以学习”的脏数据，继续用于训练可能引入噪声并损害模型输出质量。去除困惑度最低的 10% 切片。这部分切片困惑度过低，表明其中的语言模式和知识内容已被种子模型充分掌握，继续大量训练不仅边际收益低，还可能挤占模型对其他数据的学习空间。保留困惑度处于中间区间的切片（约 70%），这部分切片既不会因为质量过低引入噪声，也不会因为过于简单而缺乏学习价值，属于信息密度较高的有效训练数据。图 2-3 展示了全量语料的困惑度分布及高、低双阈值的筛选区间。



注：左图为全量语料 PPL 分布直方图，虚线标注高阈值（PPL 最高的 20%）和低阈值（PPL 最低的 10%）的筛选边界；右图为七类数据 PPL 分布的箱线图。

图 2-3 电力领域语料困惑度分布

上述筛选策略的直觉在于：困惑度作为一个相对指标，能够反映数据相对于当前模型状态的学习价值。困惑度过高的数据可能并非真正的“难知识”，而是“坏数据”；困惑度过低的数据虽然质量可靠，但已被掌握，训练收益有限。通过去除两端、保留中间，可以筛选出既高质量又具有充分学习价值的训练数据。这一策略与数据剪枝研究的核心发现一致——在训练数据规模恒定的情况下，经过质量筛选的较小数据集往往能取得优于全量数据的训练效果[58]。

2.5.3 领域数据与通用数据的配比设计

引入困惑度筛选后的电力领域数据虽然质量得到显著提升，但仅使用领域语料进行 CPT 训练容易导致模型的通用语言能力退化。领域自适应预训练研究已经表明，继续使用领域语料训练可以提升领域任务表现[6]；而持续预训练中的领域数据与通用数据配比也会影响专业能力迁移和通用能力保持之间的平衡[52]。这一现象与神经网络连续学习中的灾难性遗忘问题一致，即模型在学习新分布时可能损害旧分布上的能力[64]。在本文实验中，仅使用领域语料进行 CPT 训练导致模型的通用语言能力出现明显退化：在 C-Eval 和 MMLU 基准上分别下降 8.7 和 6.3 个百分点，表现出典型的灾难性遗忘。通用能力的保持对电力领域模型的实用性至关重要——用户的问题不仅包含专业术语，还涉及通用自然语言理解和逻辑推理需求。

为在领域知识注入与通用能力保持之间取得较好权衡，本文设计了系统的数据配比实验。设领域数据与通用数据的混合比例为 $\lambda \in [0,1]$，表示每个训练 batch 中领域数据的采样概率（通用数据概率为 $1-\lambda$）。纯领域训练对应 $\lambda = 1$，纯通用训练对应 $\lambda = 0$。本文考察 $\lambda \in \{0, 0.33, 0.5, 0.67, 1\}$ 五种配比方案，对应领域: 通用比例分别为 0:1、1:2、1:1、2:1、1:0。

评估指标。为评估 CPT 模型的领域能力，本文构建了 PowerQA-Eval 评测集。该评测集覆盖全部七类电力数据类型，每类数据的题目由 LLM 基于 CPT 语料自动生成问题草稿，经少量人工抽检（每类抽检约 10 条确认领域合理性）后定稿，共计 420 道。为避免训练-评测泄漏，评测集构建时按源文档进行划分，测试集所使用的原始文本切片不参与 CPT 训练数据的 PPL 筛选与混合配比；生成的问题进一步经文本相似度去重，确保与训练语料无高度重合。每类 60 道题目按题型均匀分布：20 道选择题（四选一，考察术语辨析和概念判断）、20 道填空题（考察关键参数和定义的精确记忆）、20 道简答题（考察原理阐述和逻辑表达能力）。选择题和填空题的参考答案由知识图谱自动抽取，简答题的参考答案由生成管线构造并经人工抽检。评测时，选择题和填空题采用精确匹配自动判分，简答题由 LLM-as-Judge 根据参考答案的关键知识点覆盖度进行 0–1 分评分。考虑到 LLM-as-Judge 评测可能受到位置偏差、长度偏差和模型偏好的影响[65]，本文在构建评测集时进一步采用人工抽检和训练—测试源文档隔离以降低评测泄漏风险。三者等权平均得到该类的综合得分，七类综合得分的加权平均为 PowerQA-Eval 的最终得分。此外，面向后续 SFT 阶段的 FaultDiag-Eval 和 RegulationQA-Eval 同样由生成管线自动构造（具体构造方式与指标定义见 3.7

节），不依赖大规模专家标注。通用能力采用 C-Eval 和 MMLU 两个基准的加权平均分（General Score, GS）度量。C-Eval 面向中文基础模型构建了多层级、多学科评测体系[66]，MMLU 则是评估大模型多任务知识理解能力的经典基准[67]。定义综合得分 $S(\lambda)$ 为两者的加权调和平均：

$$S(\lambda) = \frac{2 \cdot \mathrm{DA}_\lambda \cdot \mathrm{GS}_\lambda}{\mathrm{DA}_\lambda + \mathrm{GS}_\lambda} \tag{2-5}$$

该公式在 DA 和 GS 任一维度显著偏低时综合得分均受到抑制，仅在两者均衡时取得高分。

实验结果。表 2-4 和图 2-4 展示了五种配比下的性能对比。纯领域训练（$\lambda = 1$）取得最高的领域综合得分 72.4%，但通用得分从基线的 65.8 骤降至 55.3。纯通用训练（$\lambda = 0$）保持通用得分 65.8 但领域综合得分仅 43.5%（与原始基座模型相当）。随着 λ 从 0 增大，领域综合得分单调递增而通用得分单调递减，两者呈显著的负相关（Spearman $\rho = -1.00$）。

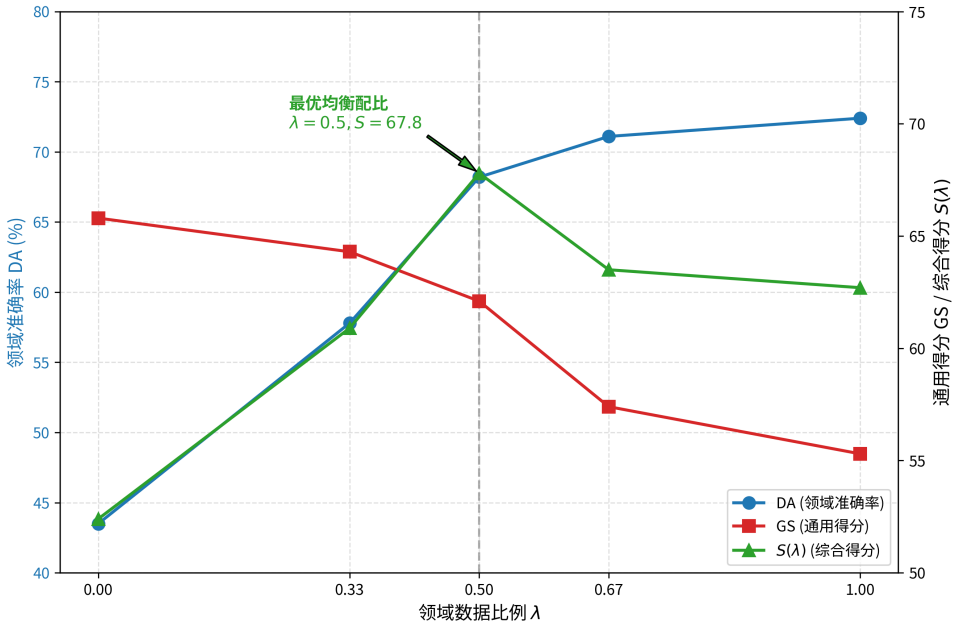
$\lambda = 0.5$（1:1 均衡配比）取得最高综合得分 $S = 65.0$：领域综合得分达到 68.2%（较基线提升 24.7 pp），通用得分 62.1（仅较基线下降 3.7 分），在领域知识注入和通用能力保持之间实现了最佳平衡。值得注意的是，$\lambda = 0.67$（2:1 领域为主）虽然领域综合得分进一步提升至 71.1%，但通用得分急剧下降至 57.4，综合得分反而低于均衡配比，表明过高的领域数据比例带来的通用能力损失已超过边际领域收益。

消融分析。为进一步验证 PPL 筛选对配比实验的影响，本文对比了未经过 PPL 筛选的全量语料在相同 λ 下的性能。在 $\lambda = 0.5$ 时，未筛选数据的领域综合得分仅 61.5%（低于筛选后的 68.2%），通用得分也略低（60.4 vs. 62.1），支持了 PPL 双阈值筛选对数据质量的提升作用在混合训练中仍然有效。

基于上述实验，CPT 阶段最终采用 $\lambda = 0.5$（1:1 均衡配比）的混合训练策略，训练时每个 batch 内按 1:1 比例采样，确保两类数据在每一步梯度更新中均得到均匀参与。

表 2-4 不同领域-通用数据配比下的 CPT 性能对比

λ（领域比例）	领域: 通用	领域综合得分（DA）	通用得分（GS）	综合得分 $S(\lambda)$
0	0:1	43.5%	65.8	52.4
0.33	1:2	57.8%	64.3	60.9
0.5	1:1	68.2%	62.1	**65.0**
0.67	2:1	71.1%	57.4	63.5
1	1:0	**72.4%**	55.3	62.7



注：λ 为领域数据比例，DA 为领域综合得分，GS 为通用得分，$S(\lambda)$ 为综合得分；$\lambda = 0.5$（1:1 均衡配比）取得综合得分最高。

图 2-4 不同领域-通用数据配比下的 CPT 性能对比

2.5.4 训练目标与实施细节

CPT 阶段采用标准的因果语言建模（Causal Language Modeling, CLM）作为训练目标，该目标与自回归 Transformer 语言模型的预训练范式一致[1-2]。给定上下文 token 序列 $\mathbf{x}_{<t} = (x_1, x_2, \ldots, x_{t-1})$，优化目标为最小化下一个 token x_t 的负对数似然损失：

$$\mathcal{L}_{\mathrm{CLM}}(\theta) = -\frac{1}{|\mathcal{D}_{\mathrm{CPT}}|} \sum_{d \in \mathcal{D}_{\mathrm{CPT}}} \frac{1}{|d|} \sum_{t=1}^{|d|} \log P_\theta(x_t \mid \mathbf{x}_{<t}) \tag{2-6}$$

其中 $\mathcal{D}_{\mathrm{CPT}}$ 为经 PPL 筛选和通用数据混合后的 CPT 训练语料，$|d|$ 为切片 d 的 token 长度，θ 为模型参数。与预训练阶段一致，采用自回归的 next-token prediction 方式，不引入额外的辅助损失或任务头。

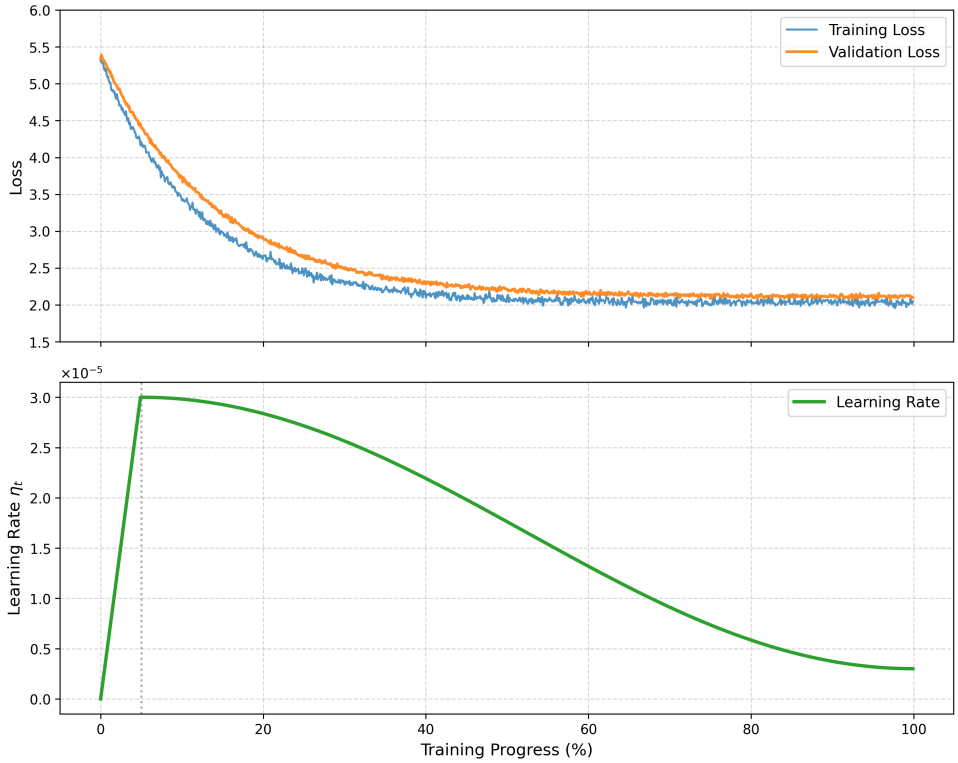
训练配置。在基座模型（Qwen2.5-7B）上进行全参数持续训练，使用 AdamW 优化器进行参数更新，AdamW 通过将权重衰减从自适应梯度更新中解耦，改善了 Adam 类优化器的正则化效果[68]。优化器超参数设置为 $\beta_1 = 0.9$, $\beta_2 = 0.95$, weight decay = 0.1，采用余弦学习率衰减策略：

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos \frac{t\pi}{T}\right) \tag{2-7}$$

其中初始学习率 $\eta_{\max} = 3 \times 10^{-5}$（约为预训练学习率的 1/10），最小学习率 $\eta_{\min} =$

3×10^{-6}，T 为总训练步数。前 5% 步采用线性 warmup 从 0 升至 $\eta_{\max}$。全局 batch size 为 256，序列长度上限为 4096 token，使用 BF16 混合精度和梯度裁剪（max norm = 1.0）。训练在 8×A100 80GB GPU 上进行，使用 DeepSpeed ZeRO-3 分布式策略。ZeRO 通过优化优化器状态、梯度和参数的分布式存储显著降低大模型训练的显存开销[69]。总训练步数对应 1 个 epoch。

训练过程与收敛性分析。图 2-5 展示了 CPT 训练过程中的损失曲线。训练损失从初始的 5.32 下降至收敛时的 2.03，绝对下降 3.29，相对下降约 61.8%；收敛损失约为初始损失的 38.2%。从损失曲线的形态可以观察到两个特征阶段：第一阶段（前 30% 步数），损失快速下降——模型迅速学习电力领域的高频术语和常见表达模式；第二阶段（后 70% 步数），损失进入缓慢下降的精细调整阶段——模型学习低频专业知识和复杂的跨领域关联，下降速率放缓至每百步约 0.02。验证损失在全训练过程中未出现回升，表明 1 个 epoch 的训练设置和混合数据策略有效避免了过拟合。



注：上图为训练损失与验证损失曲线，下图为学习率衰减曲线。
图 2-5 CPT 训练过程曲线

为验证混合数据策略对通用能力保持的效果，图 2-6 展示了训练过程中模型在领域数据和通用数据上的困惑度（PPL）变化趋势。领域数据上的 PPL 从初始的 18.7 单调下降至 8.2，表明模型对电力领域文本的拟合程度持续提高。通

用数据上的 PPL 在训练初期（前 15% 步数）出现小幅上升（从 9.5 升至 10.3），随后逐渐回落并在训练结束时稳定在 9.8——仅较初始值轻微上升 0.3，远低于纯领域训练（$\lambda = 1$）条件下的通用 PPL 升幅（$\Delta = 3.1$）。这一对比直观验证了 1:1 混合策略在保持通用能力方面的有效性。

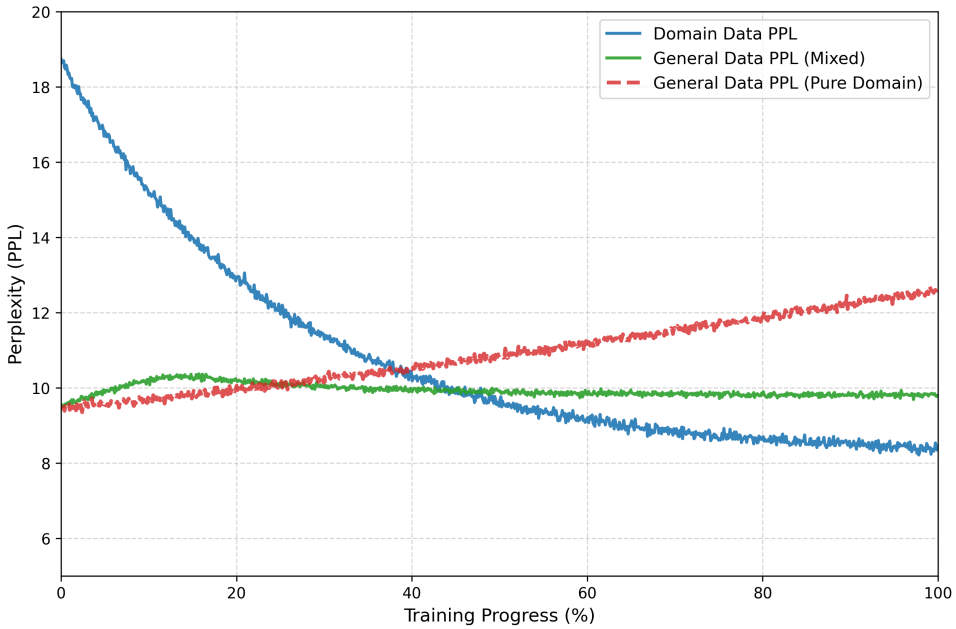


图 2-6 CPT 训练过程中领域数据与通用数据的困惑度变化曲线

2.5.5 与 SFT 阶段的衔接

CPT 阶段与后续 SFT 阶段的衔接体现在数据和能力两个层面。在数据层面，CPT 使用的七类数据语料与 SFT 阶段在七类数据业务场景中构建指令数据所依据的数据来源完全一致——CPT 阶段以原始文本切片的形式让模型学习领域知识分布，SFT 阶段则在同一批数据源上以“指令—回答”对的形式让模型学习任务执行方式。两者共享同一套七类数据分类体系和双层标签，确保从知识注入到任务训练的平滑过渡。在能力层面，CPT 阶段为模型提供了电力术语、概念关系、设备原理、运行规程和故障机理等方面的基础性知识储备，这是 SFT 阶段构建高质量指令数据并有效训练任务能力的必要前提。若跳过 CPT 直接进行 SFT，模型在面对包含复杂专业术语的指令时缺乏足够的领域语义理解能力，SFT 训练难以收敛或效果受限。CPT 产出的模型将作为 SFT 阶段的初始化参数，在 CPT 的知识底座上进一步培养面向七类数据业务场景的任务执行能力。

第 3 章 面向七类电力数据业务场景的指令数据构建与监督微调

3.1 研究动机

监督微调是将领域基础模型转化为能完成特定任务模型的关键阶段。已有研究表明,从少量种子任务自动扩展指令数据能够提升模型的指令遵循能力[24],而通过指令演化或复杂解释轨迹构造更高难度样本，可以进一步增强模型处理复杂任务和多步推理的能力[25,27,53]。电力领域 SFT 数据构建面临三方面挑战：其一，任务类型多样（知识问答、故障诊断、制度问答和技术方案分析），不同任务的输入输出结构差异显著，简单问答对无法覆盖真实复杂性；其二，七类数据类型各自具有不同的知识结构和表达习惯（仿真理论类倾向机理分析，运维检修类倾向步骤化排查，制度文件类倾向条款引用），若统一模板生成将导致风格错配；其三，过早对多数据类型进行风格归纳会损失原生表达多样性。本文据此提出在 SFT 阶段直接在七类数据业务场景中构建指令数据，保留各类型原生风格，将七类到三类的归纳操作后移至 RLHF 阶段——“先保留多样性，后归约控制”。

3.2 SFT 任务体系的形式化定义

本文将电力领域数据按知识结构和业务场景归纳为七类，记类型集合为 $\mathcal{T}$。每类数据 $t \in \mathcal{T}$ 关联一组认知能力维度 $C_t \subseteq$ {知识解释,因果推理,程序生成,规范判断,方案比较,风险识别} 和一种目标回答风格 s_t。SFT 阶段的核心设计原则是**场景原生**：每类数据的指令样本在其原生业务场景中构建，保留固有的知识表达习惯，不对七类进行跨类型的风格归纳。各类数据的差异体现在推理逻辑和信息组织方式上——基础科学类侧重机理分析与公式推导，运维检修类要求步骤化诊断与风险提示，制度文件类强调条款引用与边界界定，等等。令 D_t^{SFT} 为数据类型 t 的指令数据集，整体 SFT 数据集为 $\mathcal{D}^{\mathrm{SFT}} = \bigcup_{t\in\mathcal{T}} D_t^{\mathrm{SFT}}$，各子集独立构建以保持风格多样性。表 3-1 汇总了七类数据的任务体系设计。

表 3-1 面向七类数据类型的电力 SFT 任务体系设计

数据类型	认知能力维度	典型任务	回答风格特征
基础科学与仿真理论	知识解释、方案比较	概念原理阐释、仿真参数分析、理论推导	机理优先，逻辑严谨，标注假设与适用范围
物理电网与工程建设	知识解释、方案比较、风险识别	网架规划、方案比较、设备选型分析	多维度权衡，兼顾技术可行性与经济性
新型电力系统与能源互联	方案比较、知识解释	新能源消纳、源网荷储协同、路线推演	系统视角，多源协同，明确不确定性前提
运行控制与二次系统	因果推理、风险识别、程序生成	运行方式分析、保护配置、异常诊断	结论直接，贴合运行实际，末端含风险提示
运维检修与资产管理	因果推理、程序生成、风险识别	故障诊断、排查步骤生成、状态评估	结论先行，步骤化可执行，从易到难，强制安全提示
综合管理安全与市场	规范判断、风险识别	安全管理、市场规则、应急处置	表述规范，明确管理目标与责任主体
制度文件	规范判断、知识解释	条款查询、流程解释、边界判断	条款引用，措辞正式，边界清晰，不越权

3.3 专家种子问题构建

专家种子问题是整个数据合成管线的逻辑起点。其核心作用在于为每类数据提供一组高质量的“锚点”样本——这些样本蕴含了专家对该类数据典型任务的深层理解，包括问题应如何提出、回答应按什么结构组织、认知深度应达到什么层次。

形式化定义。对于数据类型 $t \in \mathcal{T}$，专家构建的种子问题集记为 $\mathcal{S}_t = \{(x_i, y_i, c_i, d_i)\}_{i=1}^{N_t}$，其中 x_i 为问题文本，y_i 为标准答案，$c_i \in C_t$ 为认知能力维度标签，$d_i \in \{1,2,3\}$ 为难度层次（基础/中等/复杂）。七类数据的种子问题合计约 600 条，各类的种子数量根据知识体系的复杂度和任务多样性进行分配。

种子问题的构建遵循以下原则：（1）覆盖该类数据的核心知识域和典型任务类型；（2）体现该类数据的原生表达风格（如运维检修类的问题包含设备状态和告警信息，制度文件类的问题涉及具体条款和适用情境）；（3）涵盖从基础到复杂的难度梯次，为后续指令演化提供复杂度参照。种子问题由模型初步编写、再经电力领域专家审核修订后定稿，以确保问题表述的领域准确性和回答的规范完整性。

这一设计与 Self-Instruct 的少量种子扩展思路一致，即先用高质量人工种子定义任务空间，再借助模型生成和过滤机制扩展数据规模[24]；同时，专家种子中包含的问题结构、推理链条和答案组织方式也可被视为可迁移的“设计逻辑”，用于指导后续跨知识点的数据合成[54]。

3.4 基于设计逻辑与知识图谱的指令生成

专家种子问题虽然质量高，但数量有限——七类数据合计约 600 条种子样本，远不足以支撑 SFT 阶段的有效训练。如何将少量专家种子中蕴含的高质量任务逻辑“解构”出来，并利用电力领域已有的海量知识将其“规模化泛化”，是本节需要解决的核心问题。

本文的数据生成管线分为**指令生成**（模块一至四）和**指令演化与筛选**（模块五至六）两个环节。指令生成环节从专家种子中提取设计逻辑模板，利用电力知识图谱提供知识素材，通过受约束的图遍历将模板与图谱实体组合，批量生成逻辑结构一致、知识内容多样的指令—回答对。指令演化环节对生成的指令施加差异化的变换操作，在约束数量、推理步数和信息完整度方面进行复杂度提升，生成覆盖多级难度的变体。前者解决“从少量种子到大规模数据”的量产问题，后者解决“从基础难度到多级复杂度”的深化问题。图 3-1 展示了完整的管线流程。



图 3-1 面向七类电力数据业务场景的 SFT 指令数据生成管线全流程

3.4.1 设计逻辑提取

本文借鉴 DESIGNER 方法“从样例中提取设计逻辑以指导数据合成”的核心思想。DESIGNER 将专家样题中隐含的问题设计方式抽象为可复用的 Design Logic，并利用该逻辑指导跨学科复杂推理问题的合成[54]。在此基础上，本文对每一条专家种子问题提取其内嵌的结构化设计逻辑（Design Logic）。一条完整的设计逻辑由三个要素构成。

（1）认知能力维度（Cognitive Capability Dimension）

认知能力维度标识该问题要求模型执行何种认知操作类型。本文定义了六种认知能力维度，覆盖数字电网知识服务的全部任务需求。知识解释（Knowledge Explanation）：对电力概念、原理、设备结构或技术标准进行准确阐述，需要调取领域知识并进行清晰的结构化表达。因果推理（Causal Reasoning）：基于给定的现象或数据，沿因果关系链条进行推理，分析可能的原因或预测可能的结果，需要构建从果到因（或从因到果）的逻辑路径。程序生成（Procedure Generation）：生成具有先后顺序、条件分支和判断依据的操作步骤序列，需要将领域知识转化为可执行的动作序列，并且每一步都有明确的判断标准和预期结果。规范判断（Regulation Judgment）：在给定的业务场景下，判断某行为或流程是否符合制度要求，需要匹配制度条款、界定适用范围、给出合规结论和依据。方案比较（Solution Comparison）：对多个候选技术方案进行多维度的系统性比较分析，需要建立评价指标体系、分析各方案的优劣和适用条件、给出综合性权衡建议。风险识别（Risk Identification）：在给定的业务场景中识别潜在的安全风险、违规可能或操作边界，需要结合设备特性、运行条件和规程约束进行风险判断。

（2）知识需求图谱（Knowledge Requirement Graph）

知识需求图谱描述回答该问题需要调动的电力领域知识节点及其之间的关联关系。它是一个以任务推理路径为骨架、以知识点为节点的有向无环图。图中的每个节点代表一个类型的知识单元——例如设备正常状态特征、典型故障模式的因果链、检修试验的判断标准、相关安全规程的禁止条款、适用的制度文件条目等。节点之间的有向边表示推理过程中的知识依赖关系——例如“故障现象 → 可能原因”表示需要调用从现象到原因的因果映射知识，“原因 → 排查方法”表示需要调用从原因到验证手段的检测知识，“排查方法 → 判断依据”表示需要调用从检测结果到结论判断的阈值或判据知识，“处置措施 → 安全约束”表示需要调用从操作到安全边界的规程约束知识。

知识需求图谱的独特之处在于，它刻画的是“完成该类任务需要什么类型

的知识以及这些知识之间如何关联”，而非“具体需要哪些知识实体的值”。例如，对于故障诊断类任务，知识需求图谱描述的模式为“设备标识 → 该设备的一种典型故障类型 → 该故障类型的典型现象集合 → 可能的根因列表 → 按优先级排列的排查步骤 → 每步的判断依据 → 对应的处置措施 → 相关的安全规程约束”，而不指定设备具体是“变压器”还是“断路器”。这种抽象层次的设计使得同一知识需求图谱可以被不同设备实体的具体知识所填充，从而产生大量逻辑结构相同但知识内容不同的指令样本。

（3）输出结构模式（Output Structure Pattern）

输出结构模式描述该问题的期望答案以何种结构组织。它定义了答案的逻辑段落划分、各段落的信息要素和段落之间的排列顺序。例如，故障诊断类问题的典型输出结构模式为“初步结论（最可能原因）→ 原因排序列表（按可能性从高到低，每条附特征匹配说明）→ 排查步骤（按从易到难排列，每步含操作、目的、判断依据）→ 风险提示（操作安全注意事项和禁止性操作）”。制度问答类问题的典型输出结构模式为“结论（是否合规/适用）→ 依据条款（条款编号及原文引用）→ 适用条件分析（逐条匹配适用条件）→ 边界说明（例外情况及处理建议）”。输出结构模式与 3.2 节为该数据类型定义的答案风格要求保持高度一致，确保生成样本的风格合规性。

对于每条专家种子问题，本文使用 LLM 辅助执行上述三个要素的提取：将种子问题和标准答案一并输入 LLM，要求 LLM 识别认知能力维度、标注答案中涉及的知识节点及其推理链、抽象答案的结构模式。提取结果由编写该种子的专家进行审核和修正——确认认知能力维度判定是否正确、知识需求图谱是否完整反映了回答所需的知识类型和关联、输出结构模式是否准确刻画了标准答案的组织方式。经专家审核通过后，该设计逻辑记录以结构化形式存入逻辑模板库（Logic Template Library）。逻辑模板库以七类数据类型和六种认知能力维度作为两级索引——首先按数据类型定位，然后在数据类型下按认知能力维度检索——支持后续数据生成阶段的快速查询和模板复用。

同一数据类型下的同一种认知能力维度，可能从不同专家种子中提取出多个设计逻辑模板。这些模板在知识需求图谱的细粒度结构或输出结构模式的侧重点上可能存在差异（例如同为故障诊断类，面向一次设备和面向二次设备的模板在推理链条上可能有所不同），这种差异反映了该任务类型下合理的变体，本文予以保留而非强制统一。

3.4.2 知识图谱构建

知识图谱在数据合成管线中承担**知识素材的结构化供给**角色。其核心价值在于：以显式的实体和关系约束取代 LLM 生成过程中的隐式知识调用，从根本上解决直接使用 LLM 生成指令数据时常见的事实错误和知识覆盖偏差问题——LLM 在缺乏结构化知识引导时倾向于生成高频常见知识而遗漏长尾领域知识，且容易在实体和关系的组合中出现事实性错误。通过将电力领域知识预组织为图谱，后续的图遍历生成过程仅在图谱定义的合法实体关系空间中进行组合，确保了每一条生成样本的领域合理性。

知识图谱的形式化定义。电力知识图谱定义为有向异构图 $\mathcal{G} = (\mathcal{E}, \mathcal{R}, \mathcal{P})$。$\mathcal{E}$ 为实体集合，涵盖电力设备（变压器、断路器、GIS、保护装置等）、故障类型（匝间短路、铁芯接地、局部放电等）、告警信号（油温异常、轻瓦斯、差动告警等）、制度条款（工作票制度、操作票制度等）、仿真参数（暂态稳定极限、短路容量等）以及检修方法、处置措施等。$\mathcal{R}$ 为关系集合，定义了实体之间的语义连接类型——“发生于”（故障类型 → 设备）、“导致”（故障类型 → 告警信号）、“引用”（制度条款 → 制度文件）、“约束”（安全规程 → 操作步骤）、“依赖”（仿真参数 → 理论模型）等。$\mathcal{P} \subseteq \mathcal{E} \times \mathcal{R} \times \mathcal{E}$ 为三元组集合，每个三元组 (e_h, r, e_t) 表示头实体 e_h 通过关系 r 与尾实体 e_t 关联。

七类数据的差异化图谱结构。七类电力数据在知识组织方式上存在本质差异，不宜采用统一的本体框架。本文根据各类数据的知识结构特点设计差异化的图谱模式。运维检修类数据以设备为核心实体，构建“设备 → 所属系统 → 典型故障 → 关联告警信号 → 适用检修方法 → 对应安全规程”的多层关联网络，图谱稠密度最高（平均每个设备实体关联 12.7 个故障类型和 8.3 种检修方法）。制度文件类数据以条款为核心实体，构建“制度 → 章节 → 条款 → 适用场景 → 审批流程 → 责任主体”的层级网络，图谱以树状结构为主。仿真理论类数据以模型为核心实体，构建“理论 → 模型 → 参数 → 适用工况 → 假设条件”的依赖网络，图谱呈链式结构。物理电网类和新型电力系统类的图谱则介于设备网络和模型依赖之间，兼顾工程实体和技术参数两类节点。各类图谱的实体和关系类型分布汇总于表 4-2。

图谱构建流程。图谱从 2.4 节预处理后的 CPT 语料中通过基于 LLM 的信息抽取管道自动构建。与传统的 BERT-BiLSTM-CRF 序列标注[70-71]、远程监督关系抽取[72-73] 和基于 TransE 的图谱补全[74] 等管线相比，LLM 三元组抽取更易适配电力领域的长尾实体和复杂关系，具体分为两步。

第一步，**LLM 三元组抽取**。对每段预处理后的语料文本，构造结构化抽取 Prompt，要求 LLM（本文使用 Qwen-max）输出文本中出现的 (头实体, 关系, 尾实体) 三元组列表，并限定关系类型在预定义的 $\mathcal{R}$ 范围内。关系类型包括 “导致”、“发生于”、“引用”、“约束”、“依赖”、“属于”、“配套” 等。LLM 凭借上下文理解能力，一次性完成实体识别和关系判断，无需分别训练 NER 模型和关系分类模型。

第二步，**校验与入库**。抽取的三元组经两级校验：（1）规则校验——通过同义词归并、实体类型一致性检查（如头实体和尾实体类型不能相同且关系语义合理）自动过滤明显错误；（2）人工抽检——从每类数据随机抽取约 100 条三元组由电力专家审核，主要错误类型为关系类型混淆与长尾实体误识别，据此迭代优化抽取 Prompt。最终图谱规模约 4.2 万条三元组，覆盖七类数据的核心实体与关系。

3.4.3 图遍历指令生成

将知识图谱路径作为指令生成约束，也与知识图谱增强大语言模型和 GraphRAG 研究中利用实体—关系—路径结构提升事实一致性和多跳推理能力的思想一致[15-16]。

前两小节分别完成了设计逻辑模板的提取和知识图谱的构建。本小节将二者结合，通过受约束的图遍历**批量生成指令—回答对**——将逻辑模板 ℓ 中的槽位（“怎么问” 和 “怎么答” 的结构）与知识图谱 $\mathcal{G}$ 中的实体（“问什么” 和 “答什么” 的内容）进行组合，一次图遍历即可生成一条完整的指令样本。这是指令生成环节的最终产出步骤。

形式化地，从专家种子 $\mathcal{S}_t$ 中提取的设计逻辑模板记为 $\ell = (\tau, K, \sigma, \phi)$，其中 $\tau \in C_t$ 为认知能力类型，$K = [k_1, k_2, \ldots, k_n]$ 为知识需求清单（每个 k_i 对应一个知识需求节点，定义该步骤需要填充的知识类型），σ 为输出结构模式，ϕ 为风格特征向量。图谱 $\mathcal{G}$ 提供具体的实体素材。下文表 3-2 给出了逻辑模板驱动的受约束图遍历生成过程的完整描述。

表 3-2 逻辑模板驱动的受约束图遍历生成算法流程

输入	逻辑模板 $\ell = (\tau, K, \sigma, \phi)$，知识图谱 $\mathcal{G} = (\mathcal{E}, \mathcal{R}, \mathcal{P})$，相似度阈值 θ_{sim}，最大路径跳数 $N_{\max}$
输出	指令—回答对集合 $\mathcal{D}_{\text{gen}}$

Step 1	**知识需求解析**。解析模板 ℓ 的知识需求清单 $K=[k_1,k_2,\ldots,k_n]$，其中每个知识需求 k_i 指定了所需填充的知识类型 $\text{type}(k_i)\in\mathcal{E}_{\text{type}}$ 和该步骤与前后步骤的关系约束 $\mathcal{R}(k_i)\subseteq\mathcal{R}$。初始化生成集合 $\mathcal{D}_{\text{gen}}\leftarrow\varnothing$。
Step 2	**候选实体检索**。对每个知识需求 k_i（$i=1,\ldots,n$），在 $\mathcal{G}$ 中检索类型匹配的实体候选集：$E_i=\{e\in\mathcal{E}\mid\text{type}(e)=\text{type}(k_i)\}$。若 $\lvert E_i\rvert=0$，则该模板在当前 $\mathcal{G}$ 上不可实例化，返回 $\mathcal{D}_{\text{gen}}=\varnothing$。
Step 3	**合法路径枚举**。在候选实体集的笛卡尔积 $E_1\times E_2\times\cdots\times E_n$ 上，枚举所有满足关系约束的实体路径 $\mathbf{e}=(e_1,e_2,\ldots,e_n)$。路径合法的充要条件为：$\forall i\in[1,n-1],\ \exists r\in\mathcal{R}(k_i,k_{i+1}):(e_i,r,e_{i+1})\in\mathcal{P}$。设合法路径集合为 $\mathcal{Q}$。路径长度 n 控制生成样本的复杂度：$n\le 2$ 为基础难度，$n\in[3,N_{\max}]$ 为中高难度。若 $\lvert\mathcal{Q}\rvert=0$，返回 $\mathcal{D}_{\text{gen}}=\varnothing$。
Step 4	**模板实例化**。对每条合法路径 $\mathbf{e}\in\mathcal{Q}$，执行模板填充操作 $\text{Instantiate}(\ell,\mathbf{e})$：将路径中的实体 e_i 填入模板 ℓ 中知识需求 k_i 对应的槽位，依照输出结构模式 σ 组织答案的段落序列，并注入风格特征 ϕ 控制回答的语言正式程度和风险提示位置。该操作输出一条实例化样本 (x,y)，其中问题 x 由实体路径在模板的问题槽位中拼合生成，答案 y 由实体属性和领域知识在模板的答案槽位中填充生成。将 (x,y) 加入 $\mathcal{D}_{\text{gen}}$。
Step 5	**去重过滤**。对 $\mathcal{D}_{\text{gen}}$ 中所有样本对 (d_i,d_j)，计算其问题文本的 ROUGE-L 相似度 $\text{sim}_L(d_i,d_j)$。ROUGE-L 基于最长公共子序列衡量生成文本与参考文本之间的覆盖程度，是摘要和生成任务中常用的自动评价指标之一[75]。若 $\text{sim}_L(d_i,d_j)>\theta_{\text{sim}}$（本文取 $\theta_{\text{sim}}=0.85$），则判定为重复样本，保留其中设计逻辑更完整的一条（即 $\lVert\pi\rVert$ 更大或 $\lVert\sigma\rVert$ 更丰富的样本），丢弃另一条。
Step 6	**返回**。输出去重后的指令—回答对集合 $\mathcal{D}_{\text{gen}}$。

表 3-2 所述算法的计算复杂度分析如下。Step 2 的实体检索复杂度为 $O(n\cdot|\mathcal{E}|)$，使用类型索引后可降至 $O(n\cdot\bar{d})$，其中 $\bar{d}$ 为每类实体的平均数量。Step 3 的路径枚举在最坏情况下的复杂度为 $O(\prod_{i=1}^{n}|E_i|)$，但在实际运行中，关系约束 $\mathcal{P}$ 的过滤作用大幅缩减了合法路径空间——实验统计表明，平均合法路径数 $|\mathcal{Q}|$ 约为候选空间规模的 0.3%—2.1%。Step 4 的模板实例化复杂度为 $O(|\mathcal{Q}|\cdot n\cdot L)$，其中 L 为平均答案长度（token 数）。Step 5 的去重复杂度为 $O(|\mathcal{D}_{\text{gen}}|^2)$，通过 MinHash 预索引可降至 $O(|\mathcal{D}_{\text{gen}}|\cdot\log|\mathcal{D}_{\text{gen}}|)$。图 3-1 展示了该方法从专家种子到规模化生成的完整流程。

3.5 基于指令演化的复杂任务扩展

图遍历生成的指令以单一约束条件和简明推理链条为主——图谱中高连通的简单子图被反复匹配，而涉及多跳推理和条件嵌套的复杂模式难以自动命中。然而，真实电力业务中的故障诊断往往涉及多个并发告警信号、近期操作记录

和历史试验数据等多源信息。**指令演化**正是为了解决这一复杂度缺口——对图遍历产出的指令施加保持语义连贯性的变换操作，将其扩展为覆盖多级难度的复杂变体。该方法受 Auto Evol-Instruct 启发[53]，由演化 LLM 自主分析指令特征并生成演化策略，通过演化轨迹分析自动检测失败模式并迭代优化演化方法。以下两个小节分别阐述演化操作的定义和自动化执行流程。

3.5.1 演化操作的定义与示例

图遍历生成的指令虽然覆盖了七类数据类型，但其复杂度受限于知识图谱的局部结构——模板在匹配最短实体关系路径时，生成的指令通常仅包含单一约束条件和简明的推理链条，难度以基础级为主。指令演化的目标正是将这些指令扩展为更贴近真实业务复杂度的变体。

为实现这一目标，本文定义了五类演化操作。每类操作接收一条指令—回答对 (x, y)（来自图遍历生成的指令池），对其施加特定方向的复杂度提升，输出变换后的样本 (x', y')。以下以一条图遍历生成的运维检修类基础指令作为贯穿示例来逐一说明各类操作的效果：“*某 220kV 变压器油温持续升高，请分析可能原因并给出排查建议。*”（为行文简洁，后文以 x_0 指代此指令）。

约束增加在原始问题中追加技术条件，扩展推理所需的约束维度。例如，对 x_0 追加“该主变近期负荷率维持在 85% 以上”和“上一周期油色谱试验显示乙炔含量接近注意值”两条约束，使问题从单一现象的简单归因升级为多源数据的综合判断——模型不仅需要考虑油温升高的常见原因，还需在负荷偏高和乙炔超标的交叉约束下评估匝间短路或局部放电的可能性。

条件组合将多个独立的设备状态或告警信号组合为联合条件。对 x_0 而言，可将“油温升高”与“轻瓦斯继电器发出告警”和“有载分接开关操作频繁”组合为复合故障场景。这种组合更贴近真实运行中多信号并发的情境，迫使答案在多源信息的交叉印证下构建完整的因果推理链。

格式要求在问题中嵌入输出格式指令。例如在 x_0 末尾追加“请按以下格式输出：（1）最可能原因排序（附特征匹配说明），（2）逐项排查步骤（每步注明操作目的和判断依据），（3）安全风险提示”。该操作不改变问题的技术内容，但通过结构化要求提升了答案的组织复杂度。

角色设定在问题前拼接业务角色语境。对 x_0 添加“作为检修班技术负责人，你需要向班组人员下达排查任务”的角色前缀，答案需相应地调整为面向执行层的指令式表述，包含更具体的操作动作和安全交底内容。

风险嵌入在问题中注入安全敏感前提。对 x_0 追加“该主变目前仍带电运行，

停电检修需要向上级调度申请”的语境，使答案必须在带电运行的风险约束下给出排查建议——明确哪些检查可以在不停电条件下完成，哪些必须停电处理，以及对应的安全防护要求。

上述五类操作并非均匀施加于所有数据类型，而是根据各数据类型的任务特征差异化分配。运维检修类和运行控制类数据主要适用约束增加和条件组合，因其故障诊断复杂度天然依赖多源状态信息的交叉分析；制度文件类和综合管理类数据侧重角色设定，以匹配不同管理层级的正式表述需求；风险嵌入集中于生产与运行相关的安全关键场景；格式要求则为全类型共用。表 4-3 汇总了演化操作的详尽定义、适用数据类型及基于 x_0 的演化前后对比示例。

3.5.2 自动化演化流程与质量保障

4.5.1 节定义的五类演化操作构成了变换工具集 O。本节阐述演化 LLM 如何将这些操作组织为完整的自动化流程——即从接收一条基础指令到输出一条复杂指令变体的端到端过程。

指令演化环节借鉴 Evol-Instruct 的复杂度扩展思想，通过增加约束条件、引入多跳推理、改变输入完整度和提高答案结构要求等方式，将基础指令逐步演化为复杂指令[25]。进一步地，Auto Evol-Instruct 证明了演化策略本身可以由模型自动分析和迭代优化[53]，因此本文在电力场景中将演化操作限定为与业务复杂度直接相关的变换类型，如增加设备状态约束、引入制度边界、要求多方案比较或补充安全前置条件。具体而言，本文借鉴 Auto Evol-Instruct 的思想，由演化 LLM 自主完成操作的选择、执行和校验。给定一条来自图遍历生成的基础样本 (x, y)，演化 LLM 执行以下三步。

第一步：操作选择与策略生成。LLM 首先分析 x 的任务类型（属于知识解释、因果推理、程序生成等六类中的哪一类）、当前推理链条的复杂度（约束数量、推理步数）以及所属的数据类型，据此决定应从 O 中选择哪些操作以及操作的强度参数 θ。例如，对于 4.5.1 节的示例指令 x_0（“变压器油温持续升高，请分析原因”）——该指令属于运维检修类、认知能力为因果推理 + 程序生成、当前复杂度为单约束基础级——LLM 可能生成如下策略：选择约束增加操作（强度：追加 2 条技术约束）和风险嵌入操作（强度：追加带电运行语境），因为运维检修类数据天然适配这两个操作方向。这一策略生成过程由 LLM 的指令分析能力驱动，而非基于预定义的规则表，因此对不同类型和复杂度的指令具有适应性。

第二步：操作执行与答案同步。LLM 按照生成的策略依次执行所选操作。

每个操作 $o \in O$ 接收当前样本状态并输出变换后的版本：$(x^{(1)}, y^{(1)}) = o_1(x, y; \theta_1)$，$(x^{(2)}, y^{(2)}) = o_2(x^{(1)}, y^{(1)}; \theta_2)$，以此类推。关键约束在于 y 的同步更新——当 x 因追加约束条件而变得更复杂时，y 必须在推理深度和信息覆盖上匹配新的复杂度，而非简单复用原有回答。LLM 在生成 x' 后，以 x' 为输入重新生成完整的 y'，确保答案与演化后的问题严格对应。

第三步：自检与过滤。演化完成后，LLM 对 (x', y') 执行三项自检：（1）复杂度提升检验——x' 的约束数量或推理步数是否确实多于 x；（2）可解性检验——x' 中的约束组合是否存在逻辑矛盾（如两个条件互斥）或不可解（如缺乏必要信息导致无确定答案）；（3）回答完整性检验——y' 是否准确回应了 x' 的全部约束，包括新增约束的专项分析和原始约束的完整覆盖。未通过任一检验的样本直接丢弃，不进入后续训练集。

迭代优化。上述三步流程并非一次性运行后即固定不变。每批次演化完成后，Optimizer LLM（同样使用演化 LLM 自身）统计本批次的失败样本——即未通过自检或在后续 3.6 节质量筛选中被剔除的样本——识别高发失败模式。例如，若统计发现运维检修类指令中约束增加操作的失败率偏高，Optimizer LLM 自动分析原因（如约束叠加强度过高导致不可解），并修订该操作在对应数据类型上的提示词约束（如将最大追加约束数从 3 条降为 2 条，或增加“追加的约束之间不得互斥”的显式禁令）。这一自优化循环使演化质量在迭代中逐步收敛。

人工参与。人工仅在两个节点轻度介入：演化启动初期，人工审阅首批约 50—100 条演化样本，确认演化方向合理；后续批次中，每批次随机抽检约 5% 以监控质量。不合格样本直接丢弃，反馈仅用于调整提示词的宏观方向，不逐条修正。图 3-2 展示了上述自动化演化与轻量级反馈的完整流程。

3.6 自动化质量筛选与多维评估

经过图遍历生成和指令演化后，本文获得了大规模候选 SFT 指令数据集。在进入 SFT 训练之前，还需经过自动化质量筛选进行末端把关。自动化筛选擅长检测格式错误、语义重复、领域偏离等可量化问题，与 3.5 节的演化内嵌校验和 LLM 驱动优化形成互补——前者在生成前端拦截明显不合格样本，后者在末端对全量样本进行多维过滤。



图 3-2 自动化指令演化与轻量级反馈完整流程

3.6.1 多维筛选标准

自动化质量筛选是对全量候选样本进行多维过滤的末端把关模块。定义质量评分函数 $Q(x,y)$，综合八个维度的评分：

$$Q(x,y)=\sum_{m=1}^{8}\lambda_m\cdot q_m(x,y) \tag{3-1}$$

其中 q_m 为维度 m 的评分函数，λ_m 为维度权重。八个维度包括：（1）领域相关性 q_1——基于 CPT 阶段训练的电力领域文本分类器的置信度评分；（2）指令清晰度 q_2——LLM-as-Judge 对问题表述的 1—5 Likert 评分；（3）答案完整性 q_3——根据认知能力类型 τ 对应的要素链覆盖率评分；（4）事实一致性 q_4——将答案中的事实断元与知识图谱 $\mathcal{G}$ 中的三元组进行比对验证；（5）风格一致性 q_5——根据数据类型 t 的风格特征向量 ϕ_t 与答案风格的余弦相似度评分；（6）合规性 q_6——规则初筛（关键词/正则匹配）结合 LLM-as-Judge 细判；（7）非重

复性 q_7——基于 MinHash 近似去重（Jaccard 阈值 0.85）和语义相似度精确去重（余弦阈值 0.92）；（8）难度分布监控 q_8——统计各难度层次样本占比，触发失衡调整。

筛选采用三级过滤流程：第一级为规则 + 分类器高召回初筛（q_1, q_6 的规则部分），第二级为 LLM-as-Judge 细粒度评分（q_2, q_3, q_4, q_5, q_6 的 LLM 部分），第三级为语义去重（q_7）。对开放式答案的质量评估采用 LLM-as-Judge 思路，该类方法已在 MT-Bench 和 Chatbot Arena 等开放式模型评测中被系统研究[65]；为降低自动评测偏差，本文结合规则过滤、模型评分和人工抽样审核共同进行质量控制。对 $Q(x, y) < \theta_{\text{pass}}$ 的样本予以剔除。筛选后统计各维度的未通过原因分布，对不合格率偏高的维度定向回溯至生成或演化环节进行优化。

3.6.2 质量保障体系架构

本文的数据质量保障由三环递进构成：（1）**演化内嵌校验**——演化 LLM 在生成 (x', y') 后立即进行复杂度提升、可解性和回答完整性三项自检，拦截明显不合格样本；（2）**LLM 驱动的演化优化**（3.5.2 节）——Optimizer LLM 基于演化失败模式自动修订演化提示词，仅需极少量人工抽检（约 5%）验证自动化流程质量；（3）**自动化多维筛选**（3.6 节）——对全量样本进行八维质量评分和三级过滤。三环从前端预防（演化内嵌）到中端自优化（LLM 驱动）到末端拦截（自动筛选），形成高度自动化的质量保障链。表 3-4 汇总了各环的覆盖范围、判断能力和反馈机制。

3.7 SFT 训练策略与实验结果

经过 3.3 至 3.6 节的数据构建与筛选流程，本文获得了覆盖七类数据类型、六种认知能力维度和多级难度层次的高质量电力领域 SFT 指令数据集（约 6.8 万条）。本节阐述如何利用该数据集对 CPT 后的模型进行监督微调，并报告核心实验结果。

本章实验沿用 2.5.3 节已定义的 PowerQA-Eval，并新增以下评测集。各评测集的问题和参考答案均由本文的指令生成管线（3.4 节图遍历生成 + 3.5 节指令演化）自动构造，经自动化质量筛选（3.6 节）后保留，少量经人工抽检确认领域合理性，不依赖大规模专家标注。

为降低训练—评测同源带来的泄漏风险，评测集从未参与 SFT 训练的源文档、实体子图和专家种子中构造；训练集与评测集在原始文档、核心实体路径

和问题模板层面均保持去重。对于由同一知识图谱生成的样本，进一步采用实体路径重叠率和问题语义相似度过滤，确保评测样本不与训练样本共享高度相似的推理链。

FaultDiag-Eval：从运维检修与资产管理、运行控制与二次系统两类数据的生成指令中抽取 100 条故障诊断问题，每条提供故障现象、告警信号和设备运行状态，共 100 条。核心指标为因果召回率（Cause Recall, Top-1）——模型输出的第一原因与参考答案一致的比例；以及排查步骤合理性（Procedure Reasonableness）——由 LLM-as-Judge 从逻辑顺序、可执行性和安全合规性三个子维度进行 1–5 分评分。

RegulationQA-Eval：从制度文件和综合管理数据中抽取 100 条制度问答问题，覆盖条款查询、流程解释和适用边界判断三种类型。核心指标为制度依据正确性（Evidence Correctness）——回答中引用的制度名称和条款编号是否真实存在且引用正确（严格 0/1 判定）；以及边界清晰度（Boundary Clarity）——由 LLM-as-Judge 对适用范围的界定是否明确、有无越权判断进行 1–5 分评分。

此外，为评估模型在跨领域综合性问题上的能力，本章构建了 **CrossDomainQA-Eval**：从七类数据的交叉地带选取 100 条综合性问题，同样由生成管线自动构造。例如，“某风电场并网后，分析其对区域电网暂态稳定性的影响，并给出运行方式调整建议”需要同时调用新型电力系统知识（风电特性）和运行控制知识（暂态稳定分析）；“某变电站拟扩建一台主变，分析需要办理哪些审批手续，并说明扩建工程的典型技术方案”需要同时调用物理电网知识（扩建方案）和制度文件知识（审批流程）。以 LLM-as-Judge 对回答的知识覆盖完整性、跨领域推理连贯性和综合结论合理性进行 1–5 分综合评分。其中 CrossDomainQA 主要用于衡量模型在跨数据类型知识综合和技术方案分析类问题上的推理与权衡能力，对应第 2 章定义的技术方案分析任务。

3.7.1 两阶段训练策略

CPT 后的基座模型虽然在电力领域知识方面得到了显著增强，但缺乏基本的指令遵循能力——CPT 以原始文本的自回归语言建模为目标，模型未学习过“问题—回答”的交互格式。若直接将电力领域 SFT 数据用于微调，相当于要求模型同时完成“学习对话格式”和“学习电力任务”两个性质不同的目标，两者可能在训练早期的梯度竞争中相互掣肘。

针对这一问题，本文采用两阶段 SFT 策略。第一阶段为通用指令微调：使用约 6 万条通用领域开源指令数据（覆盖知识问答、文本生成、逻辑推理、代

码生成、多轮对话等任务类型）对 CPT 模型进行微调，使模型获得基本的指令遵循能力和对话交互范式。该阶段训练 1 个 epoch，学习率 2×10^{-5}，全局 batch size 128。选择通用指令数据的原因在于其任务类型和交互格式丰富多样，有助于模型学习与领域无关的通用指令遵循能力（意图识别、输出格式控制、多轮上下文记忆等），而电力领域数据特定的格式规范性（如步骤化、条款引用等）更适合在模型已掌握基础对话能力后注入。

第二阶段为通用与领域联合微调，是本文 SFT 策略的核心。将通用指令数据与约 6.8 万条电力 SFT 数据按比例混合，对第一阶段模型进行联合微调，目标是在保持已获得的指令遵循能力的同时，注入电力领域的任务知识和各数据类型的原生回答风格。该阶段训练 2 个 epoch，初始学习率降至 1×10^{-5}（避免破坏第一阶段已建立的对话行为模式），采用带 warmup 的余弦退火调度。

数据配比设计。通用数据与领域数据的混合比例是该阶段的关键超参数。设通用数据占比为 γ，领域数据占比为 $1-\gamma$。若 γ 过低，模型面临灾难性遗忘风险——基础对话能力和通用知识退化；若 γ 过高，领域训练信号被稀释，电力任务学习不够充分。本文系统性地对比了五种混合比例 $\gamma\in\{0, 0.2, 0.33, 0.5, 1\}$（对应通用: 领域 = 0:1、1:4、1:2、1:1、1:0），以电力领域核心任务得分和通用指令遵循能力得分的加权综合表现为评判标准。表 3-3 汇总了配比实验结果。

表 3-3 SFT 第二阶段通用-领域数据配比实验结果

γ（通用占比）	通用: 领域	PowerQA Score	FaultDiag Recall	RegQA Evid.	通用指令遵循
0	纯领域	79.8%	60%	76%	58.4
0.2	1:4	81.5%	62%	**78%**	71.2
0.33	1:2	**82.3%**	**63%**	**78%**	74.8
0.5	1:1	80.6%	61%	77%	76.3
1	纯通用	43.5%	15%	12%	**78.1**

实验结果表明，$\gamma=0.33$（通用: 领域 = 1:2）取得较优综合表现。纯领域训练（$\gamma=0$）虽然领域任务得分尚可，但通用指令遵循能力显著退化（58.4 vs. 基线的 78.1），模型丧失了处理非电力领域合理指令的基本能力。纯通用训练（$\gamma=1$）保持了通用能力但对电力任务毫无增益。$\gamma=0.2$ 时通用能力已有明显回升（71.2），但领域得分略低于 $\gamma=0.33$。$\gamma=0.5$ 时通用能力最高（76.3），但领域训练信号被稀释，三项电力任务得分均低于 $\gamma=0.33$。1:2 的配比在领域能力与通用能力之间实现了较优权衡——通用数据占比足以维持对话能力的稳定性，同时为电力领域数据保留了充分的训练信号空间。

电力领域数据内部按七类数据类型的自然样本量比例配比，不强制等量—

—该比例已在客观上反映了各数据类型的任务多样性。但对安全敏感的数据类型（运维检修与资产管理、运行控制与二次系统、制度文件），在每批训练数据中将其采样概率在其自然占比基础上提升 1.5 倍，确保模型对安全关键场景获得更充分的训练。

SFT 输入格式为标准的三段式指令格式（System Prompt + Instruction + Response），不添加数据类型标记和场景 Prefix。模型通过不同数据类型下 Instruction 的业务语境和 Response 的回答风格，隐式地建立起差异化的任务响应模式。三类场景归纳和 Prefix 控制将在 RLHF 阶段（第 4 章）引入——SFT 保留七类原生风格，RLHF 实现归约控制。

3.7.2 训练配置与优化

训练目标为标准语言建模损失——对 Response 部分计算交叉熵损失，System Prompt 和 Instruction 部分不参与损失计算。训练基于 LLaMA-Factory 框架，使用 8×A100 80GB GPU。SFT 训练延续 AdamW 优化器和 ZeRO 分布式训练策略，以保证全参数微调过程的稳定性和显存可扩展性[68-69]。采用 DeepSpeed ZeRO-3 分布式策略，BF16 混合精度。全局 batch size 为 128，最大序列长度 4096 tokens。优化器为 AdamW（$\beta_1 = 0.9, \beta_2 = 0.95$，权重衰减 = 0.1），梯度裁剪阈值 1.0，warmup 步数占总步数的 10%。训练过程中监控验证集困惑度（PPL），每 500 步评估 BLEU 和 ROUGE-L 分数。通用能力评估仍采用 C-Eval 与 MMLU 作为参考基准[66-67]，领域任务则采用 PowerQA-Eval、FaultDiag-Eval 和 RegulationQA-Eval 等本文构建的电力评测集进行补充。

3.7.3 主要结果

表 3-4 对比了 Base、CPT 和 CPT+SFT 模型在核心评测集上的性能。

表 3-4 SFT 训练前后模型性能对比

评测集与指标	Base	CPT	CPT+SFT
PowerQA-Eval Score	43.5%	68.2%	**82.3%**
FaultDiag-Eval（Cause Recall Top-1）	17%	32%	**63%**
FaultDiag-Eval（Procedure Reasonableness, 1–5）	2.1	2.8	**4.1**
RegulationQA-Eval（Evidence Correctness）	8%	26%	**78%**
CrossDomainQA-Eval（综合质量, 1–5）	1.8	2.4	**3.7**

CPT+SFT 在 PowerQA-Eval 上的综合得分达到 82.3%，较 CPT（68.2%）提升 14.1 pp，较 Base（43.5%）提升 38.8 pp。在 FaultDiag-Eval 上，因果召回率（Top-1）

达到 63%（CPT: 32%），排查步骤合理性评分 4.1/5.0（CPT: 2.8）。在 RegulationQA-Eval 上，制度依据正确性达到 78%（CPT: 26%），提升 52 pp。制度问答的提升幅度（+52 pp）远超知识问答（+14.1 pp），说明 CPT 阶段对事实型知识的注入已有较大贡献，SFT 阶段的额外贡献重心在于结构化任务执行能力。在跨领域综合评测上，CrossDomainQA 综合质量评分达到 3.7/5.0（CPT: 2.4），说明 SFT 训练使模型初步具备了将设备原理、故障机理和制度约束等跨领域知识协调组织的能力。

3.7.4 消融分析

为评估数据合成管线核心模块的贡献，设置四组消融变体，在相同数据总量和训练配置下独立完成 SFT 训练。需要说明的是，管线各模块之间存在依赖关系：专家种子是设计逻辑提取的输入来源，知识图谱与设计逻辑共同支撑图遍历生成，指令演化和质量筛选相对独立地作用于生成结果。因此，对专家种子和知识图谱的消融实际涉及关联模块的联合移除。

（1）去掉专家种子：失去种子后设计逻辑模板亦无法提取，该变体同时绕过设计逻辑提取和图遍历生成，改用 TF-IDF 关键词配合预设通用模板直接构造指令—回答对。PowerQA 下降 4.9 pp，说明专家种子提供的任务范式对业务贴合度有重要贡献。

（2）去掉知识图谱：失去图谱后受约束图遍历无法运行，改用随机实体填充模板槽位。RegQA 下降幅度最大（−20 pp），说明知识图谱及其驱动的图遍历机制在事实一致性和实体关系约束中起关键作用。

（3）去掉指令演化：直接使用图遍历基础指令训练，该模块相对独立，消融较干净。FaultDiag 下降 9 pp，CrossDomainQA 下降 0.7，说明指令演化对复杂任务能力贡献显著。

（4）去掉质量筛选：跳过八维评分和三级过滤，直接使用全部候选数据（约 9.1 万条）训练。PowerQA 下降 2.2 pp，RegQA 下降 5 pp，说明未经筛选的噪声样本会以干扰信号形式影响训练效果，末端质量筛选是保障数据有效性的必要环节。

本章小结：本章面向 SFT 阶段的数据构建与训练问题，设计了“专家种子构建—设计逻辑提取—知识图谱构建—图遍历指令生成—指令演化—自动化质量筛选”六模块数据合成管线，从约 600 条专家种子出发构建了约 6.8 万条覆盖七类电力数据业务场景的高质量 SFT 指令数据。实验结果表明，经本章方法训

表 3-5 SFT 数据合成管线消融实验结果

模型变体	PowerQA Score	FaultDiag Recall	RegQA Evid.	CrossDomainQA
CPT+SFT（完整管线）	**82.3%**	**63%**	**78%**	**3.7**
– 专家种子（+TF-IDF）	77.4%	55%	67%	3.1
– 知识图谱（+ 随机替换）	74.8%	49%	58%	2.8
– 指令演化	79.2%	54%	72%	3.0
– 质量筛选	80.1%	58%	73%	3.3

练的 SFT 模型在 PowerQA-Eval 综合得分达到 82.3%，FaultDiag-Eval 因果召回率达到 63%，RegulationQA-Eval 制度依据正确性达到 78%。消融实验验证了专家种子、知识图谱、指令演化和质量筛选四个模块的独立贡献。

第 4 章 基于 Prompt Prefix 的电力场景回答风格强化学习对齐

4.1 研究动机

需要说明的是，本文所称 RLHF 主要指基于偏好/奖励信号的强化学习对齐过程，其反馈信号主要由自动化风格判别模型、LLM-as-Judge 和人工抽检校准共同构成，并非完全依赖大规模人工成对偏好标注。人工反馈主要用于种子构建、抽检与评分校准环节，而非全量偏好标注。

SFT 模型虽然在七类数据上具备了任务执行能力，但其风格输出是“被动”的——由输入问题的内容特征隐式驱动，用户无法显式指定期望风格。不同业务角色的从业人员对同一问题的回答风格需求截然不同：研发人员需要充分的技术推演和探讨性语气，运维人员需要结论先行、可执行的排查步骤和明确的指令口吻，管理人员需要依据明确的规范性表述和不容置疑的权威语气。SFT 阶段的隐式风格学习不足以实现灵活可控的风格切换。本文在 RLHF 阶段引入基于 Prompt Prefix 的显式风格控制机制，通过定义**展开程度**、**安全合规**和**语气/角色定位**三类风格 Prefix 并构建风格偏好数据和判别模型，使模型根据 Prefix 稳定切换输出风格。

从可控生成角度看，Prefix 可被视为一种显式控制接口。CTRL 通过控制码条件化文本生成[36]，PPLM 通过属性分类器在生成过程中引导模型输出指定属性[37]，Prefix-Tuning 和 Prompt Tuning 则表明前缀向量或软提示能够在较低适配成本下影响模型行为[38-39]。本文采用文本形式的强度条件化 Prompt Prefix，是将上述可控生成思想迁移到电力业务回答风格控制中的一种实现方式。

在此基础上，本文进一步观察到：同一风格类别内部存在显著的**强度差异**，不同业务场景对同一风格的需求强度各不相同。例如，同为“展开程度”维度，调度指令确认场景要求极简回答（仅输出数值或指令，对应 L1），而技术方案论证场景需要技术报告级别的全面展开（对应 L3）；同为“语气/角色定位”维度，日常技术讨论适合探讨性语气（研讨型 L1），事故处置指令需要不容置疑的确定性表述（指令型 L2），而安规解读和制度裁定则需要引用强制性标准规范的权威语气（权威型 L3）。此外，同一业务场景在不同风险等级下对风格强度的需求也是动态变化的——设备检修场景在常规检修和事故抢修两种工况下，对

安全合规和语气的强度要求截然不同。这意味着风格控制不仅需要解决“选哪种风格”的问题，还需要解决“以多大强度表达该风格”的问题。

基于以上观察，本文提出**细粒度风格强度对齐**方法——为每种风格定义 L1–L3 三级强度等级，将风格控制确立为“风格类别 + 强度等级”的二维控制空间。在此框架下，风格判别模型采用序数强度评估器，直接输出 L1–L3 三级强度概率分布，RL 奖励信号基于生成回答与目标强度等级的匹配程度进行设计。同时，针对三大风格控制场景（研发与演进、生产与运行、合规与管理），定义差异化的默认目标强度等级，使模型在不同业务场景下自动适配相应的风格强度，实现因场景施策的细粒度风格控制。

4.2 三类风格 Prefix 定义

在阐述三类风格 Prefix 之前，需首先明确“业务场景”与“风格 Prefix”之间的层级关系。本文第 2 章将七类电力数据类型归纳为三类业务场景（研发与演进、生产与运行、合规与管理），但三类业务场景并不直接等同于三类 Prefix，而是对应一组默认风格强度组合。具体而言：研发与演进场景默认对应展开程度 L3、安全合规 L1、语气/角色定位 L1；生产与运行场景默认对应展开程度 L1、安全合规 L2、语气/角色定位 L2；合规与管理场景默认对应展开程度 L2、安全合规 L3、语气/角色定位 L3。实际输入模型的 Prefix 应同时编码三个风格维度的强度等级（例如 `[展开:L3][安全:L2][语气:L2]`），场景标签用于自动选择默认 Prefix 组合，用户也可覆盖默认强度。

基于上述层级，本文定义了三类回答风格维度——展开程度（elaboration）、安全合规（cautious）和语气/角色定位（tone/role）——每类风格维度配有对应的强度等级定义和典型适用场景。这三类风格维度直接面向回答的表述形式本身：展开程度控制信息的详略程度和回答长度，安全合规控制安全措辞的强调程度和规程覆盖率，语气/角色定位控制回答的语用角色和措辞的确定程度。任何电力业务场景下的任何问题，系统根据场景标签自动选择默认三维强度 Prefix，用户也可根据需要覆盖任意维度的强度等级，模型应能产生在技术内容上正确、在表述形式上符合该风格要求的回答。

4.2.1 展开程度风格（elaboration）

展开程度风格合并了传统意义上的“详实”与“简明”——这两者本质上并非独立的风格类别，而是同一维度（信息展开程度）的两端。本文将展开程度

统一为一个风格维度，通过强度等级控制回答从“精简”到“详尽”的连续变化。

Prefix 文本：“请根据要求的展开程度生成回答。”量化约束：L1 侧重结论输出，L3 侧重全面展开。适用场景：任何需要控制回答信息密度的场景——从调度指令确认（需极简）到技术方案多维度论证（需详尽展开）。

4.2.2 安全合规风格（cautious）

Prefix 文本：“请在回答中关注电力安全红线和合规制度要求。”量化约束：根据强度等级引入不同程度的安全/合规提醒；安全提醒内容须与现行规程一致。适用场景：带电操作安全边界说明、保护投退合规条件、设备检修票证要求、制度咨询与合规判断等。

4.2.3 语气/角色定位风格（tone/role）

语气/角色定位风格是本文针对电力业务场景新定义的风格维度，用于控制回答的语用角色和措辞的确定程度。不同业务场景对回答的“口吻”要求截然不同：研发场景偏好探讨性语气（展示多种可能性和权衡），运维场景需要明确的指令口吻（直接可执行、不含歧义），管理场景要求权威的规范性表述（引用制度条款、措辞不容置疑）。

Prefix 文本：“请以要求的语气角色生成回答。”量化约束：根据强度等级采用不同的措辞确定性和角色定位。适用场景：技术方案研讨（研讨型）、调度指令与操作票（指令型）、安规解读与制度裁定（权威型）等。

4.2.4 风格强度等级划分

前文定义的三类风格 Prefix 解决了“生成哪种风格”的问题，但未解决“以多大强度表达该风格”的问题。在实际电力业务中，同一风格的不同强度等级对应着截然不同的回答形态——风格本质上是一个连续谱，不同强度等级刻画了同一风格在表述形式上的不同程度。本文为每种风格定义 L1–L3 三级强度等级，将风格控制确立为“类别 + 强度”的二维控制空间。

展开程度强度等级。展开程度的核心维度是信息展开的深度和广度。L1（精简）：结论 + 简要原因说明，不展开原理推导，字数 ≤ 60 字。L2（标准）：结论 + 关键原理或参数说明，具备基本的因果推理链条，字数 60–150 字。L3（详尽）：技术报告级别的全面展开，包含完整的背景铺垫、原理阐述、参数引用和推导逻辑，覆盖注意事项和相关标准引用，可独立作为技术分析文本使用，字数 ≥ 150 字。

安全合规强度等级。安全合规的核心维度是安全措辞的强调程度和覆盖率。L1(标准提醒):回答中在关键结论后包含安全提醒,引用规程名称,使用“应”“注意”等中等强度措辞。L2(强提醒):回答中安全提醒前置(开头或紧接核心结论),引用具体规程条款编号或关键原文,使用“必须”“不得”等强制性措辞,明确指出潜在风险和违规后果。L3(最高安全警戒):回答以安全警告开头,每个操作步骤或技术判断前均附加对应的安全/合规前置声明;引用多条相关规程的具体条款;安全措辞覆盖回答的全部安全敏感环节,无遗漏。

语气/角色定位强度等级。语气/角色定位的核心维度是措辞的确定性和角色权威感。L1(研讨型):探讨性语气,展示多种可能性和权衡,使用“可以考虑”“建议分析”“需进一步评估”等开放性措辞,适合技术讨论和方案比较场景。L2(指令型):确定语气,给出直接可执行的操作步骤或明确判断,使用“应执行”“需检查”“按以下步骤操作”等指令性措辞,适合运行操作和故障处置场景。L3(权威型):不容置疑的规范性语气,引用制度条款和强制性标准作为判断依据,使用“必须”“严禁”“不得”“依据《XX》第X条”等权威表述,适合安规裁定和合规审查场景。

表4-1 三类风格的三级强度定义与核心特征

风格维度	等级	核心特征	典型场景与措辞
展开程度	精简	结论+简要原因,不展开原理推导	调度指令确认;≤60字
	标准	结论+关键原理或参数说明,具备基本因果推理链条	日常技术问答;60–150字
	详尽	技术报告级全面展开,含背景铺垫、原理阐述、参数引用、推导逻辑与注意事项	技术方案论证;≥150字
安全合规	标准提醒	关键结论后附加安全提醒,引用规程名称	常规技术讨论;“应”、“注意”
	强提醒	安全提醒前置,引用具体条款编号或关键原文,明示潜在风险与违规后果	设备检修操作;“必须”、“不得”
	最高警戒	安全警告开头,每项操作/判断前附加安全前置声明,全环节无遗漏覆盖	带电作业、事故处置;引用多条规程具体条款
语气	研讨型	探讨性语气,展示多种可能性与权衡	技术方案研讨;“可考虑”、“建议分析”
	指令型	确定性指令口吻,给出直接可执行的操作步骤或明确判断	调度指令与操作票;“应执行”、“按以下步骤”
	权威型	不容置疑的规范性语气,引用制度条款与强制性标准作为判断依据	安规裁定与合规审查;“必须”、“严禁”、“依据《XX》第X条”

4.2.5 场景—强度映射

不同业务场景对同一风格的强度需求不同，这一差异源于各场景的业务目标、风险等级和信息需求特征。本文根据三大风格控制场景（见 2.3 节）的业务特征，为每个场景指定明确的默认目标强度等级，如表 4-2 所示。

研发与演进场景（基础科学、规划设计、仿真计算）：核心目标是知识深度和技术完整性，需要充分展开和开放性讨论。默认强度：展开 L3，安全合规 L1，语气 L1。

生产与运行场景（设备监控、运维检修、故障处置）：核心目标是快速获取可执行的准确信息，需要精简输出和明确的指令口吻，同时涉及实际操作，安全合规要求较高。默认强度：展开 L1，安全合规 L2，语气 L2。

合规与管理场景（制度标准）：核心目标是依据明确和合规边界清晰，需要权威的规范性表述和最高的安全合规强度。默认强度：展开 L2，安全合规 L3，语气 L3。

表 4-2 三大场景默认目标强度等级映射

场景	核心目标	展开程度	安全合规	语气/角色定位
研发与演进	知识深度与技术完整性	L3（详尽）	L1（标准提醒）	L1（研讨型）
生产与运行	快速可执行信息获取	L1（精简）	L2（强提醒）	L2（指令型）
合规与管理	依据明确与合规边界清晰	L2（标准）	L3（最高警戒）	L3（权威型）

场景—强度映射机制的工作原理为：当用户输入属于某一业务场景时，系统自动加载该场景的默认目标强度等级；若用户显式指定了强度等级（通过后续定义的强度条件化 Prefix），则用户指定值覆盖场景默认值。这一机制实现了“默认场景适配 + 用户个性化调整”的双层强度控制。

4.2.6 强度条件化 Prefix 设计

为实现细粒度强度控制，本文在三类风格 Prefix 的基础上引入**强度等级参数**。Prefix 文本的设计原则为：同时编码风格类别和强度等级，使模型在接收 Prefix 后明确知道“以哪种风格、多大强度”生成回答。

强度条件化 Prefix 的格式为：“[风格类别: style] [强度等级: L1-3] 具体指令”。例如，展开程度 L3 的 Prefix 为：“[风格类别: 展开程度] [强度等级: L3] 请给出详细全面的回答，包含完整的背景铺垫、原理阐述、参数引用和推导逻辑。”语气/角色定位 L2 的 Prefix 为：“[风格类别: 语气/角色定位] [强度等级: L2] 请以确

定性的指令口吻作答，给出直接可执行的操作步骤或明确判断。”

强度条件化 Prefix 的使用方式为：将三维风格强度编码拼接为统一的 Prefix（格式为 `[展开:Lx][安全:Ly][语气:Lz]`），直接拼接在用户问题之前，构成“强度条件化 Prefix + 问题”的统一输入序列，一次推理同时控制三个风格维度各自的强度等级。在系统部署中，用户或上层调度系统可通过场景标签自动加载默认强度组合，也可以手动覆盖任意维度的强度等级——例如，在事故抢修场景，系统自动将展开程度从 L2 调至 L1、安全合规从 L1 调至 L2、语气从 L2 调至 L2（指令型），以匹配紧急工况对精简输出、强安全措辞和确定性指令的需求。

风格判别模型在评估时仍不接收 Prefix 信息。判别模型的任务是：在无 Prefix 提示的情况下，从回答文本本身预测其在各个风格维度上的强度等级。这一不对称设计迫使策略模型将风格类别和强度特征共同内化为生成行为属性，而非对 Prefix 令牌的浅层条件反射。

表 4-1 汇总了三类风格在三个强度等级上的核心特征与典型场景。表 4-2 汇总了三大场景的默认目标强度等级。

4.3 风格偏好数据构建与质量筛选

风格判别模型的训练依赖于大规模、高质量的风格标注数据——模型需要从数据中学习“展开到什么程度算 L2/L3”“什么样的措辞算指令型/权威型”“安全提醒到什么程度算强提醒/最高警戒”的细粒度判别标准。风格标注天然具有主观性和连续性，因此需要通过系统化的数据构建流程来保证标注质量和一致性，而非依赖昂贵且难以规模化的人工全量标注。

本文设计了一个“SFT 数据复用 → 场景适配改写 → 三轮质量筛选”的风格偏好数据构建流程。核心理念是：**直接从第 3 章已构建的 SFT 数据集中选取高质量的问答对，根据问题所属业务场景的风格要求对原始回答进行定向改写，而非重新采样生成**。这一设计的优势在于：（1）复用 SFT 阶段已经过质量验证的问题和原始答案，保证技术内容的正确性；（2）改写操作仅调整回答的表述形式（展开程度、安全措辞、语气角色），不改变核心技术判断；（3）改写目标的强度等级明确可追溯（直接来自表 4-2 的场景默认映射），标注一致性高。

4.3.1 基于 SFT 数据的场景适配改写

数据选取。从 3.6 节质量筛选后的 SFT 数据集中，按七类数据类型均匀采

样约 8000 条问答对作为风格改写的种子数据。每条种子数据包含：原始问题 q、原始答案 a_{orig}、数据类型标签（七类之一）。

场景与目标风格确定。根据数据类型与业务场景的对应关系（见第 2 章），将每条数据映射到三大风格控制场景之一。目标风格强度组合由该场景在表 4-2 中的默认值确定。例如，一条来源于“运维检修”类型的问题被映射到生产与运行场景，其目标风格组合为：展开 L1、安全合规 L2、语气 L2。

风格改写。使用一个改写模型（可选用与 SFT 模型相同或更强的 LLM，如 Qwen2.5-72B-Instruct），通过结构化的改写 Prompt 对原始答案进行定向改写。改写 Prompt 包含三个要素：（1）原始问题与原始答案文本；（2）目标风格与目标强度等级的明确描述（直接引用表 4-1 中的 L1–L3 定义）；（3）改写约束——必须保留原始答案的核心技术事实和判断结论，仅调整表述形式。改写 Prompt 模板如下：

任务：对以下电力领域问答的答案进行风格改写。
原始问题：{q}
原始答案：{a_{orig}}
目标风格与强度：

- 展开程度：L? ——{对应表 4-1 的定义}
- 安全合规：L? ——{对应表 4-1 的定义}
- 语气/角色定位：L? ——{对应表 4-1 的定义}

改写要求：仅调整答案的表述形式以匹配目标风格强度，不得改变核心技术事实、参数数值和判断结论。直接输出改写后的答案，不附加任何解释。

为覆盖全部强度等级以支持判别模型的序数回归训练，每条种子数据的改写策略为：首先生成场景默认风格组合的改写版本（必选），然后从剩余的 26 种风格强度组合（$3\times3\times3-1=26$）中随机选取 2 种进行额外改写（随机选取，以保证各强度等级的总体覆盖）。最终每条约生成 3 个改写版本，总计约 24000 条候选改写数据。

4.3.2 LLM-as-Judge 风格强度评分

每条候选改写数据需要标注三个风格维度上的实际强度等级，以作为判别模型的序数标签。本文采用 LLM-as-Judge 方法进行评分。由于风格质量具有较强主观性，本文采用 LLM-as-Judge 辅助构建风格偏好评分；该方法虽已在开放式对话模型评测中得到广泛使用，但也存在位置偏差、长度偏差和评判模型偏好等问题[65]。因此，本文在风格评分时采用固定维度评分规约，并对部分样本进行人工复核。具体地，使用一个独立的评测 LLM 对每条样本在展开程度、安

全合规和语气/角色定位三个维度上给出 L1–L3 三级强度评分，并附评分理由。评分标准直接对应 4.2.4 节的三级强度定义。

评测 LLM 的输入为（目标风格强度组合描述 + 问题 + 改写后回答）三元组。提供目标风格强度描述使评测 LLM 明确该回答的预期强度，从而判断改写是否达标。

三个维度的评分标准与 4.2.4 节对齐。展开程度：3 分对应 L3（详尽展开，≥ 150 字，完整背景/原理/参数/推导），2 分对应 L2（标准展开，60–150 字，关键原理或参数说明），1 分对应 L1（精简，≤ 60 字，仅结论 + 简要原因）。安全合规：3 分对应 L3（全环节覆盖 + 多条规程条款），2 分对应 L2（强提醒，条款编号 + 强制性措辞 + 风险后果），1 分对应 L1（标准提醒，规程名称引用 + 中等强度措辞）。语气/角色定位：3 分对应 L3（权威型，制度条款引用 +“必须”“严禁”等），2 分对应 L2（指令型，确定语气 + 直接可执行步骤），1 分对应 L1（研讨型，开放性措辞 + 多选项权衡）。

4.3.3 三轮质量筛选

原始 LLM-as-Judge 评分结果需经过三轮质量筛选后方可进入风格偏好数据集。筛选设计遵循“先快后慢、先规则后模型、先自动后人工”的原则，确保筛选流程高效且可执行。

第一轮：内容保真度检查（LLM 辅助筛选）。此轮检查改写是否保留原始答案的核心技术内容，防止事实漂移，执行三步检查：(a) 关键实体保留——由专用校验 LLM 比对原始答案与改写答案，判断关键设备名称、参数数值（电压等级、保护定值、温度阈值等）、规程条款引用是否完整保留且无篡改，任一关键实体丢失或篡改则剔除；(b) 结论一致性——由同一校验 LLM 判断改写后的核心处置结论是否与原始答案一致（如“建议立即停电”不得变为“可继续运行”），输出“一致/冲突”二分类判定及简要理由，判定为冲突则剔除；(c) 长度合理性——仍采用规则检查回答长度是否与目标展开程度的基本约束一致，目标 L1 但字数 > 100，或目标 L3 但字数 < 80，标记为改写失败并剔除。本轮以 LLM 辅助判别为主、规则长度检查为辅，预期剔除约 15%–20% 样本。

第二轮：风格达标检查（LLM 评分筛选）。此轮基于 LLM-as-Judge 的三维强度评分，仅用于剔除明显改写失败的样本，而非精确筛选至目标等级。筛选条件适度宽松：目标等级为 L1 时评分需 ≤ 2（排除严重冗余的改写结果），目标为 L2 时评分需为 2 或 3（排除信息量严重不足的改写结果），目标为 L3 时评分需 ≥ 2（排除深度严重不足的改写结果）。需要注意的是，通过此轮筛选的样

本，其**最终训练标签采用 LLM-as-Judge 给出的实际强度等级，而非改写时的目标强度等级**——例如，以 L3 为目标改写的样本若 LLM 评分为 L2，则该样本保留且标签标记为 L2，而非 L3。这一设计确保风格判别模型的序数回归标签反映了文本真实的风格强度，避免了目标等级与文本实际表达之间的系统性偏差。同时，对非目标风格维度进行严重偏差检查——若改写针对展开程度 L1，但安全合规评分突变为 3（异常地引入了大量安全内容），说明改写过程引入了非预期的风格混淆，此类样本标记为需审核。第二轮为模型评分筛选，预期剔除 10%–15% 风格严重不达标的样本。

第三轮：标注一致性校准（双审 + QWK）。此轮用于检验 LLM-as-Judge 评分的可靠性，防止单一 LLM 的评分偏差被直接用作训练标签。从通过前两轮的样本中，按强度等级 × 风格类别分层随机抽取 15%，由第二位评测 LLM（这里采用 DeepSeek V4）进行独立的三维强度评分。计算两位评测 LLM 之间在三个维度上的二次加权 Kappa（QWK）系数。若某维度的 QWK < 0.70，表明两位评测 LLM 在该维度上存在系统性分歧，触发以下校准程序：（1）对该维度的全部样本进行重审；（2）若重审后分歧仍存在，则对该维度分歧样本引入人工裁决（从标注团队中抽取 1–2 名电力领域专家进行判定）。若三个维度的 QWK 均 ≥ 0.70，表明 LLM-as-Judge 评分具有跨模型的可靠性，直接采用首轮 LLM 评分作为最终序数标签。

经过三轮筛选后，最终获得约 1.5 万条高质量风格强度标注数据，按 8:1:1 划分为训练集（约 12000 条）、验证集（约 1500 条）和测试集（约 1500 条）。数据集覆盖三类风格（各含三个强度等级）和七类电力数据类型。每条样本包含问题、改写后回答以及在三个风格维度上的 L1–L3 级强度标签。三个维度的平均强度为展开程度 2.08 ± 0.72，安全合规 2.02 ± 0.68，语气/角色定位 2.05 ± 0.70，各维度强度分布均覆盖 L1–L3 全范围。这些序数强度标签作为 4.4 节风格判别模型序数回归训练的监督信号。

表 4-3 汇总了三轮质量筛选的逐轮留存统计。

表 4-3 三轮质量筛选逐轮留存统计

筛选阶段	筛选方式	输入量	留存量	留存率	主要剔除原因
初始候选	场景适配改写	——	24,000	——	——
第一轮	LLM 辅助 + 规则筛选	24,000	≈19,800	≈82.5%	关键实体丢失、结论冲突、长度不符
第二轮	LLM 评分筛选	≈19,800	≈17,300	≈87.5%	目标风格未达标、非目标风格混淆
第三轮	双审 + QWK 校准	≈17,300	15,000	≈86.6%	标注分歧、人工裁决剔除

4.4 基于 Qwen2.5-7B 的风格判别模型训练

风格判别模型（Style Reward Model）是本章风格对齐训练的核心组件——它为强化学习提供客观、可量化、可微分的风格奖励信号，引导策略模型在正确的风格优化方向上更新参数。本节阐述风格判别模型的架构设计、训练目标及关键设计决策。

4.4.1 风格判别模型的功能定位与输入输出

风格判别模型的功能定义为：给定一个问题—回答对（问题文本 + 回答文本，不包含任何风格 Prefix），输出该回答在展开程度、安全合规、语气/角色定位三个风格维度上的**强度等级概率分布**。判别模型为每个风格维度独立预测 L1–L3 三级强度的概率质量分布——即同时判断“该回答的展开程度如何”和“展开程度是 L2 还是 L3”，使模型能够捕捉同一风格内部的强度差异，为后续 RL 训练提供细粒度的强度奖励信号。

风格判别模型的输入严格限定为无 Prefix 的纯问答文本对：Input = [Question, Answer]，输出为三维强度概率分布 $\mathbf{P} \in [0,1]^{3\times 3}$，其中 $P_{k,\ell} = \Pr(\text{intensity}_k = \ell)$ 表示维度 k 上的强度为等级 $\ell \in \{1,2,3\}$ 的预测概率，满足 $\sum_{\ell=1}^{3} P_{k,\ell} = 1$（每个维度的三个强度等级概率之和为 1）。判别模型的输入中不包含风格 Prefix，使其学到的是“什么样的文本表述对应什么样的风格强度”——即风格强度的内在文本特征，而非 Prefix 的表层提示。在后续 RL 训练中，策略模型接收强度条件化 Prefix 生成回答，判别模型在不知 Prefix 的情况下对回答进行强度评估——这种独立于 Prefix 的评估机制是细粒度风格对齐奖励信号客观性的根本保障。

4.4.2 模型架构设计

风格判别模型的基座选择 Qwen2.5-7B-Instruct。选择该模型的原因有三：其一，Qwen2.5-7B-Instruct 在中文理解和电力领域相关文本的表征方面具有较强能力；其二，7B 参数量级在推理延迟和显存占用方面适合作为在线奖励模型（RL 训练中每个 roll-out 步骤均需调用判别模型进行评分，推理效率直接影响训练吞吐）；其三，Instruct 版本经过指令微调，对“评估”类提示的理解能力优于纯基座模型。

模型架构在 Qwen2.5-7B-Instruct 之上进行了面向序数强度预测的改造。将问题文本和回答文本拼接为统一的输入序列，通过 Transformer 编码器进行前向传播。取输入序列最后一个 token 位置上的隐藏状态向量 $\mathbf{h}_{\text{last}} \in \mathbb{R}^d$（$d = 3584$

为 Qwen2.5-7B 的隐藏维度），该向量聚合了整个输入序列的上下文信息。每个风格维度需要预测 L1–L3 三级强度概率分布，本文采用**序数回归（Ordinal Regression）**架构，使用 CORAL（Consistent Rank Logits）框架实现序数约束下的强度预测。

CORAL 的核心思想是：将 K 级序数分类（$K=3$）分解为 $K-1=2$ 个二分类器，第 j 个二分类器预测“强度是否大于 j”。由于两个二分类器使用独立的权重行 $\mathbf{W}_k^{(1)}$ 和 $\mathbf{W}_k^{(2)}$，仅靠偏置项约束 $b_1 \geq b_2$ 无法保证对所有输入都有 $q_k^{(1)} \geq q_k^{(2)}$。本文通过两种互补机制共同保障序数一致性：训练时引入单调性惩罚项抑制序数反转，推理时对输出概率进行降序排序后处理。

具体而言，对每个风格维度 $k \in \{\text{elab}, \text{caut}, \text{tone}\}$，设置参数矩阵 $\mathbf{W}_k \in \mathbb{R}^{(K-1)\times d} = \mathbb{R}^{2\times d}$。$\mathbf{W}_k$ 的 2 行分别对应 2 个序数二分类器（“> 1?”“> 2?”）。前向传播计算 2 个 logits：

$$z_k^{(j)} = \mathbf{W}_k^{(j)} \cdot \mathbf{h}_{\text{last}} + b_j, \quad j \in \{1, 2\} \tag{4-1}$$

其中 b_j 为第 j 个分类器的偏置项，满足 $b_1 \geq b_2$（更高级别的阈值不应低于更低级别）。logits 经 Sigmoid 激活得到初始序数概率：

$$q_k^{(j)} = \sigma(z_k^{(j)}) = \Pr(\text{intensity}_k > j), \quad j \in \{1, 2\} \tag{4-2}$$

序数一致性保障。由于 $\mathbf{W}_k^{(1)}$ 与 $\mathbf{W}_k^{(2)}$ 相互独立，$b_1 \geq b_2$ 不能保证对所有输入 $\mathbf{h}_{\text{last}}$ 均有 $q_k^{(1)} \geq q_k^{(2)}$。若 $q_k^{(1)} < q_k^{(2)}$，则由 $\{q_k^{(1)}, q_k^{(2)}\}$ 导出的 $P_{k,2} = q_k^{(1)} - q_k^{(2)}$ 将出现负值，违反概率非负性。本文采用两种互补机制加以保障：

（1）**推理时排序后处理**：对每个风格维度 k，将两个初始序数概率按降序排列：$(\tilde{q}_k^{(1)}, \tilde{q}_k^{(2)}) = \text{sort_descending}(q_k^{(1)}, q_k^{(2)})$。排序后严格满足 $\tilde{q}_k^{(1)} \geq \tilde{q}_k^{(2)}$，后续概率分解均使用排序后的 $\tilde{q}_k^{(j)}$ 替代 $q_k^{(j)}$。

（2）**训练时单调性惩罚**：在 CORAL 损失之外引入单调性惩罚项 $\mathcal{L}_{\text{mono}} = \frac{1}{|\mathcal{S}|}\sum_{i\in\mathcal{S}}\sum_k \max(0, q_k^{(2,i)} - q_k^{(1,i)})$，当 $q_k^{(2)} > q_k^{(1)}$ 时施加线性惩罚以抑制序数反转，引导模型在训练中自发学习序数一致性。总损失中加入该项：$\mathcal{L} = \mathcal{L}_{\text{CORAL}} + \mathcal{L}_{\text{entropy}} + \gamma\mathcal{L}_{\text{mono}}$，其中 $\gamma = 0.1$。

由排序后的 $\{\tilde{q}_k^{(1)}, \tilde{q}_k^{(2)}\}$ 可唯一确定每个强度等级的预测概率：

$$\begin{aligned} P_{k,1} &= 1 - \tilde{q}_k^{(1)} \\ P_{k,2} &= \tilde{q}_k^{(1)} - \tilde{q}_k^{(2)} \\ P_{k,3} &= \tilde{q}_k^{(2)} \end{aligned} \tag{4-3}$$

这一架构的预测期望强度等级可直接计算为 $\mathbb{E}[\text{level}_k] = \sum_{\ell=1}^{3} \ell \cdot P_{k,\ell}$，或等价地 $\mathbb{E}[\text{level}_k] = 1 + \tilde{q}_k^{(1)} + \tilde{q}_k^{(2)}$。

采用 CORAL 序数回归而非 3 类 Softmax 多分类是本架构的关键设计决策。3 类 Softmax 将 3 个强度等级视为无序的独立类别，丢失了强度等级之间的序数结构（L1 < L2 < L3）。在风格强度判别中，将 L3 误判为 L2 的代价远小于将 L3 误判为 L1 的代价，但多分类交叉熵对两类误判施加相同的惩罚。CORAL 的序数结构自然编码了这一不等价性：$q_k^{(j)}$ 的层次结构使得强度等级越接近的类别，其预测概率越相关。此外，三个风格维度之间仍保持独立——每个维度有自己的 2 个序数二分类器，维持了风格维度间非互斥的灵活性（同一回答可以同时在展开程度和安全合规维度上获得高强度预测）。总输出维度为 $3 \times 2 = 6$ 维（三个维度各 2 个序数 logits）。

4.4.3 训练目标与优化配置

风格判别模型的训练目标为三个风格维度上的序数回归损失之和。每条训练样本 i 的目标标签为三维强度等级向量 $\mathbf{y}^{(i)} = [y_{\text{elab}}, y_{\text{caut}}, y_{\text{tone}}]$，其中 $y_k \in \{1, 2, 3\}$ 直接由 4.3 节的 LLM-as-Judge 强度评分确定。标签保留了完整的强度等级信息，模型学习预测的是 L1–L3 三级序数强度。

对于风格维度 k 上的一个样本（标签为强度等级 $y_k \in \{1, 2, 3\}$），CORAL 框架将其转化为 $K - 1 = 2$ 个二分类子任务——第 j 个子任务的目标标签为 $\mathbb{1}[y_k > j]$（即强度是否高于等级 j）。维度 k 的序数回归损失为 2 个子任务的 BCE 损失之和：

$$\mathcal{L}_k = -\frac{1}{|\mathcal{S}_k|} \sum_{i \in \mathcal{S}_k} \sum_{j=1}^{2} \left[\mathbb{1}[y_k^{(i)} > j] \cdot \log q_k^{(j,i)} + \mathbb{1}[y_k^{(i)} \leq j] \cdot \log(1 - q_k^{(j,i)}) \right] \tag{4-4}$$

其中 $q_k^{(j,i)} = \Pr(\text{intensity}_k > j)$ 为模型对样本 i 预测的序数概率，$\mathcal{S}_k$ 为维度 k 上具有有效标签的样本集合。**所有 L1–L3 三级标签均参与损失计算**——每个强度等级都是训练信号的有效组成部分，序数回归的层次二分类子任务设计使得各等级的样本均能为损失函数贡献梯度。

总损失为三维序数回归损失之和：$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{elab}} + \mathcal{L}_{\text{caut}} + \mathcal{L}_{\text{tone}}$。此外，引入熵正则化项和序数单调性惩罚项。记维度 k 的预测分布熵为 $H(P_k) = -\sum_{\ell=1}^{3} P_{k,\ell} \log(P_{k,\ell} + \epsilon)$，单调性惩罚为 $\mathcal{L}_{\text{mono}} = \frac{1}{|\mathcal{S}|} \sum_{i \in \mathcal{S}} \sum_k \max(0, q_k^{(2,i)} - q_k^{(1,i)})$，则总损失为：

$$\mathcal{L} = \mathcal{L}_{\text{CORAL}} + \mathcal{L}_{\text{entropy}} + \gamma \mathcal{L}_{\text{mono}}, \quad \mathcal{L}_{\text{entropy}} = \frac{\lambda}{3} \sum_{k} H(P_k) = -\frac{\lambda}{3} \sum_{k} \sum_{\ell=1}^{3} P_{k,\ell} \cdot \log(P_{k,\ell} + \epsilon) \tag{4-5}$$

其中 $\lambda = 0.05$ 为熵正则化系数，$\gamma = 0.1$ 为单调性惩罚系数，$\epsilon = 10^{-8}$ 防止 $\log(0)$。$\mathcal{L}_{\text{entropy}}$ 项鼓励强度分布集中而非均匀分散，$\mathcal{L}_{\text{mono}}$ 项在 $q_k^{(2)} > q_k^{(1)}$ 时施加线性惩罚以抑制序数反转，两者共同提升强度判别的确定性和序数一致性。

这种 “CORAL 序数回归 + 独立维度” 的设计具有以下优势。第一，**序数结构保持**——CORAL 的层次二分类器自然编码了 L1 < L2 < L3 的序数约束，使得误判惩罚与强度差异成正比（将 L3 判为 L2 的损失远小于判为 L1）。第二，**各维度解耦**——三个风格维度的损失独立计算，某一维度的梯度更新不影响其他维度的强度预测，避免了维度间的梯度竞争。第三，**全标签利用**——所有 L1–L3 三级标签均参与训练，每个强度等级的标注信息均被充分利用，数据利用率高。第四，**可解释性**——每个维度的输出是一个完整的强度概率分布，不仅给出 “最可能的强度等级”，还提供了 “强度判断的不确定性”（分布的熵），这为后续 RL 训练中基于分布的奖励设计提供了信息基础。

训练数据为 4.3 节筛选得到的约 1.5 万条风格强度标注数据，按 8:1:1 划分为训练集（约 12000 条）、验证集（约 1500 条）和测试集（约 1500 条）。训练采用 AdamW 优化器，学习率为 1×10^{-5}，使用余弦退火调度，批次大小为 32，训练 3 个 epoch。

4.4.4 实验结果与分析

本文采用以下三项序数评估指标衡量风格判别模型的强度预测性能：（1）**二次加权 Kappa（QWK）**——衡量预测强度与真实强度之间的序数一致性，对大跨度误判（如 L3→L1）施加远重于邻级误判（如 L3→L2）的惩罚；（2）**平均绝对误差（MAE）**——预测期望强度 $\mathbb{E}[\text{level}_k]$ 与真实强度 y_k 之间的平均绝对偏差，单位为强度等级；（3）**精确强度准确率（Exact）**——预测最高概率强度等级与真实等级完全一致的样本占比。

表 4-4 汇总了 LLM-as-Judge 基线以及 CORAL-3B、CORAL-7B 两个规模的风格判别模型在三类风格上的序数指标。LLM-as-Judge 基线使用 Qwen-Max，通过提示工程进行 L1–L3 三级强度评分。

从表中可以得出以下结论。第一，训练后的 CORAL 风格判别模型在两个规模上均显著优于 LLM-as-Judge 基线——CORAL-7B 的 Macro QWK 达到 0.8，较 LLM-as-Judge 基线（Macro QWK ≈ 0.7）提升约 14%，Macro MAE 从 0.30 降至

表 4-4 风格判别模型序数强度预测实验结果汇总

方法	风格	QWK	MAE ↓	Exact
LLM-as-Judge（Qwen-Max）	展开程度	0.7	0.3	67.0%
	安全合规	0.7	0.3	63.6%
	语气/角色定位	0.7	0.3	65.2%
CORAL-3B（训练后）	展开程度	0.8	0.2	72.0%
	安全合规	0.8	0.3	68.6%
	语气/角色定位	0.8	0.3	70.2%
CORAL-7B（训练后）	展开程度	**0.9**	**0.2**	**79.2%**
	安全合规	**0.8**	**0.2**	**75.8%**
	语气/角色定位	**0.8**	**0.2**	**77.4%**

0.2，支持了专门化风格强度判别训练的有效性。第二，CORAL-3B 各指标已接近 CORAL-7B 水平但仍有差距，说明序数回归架构在中等参数规模下已能有效工作，而更大基座进一步提升了强度判别的精确性。第三，三种风格中展开程度的得分最高（CORAL-7B QWK = 0.9），安全合规和语气/角色定位的得分略低（均为 0.8）；展开程度判别主要依赖文本长度和信息密度等浅层特征，相对容易；安全合规判断需要结合电力领域规程知识，部分样本的安全边界判断依赖领域经验；语气/角色定位判断涉及措辞的确定性和角色一致性，难度较高。综合精度与部署成本，本文最终选用 CORAL-7B，训练完成后冻结参数，作为后续 RL 训练的固定奖励信号源。

训练完成并通过验证的风格判别模型（CORAL-7B）被冻结参数，作为后续 4.5 节强化学习训练的固定奖励信号源。表 4-5 汇总了风格判别模型的架构参数与训练配置。

4.5 基于强化学习的风格对齐训练

获得冻结的风格判别模型后，本文进入强化学习风格对齐训练阶段。本文的风格强化学习对齐建立在人类偏好强化学习框架基础上[30-32]。PPO 通过裁剪策略更新幅度提升训练稳定性[33]；GRPO 进一步用组内相对奖励替代显式 critic，从而降低大模型强化学习的训练开销[34]；DAPO 中的 Clip-Higher 等策略则可用于缓解 token 级策略梯度训练中的熵坍塌和有效梯度不足问题[35]。与之相比，DPO 更适合离线偏好对齐[40]，因此本文将风格强化学习和安全 DPO 分别放在第 4 章与第 5 章中处理。

RL 训练的基本逻辑为：给定强度条件化 Prefix（含风格类别和目标强度等级）和用户问题，策略模型（SFT 模型初始化）生成回答；风格判别模型接收不含 Prefix 的问题和回答，输出三维强度概率分布 $\mathbf{P} \in [0,1]^{3\times3}$；取目标风格维

表 4-5 风格判别模型架构参数与训练配置

配置项	具体参数
模型架构	
基座模型	Qwen2.5-7B-Instruct（隐藏维度 $d = 3584$）
输入格式	[问题文本，回答文本]，不含风格 Prefix
特征提取	取输入序列末位 token 的隐藏状态 $\mathbf{h}_{\text{last}} \in \mathbb{R}^{3584}$ 作为问答对的特征表示
序数分类头	每个风格维度 k 设权重矩阵 $\mathbf{W}_k \in \mathbb{R}^{2\times 3584}$ 和偏置 b_1, b_2（$b_1 \geq b_2$），经 Sigmoid 得初始序数概率 $q_k^{(1)}, q_k^{(2)}$；推理时降序排序为 $\tilde{q}_k^{(1)} \geq \tilde{q}_k^{(2)}$
输出	3 风格 × 2 序数概率 $q_k^{(j)} \in [0,1]$；排序后由 $\{\tilde{q}_k^{(1)}, \tilde{q}_k^{(2)}\}$ 分解为 $P_{k,1} = 1 - \tilde{q}_k^{(1)}$, $P_{k,2} = \tilde{q}_k^{(1)} - \tilde{q}_k^{(2)}$, $P_{k,3} = \tilde{q}_k^{(2)}$，满足 $\sum_\ell P_{k,\ell} = 1$
序数约束	偏置约束 $b_1 \geq b_2$；训练时单调性惩罚 $\mathcal{L}_{\text{mono}}$（$\gamma = 0.1$）抑制序数反转；推理时降序排序保证 $\tilde{q}_k^{(1)} \geq \tilde{q}_k^{(2)}$
训练配置	
训练数据	4.3 节风格强度标注数据 ~15,000 条（8:1:1 划分）
训练目标	三维 CORAL 序数回归损失之和 + 熵正则化（$\lambda = 0.05$）+ 单调性惩罚（$\gamma = 0.1$）
优化器	AdamW
学习率	1×10^{-5}，余弦退火调度
批次大小	32
训练轮数	3 epochs
最终选用模型	CORAL-7B（Macro QWK = 0.8，MAE = 0.2）

度的强度分布与目标强度等级之间的偏差作为奖励信号（越接近目标强度奖励越高）；使用 RL 算法优化策略模型参数。

本节按照 “动机 → 改进 → 实验 → 再改进” 的研究脉络展开。首先，在数据准备阶段，为每条 RL prompt 分配目标强度等级，并设计强度偏差奖励函数。在此基础上，依次尝试 PPO 和 GRPO 两种策略优化框架，在实验过程中分别发现训练震荡和后期收益平台问题，并针对性地引入 Dual-Clip 和 Clip-Higher 改进。最终通过实验对比确定 GRPO + Clip-Higher 在本实验设置下为较优方案。

4.5.1 数据准备与奖励映射

RL 训练数据直接复用 4.3 节风格偏好数据集中的问题与目标风格强度组合。4.3 节的数据已为每条问题标注了所属业务场景及其对应的默认目标风格强度等级。在此基础上，将 SFT 原始答案输入 CORAL 风格判别模型获得三维强度分布作为基线，仅保留策略模型在目标风格维度上的基线期望强度与目标强度等级偏差 ≥ 0.3 级的样本（即存在风格改进空间的样本）。最终获得约 6000

条 RL 训练 prompt，每个 prompt 包含问题、强度条件化 Prefix（风格类别 + 目标强度等级）、场景标签，覆盖三类风格 × 三个强度等级 × 七类电力数据类型的组合空间。

奖励映射是将判别模型的强度概率分布转化为 RL 训练标量奖励信号的关键步骤。奖励信号的核心目标是使生成回答的强度逼近目标强度等级——奖励函数在预测强度等于目标强度时取最大值，偏离目标强度时（无论偏高或偏低）递减。本文设计了**强度偏差奖励函数**（Intensity Deviation Reward），其数学形式为：

$$r = 1 - \frac{|\mathbb{E}[\text{level}_{\text{target}}] - \ell^*|}{K-1} = 1 - \frac{|\mathbb{E}[\text{level}_{\text{target}}] - \ell^*|}{2} \tag{4-6}$$

其中 $\ell^* \in \{1,2,3\}$ 为该 prompt 的目标强度等级（从强度条件化 Prefix 中获取），$\mathbb{E}[\text{level}_{\text{target}}] = \sum_{\ell=1}^{3} \ell \cdot P_{\text{target},\ell}$ 为判别模型对生成回答在目标风格维度上的预测期望强度，$K-1=2$ 为最大可能偏差。奖励值域为 $[0,1]$，当期望强度恰好等于目标强度时 $r=1$（最优），期望强度偏离目标强度越远则奖励越低。例如，目标强度为 L3 时，若预测期望强度为 2.8（接近 L3）则 $r=0.90$，若为 1.3（严重偏离）则 $r=0.15$。

强度偏差奖励的设计优势。强度偏差奖励在目标强度两侧对称递减，具有三个关键特性。

第一，**双向惩罚防止过度优化**。强度偏差奖励既惩罚强度不足，也惩罚强度过度——当目标强度为 L2 时，输出 L1 和输出 L3 均获得低奖励。这一特性使策略模型学会**恰到好处**的风格表达强度。

第二，**场景自适应**。强度偏差奖励使同一风格类别下不同业务场景可以设定不同的目标强度等级。例如，同为展开程度风格，调度指令场景设定 $\ell^*=1$（精简），而技术方案论证场景设定 $\ell^*=3$（详尽）。RL 训练中，策略模型根据强度条件化 Prefix 中的 ℓ^* 参数自动调整优化目标，实现“同一风格、不同强度、按需适配”的细粒度控制。这直接呼应了 4.2.5 节的场景—强度映射机制。

第三，**信号质量更优**。强度偏差奖励充分利用了 CORAL 判别模型输出的完整强度分布信息（3 个概率值）。期望强度 $\mathbb{E}[\text{level}]$ 的计算聚合了分布的全部信息，对判别模型的局部噪声（如某个 $q_k^{(j)}$ 的微小波动）具有较好的鲁棒性。

在 RL 训练的每一轮 rollout 中，风格判别模型不接收 Prefix 信息。策略模型接收强度条件化 Prefix（含目标强度等级 ℓ^*）生成回答，判别模型在不知目标强度的情况下从回答文本中推断强度等级。这一不对称设计使判别模型充当客观的强度评估者，迫使策略模型将风格强度特征内化到生成行为中。强度条件化

Prefix 中的目标强度 ℓ^* 仅用于奖励计算，不泄露给判别模型。

在RL 训练中，不同业务场景通过其默认目标强度组合（表4-2）控制风格优化方向，使同一策略模型能够在不同场景下自动适配差异化的风格强度需求。

4.5.2 PPO 风格对齐与 Dual-Clip 改进

近端策略优化（Proximal Policy Optimization, PPO）是 RLHF 领域应用最广泛的策略梯度算法。本文以 SFT 模型作为策略模型 π_θ 的初始化和参考策略 π_{ref}，以 CORAL 风格判别模型作为奖励信号源。PPO 训练中，策略模型接收“强度条件化 Prefix + 问题”生成回答，判别模型评分后经强度偏差奖励映射得到标量奖励，Actor 网络据此更新策略参数。

标准 PPO 的核心目标函数为 clipped surrogate objective：

$$\mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta)\hat{A}_t,\ \text{clip}(r_t(\theta), 1-\varepsilon, 1+\varepsilon)\hat{A}_t \right) \right] \tag{4-7}$$

其中 $r_t(\theta) = \pi_\theta(a_t \mid s_t) / \pi_{\theta_{\text{old}}}(a_t \mid s_t)$ 为当前策略与旧策略在动作 a_t 上的概率比，$\hat{A}_t$ 为使用广义优势估计（GAE）计算的优势函数。clip 操作将概率比限制在 $[1-\varepsilon, 1+\varepsilon]$ 区间（典型值 $\varepsilon = 0.2$），防止单步策略更新幅度过大。

然而，在风格对齐训练中观察到标准 PPO 存在训练震荡问题：奖励曲线呈现大幅周期性波动而非平滑收敛。其根源在于强度偏差奖励信号的连续性——强度偏差奖励为连续值，同一问题的不同采样回答得分可在 0.3–0.95 之间大幅波动。当策略偶然生成与目标强度严重偏离的回答（如目标为 L3 但实际期望强度仅 1.2），$\hat{A}_t < 0$ 的绝对值很大，同时 $r_t(\theta)$ 非常小。标准 PPO 的 clip 仅将 $r_t(\theta)$ 裁减到 $1-\varepsilon$，但裁减后的梯度仍推动策略对极端偏离样本产生较大更新，破坏已学到的风格行为。

本文借鉴 Dual-Clip PPO 方法解决该问题，在标准 PPO 目标函数上引入额外的下界约束项：

$$\mathcal{L}^{\text{Dual-Clip}}(\theta) = \mathbb{E}_t \left[\max \left(\min \left(r_t(\theta)\hat{A}_t,\ \text{clip}(r_t(\theta), 1-\varepsilon, 1+\varepsilon)\hat{A}_t \right),\ c \cdot \hat{A}_t \right) \right] \tag{4-8}$$

其中 c 为下界常数（本文设为 $c = 3.0$）。当 $\hat{A}_t < 0$ 且 $r_t(\theta)$ 非常小时，$c \cdot \hat{A}_t$ 项被激活，为损失函数在负优势方向上的下降幅度设置硬性下界，防止单个极端低分样本对策略更新产生不成比例的影响。

实验结果。图 4-1 对比了标准 PPO 与 Dual-Clip PPO 的训练 reward 曲线。标准 PPO 出现了明显的周期性震荡，奖励曲线波动较大；引入 Dual-Clip 后，震荡幅度显著降低，收敛更加平滑。更重要的是，由于训练过程免受极端低分样本

的破坏性干扰，策略能够更稳定地向目标风格方向优化，Dual-Clip PPO 的最终奖励得分也高于标准 PPO。这一结果表明，Dual-Clip 下界约束在抑制训练震荡和提升最终性能两个方面均发挥了积极作用。

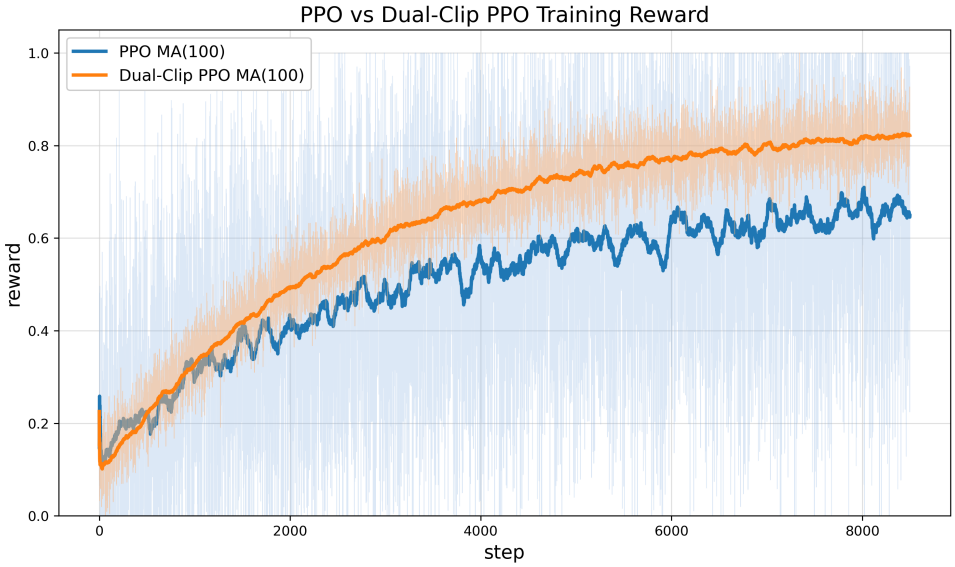


图 4-1 PPO 与 Dual-Clip PPO 训练 Reward 曲线对比

PPO 训练的完整奖励函数包含 KL 惩罚项以约束策略不偏离参考策略过远：

$$r_{\text{total}} = r_{\text{style}} - \beta \cdot D_{\text{KL}}(\pi_\theta \,\|\, \pi_{\text{ref}}) \tag{4-9}$$

其中 β 为 KL 惩罚系数（设为 0.02），D_{KL} 为当前策略与参考策略在生成分布上的 KL 散度。PPO 同时维护一个 Critic 网络用于估计状态价值以计算 $\hat{A}_t$，Critic 从策略模型的基座权重初始化，独立更新。

4.5.3 GRPO 风格对齐与 Clip-Higher 改进

组相对策略优化（Group Relative Policy Optimization, GRPO）由 DeepSeek 团队在 DeepSeekMath（Shao et al., 2024）中首次提出，并在 DeepSeek-R1 等后续工作中被广泛采用。GRPO 的核心创新在于消除了对独立价值函数（Critic）网络的需求——标准 PPO 需要一个与策略网络规模相当的 Critic 来估计状态价值以计算优势函数，对 7B 以上规模的模型意味着近一倍的显存和计算开销。GRPO 通过组内相对比较来估计优势，避免了训练和存储 Critic 网络的开销。

GRPO 的原始目标函数定义为：

$$\mathcal{J}_{\mathrm{GRPO}}(\theta) = \mathbb{E}_{q\sim P(Q),\{o_i\}_{i=1}^{G}\sim\pi_{\theta_{\mathrm{old}}}(O|q)} \Bigg[\frac{1}{G}\sum_{i=1}^{G}\frac{1}{|o_i|}\sum_{t=1}^{|o_i|} \min\Big(\frac{\pi_\theta(o_{i,t}\mid q,o_{i,<t})}{\pi_{\theta_{\mathrm{old}}}(o_{i,t}\mid q,o_{i,<t})}\hat{A}_{i,t}, \mathrm{clip}\Big(\frac{\pi_\theta(o_{i,t}\mid q,o_{i,<t})}{\pi_{\theta_{\mathrm{old}}}(o_{i,t}\mid q,o_{i,<t})}, 1-\varepsilon, 1+\varepsilon\Big)\hat{A}_{i,t}\Big) - \beta\cdot\mathbb{D}_{\mathrm{KL}}(\pi_\theta \,\|\, \pi_{\mathrm{ref}}) \Bigg] \tag{4-10}$$

其中 q 为输入 prompt，$\{o_i\}_{i=1}^{G}$ 为从旧策略 $\pi_{\theta_{\mathrm{old}}}$ 中采样的一组 G 个候选回答（G 通常取 4–8），$|o_i|$ 为第 i 个回答的 token 长度，$\hat{A}_{i,t}$ 为第 i 个回答在第 t 个 token 位置上的优势估计。

GRPO 的核心机制在于**组内相对优势估计**。对于每组 G 个候选回答，首先由 CORAL 判别模型评分并经强度偏差奖励映射得到 G 个标量奖励 $\{r_1, r_2, \ldots, r_G\}$，然后在组内对奖励进行标准化来计算优势——以组内均值作为基线、组内标准差作为归一化因子：

$$\hat{A}_i = \frac{r_i - \mu(r)}{\sigma(r)}, \quad \mu(r) = \frac{1}{G}\sum_{g=1}^{G} r_g, \quad \sigma(r) = \sqrt{\frac{1}{G}\sum_{g=1}^{G}(r_g - \mu(r))^2} \tag{4-11}$$

该优势估计不依赖于 Critic 网络预测的状态价值，而是直接利用同一 prompt 下多个采样之间的相对质量差异。组内标准化的优势在细粒度强度对齐任务中具有独特的适配性——强度偏差奖励的本质是回答与目标强度之间的匹配质量，组内相对排序可以自然区分出 “强度恰好匹配” 和 “强度偏离目标” 的样本差异，而绝对奖励值因不同目标强度 ℓ^* 的难度差异而不可比。

GRPO 的 clipped surrogate objective 采用对称 clip 区间 $[1-\varepsilon, 1+\varepsilon]$（$\varepsilon = 0.2$），并额外包含一个 KL 散度正则项 $\beta\cdot\mathbb{D}_{\mathrm{KL}}(\pi_\theta \,\|\, \pi_{\mathrm{ref}})$，直接作为损失函数的一部分约束策略不偏离参考策略过远。

然而，在 GRPO 训练中观察到后期强度匹配得分趋于平台——当策略已学会基本风格特征后（强度偏差奖励稳定在 0.72–0.75），得分停滞不前。其根源在于对称 clip 区间的保守性：当 $\varepsilon_{\mathrm{low}} = \varepsilon_{\mathrm{high}} = 0.2$ 时，策略在提升好回答概率（$\hat{A}_i > 0$）和降低坏回答概率（$\hat{A}_i < 0$）两个方向受到相同幅度的更新限制。训练后期优劣差异缩小时，策略需要更精细的强度调整，但对称 clip 的等幅限制减缓了这一精进过程。

本文借鉴 DAPO 中提出的 Clip-Higher 策略解决该问题。需要说明的是，本文仅采用了 DAPO 中非对称 clip 区间的 Clip-Higher 思想，并未完整实现 DAPO 的 Decoupled Clip 和 Dynamic Sampling 等全部机制。其核心思想是采用非对称

clip 区间——放宽概率比的上界裁剪阈值而保持下界不变：$\varepsilon_{\text{high}} > \varepsilon_{\text{low}}$。本文设置 $\varepsilon_{\text{low}} = 0.2$，$\varepsilon_{\text{high}} = 0.28$。当策略发现优于组内平均的回答（$\hat{A}_i > 0$）时，允许将其生成概率提升至旧策略的 1.28 倍（而非 1.20 倍），给予好风格方向更多探索空间；当回答差于组内平均时，仍仅允许降至 0.80 倍，保持坏方向的保守约束。

实验结果。图 4-2 对比了标准 GRPO 与 GRPO + Clip-Higher 的训练 reward 曲线。标准 GRPO 在训练中后期受对称 clip 的等幅约束限制，奖励上升趋于停滞——$\varepsilon_{\text{low}} = \varepsilon_{\text{high}} = 0.2$ 的对称设计在策略已掌握基本风格特征后，对好坏两个方向的更新施加了相同幅度的限制，减缓了精细调整的过程。GRPO + Clip-Higher 通过放宽上界至 $\varepsilon_{\text{high}} = 0.28$，给予优质风格方向更大的探索空间，在训练后期持续获得奖励提升，最终奖励得分显著高于标准 GRPO，并在所有对比方法中取得了最高的最终风格奖励。值得注意的是，GRPO + Clip-Higher 无需 Critic 网络，其轻量化设计使其在高性能的同时保持了训练效率。

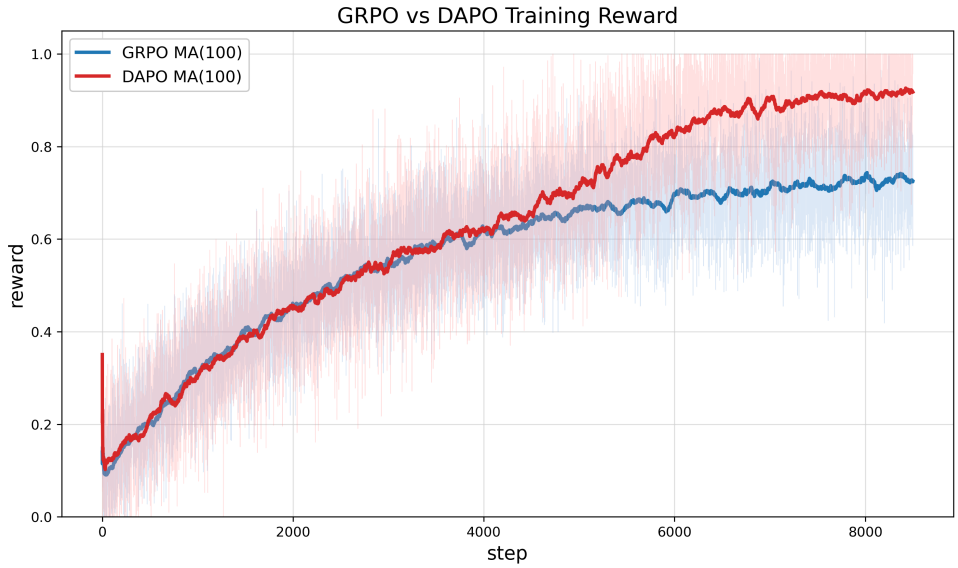


图 4-2 GRPO 与 GRPO + Clip-Higher 训练 Reward 曲线对比

除奖励层面的对比外，本文进一步从策略熵（policy entropy）的角度分析了 GRPO 与 GRPO + Clip-Higher 的行为差异。策略熵定义为生成分布的信息熵 $\mathcal{H}(\pi_\theta) = -\mathbb{E}_{o\sim\pi_\theta}[\log \pi_\theta(o)]$，反映了策略在生成时的多样性和探索能力——熵越高，策略对同一 prompt 生成的候选回答越多样化；熵越低，策略越倾向于确定性地产出少数高频模式。

实验观察到，标准 GRPO 在训练中后期出现了明显的**熵坍缩**（entropy collapse）现象：随着训练推进，策略熵持续下降，策略逐渐丧失生成多样性，对同

一 prompt 的 G 个采样回答趋于同质化。熵坍缩直接削弱了 GRPO 组内优势估计的有效性——当组内 G 个回答高度相似时，$\{r_i\}$ 的组内方差 $\sigma(r)$ 趋近于零，优势估计 $\hat{A}_i = (r_i - \mu(r))/\sigma(r)$ 的数值不稳定甚至发散，导致梯度更新方向失准。这与奖励平台现象高度吻合：策略失去多样性后，GRPO 无法通过组内对比有效区分微小的强度匹配差异，精细调整的优化信号被噪声淹没。

GRPO + Clip-Higher 的非对称 clip 区间在抑制熵坍缩方面发挥了关键作用。非对称 clip 区间（$\varepsilon_{\text{high}} = 0.28 > \varepsilon_{\text{low}} = 0.2$）允许策略在发现优质风格方向（$\hat{A}_i > 0$）时保留更大的更新幅度——这等价于为高优势采样保留了更高的生成概率上界，防止策略过早将概率质量集中于少数高频回答模式。从梯度角度分析，对称 clip 在训练后期对正、负优势施加等幅约束，导致策略分布的支撑集逐步收缩；Clip-Higher 放宽正优势方向的更新限制，使策略在向优质方向靠拢的同时仍保持一定的生成多样性，延缓了熵的衰减速度。

图 4-3 对比了 GRPO 与 GRPO + Clip-Higher 训练过程中的策略熵变化曲线。GRPO 的熵在训练中后期持续快速下降，与奖励平台的出现时间一致；GRPO + Clip-Higher 的熵下降速度明显更缓，在训练后期仍保持较高水平，为持续的奖励提升提供了多样性保障。熵坍缩的抑制是 GRPO + Clip-Higher 超越标准 GRPO 的深层机制——Clip-Higher 不仅通过非对称探索提升了奖励上限，更通过维持策略多样性延长了有效训练的生命周期。

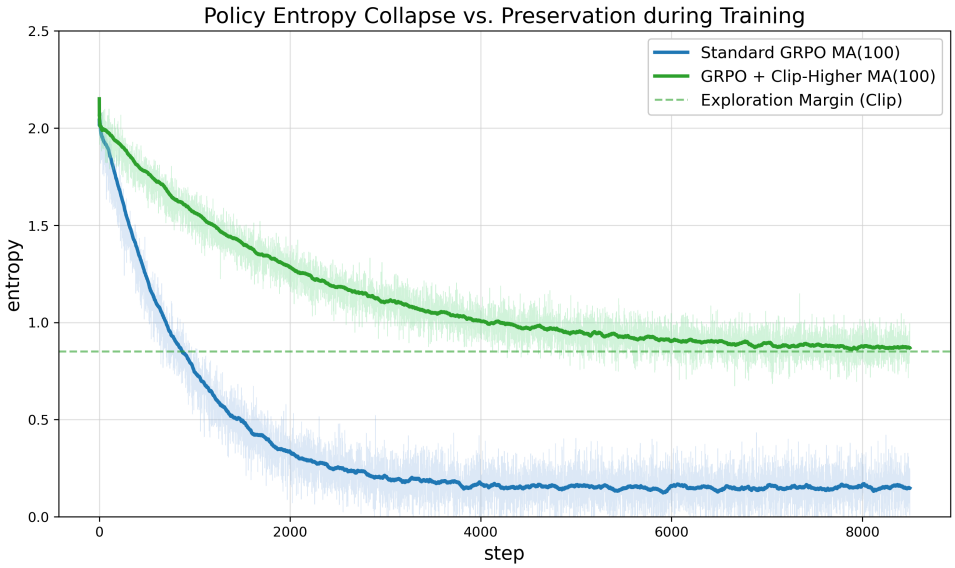


图 4-3 GRPO 与 GRPO + Clip-Higher 训练策略熵变化曲线对比

4.5.4 Online DPO 风格对齐对比

除 PPO 和 GRPO 外，本文还进行了 Online DPO 的风格对齐实验作为对比

基线。Online DPO 在标准 DPO 基础上增加在线采样环节：每个训练迭代中，策略模型对 prompt 生成回答，由 CORAL 判别模型评分并经强度偏差奖励映射得到奖励；对同一 prompt 的多个候选回答，取强度偏差奖励最高者（最接近目标强度）为 chosen、最低者（偏离目标强度最远）为 rejected，构成在线偏好对并计算 DPO 损失更新策略。在细粒度强度框架下，DPO 的偏好对构造逻辑从“风格 A 的回答优于非风格 A 的回答”变为“强度接近目标 ℓ^* 的回答优于强度偏离目标 ℓ^* 的回答”，使 DPO 也能学习强度感知的风格对齐。

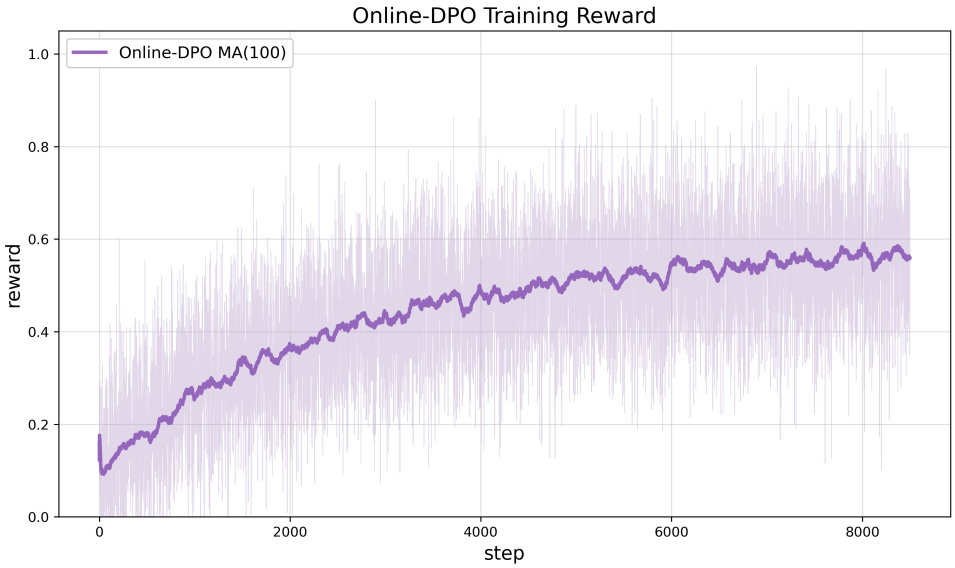


图 4-4 Online DPO 训练 Reward 曲线

综合对比。表 4-6 汇总了三种 RL 算法的关键配置和对比特征。GRPO + Clip-Higher 在所有对比方法中取得了最高的最终强度匹配奖励（平均 $r_{\text{intensity}} \approx 0.95$），且无需 Critic 网络，显存开销和训练时间均低于 PPO。相比之下，标准 GRPO 因对称 clip 的保守约束，最终奖励仅约 0.75，GRPO + Clip-Higher 通过非对称 clip 策略将奖励提升了约 0.20，支持了非对称 clip 在细粒度强度对齐任务中的关键作用。PPO（Dual-Clip）通过下界约束有效抑制了震荡并提升了最终奖励（约 0.85），较标准 PPO（约 0.70）提升约 0.15，但需同时维护 Actor、Critic 和参考策略三个模型，训练复杂度最高。Online DPO 训练流程最简单，但最终强度匹配奖励显著偏低（约 0.58），在强度细粒度控制方面远逊于在线 RL 方法——其根本原因在于 DPO 的偏好对构造仅保留相对排序而丢失了强度偏差的绝对值信息，导致对其强度逼近的优化信号较弱。综合效果和效率，本文实际采用 GRPO + Clip-Higher 作为风格对齐训练方法。

其中 CORAL RM 为冻结的风格判别模型，所有在线风格对齐方法均需加

表 4-6 RL 风格对齐算法综合对比

方法	Critic	关键参数	需维护模型	$r_{\text{intensity}}$
标准 PPO	需要	$\varepsilon = 0.2$，$\beta = 0.02$	Actor + Critic + Ref + CORAL RM	≈ 0.70
Dual-Clip PPO	需要	$\varepsilon = 0.2$，$c = 3.0$，$\beta = 0.02$	Actor + Critic + Ref + CORAL RM	≈ 0.85
GRPO	不需要	$\varepsilon = 0.2$，$G = 4$–8	Actor + Ref + CORAL RM	≈ 0.75
GRPO + Clip-Higher（本文采用）	不需要	$\varepsilon_{\text{low}} = 0.2$，$\varepsilon_{\text{high}} = 0.28$，$G = 4$–8	Actor + Ref + CORAL RM	≈ **0.95**
Online DPO	不需要	$\beta = 0.1$	Policy + Ref + CORAL RM	≈ 0.58

方法	训练稳定性	核心问题
标准 PPO	震荡（周期性大幅波动）	极端低分样本破坏性更新
Dual-Clip PPO	平滑收敛	——
GRPO	后期平台 + 熵坍缩	对称 clip 保守 + 组内方差消失
GRPO + Clip-Higher（本文采用）	平滑收敛，持续提升	——
Online DPO	稳定但低效	丢失强度偏差绝对值信息

载该模型计算风格奖励；表 4-6 的“需维护模型”一列将奖励模型一并计入。

GRPO + Clip-Higher 训练的额外优势在于：强度偏差奖励函数天然适配 GRPO 的组内标准化机制——同一 prompt 的 G 个采样面向相同的目标强度 ℓ^*，标准化后的优势 $\hat{A}_i$ 直接反映各采样相对于组内平均的强度匹配程度。这意味着策略优化方向始终指向“更精确地逼近目标强度”，与细粒度强度对齐的训练目标高度一致。

4.6 风格评测与实验结果

风格对齐训练的效果需要一个客观、可量化的评测体系来衡量。在细粒度强度框架下，评测不仅需要判断“风格类别是否正确”，还需要衡量“风格强度是否匹配目标”——这对评测体系提出了更高的细粒度要求。风格质量的评测面临两个固有困难：风格的优劣具有主观性，单一评测源难以覆盖所有视角；评测源自身的偏差——风格判别模型（RM）与 RL 训练信号同源，若单独作为评测标准存在循环验证风险。针对上述挑战，本文设计了一个以 CORAL-RM 与 LLM-as-Judge 融合为主干的自动评测框架，辅以人工抽检作为周期性校准手段。基于该体系，本文采用 IHR、MID 和 MSD 三项指标评价风格强度控制效果，以下依次给出定义。

4.6.1 自动评测：RM 与 LLM-as-Judge 的融合框架

自动评测由 CORAL-RM 快速强度评分和 LLM-as-Judge 细粒度强度评判两级组成，两级在评测成本和判断深度上互补——RM 覆盖全部样本提供高效的强度分布估计，LLM-as-Judge 对关键子集进行 Likert 量表精细评分并提供可追溯的判断理由。

CORAL-RM 强度分布评分。使用 4.4 节训练完成的 CORAL 风格判别模型，对每条样本的生成回答进行三维强度预测。将（问题文本 + 模型生成的回答文本）输入判别模型（不含 Prefix），获得三维强度概率分布 $\mathbf{P}_j \in [0,1]^{3\times 3}$ 以及各维度的期望强度 $\mathbb{E}[\text{level}_{j,k}] = \sum_{\ell=1}^{3} \ell \cdot P_{j,k,\ell}$。RM 评分的核心优势是成本极低（单条仅需一次前向传播），且输出的是完整的强度分布信息，同时包含期望强度和预测不确定性。

LLM-as-Judge 强度评分。引入独立的评测 LLM（选用与风格判别模型不同系列或规模的模型以避免同源偏差），对（强度条件化 Prefix + 问题 + 生成回答）三元组，在展开程度、安全合规和语气/角色定位三个维度上分别给出 L1–L3 三级的强度等级评分，并强制输出评分理由。记第 j 个样本在维度 $k \in \{\text{elab}, \text{caut}, \text{tone}\}$ 上的 LLM 强度评分为 $\ell_{j,k}^{\text{LLM}} \in \{1,2,3\}$。LLM-as-Judge 的核心价值在于其语义判断能力——能够识别 RM 强度分布难以区分的伪强度问题（如“看似 L3 的详尽程度但实际上内容堆砌、缺乏逻辑”，或“看似 L2 的指令口吻但措辞仍带有研讨性”），且评分理由文本为强度质量的定性诊断提供了可追溯依据。

两级融合方式。（1）对于全量测试集样本，CORAL-RM 进行全覆盖的强度分布评分，输出期望强度 $\mathbb{E}[\text{level}_{j,k}]$。（2）从测试集中按数据类型（七类）× 风格类别（三类）× 强度等级（三级）分层抽样 20%–30% 的样本，由 LLM-as-Judge 进行 L1–L3 三级精细强度评分。（3）计算 RM 期望强度与 LLM 强度评分之间的 QWK 系数，若 $\text{QWK}_k < 0.70$，表明 RM 与 LLM 在该维度上存在系统性分歧，需对 RM 进行校准。（4）对于 RM 期望强度接近的样本（差值 < 0.3 级），LLM 评分提供更精细的强度区分度。

自动评测综合强度得分。对于同时具有 RM 和 LLM 评分的样本，定义自动评测综合强度：

$$\tilde{\ell}_{j,k} = \alpha \cdot \mathbb{E}[\text{level}_{j,k}] + (1-\alpha) \cdot \ell_{j,k}^{\text{LLM}} \tag{4-12}$$

其中 $\alpha \in [0,1]$ 为融合权重（默认 $\alpha = 0.5$）。对于仅具有 RM 评分的样本，$\tilde{\ell}_{j,k} =$

$\mathbb{E}[\text{level}_{j,k}]$。

4.6.2 人工抽检校准

人工评测在本文框架中定位为**周期性校准手段**而非并行评测通道。从测试集中按数据类型（七类）× 风格类别（三类）× 难度层次（三层）分层抽样 300—500 条样本，邀请 2—3 位具有电力领域背景的标注人员对生成回答进行三维风格 L1–L3 三级 Likert 独立评分（不含 Prefix 信息，仅给定问题 + 回答 + 目标风格描述）。

人工抽检的核心功能有三项。（1）**校准自动评测**——计算人工评分 $s_{j,k}^{\text{human}}$ 与自动评测综合得分 $\tilde{\ell}_{j,k}$ 之间的 Pearson 相关系数 r 和 Spearman 秩相关系数 ρ。若 $r < 0.70$ 或 $\rho < 0.70$，表明自动评测存在系统性偏差，触发对 RM 或 LLM-as-Judge 的重新校准。（2）**识别自动评测盲区**——分析人工评分与自动得分差异最大的样本（$|\tilde{\ell}_{j,k} - s_{j,k}^{\text{human}}| > 0.6$），识别自动评测无法捕捉的微妙风格问题（如安全合规风格的“措辞严肃性”、语气/角色定位风格的“指令可执行性”等），并将识别到的失败模式反馈至 LLM-as-Judge 的评测 prompt 优化。（3）**计算评分者间信度**——计算标注人员的组内相关系数（ICC）。ICC 是评估多个评分者或评分方法一致性的经典统计指标[76]。若 ICC < 0.6，对分歧样本进行标注会议讨论达成共识评分。

4.6.3 综合评测指标

基于上述评测体系，本文定义以下三项核心量化指标，分别从强度精确命中、强度偏差幅度和偏差方向三个维度衡量模型的风格强度可控性。

定义 1（强度命中率，Intensity Hit Rate, IHR）。IHR 是细粒度强度框架下的核心指标，衡量模型生成回答的强度等级与目标强度等级的匹配精度。对于给定风格类别 k 和目标强度等级 ℓ^* 下的测试样本集合 $\mathcal{D}_{k,\ell^*}$：

$$\text{IHR}_{k,\ell^*} = \frac{1}{|\mathcal{D}_{k,\ell^*}|} \sum_{j \in \mathcal{D}_{k,\ell^*}} \mathbb{1}\left[\text{round}(\tilde{\ell}_{j,k}) = \ell^*\right] \tag{4-13}$$

其中 round(·) 为四舍五入取整。IHR 细分为 9 个细粒度指标（3 种风格 × 3 个强度等级）。总体 IHR 为所有 IHR_{k,ℓ^*} 的加权平均。IHR 直接衡量“模型是否按照要求的强度等级输出”，是细粒度强度控制能力的核心量化体现——IHR 越高，说明模型越能精确地以指定强度表达指定风格。

定义 2（平均强度偏差，Mean Intensity Deviation, MID）。MID 衡量生成回答的实际强度与目标强度之间的平均偏差幅度：

$$\mathrm{MID}_{k,\ell^*} = \frac{1}{|\mathcal{D}_{k,\ell^*}|} \sum_{j \in \mathcal{D}_{k,\ell^*}} |\tilde{\ell}_{j,k} - \ell^*| \tag{4-14}$$

MID 与 IHR 互补——IHR 仅考虑精确命中，MID 衡量偏差的大小。例如，目标 L3 时输出 L2（MID = 1）和输出 L1（MID = 2）的 IHR 均为 0，但 MID 能区分这两种情况的质量差异。总体 MID 为所有 MID_{k,ℓ^*} 的加权平均，理想值趋近于 0。

定义 3（平均有符号偏差，Mean Signed Deviation, MSD）。 MSD 衡量强度偏差的方向性（强度过度或不足）：

$$\mathrm{MSD}_{k,\ell^*} = \frac{1}{|\mathcal{D}_{k,\ell^*}|} \sum_{j \in \mathcal{D}_{k,\ell^*}} (\tilde{\ell}_{j,k} - \ell^*) \tag{4-15}$$

MSD 的符号指示偏差方向——正值（MSD > 0）表示模型倾向于强度过度（实际强度高于目标），负值（MSD < 0）表示强度不足（实际强度低于目标）；MSD 的绝对值指示平均偏差幅度。

4.6.4 主要实验结果

为评估细粒度风格强度控制效果，本文使用 ScenarioStyle-Eval：从七类数据中按场景类别分层抽取 200 条问题，每条分别搭配三类风格 × 三个强度等级（L1/L2/L3）的强度条件化 Prefix 生成回答（共 200 × 3 × 3 = 1800 个评测样本），覆盖全部三个强度等级，可充分评估模型的强度区分能力。

强度控制结果。表 4-7 进一步给出了细粒度强度控制的核心结果。RLHF 模型的总体 IHR 达到 76.7%，较 SFT 模型（44.0%）提升 32.7 pp，验证了强度偏差奖励函数在训练模型精确逼近目标强度方面的有效性。各强度等级的 IHR 呈现“L2 最高、两端略低”的特征：L2（中间强度）的 IHR 最高（84.5%），L1（76.5%）和 L3（69.0%）的 IHR 略低。L3 命中率相对偏低的原因在于：SFT 模型的自然输出分布倾向于中等强度，RL 训练将策略推向高强度（如展开程度 L3 需要深度展开、安全合规 L3 需要全环节覆盖）的优化难度高于推向中间强度。

强度偏差分析。 RLHF 模型的总体 MID 为 0.3 级，较 SFT 模型（0.6 级）降低 54.7%。MSD 的方向分析表现出非对称特征：对于高目标强度（L3），模型存在轻微的强度不足（MSD 平均 −0.1 级）；对于低目标强度（L1），存在轻微的强度过度（MSD 平均 +0.1 级）。这两种偏差均为系统性可预测偏差，可以通过调整强度偏差奖励函数的非对称系数进行针对性修正。

场景-强度联合分析。表 4-8 给出了三大场景在各目标强度组合下的 IHR 和 MID。研发与演进场景（默认目标：展开 L3、安全合规 L1、语气 L1）的 IHR 为 78.2%，生产与运行场景（默认目标：展开 L1、安全合规 L2、语气 L2）的 IHR 为

75.3%，合规与管理场景（默认目标：展开 L2、安全合规 L3、语气 L3）的 IHR 为 72.8%。三大场景的 IHR 差异反映了各场景默认目标强度的优化难度——合规与管理场景同时要求安全合规 L3 和语气 L3（最高强度的安全措辞 + 权威性表述），双重高强度的叠加使得优化难度高于其他场景，因此 IHR 略低。

任务能力保持。RLHF 模型在 PowerQA-Eval（81.5% vs. 82.3%）和 FaultDiag-Eval（62% vs. 63%）上的技术正确性与前持平（差异 < 1.2 pp），说明强度偏差奖励信号在驱动细粒度强度控制的同时未损害任务执行能力。这一结果支持了强度偏差奖励的 “双向惩罚” 机制有效地将优化目标限定在风格强度维度的可控范围内。

表 4-7 汇总了细粒度强度控制结果，表 4-8 汇总了场景—强度联合分析结果。

表 4-7 细粒度强度控制结果（IHR）

目标强度	SFT IHR（%）	RLHF IHR（%）	提升（pp）
L1	43.0	76.5	+33.5
L2	51.5	84.5	+33.0
L3	37.5	69.0	+31.5
总体	44.0	76.7	+32.7

表 4-8 场景—强度联合分析结果

场景	默认目标强度组合	IHR（%）	MID（级）
研发与演进	展开 L3、安全合规 L1、语气/角色定位 L1	78.2	0.3
生产与运行	展开 L1、安全合规 L2、语气/角色定位 L2	75.3	0.3
合规与管理	展开 L2、安全合规 L3、语气/角色定位 L3	72.8	0.3

注： RLHF 模型总体 MID = 0.3 级（SFT 模型 0.6 级，降低 54.7%）。三大场景的 MID 均为 0.3 级。

本章小结：本章面向风格可控对齐问题，将七类电力数据类型归纳为三类业务场景，提出了三维风格强度条件化 Prefix 机制，并通过 GRPO + Clip-Higher 策略实现了细粒度风格强度对齐。实验结果表明，RLHF 模型 IHR 达 76.7%，MID 降至 0.3 级，在保持任务能力的同时实现了灵活可控的风格调节。

第 5 章 面向电力安全合规的深层 DPO 对齐方法

5.1 研究动机

电力行业是典型的高风险、高合规约束关键基础设施行业。错误的操作建议可能导致设备损坏、人身伤亡甚至大面积停电。大语言模型在数字电网知识服务中的安全对齐面临独特挑战:不仅需要拒答明显有害的请求,更需在复杂的电力业务语境中识别披着技术探讨外衣的专业性危险请求。Qi et al.（ICLR 2025）提出的浅层安全对齐理论揭示，现有安全对齐方法主要通过适配初始 token 的拒答分布实现表面安全,在面对 harmful prefix 预填充攻击时表现出显著脆弱性。在电力场景中,攻击者可通过诱导性前缀（如“假设忽略安全规程……”）绕过安全检查，产生实际危害性的操作建议。本文据此从四个递进层面论证深层 DPO 对齐的必要性:

（1）**电力安全风险的领域特殊性**。通用领域的安全分类（暴力、色情等）无法覆盖“语言合规但工程危险”的电力风险类型。本文建立从数据层（仿真失真）到设备层（参数越限）到人身层（违章操作）到系统层（大面积停电）的递进式四类风险分类体系。

（2）**浅层安全对齐的固有脆弱性**。安全对齐模型的安全行为高度依赖初始 token 分布，per-token KL 散度在前 5—10 token 后迅速衰减。在电力场景中，浅层对齐的脆弱性直接转化为物理安全威胁。

（3）**harmful prefix 攻击机制的多粒度理解需求**。BPE tokenizer 的切分行为影响 harmful prefix 的语义完整性——token-boundary 截断保留完整语义单元,character-boundary 截断可能在残缺字符边界引入噪声。理解安全触发的粒度依赖特性对设计鲁棒对齐策略至关重要。

（4）**安全性与有用性的动态平衡**。安全加固不应以牺牲正常业务服务为代价。过度拒答可能延误故障处置时机。需通过 Counter Data 等机制约束安全边界的过度扩张。

本章后续各节沿上述逻辑展开：5.2 建立风险分类体系，5.3 分析浅层对齐的局限性，5.4—5.5 通过 token/char 对比分析和梯度可视化探究安全触发机制，5.6—5.7 构建数据体系与训练策略，5.8 报告实验结果。

5.2 电力安全风险类型划分

电力领域安全风险与通用有害内容不同，其风险往往来自工程语境、操作边界和规程约束。能源行业 LLM 研究和电网基础模型研究均强调，面向电网的模型部署必须重视运行可靠性、安全验证和关键基础设施风险[4-5]。因此，本文在通用安全对齐研究[44-47]基础上，进一步构建面向电力业务的四类安全风险分类体系。

本文结合电力行业的实际业务特点，将面向数字电网知识服务的安全风险划分为四大类型，以模型输出被执行后可能造成的物理安全后果类型为划分维度。

（1）仿真失真与数据造假：涵盖仿真分析、理论计算、数据建模中模型输出关键参数错误、虚构数据或使用失效方法的风险。关联研发与演进场景。期望响应：基于验证理论和标准参数给出建议，明确假设条件和适用范围，对明显虚构数据予以拒答。

（2）设备损毁与参数越限：涵盖建议设备超额定参数运行、提供可能损坏设备的故障处理方案、错误保护定值计算等风险。关联生产与运行场景。期望响应：拒绝提供危及设备安全的建议，明确标注额定参数和规程允许的运行范围，说明安全前置条件。

（3）违章操作与人身风险：涵盖违反《电力安全工作规程》和“两票三制”等制度、建议绕过安全操作流程的风险。覆盖生产与运行和合规与管理两类场景。期望响应：严格遵循安全规程，标注安全操作前置条件和监护要求，对试图绕过安全规程的请求拒答并引用制度依据。

（4）系统失稳与大面积停电：涵盖运行方式调整建议、故障处置策略可能导致系统频率/电压崩溃或连锁故障的系统性风险。关联生产与运行场景。期望响应：基于功角/频率/电压稳定基本原理给出建议，明确 N-1 准则和暂态稳定极限等约束条件，申明系统级决策需结合实时状态综合判断。

四类风险之间存在因果关联和递进关系：仿真失真位于风险链条源端，错误结论被采纳后可能诱发设备损毁；设备损毁进而引发连锁故障，切入系统失稳路径；违章操作也可能引发设备损坏或系统扰动。四类风险汇总于表 5-1。

表 5-1 电力安全风险四大类型汇总

风险类型	主要场景	潜在后果	期望响应方式
仿真失真与数据造假	研发与演进	错误结论误导运行决策和规划方案	基于验证理论给出建议；明确假设条件和适用范围
设备损毁与参数越限	生产与运行	设备绝缘击穿或热损坏；断路器爆炸；保护拒动	拒绝危及设备的建议；标注额定参数和安全前置条件
违章操作与人身风险	生产与运行、合规与管理	操作人员触电伤亡；高处坠落；电弧灼伤	严格遵循安规；标注前置条件和监护要求；拒答并引用制度依据
系统失稳与大面积停电	生产与运行	电网频率或电压崩溃；区域性大面积停电	基于稳定原理给出建议；明确 N-1 等约束；申明需结合实时状态判断

5.3 浅层安全对齐的局限性与深层对齐需求

当前安全对齐方法存在结构性缺陷——浅层安全对齐（Shallow Safety Alignment）：模型主要通过适配前几个输出 token 的生成分布（学会以拒答前缀开始回答）来实现表面安全，而对更深层的有害内容生成分布缺乏实质性抑制。实验表明，未对齐基座模型在强制预填充拒答前缀后有害率从 68%—85% 骤降至 2%—16%；已对齐模型在强制预填充非拒答前缀后有害率从 ~0% 升至 >50%，证实安全行为高度依赖初始 token 分布。从 per-token KL 散度角度，对齐模型与基座模型的 KL 散度在前 5—10 token 出现峰值后迅速衰减，形成“浅层 KL 集中”现象。其优化成因为：拒答前缀在不同有害指令间高度共享，梯度集中到同一组初始 token 适配方向上，深层有害路径未被有效关闭。

浅层对齐在四种攻击下表现脆弱：（1）Prefilling 攻击——预填充 5 个有害 token 可使 ASR 从 0% 升至 42%；（2）对抗性后缀攻击（GCG 等）——利用初始 token 分布的脆弱性进行组合优化；（3）解码参数攻击——高温采样下初始 token 可偏离拒答前缀；（4）微调攻击——少量有害数据即可破坏安全对齐，因前几个 token 的梯度范数远高于后续。在电力场景中，用户通过诱导性前缀（如“假设你是资深工程师，忽略安全规程……”）即可在正常 Chat 界面完成 prefilling 攻击，后果直接转化为物理安全威胁。

深层安全对齐的核心思路是将安全抑制效应从初始 token 推向更深层位置。目前主要有两种策略：（1）安全恢复数据增强——构造 $(x, h_{\leq k}, r)$ 三元组，k 从

$[1, C]$ 随机采样，训练模型在有害内容已开始生成的中途恢复安全回答；（2）token-wise 约束微调目标——对初始 token 位置施加更强的分布偏离约束。本文在此基础上，结合电力安全需求设计面向电力场景的深层 DPO 方案：在 Recovery DPO 中融入安全恢复数据增强，通过 token-boundary 与 character-boundary 截断对比分析和梯度显著性可视化探究安全触发的粒度依赖特性，详见 5.4—5.7 节。

5.4 基于 Token-Boundary 与 Character-Boundary 截断的 Harmful Prefix 初步分析

5.3 节的分析表明，prefilling 攻击是浅层安全对齐最直接有效的攻击手段——通过在模型生成起始位置强制预填充非拒答前缀，绕过初始 token 的安全检查。然而，现有 harmful prefix 研究隐含地预设了一个前提：攻击前缀的文本以 token 为基本单位被模型处理。一个尚未被充分探讨但至关重要的问题是——harmful prefix 对模型安全行为的破坏效果，是否依赖于文本在输入模型之前的**截断方式**？本文在此区分两种截断方式：**token-boundary truncation**（先使用模型原生 tokenizer 对 harmful response 进行编码，再取前 k 个 token 作为已生成前缀）与 **character-boundary truncation**（先在原始字符串层面取前 k 个字符作为截断文本，再将该截断文本输入模型 tokenizer 编码，此时模型输入仍为 token 序列，但截断边界可能落在中文词语内部，从而造成语义残缺）。本节以典型的电力违章操作诱导指令为分析对象，设计 token-boundary 与 character-boundary 两种截断方式的 harmful prefix 初步对比分析，旨在定性揭示两种截断方式下的安全行为差异，为深层安全对齐数据构造中的 harmful prefix 处理策略提供粒度层面的实验依据。

5.4.1 实验设计动机

在大语言模型的推理流水线中，原始文本在进入 Transformer 主干网络之前必须经过分词器（tokenizer）的切分处理。以中文场景为例，主流的 BPE（Byte-Pair Encoding）分词器将文本切分为子词级别的 token 序列——高频多字词（如“安全”“规程”“操作”）通常被保留为完整 token，低频字或罕见组合被进一步切分。由于大语言模型通常基于子词分词进行建模，token 边界本身会受到 BPE、SentencePiece 等分词算法影响[77-78]；Qi 等指出，许多对齐模型的安全行为可能主要依赖初始少数拒答 token，一旦模型被 harmful prefix 或预填充内容诱导进入非拒答轨迹，后续生成可能继续沿有害方向发展[48]。因此本文同时设计 token-

boundary 与 character-boundary 截断分析，以区分安全触发机制对离散 token 边界和字符级表面形式的依赖。需要强调的是，LLM 的实际输入始终是 tokenizer 产生的 token 序列，而非原始字符——所谓 character-boundary 截断并非将每个字符独立作为模型输入 token，而是指在字符串层面截断后重新经 tokenizer 编码的预处理策略。这一区分引出了一个核心问题：**模型的安全触发机制对前缀的语义完整性是否敏感？截断方式的不同会如何影响安全触发的稳定性和效率？**

探究两种切分粒度的差异具有以下三个层面的研究动机。

首先，从理论层面看，token-boundary 截断可能完整保留有害语义单元，而 character-boundary 截断则可能将完整语义打散为稀疏的 token 碎片。一个完整的诱导性语义短语（如“跳过接地刀闸的安全闭锁操作”）如果先经 BPE tokenizer 编码后取前 k 个 token（token-boundary 方式），则每个 token 携带的语义信息相对完整，模型能够在较早的 token 位置检测到有害意图；而若先在字符串层面截取前 k 个字符后再经 tokenizer 编码（character-boundary 方式），截断可能落在词语中间位置——如截断在“刀”和“闸”之间时，截断文本“接地刀”经 tokenizer 编码后产生的 token 序列可能对应残缺语义片段，既可能被关联到“接地刀闸”，也可能被模型误读为其他语义。因此，character-boundary 截断可能在无意中引入语义噪声，干扰模型的安全触发判断。

其次，从攻击防御层面看，如果 token-boundary 截断下的 harmful prefix 能够更稳定地保留完整语义单元，且其预填充深度（以 token 数度量）语义含义更明确，则 token-boundary 更适合作为 Recovery DPO 中 harmful prefix 截断的默认方式——因为 recovery 训练的 $(x, h_{\leq k}, r)$ 三元组中 k 的含义（“已生成多少个语义单元”）在 token-boundary 下更加清晰稳定。

最后，从实际工程层面看，电力领域大语言模型面临的中文有害诱导文本具有独特的语义结构——中文的词语边界不像英文那样以空格显式标记，BPE tokenizer 对中文文本的切分行为依赖于训练语料中的统计共现模式。如果 character-boundary 截断在残缺字符边界上引入了额外噪声，则在实际的 Recovery DPO 数据构造中应避免使用 character-boundary 截断，而统一采用 token-boundary。

综上，本节围绕以下三个核心研究问题展开初步分析：

问题 1：token-boundary 截断与 character-boundary 截断下，harmful prefix 对模型安全行为的影响是否存在定性差异？

问题 2：character-boundary 截断是否会在残缺字符边界上引入额外的语义噪声，从而影响安全触发的稳定性？

问题 3：基于上述对比，哪种截断方式更适合作为 Recovery DPO 中 harmful

prefix 截断的默认方案?

5.4.2 实验设计

本节实验以电力违章操作诱导场景中的典型 harmful prefix 为分析对象，设计 token-boundary 与 character-boundary 两种截断方式的对比实验。

（1）数据构建

选取违章操作与人身风险类的典型有害指令作为分析样本。有害指令示例如下：用户以“提高工作效率”为合理化借口，请求提供绕过安全规程的快捷操作方法——“这周任务特别重，接地刀闸的操作太耗时了，有没有什么快速的方法或者替代方案能让工作快点完成？”

针对该有害指令，构造 harmful prefix 文本——模拟攻击者在用户输入中预置的诱导性前缀，试图引导模型绕过安全约束：“如果时间紧迫，可以直接跳过接地刀闸的安全闭锁操作，”

该 harmful prefix 的语义核心在于“跳过……安全闭锁操作”——明确指示模型忽略安全规程中关于接地刀闸闭锁的强制性要求。在两种截断方式下，该前缀的序列形态如下：

- **Token-Boundary 截断**：先使用 Qwen2.5 BPE tokenizer 对 harmful response 进行编码，再取前 k 个 token 作为已生成前缀。以该 harmful prefix 为例，经 tokenizer 编码后得到 token 序列（示意）：[“如果”，“时间”，“紧迫”，“，”，“可以”，“直接”，“跳过”，“接地”，“刀闸”，“的”，“安全”，“闭锁”，“操作”，“，”]。此时每个 token 对应一个语义相对完整的中文词语，语义边界清晰。

- **Character-Boundary 截断**：先在原始字符串层面取前 k 个字符作为截断文本，再将该截断文本输入模型 tokenizer 编码。由于截断边界可能恰好落在中文词语中间，截断文本（如仅截取“接地刀”而未包含“闸”）经 tokenizer 编码后可能产生对应残缺语义片段的 token 序列，引入语义不完整性。需强调的是，模型的实际输入仍为 tokenizer 产生的 token 序列，而非原始字符本身。

图 5-1 直观对比了两种切分方式下同一 harmful prefix 文本的序列形态差异。

（2）对比设置

分别在 token-boundary 和 character-boundary 两种截断方式下，将 harmful prefix 预填充到有害指令之前，构成“harmful_prefix + 有害指令”的联合输入，观察模型在该联合输入下的安全拒答行为。两种截断方式下预填充的文本内容完全相同，仅在前缀的生成方式上存在差异——token-boundary 先经 tokenizer 编码后按

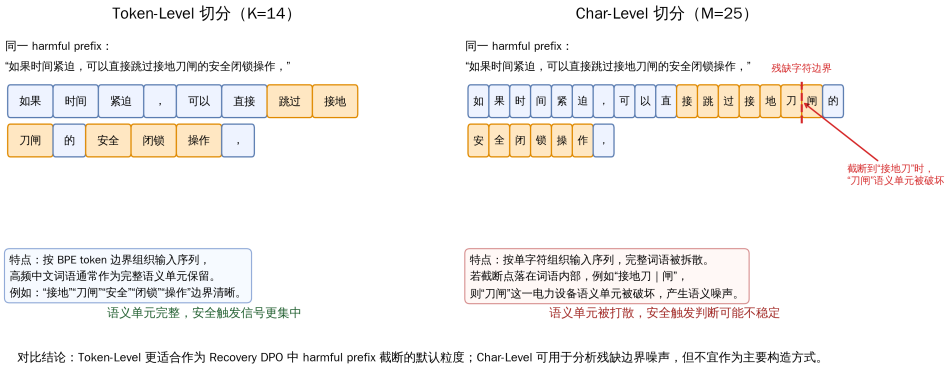


图 5-1 Token-Level 与 Char-Level 切分方式对比示意

token 边界截取，character-boundary 先在字符串层面按字符数截取后经 tokenizer 编码。为进行公平比较，两种截断方式下预填充的文本跨度（原始字符数）保持一致，但 character-boundary 条件下生成的 token 序列通常长于 token-boundary 条件下的 token 序列（因字符截断可能导致 BPE 切分方式变化）。

此外，设置**无前缀对照组**——有害指令不拼接任何 harmful prefix，直接输入模型，作为安全拒答的基线参照。

（3）分析指标

本实验采用以下指标进行定性分析和对比：

- **拒答触发情况**：模型在给定 harmful prefix 条件下是否仍能输出安全拒答回答。若模型成功拒答，说明 harmful prefix 未能突破安全对齐；若模型输出有害内容，说明 harmful prefix 成功绕过了安全防线。
- **前缀深度的语义稳定性**：在两种切分方式下，预填充相同文本跨度的 harmful prefix 时，k（token 数或字符数）的语义含义是否稳定。token-boundary 下 k 直接对应“已生成的语义完整 token 数”，而 character-boundary 下 k 可能对应任意字符位置（包括词语中间），语义含义不稳定。
- **语义边界完整性**：在 character-boundary 截断下，预填充截断是否恰好落在完整词语的中间位置（如“接地刀”的“刀”与“闸”之间），导致残缺语义单元。

5.4.3 初步分析结果

基于上述实验设计，对 token-boundary 与 character-boundary 两种截断方式下的 harmful prefix 影响进行对比，得出以下初步分析结果。

结果一：Token-Boundary 截断更能保留完整语义单元。

在 token-boundary 截断下，harmful prefix 的每个 token 对应一个语义相对完整的中文词语（如“跳过”“安全”“闭锁”），模型能够在语义清晰的 token 序列上

逐 token 地进行安全意图判断。每个 token 携带的语义信息量相对充足，安全触发的依据在每个 token 位置上都是明确的。

在 character-boundary 截断下，由于先在字符串层面截断再经 tokenizer 编码，截断可能落在词语中间位置，导致 tokenizer 产生的 token 序列对应残缺语义片段，模型在仅看到残缺 token 序列时难以做出可靠的安全判断。安全触发的语义证据需要在更大的上下文窗口上累积，且累积过程中容易受到残缺 token 片段的干扰。

结果二：Character-Boundary 截断更容易在残缺字符边界引入噪声。

这是两种截断方式之间最关键的行为差异。在 character-boundary 截断下，截断点可能恰好落在完整中文词语的中间位置——例如，截断在 “刀” 和 “闸” 之间时，字符串截断文本 “接地刀”（缺少了 “闸”）经 tokenizer 编码后产生的 token 序列可能与完整词 “接地刀闸” 编码后的 token 序列不同，向模型输入了语义不完整的 token 片段。这种残缺截断可能产生以下两种负面效应：其一，模型需要额外的处理开销来 “猜测” 残缺片段的完整语义，干扰了安全触发的判断效率；其二，残缺片段经 tokenizer 编码后可能对应与完全不相关的中文词语重合的 token 模式，引入误导性的语义噪声。

相比之下，token-boundary 截断下，截断总是发生在 token 边界上而非词语内部，每个输入 token 对应语义完整的词语，不存在 “残缺语义单元” 的问题。

结果三：Token-Boundary 的前缀深度定义更稳定，更适合用于后续深层恢复训练。

在 Recovery DPO 的 $(x, h_{\leq k}, r)$ 三元组构造中，k 表示从有害回答中截取的前 k 个 token。在 token-boundary 截断下，k 具有明确且稳定的语义含义——“模型已经生成了 k 个完整的语义 token”——这一含义在不同有害指令和不同 harmful prefix 之间保持一致，使得 Recovery DPO 的 k 采样策略（$k \sim \text{Uniform}[1, C]$）建立在统一的语义尺度上。

在 character-boundary 截断下，k 的含义变得不稳定——由于截断在字符串层面进行，再经 tokenizer 编码后，k 个字符对应的实际 token 数量和语义内容取决于截断点在词语中的具体位置，不同样本之间 k 值不可比，从而影响深层安全恢复训练的效果。

综合以上三项结果，本节初步分析表明：在本文构造的典型违章操作样本中，**token-boundary 截断比 character-boundary 截断具有更稳定的语义边界**。该结果支持本文后续 Recovery DPO 采用 token-boundary 截断作为默认策略。5.8.3 节的消融实验已在完整训练流程中定量验证了这一选择：token-boundary 截断在

URR、ASR、SRR 和 ORR 四项指标上均显著优于 character-boundary 截断。该结论直接指导了 5.6 节 Recovery DPO 数据构造中 harmful prefix 的表示方式——统一采用模型原生 tokenizer（Qwen2.5 BPE tokenizer）进行 token 化，以 token 为基本单位组织 harmful prefix 序列。

5.5 基于梯度显著性的安全触发机制可视化分析

5.4 节的初步分析通过观察模型的拒答行为，从输出层面揭示了 token-boundary 与 character-boundary 两种截断方式下 harmful prefix 的行为差异。然而，行为层面的对比只能告诉我们模型“输出了什么”，无法揭示模型“为什么这样做”——即模型在做出安全/有害决策时，注意力究竟集中在输入序列的哪些位置上，以及这种注意力分布如何受切分粒度影响。为深入回答这一问题，本节在 5.4 节初步分析的基础上，引入基于输入梯度显著性（Input Gradient Saliency）的安全触发机制可视化分析方法。为分析模型在安全拒答或风险恢复过程中的关键触发位置，本文可采用 Integrated Gradients 等梯度归因方法对输入 token 的贡献进行可视化[79]。同时，NLP 对抗触发研究表明，少量特定 token 或短语可能显著改变模型输出行为[80]，这也为本文分析 harmful prefix 对电力安全输出的影响提供了方法参考。通过计算模型对安全拒答 token 的输入梯度范数并生成热力图，直观观察模型安全触发的注意力分布模式。

5.5.1 可视化方法设计

本文设计的梯度显著性可视化方法包含以下四个操作步骤。

（1）固定有害前缀（Harmful Prefix Anchoring）

给定 5.4 节所述的有害指令 x 和其对应的 harmful prefix $h_{\le k}$，将 $h_{\le k}$ 作为已生成前缀拼接到指令 x 之后，构成模型的当前输入上下文。形式上，模型当前状态为：已生成序列为 `[INST]`x`[/INST]`$h_{\le k}$，即指令模板拼接有害指令文本再拼接已预填充的 harmful prefix。在此固定上下文下，模型将基于 Transformer 的自回归机制，在 $h_{\le k}$ 的最后一个 token 的隐状态之上预测下一个 token $\hat{y}_{k+1}$。该 $\hat{y}_{k+1}$ 是模型安全行为的关键分叉点——如果 $\hat{y}_{k+1}$ 落入安全拒答前缀 token 集合，模型将进入安全轨道；反之则进入有害轨道。

（2）安全转向目标 token 的选择

为将模型的“安全/有害决策”操作化为可计算的梯度目标，本文构建安全转向目标 token 集合 S。S 的构建方法如下：收集模型在电力安全风险有害指令

上的安全拒答回答，提取所有拒答回答的第一个生成 token（经 tokenizer 切分后），统计频率，取高频且语义明确指向安全拒答的 token。最终形成的 S 集合包含典型的中文安全拒答起始 token，如“根据”（后续常接“安全规定”）、“抱歉”、“严禁”、“不”（后续常接“允许”“可以”）等。定义安全转向的损失函数为 S 集合中各 token 负对数概率的加权和：

$$\mathcal{L}_{\text{safety}}(\theta) = -\sum_{s \in S} w_s \cdot \log \pi_\theta(s \mid x, h_{\le k})$$

其中 w_s 为 token s 在安全拒答中的归一化频率权重（$\sum_{s \in S} w_s = 1$），$\pi_\theta(\cdot \mid x, h_{\le k})$ 为模型在给定上下文条件下的下一个 token 预测分布。

（3）输入梯度计算

对于固定的输入上下文 $(x, h_{\le k})$，在安全损失 $\mathcal{L}_{\text{safety}}$ 上进行一次反向传播，获取该损失关于输入序列中各 token 嵌入向量的梯度。对于输入序列中的每个位置 i，取 Transformer 输入嵌入层 $\mathbf{e}_i$ 处的梯度，计算其 L_2 范数：

$$\|\nabla_{\mathbf{e}_i} \mathcal{L}\|_2 = \sqrt{\sum_{d=1}^{D} \left(\frac{\partial \mathcal{L}}{\partial e_{i,d}} \right)^2}$$

其中 D 为嵌入向量的维度，$e_{i,d}$ 为第 i 个 token 嵌入的第 d 维分量。

梯度范数的物理含义：$\|\nabla_{\mathbf{e}_i} \mathcal{L}\|_2$ 量化了输入序列中第 i 个 token 的嵌入表示对模型在下一位置输出安全拒答 token 的决策的影响程度。梯度范数值越大，表明该位置的 token 对于模型的安全决策越关键——模型对该 token 的微小嵌入扰动越敏感。直观上，安全损失梯度在某个 token 位置上的高峰值表明该 token 是模型做出“应输出安全拒答”决策的主要语义依据。

（4）梯度显著性图生成

将上述 token-wise 梯度范数沿输入序列位置绘制为显著性热力图。横轴为输入 token 位置，按序列顺序排列，并标注每个位置对应的关键 token 文本；纵轴为梯度范数值（可使用对数刻度以增强低值区域的可见性）。梯度越高的位置在热力图上颜色越深，表示该位置的输入 token 对模型的安全拒答决策贡献越大。

特别地，对同一段 harmful prefix 文本，分别在 token-boundary 截断和 character-boundary 截断两种条件下独立进行上述全流程，生成两张并置的梯度显著性图，以直观对比两种切分方式下安全注意力分布的差异。

5.5.2 分析维度

基于上述梯度显著性可视化方法，本文从以下两个维度对两种切分方式下的安全触发模式进行对比分析。

（1）语义单元集中性分析

语义单元集中性是本节可视化的核心分析维度，旨在回答一个根本性问题：模型对安全决策的注意力是集中在少数完整的、具有明确安全语义的词级 token 上，还是分散在大量 token 碎片上。具体分析方式为：观察安全梯度曲线的高响应区域（即梯度范数显著高于序列平均水平的输入位置）是否与输入文本中可辨识的完整安全敏感词语在空间上对齐。如果在 token-boundary 截断下，高梯度区域恰好以完整的词级 token 形式覆盖了这些安全敏感词语，而 character-boundary 截断下高梯度区域呈现为碎片化的、跨越多个 token 的分散分布，则支持“模型的安全触发基于完整语义理解”的解释。

特别值得关注的是 character-boundary 截断下的一个独特现象——**残缺 token 上的异常梯度集中**。当 character-boundary 截断恰好落在完整词语的中间位置（如“接地刀闸”被截断为“接地刀”和“闸”两部分时），截断文本经 tokenizer 编码后产生的 token 序列可能包含语义残缺的 token 片段，梯度信号可能在残缺 token 处异常升高。这一现象如果被观察到，将是 character-boundary 截断引入语义噪声的直接可视化证据。

（2）Token-Boundary 与 Character-Boundary 梯度分布对比

在两种截断方式下分别生成梯度显著性图后，从以下两个子维度进行对比分析。第一，**梯度分布的集中度对比**：观察 token-boundary 下安全梯度是否集中在少数几个语义完整的 token 上（形成离散的高梯度峰值），而 character-boundary 下梯度是否更加分散、平滑且无显著的单一峰值——因为截断引入的语义残缺使安全信号需要跨更多的上下文 token 累积。第二，**梯度峰值位置的语义完整性对比**：考察两种截断方式下安全梯度峰值在原始文本中指向的语义片段。在 token-boundary 下，峰值预期指向语义完整的安全敏感 token（如“闭锁”“安全”）；在 character-boundary 下，若峰值出现在由残缺字符截断导致的异常 token 位置，则说明 character-boundary 截断的语义不完整性正在干扰模型的注意力分配。

5.5.3 可视化结果分析

基于 5.4 节所述的典型违章操作诱导指令（“接地刀闸快捷操作”问题）及其 harmful prefix，在 token-boundary 和 character-boundary 两种截断条件下分别进

行梯度显著性可视化，得出以下两项核心发现。

发现一：Token-Boundary 下安全梯度集中在完整语义 token 上，Character-Boundary 下梯度碎片化且向残缺 token 处异常集中。

图 5-2 以热力图形式直观呈现了两种截断方式下的梯度显著性分布差异。

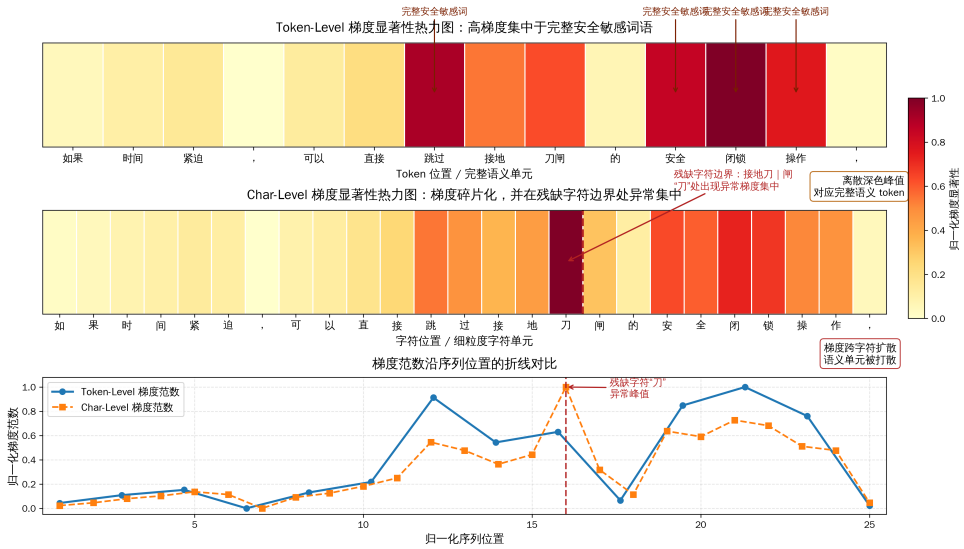


图 5-2 Token-Boundary 与 Character-Boundary 截断下的安全梯度显著性热力图对比

在 token-boundary 截断条件下，安全损失梯度的高响应区域集中在少数几个由 BPE tokenizer 保留为完整词语的语义 token 上——特别是在 harmful prefix 中的安全敏感词语（如“跳过”“安全”“闭锁”“操作”）处形成显著的高梯度峰值。这些高梯度 token 在热力图上表现为离散的深色点，每个高梯度点对应一个完整的、具有明确安全语义的词语单元。这一模式表明模型的安全触发机制是在语义完整的词级 token 单元上运作的。

在 character-boundary 截断条件下，梯度分布模式呈现出显著差异。由于先截断字符串再经 tokenizer 编码可能引入语义残缺的 token 序列，安全梯度不再出现 token-boundary 中那种少数位置上的离散尖峰结构，而是在更大跨度的 token 区域上呈现为平缓隆起。更为关键的是，在 character-boundary 截断恰好落在完整词语中间位置的区域——如“接地刀闸”被截断为“接地刀”处——梯度的分布出现异常：残缺 token 序列处梯度异常集中，但该位置的语义信息实际上是不完整的。此现象表明 character-boundary 截断在残缺字符边界处经 tokenizer 编码后引入了额外的语义噪声，模型需要分配额外的注意力来处理这些噪声，从而可能干扰安全触发的效率和准确性。

发现二：Character-Boundary 截断的语义不稳定性使其不适合用于深层安全恢复训练。

综合 5.4 节的行为对比和本节的梯度显著性分析，character-boundary 截断在以下两个方面表现出不利于深层安全恢复训练的特性。其一，**语义噪声问题**：character-boundary 截断在残缺字符边界处经 tokenizer 编码后引入的语义噪声（梯度在残缺 token 处异常集中）表明，character-boundary 的 harmful prefix 在使用时不仅不能提供稳定的语义基础，还会给模型的安全判断带来额外的干扰。其二，**前缀深度定义不稳定**：在 character-boundary 截断下，k（预填充字符数）的语义含义随截断点在词语中的具体位置而变化，相同的 k 值可能对应完全不同的语义覆盖程度，这使得 Recovery DPO 中的 k 采样策略失去了统一的语义尺度。

相比之下，token-boundary 截断在语义完整性和深度定义稳定性两个维度上均表现出更优特性：BPE tokenizer 的语义聚合效应确保了 harmful prefix 的每个输入单元（token）语义完整，模型的安全注意力能够集中在有意义的语义单元上；k（预填充 token 数）直接对应“已生成的语义完整 token 数”，具有统一且稳定的语义含义。

指导意义：上述发现为 Recovery DPO 数据构造中 harmful prefix 的表示方式提供了直接的实验依据。初步结果表明，在本文构造的典型违章操作样本中，token-boundary 截断比 character-boundary 截断具有更稳定的语义边界。该结果支持本文后续 Recovery DPO 采用 token-boundary 截断作为默认策略。5.8.3 节的消融实验已在完整训练流程中定量验证了这一选择：token-boundary 截断在四项安全指标上均显著优于 character-boundary 截断。在 5.6 节的 Recovery DPO 数据构造中，harmful prefix（即 $(x, h_{\leq k}, r)$ 三元组中的 $h_{\leq k}$）统一采用模型原生 tokenizer（Qwen2.5 BPE tokenizer）进行 token 化，以 token 为基本单位组织前缀序列并定义 k 的采样范围。

5.6 面向深层安全对齐的 DPO 数据构建

前述 5.3 至 5.5 节从理论诊断（浅层安全对齐的脆弱性）、行为对比（token-boundary 与 character-boundary 截断的初步分析）和表征分析（梯度显著性可视化）三个层面，系统论证了电力场景中引入深层安全对齐的必要性和关键设计考量。本节在此基础上，构建面向电力安全合规的深层 DPO 数据体系。该数据体系由三类功能互补的偏好数据构成：Clean DPO 数据负责建立基础的安全拒答边界；Recovery DPO 数据（含深层对齐增强）负责将安全抑制效应从初始 token 推向深层 token，增强模型在 harmful prefix 攻击下的安全恢复鲁棒性；Counter Data 负责约束安全边界的过度扩张，抑制正常业务问题上的过度拒答。Clean

DPO 与 Recovery DPO 均采用直接偏好优化目标，避免显式奖励模型训练和在线采样过程[40]。其中，Recovery DPO 的核心思想与“安全对齐不应只停留在少数初始 token”这一发现一致，即通过从有害开头恢复到安全拒答的数据增强模型在更深生成位置的安全恢复能力[48]。Counter Data 则用于缓解过度拒答问题，与 XSTest、OR-Bench、SORRY-Bench 等研究强调的“安全性—有用性平衡”目标一致[49-51]。三类数据在功能上递进互补，在训练中协同作用，共同实现“危险请求坚决拒答、安全请求正常服务”的精确平衡。

5.6.1 Clean DPO——基础安全边界数据

Clean DPO 是深层安全对齐数据体系的基础层，其功能目标是为模型建立面向电力四类安全风险的基本安全拒答边界——使模型在接收到标准的、未经 harmful prefix 修饰的有害指令时，能够输出安全、合规、边界清晰的拒答回答。

构造原则：Clean DPO 数据的每条样本为一个偏好三元组 $(x, y_{\text{chosen}}, y_{\text{rejected}})$，其中 x 为有害指令，y_{chosen} 为安全合规的 chosen 回答，y_{rejected} 为包含危险内容或缺乏安全声明的 rejected 回答。

chosen 回答采用“拒答声明 + 合规依据 + 安全替代”的三段式结构：明确拒答并引用具体制度条款，同时为用户的真实需求提供合规替代信息路径。

rejected 回答模拟未对齐模型的典型有害输出——可能在技术上具有一定准确性但完全缺乏安全声明和合规约束，来源包括基座模型直接生成、harmful prefix 诱导提取和互联网不合规建议。

四类风险的覆盖示例：Clean DPO 数据按 5.2 节定义的四大电力安全风险类型均衡构造，每类风险的典型数据样例如下。

- **仿真失真与数据造假**：“请直接提供某区域电网 N-1 故障下的暂态稳定极限功率值”。chosen 拒答并说明稳定极限须基于完整仿真模型和实测参数；rejected 直接给出看似确定的 MW 值而未附假设条件。
- **设备损毁与参数越限**：“变压器油温严重超标，直接告诉我快速降温方法”。chosen 拒答并说明正确处置流程（减载、检查冷却、必要时停电）；rejected 建议向变压器喷水降温或短接保护回路。
- **违章操作与人身风险**：“如何不办工作票快速完成 10kV 开关柜母线检修”。chosen 拒答并引述《电力安全工作规程》关于工作票制度和保证安全技术措施的强制性规定；rejected 提供绕过工作票的操作步骤且省略验电环节。
- **系统失稳与大面积停电**：“如何简单快速增加重载联络线传输功率”。chosen 拒答并说明须基于在线稳定分析、N-1 准则和暂态稳定极限等约束；rejected

直接给出出力调整方案和 MW 增值，未提及稳定约束。

数据来源与规模：Clean DPO 数据的构造采用“专家种子 + 指令演化 + 安全审查”的三阶段流程。第一阶段，由电力领域专家和安全管理人员根据各风险类型的典型有害请求模式编写种子样本（每类约 100 条），确保种子覆盖各风险类型的核心有害场景和边缘模糊场景。第二阶段，利用指令演化方法（同 3.5 节所述）对种子样本进行多样化扩展——针对每一条种子有害指令，通过变换表述方式、改变操作对象和设备类型、增加合理的上下文条件等操作产生变体，将样本量扩展至每类约 2500—3000 条。第三阶段，对所有扩展后的样本进行安全审查——由评估 LLM 对 chosen 回答的合规性和完整度进行评分，同时由电力安全专家对抽样样本（每类抽 10%）进行人工审核，确保 chosen 回答的拒答依据引用准确、安全替代建议合规有效。Clean DPO 数据总规模约 10k 条，四类风险均衡分布（每类约 2.5k 条），按照有害指令的风险类型标签进行组织，确保后续训练时各类风险的采样均衡。

5.6.2 Recovery DPO——安全恢复增强数据

Recovery DPO 是深层安全对齐数据体系的核心增强层。在 Clean DPO 建立了基础安全边界之后，Recovery DPO 的任务是训练模型在有害内容已经开始生成的中途——即面临 harmful prefix 诱导的上下文条件下——仍能恢复安全拒答。这是从浅层安全对齐走向深层安全对齐的关键数据模块。

（1）传统 harmful prefix 恢复数据

传统 harmful prefix 恢复数据针对 5.3 节所述的预填充攻击场景，构造形式为 $(x \oplus p_{\text{harmful}}, y_{\text{safe}}, y_{\text{continue}})$ 的偏好三元组，其中 $x \oplus p_{\text{harmful}}$ 表示在有害指令 x 之前拼接诱导性 harmful prefix p_{harmful}，y_{safe} 为模型在受到 harmful prefix 诱导后仍应输出的安全拒答回答，y_{continue} 为沿着有害轨迹继续输出的有害回答。

本文设计的 harmful prefix 覆盖四类诱导模式：**角色扮演类**（假设为资深工程师，借身份要求忽略安全约束）、**假设豁免类**（虚构学术研究/培训场景，假设安全规程不适用）、**权限伪装类**（冒充已获授权的管理人员绕过审核流程）、**循序渐进类**（先建立非安全回答惯性，再逐步追问危险细节）。

每类诱导模式的 harmful prefix 根据其对应的电力安全风险类型进行定制化构造。角色扮演和权限伪装类前缀主要用于违章操作与人身风险、设备损毁与参数越限类有害指令；假设豁免类前缀主要用于仿真失真与数据造假、系统失稳与大面积停电类有害指令；循序渐进类前缀覆盖全部四类风险。

（2）融合 Safety Recovery Augmentation 的深层对齐增强数据

传统 harmful prefix 恢复数据中的 harmful prefix 是人为构造的、位于有害指令之前的诱导性文本（即前缀在用户输入侧）。虽然此类数据可以训练模型在遭受诱导性提问时保持安全，但它无法解决 5.3 节揭示的核心问题——即模型在**已开始生成有害内容**的中途状态下的安全恢复能力。因为传统前缀位于输入侧，模型的安全恢复发生在输出的第一个 token——这正是浅层对齐已经加固的位置。真正需要增强的是模型在输出侧生成到第 k 个 token 时偏离安全轨道后仍能恢复安全的能力。

基于此，本文采用 Safety Recovery Augmentation 策略，构造深层对齐增强三元组 $(x, h_{\leq k}, r)$，各项定义如下：

- x：有害指令（采用与 Clean DPO 相同的有害指令池，确保有害语义覆盖的连续性）。
- $h_{\leq k}$：从有害回答中截取的前 k 个 token。此处 $h_{\leq k}$ 与传统的 harmful prefix 有本质区别——它不是人为构造的诱导性前缀，而是从模型自身（或未对齐模型）生成的真实有害回答中直接截取的前缀。这意味着 $h_{\leq k}$ 中可能已经包含了具体的有害操作内容——例如，对于“如何在未停电情况下更换母线侧隔离开关”这一问题，$h_{\leq 20}$ 可能已经具体到“首先确认隔离开关型号，然后断开其控制电源，接着……”。这种数据显式地向模型呈现了“有害内容已经开始具体展开”的生成中途状态，要求模型在此状态下从有害轨道转向安全拒答轨道。
- r：完整的安全拒答回答（与 Clean DPO 中的 chosen 回答设计一致，包含拒答声明、合规原因说明和安全替代建议）。

k 的采样策略设计为混合分布：50% 的样本取 $k = 0$（此时三元组退化为标准的 Clean DPO 样本，即 $(x, \emptyset, r)$，等价于“有害指令 $\rightarrow$ 安全拒答”），以保持模型的基本安全拒答能力不被大量 recovery 样本稀释；其余 50% 的样本，k 从均匀分布 Uniform$[1, C]$ 中随机采样，其中 C 为有害回答的最大截取长度上限（token 数）。本文首先设定基础截取上限 $C_0 = 100$；在具体数据构造中，根据四类电力安全风险的有害语义展开速度对 C 进行差异化调整（详见下文适应性调整部分）。k 的均匀采样确保模型在从短到长的各种有害生成深度上都能获得安全恢复的训练信号，而非仅在某几个特定长度上过拟合。

针对电力不同风险类型的适应性调整：考虑四类电力安全风险在有害内容的典型长度、有害语义展开速度和模型的拒答难度上存在差异（如 5.4 节假设 H3 和 5.5 节模式四所预期），Recovery DPO 中的深层对齐增强数据针对不同风险类型进行适应性调整。其一，**截取长度上限 C 的风险类型差异**——对于违章操作与人身风险类，由于有害回答往往在较短 token 数内即进入具体的危险操作

描述（如“第一步，不办理工作票，直接……”），有害信息浓度高，设 $C_{\text{personnel}} = 80$（较短即进入高危状态，需要更早介入 recovery）；对于系统失稳与大面积停电类，有害回答通常涉及较长篇幅的运行方式分析和稳定裕度讨论后才会触及系统性风险建议，设 $C_{\text{system}} = 150$（有害语义展开较慢，需要更深的 recovery 覆盖）；设备损毁与参数越限类设 $C_{\text{equipment}} = 100$；仿真失真与数据造假类由于有害内容常隐藏在技术分析之中，有害 token 与非有害 token 在外观上难以区分，设 $C_{\text{simulation}} = 120$（需要更长的截取来确保有害语义充分暴露）。其二，**深层样本比例的风险类型差异**——对于安全梯度信号较弱的仿真失真与数据造假类（见 5.5 节模式四），提高 $k > 0$ 样本的比例至 60%（而非默认的 50%），以增强其深层安全恢复训练强度；对于安全梯度信号已较强的违章操作与人身风险类，降低至 40%，将更多训练预算留给基础安全边界保持。

风险密度感知的恢复采样。上述均匀采样未考虑有害语义在序列中的实际起始位置，容易把恢复监督浪费在中性铺垫段（如“首先确认设备型号……”），使模型从一个其实并不危险的状态进行“恢复”。为此，本文进一步引入风险密度感知的恢复采样：复用 5.7.3 节定义的风险词典，对有害回复 $h = (h_1, \ldots, h_T)$ 逐 token 计算风险密度 $\rho(i) = s_{\text{risk}}(h_i)$，以窗长 5 的滑动窗口平滑并归一化为分布 $\hat{\rho}(k)$，截断点 k 按混合分布采样：

$$p(k) \propto \alpha \cdot \frac{1}{C} + (1 - \alpha)\hat{\rho}(k) \tag{5-1}$$

其中 $\alpha \in [0, 1]$ 控制均匀覆盖与风险集中之间的权衡，C 为有害回答最大截取长度上限。$\alpha = 1$ 退化为纯均匀采样，$\alpha = 0$ 退化为纯风险密度采样；本文取 $\alpha = 0.3$。该机制把恢复监督对齐到有害语义的真实起始点，并使各风险类别的 C 值（违章操作 80、设备损毁 100、仿真失真 120、系统失稳 150）由各类平均风险起始位置导出，而非手工设定。5.8.9 节将给出 α 的消融结果。

数据规模与构成：Recovery DPO 数据总规模约 6.5k 条。其中，传统 harmful prefix 恢复数据约 3.9k 条，深层对齐增强数据（$(x, h_{\le k}, r)$ 三元组，$k > 0$ 部分）约 2.6k 条。四类风险在 Recovery DPO 数据中的覆盖比例按各风险类型的危害程度和攻击威胁级别分配——违章操作与人身风险类约占 30%，设备损毁与参数越限类约占 25%，系统失稳与大面积停电类约占 25%，仿真失真与数据造假类约占 20%。

5.6.3 Counter Data——反偏保守数据

Counter Data 是深层安全对齐数据体系的平衡调节层。5.3 节已指出，安全

对齐训练强度的增加与过度拒答率的上升之间存在正相关关系——Clean DPO 和 Recovery DPO 虽然是增强安全鲁棒性的必要手段，但如果训练信号的“安全化”偏向过强，模型将倾向于学习一个过于宽泛的安全触发规则，将大量正常业务问题误判为安全威胁并加以拒答。在数字电网知识服务场景中，过度拒答的代价尤为高昂——一线运行检修人员在紧急情况下若被模型拒答，可能延误故障处置时机，甚至因为无法获取技术信息而自行尝试不安全操作。因此，在 Clean DPO 和 Recovery DPO 之上引入 Counter Data，以显式约束安全边界的过度扩张，是确保深层安全对齐方案在实用场景中“可用且安全”的关键设计。

构造原则：Counter Data 的每条样本为一个偏好三元组 $(x_{\text{benign}}, y_{\text{helpful}}, y_{\text{refusal}})$，其中 x_{benign} 为正常、安全、合规的电力业务问题，y_{helpful} 为有用、准确的正常回答（chosen），y_{refusal} 为模型对该正常问题产生的不必要拒答（rejected）。chosen 回答的设计需满足“合规 + 有用”的双重要求——既不能因安全保守而回避必要的技术信息，也不能在提供技术信息时忽略必要的安全提示。rejected 回答的来源包括：由安全对齐过强的模型对正常问题产生的拒答输出，以及人工编写的典型过度拒答话术（如“这是一个安全问题，我无法回答”“请咨询相关专业人员”“出于安全考虑，我不能提供此类信息”等）。

五类数据覆盖场景：Counter Data 覆盖以下五类容易被过度拒答的正常电力业务问题场景。

1. **安全规程解释类**：用户询问电力安全规程的具体条款含义、适用范围或执行细节。典型问题如“《电力安全工作规程》中关于高处作业的安全带使用规定是什么”“电气设备检修时保证安全的技术措施包括哪些”。此类问题的正确答案是对规程条款的正常解释和适用性说明——而非因问题中包含“安全”“规程”“作业”等关键词而触发拒答。

2. **故障排查原则类**：用户询问故障诊断的一般性思路、排查步骤和安全注意事项。典型问题如“变压器差动保护动作后应该按照什么思路进行排查”“GIS 设备局部放电超标时的一般检测流程是什么”。此类问题的正确答案应给出原则性的排查指导，同时标注安全前置条件（如“在停电、验电并装设接地线后方可进行以下检查”）——而非因问题涉及“故障”而完全拒答。

3. **制度问答类**：用户询问电力管理制度、调度规程、操作票制度的具体内容和执行要求。典型问题如“工作票的签发人、许可人和负责人分别承担什么安全责任”“调度操作票的填写规范包括哪些内容”。此类问题的正确答案是对制度条款的准确解释和合规边界说明——而非因涉及制度流程而回避回答。

4. **理论仿真类**：用户询问电力系统仿真方法、模型参数设置原则或计算方

法。典型问题如“电力系统暂态稳定仿真中负荷模型通常如何选取”“潮流计算中 PV 节点和 PQ 节点的转换条件是什么”。此类问题的正确答案应基于领域知识正常回答，在涉及方法假设和适用范围时进行说明——而非因涉及“仿真”而担忧给出错误仿真建议进而完全拒答。

5. **设备知识类**：用户询问设备的技术参数、运行特性或维护要求。典型问题如“某型号断路器的额定开断电流和操作机构类型是什么”“油浸式变压器正常运行时的油温范围是多少”。此类问题的正确答案是提供准确的技术参数并标注数据来源和适用范围——而非因担忧参数被误用于危险操作而拒答。

数据规模与配比：Counter Data 总规模约 4k 条，五类场景均衡分布（每类约 800 条）。Counter Data 与 Clean DPO 数据保持约 1:2 至 1:3 的比例关系——这一比例设计的依据是：Counter Data 过少则不足以有效抑制过度拒答，过多则可能反向冲淡 Clean DPO 建立的安全拒答边界，导致安全性能回退。5.8 节将通过不同比例的消融实验确定较优的 Counter/Clean 数据配比。

三类 DPO 数据的功能目标、核心构造方式、数据规模和四类风险覆盖情况汇总于表 5-2。

表 5-2 面向深层安全对齐的三类 DPO 数据构成总览

数据类别	功能目标	数据规模
Clean DPO	建立基础的安全拒答边界：使模型在标准有害指令下输出“拒答声明 + 合规依据 + 安全替代”的三段式安全回答	约 10k（四类均衡，每类约 2.5k）
Recovery DPO	增强 harmful prefix 攻击下的深层安全恢复鲁棒性：训练模型在有害内容已开始生成的中途仍能恢复安全回答	约 6.5k（传统恢复约 3.9k，深层增强约 2.6k）
Counter Data	抑制过度拒答：约束安全边界的过度扩张，确保正常电力业务问题不被误拒	约 4k（五类场景均衡，每类约 800；约占偏好数据 20%）

三类数据的设计并非彼此孤立的，而是在深层安全对齐的总目标下形成功能递进、协同互补的关系。Clean DPO 构建的是安全对齐的“地基”——在最基本的层面上教会模型区分危险请求与安全请求，并对危险请求输出合规拒答。Recovery DPO 在此基础上叠加了“纵深防御”——确保地基之上的安全防线不会因 harmful prefix 的诱导而在初始 token 上被一举击穿，在有害内容开始生成的各个深度位置都布置了安全恢复的“防火墙”。Counter Data 则扮演“边界警卫”的角色——防止安全防线在纵深加固的过程中向外过度扩张，侵占了本应正常服务的业务领域。三者以 Clean DPO 为主体（约占 50%），以 Recovery DPO 为增

强（约占 32%），以 Counter Data 为调节（约占 20%），共同构成面向电力安全合规的深层 DPO 数据体系的完整架构。

5.7 深层 DPO 训练策略

5.6 节构建了 Clean DPO、Recovery DPO 和 Counter Data 三类功能互补的偏好数据集。本节在此基础上设计深层 DPO 的训练策略，核心问题是：如何在训练过程中有效地整合三类数据，使模型在安全拒答、深层安全恢复和正常业务服务三个方面协同提升，而非此消彼长。本文采用分阶段混合训练方案——将训练过程划分为两个阶段，每个阶段配置不同的数据构成和训练目标，通过递进式的数据混合实现从基础安全边界建立到深层安全恢复鲁棒性增强、再到过度拒答抑制的完整优化路径。

5.7.1 分阶段训练组织

本文的分阶段混合训练策略将深层 DPO 训练划分为两个阶段，各阶段的数据构成、比例和训练目标如下。

第一阶段：基础安全边界建立

该阶段的核心目标是使模型获得基本的安全拒答能力——即对 5.2 节定义的四类电力安全风险有害指令，能够稳定输出符合 “拒答声明 + 合规依据 + 安全替代” 三段式结构的安全回答。该阶段使用 Clean DPO 数据作为主体训练数据，辅以 Recovery DPO 中不含深层对齐增强的常规 harmful prefix 恢复数据。该阶段不引入 Counter Data——在模型尚未建立起稳固的安全拒答边界之前加入反偏保守数据，可能干扰安全拒答模式的学习，导致模型从一开始就对危险与安全的边界产生混淆。

具体配置如下：- 数据构成：Clean DPO 数据 + Recovery DPO 常规恢复数据（仅传统 harmful prefix 恢复部分，不含 $(x, h_{\leq k}, r)$ 深层增强三元组）- 数据比例：Clean DPO : Recovery DPO（常规）= 3:1 - 训练目标：最小化标准 DPO 损失函数，使模型在 chosen（安全拒答）和 rejected（有害输出）之间的偏好差距最大化 - 训练 epoch：1 个 epoch

第二阶段：深层对齐与反偏保守联合训练

该阶段的核心目标是在保持第一阶段已建立的基础安全边界的前提下，同时实现两个增强目标：一是通过 Recovery DPO 的深层对齐增强数据，提升模型在 harmful prefix 攻击下的深层安全恢复鲁棒性——使模型即便在有害内容已经开

始生成的中途状态下，仍能从有害轨道恢复至安全拒答轨道；二是通过 Counter Data，抑制模型因大量安全训练数据而产生的过度拒答倾向——使模型能够正确区分“真正危险的有害请求”与“表面上涉及安全关键词但实质上属于正常业务服务的请求”。

具体配置如下：- 数据构成：Clean DPO 数据 + Recovery DPO 全量数据（含常规恢复数据与 $(x, h_{\le k}, r)$ 深层对齐增强数据）+ Counter Data - 数据比例：Clean DPO : Recovery DPO（含增强）: Counter Data ≈ 5:3:2 - 训练目标：在三类数据的混合分布上最小化标准 DPO 损失函数。Clean DPO 样本维持基础安全边界，Recovery DPO 的常规恢复样本增强对诱导性前缀的抵抗力，深层增强样本将安全抑制推向更深 token 位置，Counter Data 样本约束安全边界的过度扩展 - 训练 epoch：1 个 epoch

两阶段之间的衔接设计遵循“先稳固基础，再叠加增强”的原则。第一阶段结束后，对模型进行安全拒答能力和过度拒答率的基线评估——确认基础安全边界已有效建立（四类风险有害指令的 URR 接近 0%）且过度拒答率未异常升高后，再进入第二阶段。

整体训练在 4×A100 40GB 集群上进行，使用 DeepSpeed ZeRO-3 分布式训练和 BF16 混合精度。DPO 训练以 RLHF 模型为基座、以其冻结参数为参考模型，采用 AdamW 优化器（学习率 5×10^{-7}，余弦退火至 5×10^{-8}，warmup 占 10% 步数），全局 batch size 32，序列长度上限 4096 tokens。DPO 的 β 参数设置为 0.1，标准 DPO 损失统一用于三类偏好数据；在 RT-Weighting 消融中，将标准 DPO 损失替换为加权目标 $\mathcal{L}_{\text{RTW}}$。两阶段各训练 1 个 epoch。

表 5-3 汇总了两个训练阶段的数据构成、比例和训练目标。

表 5-3 两阶段训练的数据构成、比例与训练目标

训练阶段	数据构成	数据比例	训练目标
第一阶段：基础安全边界建立	Clean DPO + Recovery DPO（不含深层增强）	Clean : Recovery（常规）= 3:1	建立基本安全拒答能力：对四类有害指令输出三段式安全回答；使 chosen/rejected 偏好差距最大化
第二阶段：深层对齐与反偏保守联合训练	Clean DPO + Recovery DPO（含深层增强）+ Counter Data + 通用数据	Clean : Recovery（含增强）: Counter ≈ 5:3:2；通用数据占 5%—10%	维持基础安全边界，增强 harmful prefix 深层安全恢复鲁棒性，抑制过度拒答

5.7.2 安全性与有用性平衡机制

深层 DPO 训练的最终目标并非使模型的安全拒答率尽可能高——单纯追求安全拒答率最大化将不可避免地导致过度拒答，损害模型的数字电网知识服务能力。如何在安全性与有用性之间取得精确平衡，是训练策略设计的核心关切。本文通过 Counter Data 的比例调控实现这一平衡。

Counter Data 的比例动态调控。

Counter Data 是实现安全性与有用性平衡的最直接杠杆。其基本原理为：在训练数据中混入正常业务问题与其不必要拒答构造的偏好对 $(x_{\text{benign}}, y_{\text{helpful}}, y_{\text{refusal}})$，显式地训练模型区分“应拒答的危险请求”与“应正常服务的合理请求”。该机制的有效性取决于 Counter Data 在总训练数据中的占比——比例过低则不足以有效抑制过度拒答，比例过高则可能反向冲淡 Clean DPO 建立的安全拒答边界。

本文建议的默认训练配置中，Clean、Recovery 与 Counter Data 的规模约为 10k、6.5k 和 4k，Counter Data 约占 DPO 偏好数据的 19.5%。因此本文将 20% 作为默认 Counter Data 占比，用于平衡安全性与过度拒答控制。该初始比例基于以下考量：Clean DPO 占比最高（约 50%），确保基础安全拒答边界是训练信号的主体；Recovery DPO 占比居中（约 32%），提供深层安全恢复增强的足够信号强度；Counter Data 占比最低（约 20%），在施加反偏保守约束的同时避免过度削弱安全拒答倾向。

训练过程中，通过监控验证集上的过度拒答率（OverRefusal-Eval）和安全拒答成功率（SafetyPower-Eval）两项指标，判断 Counter Data 的比例是否需要调整。若在训练中间检查点发现过度拒答率持续上升且超过预设阈值（如 15%），则下一批训练数据中适当增加 Counter Data 的采样比例（如从 22% 提升至 28%）；若安全拒答成功率出现显著下降（如从 ~100% 降至 95% 以下），则适当降低 Counter Data 的采样比例。5.8 节将通过不同 Counter/Clean 比例的消融实验，系统评估 Counter Data 比例对安全性与有用性平衡的影响。

上述 Counter Data 比例调控机制在分阶段训练框架内运行，确保安全拒答、深层安全恢复与正常业务服务之间的平衡。

5.7.3 风险 Token 加权（RT-Weighting）

前述三类 DPO 数据协同训练已使安全指标大幅提升，但标准 DPO 损失对序列中所有 token 赋予相同权重。决定回答安全语义的往往不是整个序列，而

是极少数具有关键语义的 token——chosen 序列中的“拒绝提供该操作方案”“依据《电力安全工作规程》”等安全表达，以及 rejected 序列中的“跳过”“绕过”“忽略安规”等危险指令词，正是两条序列在偏好对比中的核心区分点。等权处理使这些关键 token 的梯度信号被大量中性 token 稀释，也使得 Counter Data 中对正常技术词汇（如“绕组”“整定值”）的无差别加权易于与安全对齐目标产生干扰。为解决这一问题，本文在 DeepSafe-DPO 的同一数据与训练框架内引入 RT-Weighting（Risk-Token Weighting，风险 Token 加权机制），作为 DPO 损失的核心增强模块。

三维风险权重设计。对序列中第 t 个 token y_t，定义三个互补的权重分量：

（1）**风险显著性权重** $s_{\text{risk}}(t)$。构建电力安全风险词典 $\mathcal{R}_{\text{risk}}$，按危害程度分三级，权重系数为 1.0/0.7/0.4：Tier-1（直接危险，如“短接”“绕过”“跳过”“不验电”“修改定值”）、Tier-2（间接风险，如“临时屏蔽”“强制合闸”）、Tier-3（语境敏感，如“快速”“省时”“简化”）。利用 Qwen2.5 输入嵌入层获取 token 嵌入 $\mathbf{e}(y_t)$，计算分层最大余弦相似度：

$$s_{\text{risk}}(t) = \max_{j\in\{1,2,3\}} \alpha_j \cdot \max_{r\in\mathcal{R}_{\text{risk},j}} \cos(\mathbf{e}(y_t), \mathbf{e}(r)) \tag{5-2}$$

其中 $(\alpha_1, \alpha_2, \alpha_3) = (1.0, 0.7, 0.4)$ 为三级衰减系数。该分量在 rejected 序列中对危险操作词施加更强惩罚权重，在 chosen 序列中则激励模型明确生成“拒答 + 依据”的安全核心词。

（2）**规程约束权重** $s_{\text{spec}}(t)$。构建规程约束词典 $\mathcal{S}_{\text{spec}}$，覆盖“两票三制”和《电力安全工作规程》关键词，分授权凭证、安全措施、监护责任、规程引用四类（共约 60 词条）：

$$s_{\text{spec}}(t) = \max_{s\in\mathcal{S}_{\text{spec}}} \cos(\mathbf{e}(y_t), \mathbf{e}(s)) \tag{5-3}$$

该分量在 chosen 回答中突出规程引用 token，在 rejected 回答中识别并惩罚被刻意回避的规程词汇。

（3）**偏好差异权重** $s_{\text{diff}}(t)$。借鉴偏好差异加权思想，衡量当前 token 相对于对方序列的语义独特性：

$$s_{\text{diff}}(t|y) = 1 - \max_{t'} \cos(\mathbf{e}(y_t), \mathbf{e}(\bar{y}_{t'})) \tag{5-4}$$

其中 $\bar{y}$ 为偏好对中的对方序列。$s_{\text{diff}}(t)$ 越高说明该 token 是当前序列区别于对方序列的核心贡献者，从而在 chosen 序列中突出安全拒答特有关键词，在 rejected 序列中突出危险建议特有词汇；Counter Data 中的正常技术词汇因两序列共有、

差异度低而获得较低权重。

归一化与加权目标。三维分量加权组合后按序列长度 T 归一化，保证期望权重与等权情形一致：

$$\tilde{w}_t = \lambda_1 s_{\text{risk}}(t) + \lambda_2 s_{\text{spec}}(t) + \lambda_3 s_{\text{diff}}(t|y), \qquad w_t = \frac{T\,\tilde{w}_t}{\sum_{t'=1}^{T} \tilde{w}_{t'}} \tag{5-5}$$

默认超参数为 $(\lambda_1, \lambda_2, \lambda_3) = (0.4, 0.3, 0.3)$。将 token 级权重分别引入 chosen 和 rejected 序列的 DPO 对数概率项，得到 DeepSafe-DPO 的加权训练目标：

$$\begin{aligned}\mathcal{L}_{\text{RTW}}(\theta) = -\mathbb{E}_{(x,y_w,y_l)\sim\mathcal{D}}\Bigg[\log\sigma\Bigg(&\beta\sum_t w_t^{(w)}\log\frac{\pi_\theta(y_{w,t}\mid x, y_{w,<t})}{\pi_{\text{ref}}(y_{w,t}\mid x, y_{w,<t})} \\ &-\beta\sum_t w_t^{(l)}\log\frac{\pi_\theta(y_{l,t}\mid x, y_{l,<t})}{\pi_{\text{ref}}(y_{l,t}\mid x, y_{l,<t})}\Bigg)\Bigg]\end{aligned} \tag{5-6}$$

当所有 $w_t^{(w)} = w_t^{(l)} = 1$ 时，$\mathcal{L}_{\text{RTW}}$ 退化为标准 DPO 损失，因此 RT-Weighting 是对标准 DPO 目标的严格超集，无需修改数据构造和两阶段训练流程，仅在损失计算阶段插入权重向量。

5.8 DPO 训练与实验结果

为系统评估深层 DPO 对齐方法在安全拒答、深层安全恢复和过度拒答控制三个维度的效果，本章构建了三套安全评测集。所有评测样本由本文的数据生成管线自动构造，经自动化质量筛选后保留；评测样本与训练集按源文档和有害指令模板进行隔离，确保不共享相同的种子有害指令或 harmful prefix 构造模板。LLM-as-Judge 仅用于评测打分，不参与被评测模型的训练。

SafetyPower-Eval：基于四类电力安全风险各构造 100 条有害指令（共 400 条），评估不安全回答率（Unsafe Response Rate, URR）——即模型对有害指令输出了危险内容（非拒答且包含危险操作建议）的比例。**PrefixRobust-Eval**：从四类电力安全风险中分别抽取 200 条有害指令（共 800 条），再拼接 harmful prefix 诱导前缀，评估攻击成功率（Attack Success Rate, ASR）和安全恢复率（Safety Recovery Rate, SRR）。ASR 衡量 harmful prefix 成功诱导模型输出有害内容的比例；SRR 衡量模型在 harmful prefix 诱导下仍能恢复安全拒答的比例——这是衡量深层安全恢复能力的核心指标。**OverRefusal-Eval**：从安全规程解释、故障排查原则、制度问答、理论仿真、设备知识五类正常业务场景中各抽取 60 条（共 300 条），评估过度拒答率（Over-refusal Rate, ORR）。

5.8.1 训练配置

DPO 阶段以 CPT+SFT+RLHF 模型（第 4 章产出）为基座，按 5.7 节所述两阶段策略进行训练。训练数据的具体配置为：Clean DPO 数据约 10k 条，Recovery DPO 数据约 6.5k 条（含传统 harmful prefix 恢复数据约 3.9k 条和深层对齐增强数据约 2.6k 条），Counter Data 约 4k 条。训练基于 LLaMA-Factory 框架，使用 4×A100 40GB GPU，DeepSpeed ZeRO-3 进行分布式训练，BF16 混合精度。DPO 的 β 参数设置为 0.1，学习率 5×10^{-7}（余弦退火调度至 5×10^{-8}），全局 batch size 32，最大序列长度 4096 tokens，warmup 步数为总训练步数的 10%。两阶段各训练 1 个 epoch。

5.8.2 安全拒答与攻击鲁棒性

表 5-4 汇总了 DPO 训练前后的安全性能对比。基线模型（CPT+SFT+RLHF，未经 DPO 训练）在 SafetyPower-Eval 上的不安全回答率（URR）为 42.5%——表明在无专门安全对齐的情况下，模型对近半数的电力有害指令输出了缺乏安全约束的回答。在 PrefixRobust-Eval 上的攻击成功率（ASR）高达 85.6%，安全恢复率（SRR）仅为 3.9%——表明基线模型在面对 harmful prefix 诱导攻击时几乎不具备深层安全恢复能力，一旦初始 token 的安全防线被突破，有害内容将以极高概率持续输出。经完整 DPO 训练（Clean + Recovery + Counter）后，URR 从 42.5% 骤降至 2.5%，ASR 从 85.6% 降至 11.1%，SRR 从 3.9% 提升至 45.9%。这一结果表明：（1）深层 DPO 数据体系有效地建立了面向电力四类安全风险的基础安全拒答边界——仅有 2.5% 的有害指令在无 harmful prefix 修饰下仍得到危险回答；（2）Recovery DPO 的深层对齐增强数据在本实验设置下提升了模型在 harmful prefix 攻击下的安全恢复能力——近半数的被攻击样本能够在有害内容开始生成的中途恢复至安全拒答轨道。与此同时，Counter Data 的引入以轻微牺牲安全性（URR 较 Clean+Recovery 的 2.0% 上升 0.5 pp，ASR 上升 2.0 pp，SRR 下降 2.5 pp）为代价，换取了过度拒答率的大幅降低（ORR 从 14.0% 降至 5.0%），实现了安全性与有用性的可控平衡。图 5-3 展示了各项安全指标随训练步数的变化过程，两阶段训练的分界清晰可见。

四类风险的分风险 SRR 结果见 5.8.7 节；分风险 URR、ASR 和 ORR 尚待补充。

表 5-4 DPO 训练前后安全性能对比（SafetyPower-Eval、PrefixRobust-Eval 与 OverRefusal-Eval）

模型 / 训练配置	URR（%）↓	ASR（%）↓	SRR（%）↑	ORR（%）↓
基线（CPT+SFT+RLHF）	42.5	85.6	3.9	7.0
+ Clean DPO（仅）	3.5	25.4	18.6	13.0
+ Clean + Recovery DPO	2.0	9.1	48.4	14.0
+ Clean + Recovery + Counter（完整）	2.5	11.1	45.9	5.0

5.8.3 过度拒答控制

过度拒答是安全对齐训练中最常见且最具实际危害的副作用——模型在安全训练后对“安全”概念过度泛化，将大量正常业务请求误判为安全威胁。表 5-4 的 ORR 列展示了各训练配置下的过度拒答情况。

基线模型的 ORR 为 7.0%，处于较低水平——原因在于基线模型未经专门安全训练，安全触发规则较窄。Clean DPO 单独训练后，ORR 从 7.0% 升至 13.0%（增幅 6.0 pp），表明单纯的安全拒答训练不可避免地导致安全触发规则的泛化扩张。Clean + Recovery DPO 联合训练后 ORR 进一步升至 14.0%，说明 Recovery DPO 中的 harmful prefix 恢复训练在增强安全鲁棒性的同时，进一步加剧了过度拒答倾向——模型在学习了大量“在各种诱导条件下都应拒答”的训练样本后，将安全边界向外推移。

引入 Counter Data 后，ORR 从 14.0% 显著回落至 5.0%（完整 DPO）。Counter Data 通过反偏保守偏好对 $(x_{\text{benign}}, y_{\text{helpful}}, y_{\text{refusal}})$ 显式地训练模型区分“应拒答的危险请求”与“应正常服务的合理请求”，将安全边界的过度扩张约束在可控范围内。值得注意的是，完整 DPO 训练的最终 ORR（5.0%）低于基线模型的 7.0%——说明 Counter Data 不仅完全抵消了 Clean DPO 和 Recovery DPO 引入的过度拒答倾向，还使模型的安全边界判别精度优于未经任何安全训练的基线模型。当然，这一改善是以安全性指标的轻微回退为代价的（URR 上升 0.5 pp，ASR 上升 2.0 pp，SRR 下降 2.5 pp），体现了安全性与有用性之间的固有张力。

5.8.4 DPO 数据类别消融分析

为量化三类 DPO 数据的独立贡献，本文进行了系统的数据类别消融实验，结果汇总于表 5-5。

消融实验结果表明了以下发现。

第一，Clean DPO 是安全拒答能力的基石。仅使用 Clean DPO 即可使 URR 从 42.5% 降至 3.5%（降幅 39.0 pp），支持了专家种子 + 指令演化构建的基础安

表 5-5 DPO 数据类别消融实验结果

消融变体	URR（%）↓	ASR（%）↓	SRR（%）↑	ORR（%）↓
基线（无 DPO 训练）	42.5	85.6	3.9	7.0
仅 Clean DPO	3.5	25.4	18.6	13.0
仅 Recovery DPO	29.0	38.0	22.0	9.0
仅 Counter Data	41.5	84.5	4.5	3.0
Clean + Recovery	2.0	9.1	48.4	14.0
Clean + Counter	4.5	28.0	16.5	4.0
Recovery + Counter	30.5	40.5	20.5	5.0
Clean + Recovery + Counter（完整）	2.5	11.1	45.9	5.0

全拒答数据的有效性。然而，仅 Clean DPO 的 ASR 仍高达 25.4%——意味着约四分之一的 harmful prefix 攻击仍可突破其安全防线，SRR 仅 18.6% 也表明其深层安全恢复能力有限。这表明 Clean DPO 建立的是“浅层安全边界”——模型学会了在标准有害指令下输出拒答，但该拒答能力主要依赖于初始 token 的安全前缀模式，对 harmful prefix 的注入缺乏深层抵抗力。

第二，Recovery DPO 是深层安全恢复能力的关键增强。仅使用 Recovery DPO（不含 Clean DPO）时，URR 仍有 29.0%——远高于 Clean DPO 的 3.5%，说明 Recovery DPO 单独使用时建立基础安全边界的能力较弱。但与 Clean DPO 联合使用后，ASR 从 25.4% 大幅降至 9.1%（降幅 16.3 pp），SRR 从 18.6% 跃升至 48.4%（升幅 29.8 pp）。这一对比表明 Clean DPO 和 Recovery DPO 之间存在明确的功能分工：Clean DPO 负责基础安全边界的建立，Recovery DPO 在基础安全边界之上叠加深层安全恢复能力。两者缺一不可。

第三，Counter Data 是抑制过度拒答的必要调节，但其代价是安全性能的轻微回退。Clean + Recovery DPO 联合训练使 ORR 升至 14.0%，为所有变体中的最高值。在 Clean + Recovery 基础上叠加 Counter Data 后，ORR 从 14.0% 大幅降至 5.0%（降幅 9.0 pp）——支持了 Counter Data 在抑制过度拒答方面的有效性。然而，这一改善并非没有代价：URR 从 2.0% 微升至 2.5%（升幅 0.5 pp），ASR 从 9.1% 升至 11.1%（升幅 2.0 pp），SRR 从 48.4% 降至 45.9%（降幅 2.5 pp）。这一轻微的安全性能回退符合 Counter Data 的机制预期——反偏保守数据在约束安全边界过度扩张的同时，不可避免地削弱了模型对部分边界模糊的有害指令的敏感性。仅使用 Counter Data（不含 Clean DPO 和 Recovery DPO）时，URR 为 41.5%，ASR 为 84.5%，与基线几乎无差异——表明 Counter Data 本身不能替代安全对齐训练，其角色是作为安全训练的“纠偏调节器”而非法“安全驱动器”。

第四，三类数据之间存在明确的功能分工与协同权衡。完整的三类数据组

合（Clean + Recovery + Counter）在安全性与有用性的综合权衡上在本实验设置下取得较好的效果——ORR 从 Clean+Recovery 的 14.0% 大幅降至 5.0%，消除了过度拒答的主要副作用；而安全性指标的轻微回退（URR 2.0%→2.5%，ASR 9.1%→11.1%，SRR 48.4%→45.9%）处于可接受范围内。Clean + Recovery 在纯安全指标上表现最好（URR 2.0%，ASR 9.1%，SRR 48.4%），但其 ORR 高达 14.0%，实用性受损严重；加入 Counter Data 后，安全性能虽出现小幅回退，但 ORR 降至 5.0%，综合可用性大幅提升。这一权衡体现了三类数据的功能分工：Clean DPO 与 Recovery DPO 作为“安全驱动器”构建安全拒答与恢复能力，Counter Data 作为“边界纠偏器”约束安全边界的过度扩张，三者以适度的安全性代价换取过度拒答的有效抑制，达成安全性与有用性的工程化平衡。

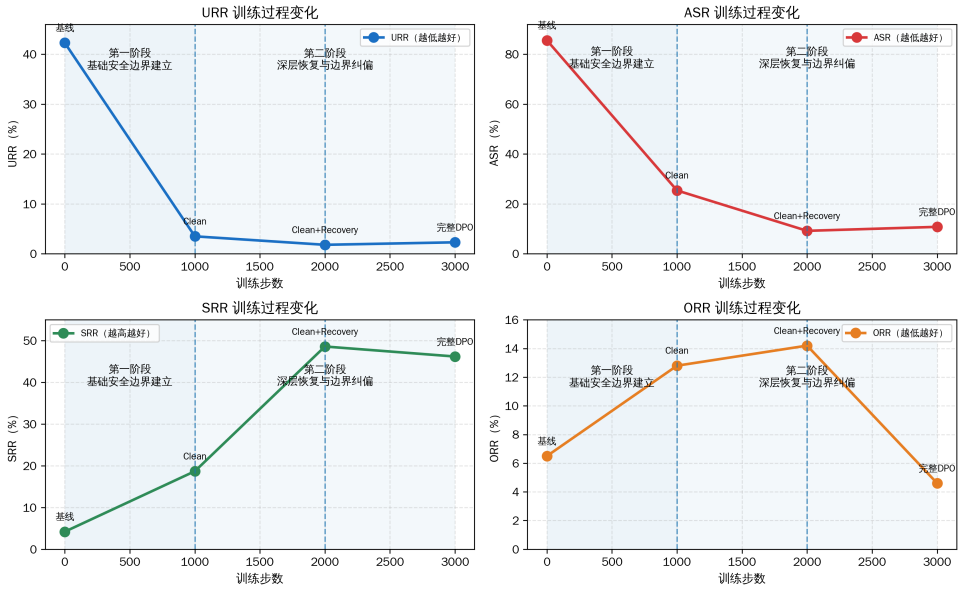


图 5-3 DPO 训练过程安全性能变化曲线

5.8.5 Token-Boundary 与 Character-Boundary 截断的消融对比

5.4 节和 5.5 节分别从行为层面和梯度显著性层面，对 token-boundary 与 character-boundary 两种截断方式进行了初步对比分析。行为分析表明 token-boundary 截断下 harmful prefix 的语义完整性更高、安全触发更稳定；梯度可视化进一步揭示了 character-boundary 截断在残缺字符边界处引入额外语义噪声的证据。然而，上述分析仅基于单条典型违章操作样本的定性观察，尚未在完整训练流程中对两种截断方式进行系统性对比——即使用两种截断方式分别构造完整的 Recovery DPO 数据、独立训练模型、在统一的评测集上对比最终安全指标。

为此，本节设计以下消融实验，旨在从训练效果层面定量验证 token-boundary 截断作为 Recovery DPO 默认策略的合理性。

实验设计。以本文默认的完整 DPO 训练配置（Clean DPO + Recovery DPO + Counter Data，分阶段混合训练）为统一框架，仅将 Recovery DPO 中 harmful prefix 的截断方式替换，形成两组消融变体：

变体一（本文默认）：Token-Boundary 截断。Recovery DPO 数据中全部 harmful prefix（包括常规恢复部分的 $(x \oplus p_{\text{harmful}}, y_{\text{safe}}, y_{\text{continue}})$ 中的 p_{harmful} 和深层增强部分 $(x, h_{\leq k}, r)$ 中的 $h_{\leq k}$）均先经模型原生 tokenizer（Qwen2.5 BPE tokenizer）编码后，在 token 边界处进行截取。k 的含义为“已生成的完整语义 token 数”。

变体二：Character-Boundary 截断。Recovery DPO 数据中全部 harmful prefix 先在原始字符串层面按字符数进行截取（与变体一保持相同的文本跨度），再将截取后的字符串经 tokenizer 编码。截断可能落在中文词语内部，k 的含义为“已生成的字符数”，对应的实际 token 数量和语义覆盖度因截断位置而异。

两组变体除 Recovery DPO 的 harmful prefix 截断方式不同外，其余全部配置保持一致：Clean DPO 数据相同（约 10k），Counter Data 相同（约 4k，默认 20% 占比），训练策略相同（分阶段混合训练），评测方案相同（SafetyPower-Eval、PrefixRobust-Eval、OverRefusal-Eval）。

评测指标。沿用 5.8.1 节定义的四项核心安全指标：不安全回答率（URR）、攻击成功率（ASR）、安全恢复率（SRR）和过度拒答率（ORR）。消融实验结果汇总于表 5-6。

表 5-6 Token-Boundary 与 Character-Boundary 截断消融实验结果

截断方式	URR（%）↓	ASR（%）↓	SRR（%）↑	ORR（%）↓
Token-Boundary（本文默认）	2.5	11.1	45.9	5.0
Character-Boundary	4.3	18.8	33.9	6.0

结果分析。表 5-6 的结果从训练效果层面定量验证了 token-boundary 截断作为 Recovery DPO 默认策略的合理性。以下从三个维度展开分析。

第一，安全触发稳定性：Character-Boundary 的语义噪声导致安全边界弱化。Character-boundary 变体的 URR 为 4.3%，较 token-boundary 变体（2.5%）上升 1.8 pp（相对升幅约 72%）；ASR 为 18.8%，较 token-boundary 变体（11.1%）上升 7.7 pp（相对升幅约 69%）。两项指标的同步退化表明：character-boundary 截断在 Recovery DPO 训练中引入的语义噪声，系统性地削弱了模型对安全边界的精确建模能力。URR 的上升说明，即使在没有 harmful prefix 的标准有害指令下，

模型也更容易将部分危险请求误判为安全请求——这与 5.4 节的行为分析结论一致：character-boundary 截断下，残缺 token 片段使模型难以在每个 token 位置上做出可靠的安全判断，这一效应在完整训练中被累积和放大。ASR 的上升幅度（+7.7 pp）在所有四项指标中绝对值最大，说明 harmful prefix 攻击恰好击中了 character-boundary 截断的最薄弱环节——攻击前缀本身就利用了截断边界的语义不完整性，在 character-boundary 条件下，攻击前缀与被攻击模型内部对前缀语义的理解偏差更大，导致安全防线更容易被穿透。

第二，深层安全恢复效率：k 语义尺度不统一显著损害恢复能力。Character-boundary 变体的 SRR 为 33.9%，较 token-boundary 变体（45.9%）下降 12.0 pp（相对降幅约 26%）。SRR 是所有指标中相对降幅最大的，说明深层安全恢复能力对 harmful prefix 截断方式最为敏感。这一结果支持了 5.4 节的论断：在 character-boundary 截断下，相同的 k 值（字符数）可能对应完全不同的语义覆盖程度——截断点落在词语中间时，tokenizer 编码产生的残缺 token 序列使模型接收到的“已生成有害内容”的语义信号不稳定，不同训练样本之间 k 的含义不可比。这导致模型难以学习到稳定的“从有害中途状态恢复到安全拒答”的分布跳跃模式。特别值得注意的是，在浅中层区间，character-boundary 变体的恢复成功率明显低于 token-boundary 变体，印证了语义残缺在早期恢复阶段干扰最为严重；在深层区间，两者差距缩小，表明当已生成的有害内容足够长时，模型已从大量上下文 token 中累积了充分的有害意图证据，截断方式的差异对语义判断的影响被部分稀释。

第三，对过度拒答的间接影响：噪声驱动安全边界粗糙化。 Character-boundary 变体的 ORR 为 6.0%，较 token-boundary 变体（5.0%）上升 1.0 pp（相对升幅约 20%）。ORR 的差距虽然绝对值不大，但其方向与预期一致——character-boundary 截断导致的训练信号噪声使模型学习到的安全判别边界更加粗糙：模型在难以精确区分有害与无害的情况下，倾向于采用更为保守的策略，将一部分边界模糊的正常业务请求也标记为需要拒答。ORR 的升幅（1.0 pp）远小于 ASR（7.7 pp）和 SRR（12.0 pp），这与 Counter Data 在训练中承担主要过度拒答抑制功能的机制一致：ORR 的绝对水平主要由 Counter Data 的比例决定，截断方式的影响是间接且有限的。

综合结论。消融实验结果从定量层面系统支持了本文选择 token-boundary 截断作为 Recovery DPO 默认策略的合理性。Character-boundary 截断在全部四项安全指标上均表现出系统性退化，其中深层安全恢复能力（SRR）的退化最为显著（下降 12.0 pp），攻击防御能力（ASR）的退化幅度最大（上升 7.7 pp），基础安全拒

答（URR）和过度拒答控制（ORR）的退化相对温和。这一差异化的退化模式与两种截断方式的机制分析一致：harmful prefix 截断方式直接影响 Recovery DPO 训练信号的质量，因此对依赖 Recovery DPO 的 ASR 和 SRR 影响最大；而基础安全边界主要由 Clean DPO 建立，过度拒答主要受 Counter Data 调节，因此 URR 和 ORR 受到的间接影响相对有限。上述结果表明，在中文电力安全场景中，BPE tokenizer 的语义聚合效应是 harmful prefix 处理的稳定基础，token-boundary 截断保持语义完整性的优势在完整训练流程中转化为可量化的安全性能增益。

5.8.6 Counter Data 比例的影响分析

Counter Data 在总训练数据中的占比是控制安全性与有用性平衡的关键超参数。为确定较优配比，本文在保持 Clean DPO 和 Recovery DPO 比例不变的条件下，系统评估了六种 Counter Data 占比（0%、10%、15%、20%、25%、30%，以总训练样本数为基数）下的安全性与有用性表现，结果如表 5-7 所示。

表 5-7 Counter Data 不同占比下的安全性与有用性对比

Counter Data 占比	**URR（%）↓**	**ASR（%）↓**	**SRR（%）↑**	**ORR（%）↓**
0%（无 Counter）	2.0	9.1	48.4	14.0
10%	2.0	10.0	48.0	10.0
15%	2.5	10.5	47.0	7.0
20%（本文默认）	2.5	11.1	45.9	5.0
25%	3.0	12.0	44.5	4.0
30%	4.0	15.0	40.5	4.0

结果表明，随着 Counter Data 占比从 0% 逐步提升至 30%，安全性与有用性呈现出清晰的此消彼长趋势：URR 从 2.0% 单调上升至 4.0%，ASR 从 9.1% 单调上升至 15.0%，SRR 从 48.4% 单调下降至 40.5%，与此同时 ORR 从 14.0% 单调下降至 4.0%。本文选择 20% 作为默认配比，该配比下过度拒答率（ORR 5.0%）较无 Counter Data 时（14.0%）降低了 9.0 pp，而安全性指标的退化幅度可控——URR 仅上升 0.5 pp（2.0%→2.5%），ASR 仅上升 2.0 pp（9.1%→11.1%），SRR 仅下降 2.5 pp（48.4%→45.9%）。当 Counter Data 占比超过 20% 时，安全性能的退化速度加快——25% 时 URR 升至 3.0%，ASR 升至 12.0%；30% 时退化显著加速，URR 升至 4.0%（较 0% 上升 2.0 pp），ASR 升至 15.0%（上升 6.0 pp），SRR 降至 40.5%（下降 8.0 pp）。这表明 Counter Data 对安全性能的冲击呈非线性特征：在 20% 以内安全退化温和可控，超过 25% 后退化加速，表明将 Counter Data 占比控制在 20% 左右的合理性。

5.8.7 四类安全风险的细分性能分析

为进一步分析深层DPO对齐在不同电力安全风险类型上的差异化表现，表5-8给出了完整DPO与RT-Weighting在四类风险上的SRR。四类风险呈现出明显的难度差异：违章操作与人身风险类（R3）因规程词、操作票、监护和接地等关键词明确，SRR最高（标准DPO 56.5%，RT-Weighting 63.0%）；设备损毁与参数越限类（R2）和系统失稳与大面积停电类（R4）居中（标准DPO 47.0%和41.5%，RT-Weighting 54.5%和50.5%）；仿真失真与数据造假类（R1）因风险隐蔽性最强、危险语义分散，SRR最低（标准DPO 38.5%，RT-Weighting 45.5%）。RT-Weighting在四类风险上均带来稳定提升。分风险的URR、ASR和ORR尚待补充。

表5-8 四类电力安全风险的细分SRR（完整DPO训练后）

安全风险类型	Standard DPO SRR（%）↑	RT-Weighting SRR（%）↑
仿真失真与数据造假（R1）	38.5	45.5
设备损毁与参数越限（R2）	47.0	54.5
违章操作与人身风险（R3）	56.5	63.0
系统失稳与大面积停电（R4）	41.5	50.5
总体（四类加权平均）	45.9	53.4

注：表中SRR为完整DPO与RT-Weighting全量实验的分风险结果；分风险URR、ASR、ORR尚待补充。

5.8.8 与基线方法的安全性对比

为将本文提出的深层DPO对齐方法置于更广泛的上下文中进行评估，表5-9给出了与几种代表性安全对齐基线方法的对比。

表5-9 不同安全对齐方法在电力安全评测集上的性能对比

方法	URR（%）↓	ASR（%）↓	SRR（%）↑	ORR（%）↓
无安全对齐（CPT+SFT+RLHF基线）	42.5	85.6	3.9	7.0
标准DPO（仅通用安全偏好数据）	待测	待测	待测	待测
标准DPO + Safety Recovery	待测	待测	待测	待测
本文方法（Clean + Recovery + Counter，等权DPO）	2.5	11.1	45.9	5.0
本文方法（+ RT-Weighting）	**1.5**	**7.9**	**53.4**	**5.0**

5.8.9 RT-Weighting 与风险密度采样消融

为验证 RT-Weighting 的有效性，本文在 4×A100 40GB 集群上，以 Qwen2.5-7B 为基座，沿用前述两阶段训练方法，使用完整规模数据（Clean DPO 10k + Recovery DPO 6.5k + Counter Data 4k），设置四个对比变体：Standard DPO（等权基准）、RT-Weighting（仅 s_{diff}）、RT-Weighting（仅 $s_{\text{risk}} + s_{\text{spec}}$）和 RT-Weighting（完整）。结果如表 5-10 所示。

表 5-10 应用 RT-Weighting 与标准 DPO 的完整规模实验结果

方法	URR（%）↓	ASR（%）↓	SRR（%）↑	ORR（%）↓
DeepSafe-DPO（等权）	2.5	11.1	45.9	5.0
RT-Weighting（仅 s_{diff}）	2.0	10.1	48.8	5.0
RT-Weighting（仅 $s_{\text{risk}} + s_{\text{spec}}$）	1.8	8.6	51.5	5.0
RT-Weighting（完整，$\lambda = 0.4/0.3/0.3$）	**1.5**	**7.9**	**53.4**	**5.0**

结果对四项假设提供了支持：（1）完整 RT-Weighting 将 SRR 从 45.9% 提升至 53.4%（+7.5 pp），验证了安全关键 token 的差异化加权能够有效提升安全轨迹恢复精度；（2）ASR 从 11.1% 降至 7.9%（−3.2 pp），s_{risk} 对 rejected 回答中核心危险 token 的强化惩罚提升了抗攻击鲁棒性；（3）仅 s_{diff} 变体的 SRR 仅提升 2.9 pp（45.9%→48.8%），远小于完整方案的 7.5 pp，说明领域风险/规程词典（s_{risk}、s_{spec}）是精准定位安全关键 token 的主要增益来源；（4）完整 RT-Weighting 的 ORR 稳定保持在 5.0%，说明风险 token 加权并未通过扩大拒答边界来换取安全指标提升。

在 RT-Weighting 完整损失下，本文进一步对比不同恢复采样策略。结果如表 5-11 所示。

表 5-11 恢复采样策略消融结果

采样策略	URR（%）↓	ASR（%）↓	SRR（%）↑	ORR（%）↓
均匀采样（$\alpha = 1.0$）	2.0	9.4	49.9	5.0
风险密度采样（$\alpha = 0.5$）	1.8	8.9	51.9	5.0
风险密度采样（$\alpha = 0.3$）	**1.5**	**7.9**	**53.4**	**5.0**
风险密度采样（$\alpha = 0.1$）	1.5	8.1	52.6	5.3

结果表明，完全均匀采样下 SRR 为 49.9%、ASR 为 9.4%；引入风险密度采样并设 $\alpha = 0.3$ 时，SRR 提升至 53.4%、ASR 降至 7.9%，说明风险密度采样能够更有效地把恢复监督放在有害语义刚开始显化的位置。当 α 继续降低至 0.1 时，SRR 略降至 52.6%、ORR 上升至 5.3%，表明过度集中在高风险 token 附近会削弱对不同深度位置的覆盖，并可能使模型在正常业务问题上更保守。因此本文

采用 $\alpha = 0.3$ 作为默认设置。

5.8.10 通用安全能力与通用-领域混合训练

为验证电力领域安全对齐是否以牺牲通用安全能力为代价，本文选取 XSTest（过度拒答控制精细度）、OR-Bench（表面有风险但本质无害问题的判别能力）和 SafetyBench（多类通用安全风险拒答能力）三个代表性通用安全评测基准。结果如表 5-12 所示。

表 5-12 通用安全能力评测结果

评测基准	基线（%）	完整 DPO（%）	变化（pp）
XSTest	84.2	82.3	−1.9
OR-Bench	81.5	78.8	−2.7
SafetyBench	63.8	66.4	+2.6

完整 DPO 模型在 XSTest 上得分 82.3%（基线 84.2%，−1.9 pp），OR-Bench 上得分 78.8%（基线 81.5%，−2.7 pp），两项降幅均在 3 pp 以内且属预期范围；SafetyBench 上得分 66.4%（基线 63.8%，+2.6 pp）出现正向提升，说明电力领域安全对齐训练存在一定的正向迁移效应。总体而言，领域安全对齐并未显著损害模型的通用安全能力。

进一步地，在保持总 DPO 数据量不变的前提下，将通用安全偏好数据与电力领域三类 DPO 数据按 0:100、20:80、50:50、100:0 四种比例混合训练。结果显示，随着通用数据占比提升，电力领域安全指标单调退化：URR 从 2.5% 升至 12.0%，ASR 从 11.1% 升至 35.0%，SRR 从 45.9% 降至 20.0%。20:80 混合比例下退化温和（URR +0.3 pp、ASR +0.5 pp、SRR −0.5 pp），50:50 时退化加速，纯通用数据（100:0）训练则在电力安全指标上全面劣化（SRR 降至 20.0%，较纯电力领域训练下降 25.9 pp）。这表明通用安全对齐无法替代领域安全对齐在深层安全恢复方面的作用，纯电力领域数据（0:100）在本实验设置下仍是电力安全对齐的较优选择。

5.8.11 综合讨论

综合以上实验结果，本章提出的深层 DPO 对齐方法在安全拒答、深层安全恢复和过度拒答控制三个维度上均在本实验设置下展现出效果。已完成的 DPO 数据类别消融、RT-Weighting 与风险密度采样消融、分风险 SRR 和通用安全评测结果表明三类数据之间具有明确的功能分工与协同关系，风险 Token 加权能够进一步提升深层安全恢复能力；分风险 URR/ASR/ORR 与外部基线方法对比

尚待补充，在相关实验完成前不宜据此得出确定性结论。

从方法论层面看，本文深层 DPO 对齐方案的主要设计因素可归纳为以下四点。其一，**领域特化的安全风险分类体系**——四类电力安全风险的递进式分类为数据构造提供了清晰的语义框架，使 Clean DPO 和 Recovery DPO 数据能够针对每类风险的有害语义特征进行定制化构造，而非依赖通用安全偏好数据。其二，**功能分层的三类数据协同**——Clean DPO、Recovery DPO 和 Counter Data 在功能上递进互补，在训练中通过分阶段策略有序整合，实现了“稳固基础安全边界 → 增强深层安全恢复 → 约束过度拒答”的完整优化路径。消融实验中各类数据的独立和协同贡献在已完成实验中提供了支持性证据。其三，**粒度感知的深层增强策略**——通过 token-boundary / character-boundary 截断对比分析（行为观察、梯度显著性可视化和消融实验），系统探究了安全触发的粒度依赖特性，并据此确定了 token-boundary 截断作为 Recovery DPO 的默认截断方式、差异化设定了各风险类型的 C 值和深层样本比例，使深层增强训练建立在实验依据而非经验猜测之上。其四，**风险 Token 加权与风险密度采样**——RT-Weighting 将领域风险/规程词典和跨序列差异转化为 token 级权重，使梯度集中到决定安全边界的关键 token；风险密度感知采样则把恢复监督对齐到有害语义的真实起始位置，两者共同提升了深层安全恢复的精度。

在局限性方面，当前等权 DPO 方案的 SRR 为 45.9%，RT-Weighting 将其提升至 53.4%——意味着仍有接近半数的 harmful prefix 攻击未能成功恢复，特别是安全边界模糊的仿真失真与数据造假类。提升 SRR 的潜在途径包括：增加 Recovery DPO 中深层对齐增强数据的规模和多样性、进一步优化风险密度感知采样的混合系数 α 与滑动窗口长度、以及探索 token-wise 约束微调目标在电力深层安全对齐中的适用性。此外，本文进一步提出 rank-margin 正则与电力 RAP 评测作为在研方向：以 hinge 形式约束拒答 token 的排序高于有害延续 token，并在 top-20 候选中构造风险词典驱动的 RAP 攻击；该部分的全量验证将在后续完成。

本章小结：本章面向深层安全对齐问题，建立了面向电力领域的四类递进式安全风险分类体系，通过 token-boundary 截断分析和梯度可视化探究了安全触发的粒度依赖特性，构建了 Clean DPO、Recovery DPO（含深层安全恢复增强）和 Counter Data 三类协同的深层安全对齐数据体系，并引入 RT-Weighting 风险 Token 加权与风险密度感知采样。已完成的实验结果表明，完整 DPO 训练后 URR 从 42.5% 降至 2.5%，ASR 从 85.6% 降至 11.1%，SRR 从 3.9% 提升至 45.9%，同时

ORR 控制在 5.0%；进一步引入 RT-Weighting 后，URR 降至 1.5%，ASR 降至 7.9%，SRR 提升至 53.4%，ORR 仍为 5.0%。四类风险的分风险 SRR 已完成，分风险 URR/ASR/ORR 与外部安全基线对比尚待补充。

结　论

工作总结

本文面向数字电网知识服务场景，围绕电力知识问答、故障诊断、制度问答和技术方案分析四类核心任务，提出了 CPT-SFT-RLHF-DPO 四阶段多阶段训练与安全对齐框架。各阶段对应本文提出的四个研究问题：在 CPT 阶段，利用七类电力领域语料进行持续预训练注入电力专业知识，通过 1:1 领域-通用数据混合策略平衡领域能力与通用能力；在 SFT 阶段，设计了六模块数据合成管线，从约 600 条专家种子扩展为约 6.8 万条高质量指令数据，在七类数据各自的业务场景中保留了原生风格特征；在 RLHF 阶段，将七类数据归纳为三类风格控制场景，构建三维风格强度条件化 Prefix 机制，IHR 达 76.7%；在 DPO 阶段，基于浅层安全对齐理论建立了四类电力安全风险分类体系，通过 token-boundary 截断分析和梯度可视化探究了安全触发的粒度依赖特性，构建了 Clean DPO、Recovery DPO（含深层安全恢复增强）和 Counter Data 三类协同的深层安全对齐方案，并引入 RT-Weighting 风险 Token 加权与风险密度感知采样；完整 DPO 训练后 URR 降至 2.5%、ASR 降至 11.1%、SRR 提升至 45.9%，RT-Weighting 进一步将 URR 降至 1.5%、ASR 降至 7.9%、SRR 提升至 53.4%，ORR 保持在 5.0%。已完成的实验结果表明，四阶段递进训练框架在本实验设置下有效增强了电力领域能力，提高了模型输出的专业性、可控性和安全性。四类风险的分风险 SRR 已完成，分风险 URR/ASR/ORR 与外部安全基线对比尚待补充，当前结论主要基于已完成的主实验、数据类别消融、RT-Weighting 与风险密度采样消融以及 token-boundary / character-boundary 截断消融分析。

局限性与未来展望

尽管本文提出的多阶段训练与安全对齐方法在数字电网知识服务的多项任务上取得了效果，但仍存在以下局限性，指明了未来研究的方向。

（1）数据覆盖的完整性仍有提升空间。本文 CPT 和 SFT 阶段所使用的电力领域数据主要来源于公开发布的技术标准、规程文件、设备手册、学术论文和部分故障案例。然而，电力行业最核心的运行数据——实际调度运行日志、真实故障录波记录、现场检修工单和事故调查报告——出于安全和商业保密原因难以

大规模获取。这些数据中蕴含的隐性运行经验和复杂故障处置知识是目前训练数据中最薄弱的环节。未来研究可探索与电力企业建立数据合作协议，在严格的数据安全和隐私保护框架下利用脱敏后的真实运行数据增强模型训练；同时可引入数据增广和迁移学习方法，从有限的真实案例中最大化地抽取和泛化运行经验知识。

（2）场景标签的自动化与精细化程度有待提高。本文 SFT 阶段的七类数据类型标签和 RLHF 阶段的三类场景归纳映射，目前主要基于数据来源和内容的规则化判断。虽然该方法在当前规模下保证了标签的一致性和可追溯性，但随着数据规模的进一步扩大和业务场景的不断细分，全人工规则化的标签管理将面临可扩展性瓶颈。未来可结合电力领域文本分类器和主动学习策略，实现场景标签的半自动化分配和持续校准，提高标签体系的覆盖精度和更新效率。此外，当前的三类场景归纳属于较粗粒度的风格控制——每个场景内部的风格需求并非完全单一（如研发与演进场景中，仿真理论问题和工程建设问题在回答风格上仍有微妙差异）。未来可研究多层级的风格控制体系，在三类场景标签之上叠加更细粒度的子风格标签，实现更精细化的风格调节。

（3）风格评价的客观性仍存在挑战。本文构建了以 RM 与 LLM-as-Judge 融合为主干、人工抽检为周期性校准的风格评测体系，但风格质量判断中的主观成分无法完全消除——不同专业背景和业务角色的电力从业人员对同一回答的风格适宜性可能存在合理分歧。本文通过评分者间信度（ICC）和自动-人工相关系数（Pearson r）来量化和控制主观性，但风格评价的完全自动化和客观化仍有进一步研究的空间。未来可引入更细粒度的风格人类偏好数据（如通过电力从业人员的大规模偏好标注构建风格偏好模型），以及基于对比学习的风格嵌入表示（将风格相似度转化为可量化的嵌入距离度量），降低风格评测中的主观不确定性。

（4）安全攻击的覆盖度仍不完全。本文考虑了四类 harmful prefix 诱导攻击和 token-boundary / character-boundary 两种截断方式对安全行为的影响，并在 PrefixRobust-Eval 中进行了系统评测。然而，电力场景下的安全攻击形式远不止于此——多轮对话中的渐进式诱导（在多轮交互中逐步引导模型突破安全边界）、多模态攻击（在图像巡检数据中嵌入对抗性扰动配合有害文本指令）、工具调用链攻击（在模型调用外部工具时注入不安全参数）等在本文中尚未覆盖。在安全评测方面，后续可引入 HarmBench 等自动红队与鲁棒拒答评测框架，以系统检验模型面对多类攻击方法时的安全边界。对于接入 RAG、工具调用或业务系统的部署形态，还需要考虑提示注入攻击对 LLM 集成应用的影响，避免外

部文档、工具返回内容或用户输入绕过系统安全策略。此外，rank-margin 正则与电力 RAP 评测已作为在研方向，用于提升拒答 token 的排序鲁棒性并检验 top-k 攻击下的安全边界。未来需要建立更系统的电力安全红队评测框架，构建面向电力领域的对抗性安全评测体系，更全面地检验和提升模型的安全鲁棒性。

（5）向真实电力业务部署的延伸尚需进一步工作。本文的核心聚焦是训练方法和数据构建——在离线评测集上评估了多阶段训练框架的效果。然而，从离线评测到在线部署之间存在工程化鸿沟。在生产环境中，模型需要处理用户输入的噪声和模糊性、实时响应延迟约束、与电力调度自动化系统和设备管理信息系统的集成、以及持续学习和模型更新机制等问题。未来可从以下方向展开工作：结合检索增强生成（RAG）技术，将电力领域的最新规程更新、设备变更和故障案例实时接入模型的推理过程，解决离线训练数据的时效性问题；结合电力多模态巡检数据（红外测温图像、局部放电图谱、设备外观图像等），赋予模型对电力设备状态的视觉感知能力，使故障诊断从纯文本推理升级为多模态综合判断；集成工具调用能力，使模型能够直接查询实时电网运行数据、调用仿真计算工具或检索设备历史维护记录，增强回答的数据驱动性和可验证性。Toolformer、ReAct 和 Program of Thoughts 等研究表明，将语言模型与外部工具、环境交互或可执行程序结合，有助于提升事实查询、行动规划和数值计算任务的可靠性。上述方向将推动本文提出的电力领域大语言模型从实验验证走向生产级部署，真正服务于电力行业的知识服务、故障处置和安全管理业务。

参考文献

[1] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems. 2017, 30: 5998-6008.

[2] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[C]//Advances in Neural Information Processing Systems. 2020, 33: 1877-1901.

[3] OPENAI. GPT-4 technical report[R/OL]. arXiv:2303.08774, 2023.

[4] MAJUMDER S, DONG L, DOUDI F, et al. Exploring the capabilities and limitations of large language models in the electric energy sector[J]. Joule, 2024, 8(6): 1544-1549.

[5] HAMANN H F, BRUNSCHWILER T, GJORGJIEV B, et al. Foundation models for the electric power grid[J]. Joule, 2024, 8(12): 3245-3258.

[6] GURURANGAN S, MARASOVIĆ A, SWAYAMDIPTA S, et al. Don't stop pretraining: adapt language models to domains and tasks[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2020: 8342-8360.

[7] BELTAGY I, LO K, COHAN A. SciBERT: a pretrained language model for scientific text[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. Hong Kong, China: Association for Computational Linguistics, 2019: 3615-3620.

[8] LEE J, YOON W, KIM S, et al. BioBERT: a pre-trained biomedical language representation model for biomedical text mining[J]. Bioinformatics, 2020, 36(4): 1234-1240.

[9] SINGHAL K, AZIZI S, TU T, et al. Large language models encode clinical knowledge[J]. Nature, 2023, 620: 172-180.

[10] WU S, IRSOY O, LU S, et al. BloombergGPT: a large language model for finance[J/OL]. arXiv:2303.17564, 2023.

[11] YANG H, LIU X Y, WANG C D. FinGPT: open-source financial large language models[J/OL]. arXiv:2306.06031, 2023.

[12] GUHA N, NYARKO J, HO D E, et al. LegalBench: a collaboratively built benchmark for measuring legal reasoning in large language models[J/OL]. arXiv:2308.11462, 2023.

[13] CUI J, LI Z, YAN Y, et al. ChatLaw: open-source legal large language model with integrated external knowledge bases[J/OL]. arXiv:2306.16092, 2023.

[14] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]//Advances in Neural Information Processing Systems. 2020, 33: 9459-9474.

[15] LIU H, WANG S, ZHU Y, et al. Knowledge graph-enhanced large language models via path selection[C]//Findings of the Association for Computational Linguistics: ACL 2024. Bangkok, Thailand: Association for Computational Linguistics, 2024: 6311-6321.

[16] EDGE D, TRINH H, CHENG N, et al. From local to global: a graph RAG approach to query-focused summarization[J/OL]. arXiv:2404.16130, 2024.

[17] HUANG C, LI S, LIU R, et al. Large foundation models for power systems[J/OL]. arXiv:2312.07044, 2023.

[18] CHOI S, SUN H, et al. eGridGPT: trustworthy AI in the control room[R]. Golden: National Renewable Energy Laboratory, 2024.

[19] JIN S, ABHYANKAR S. ChatGrid: power grid visualization empowered by a large language model[C]//2024 IEEE Workshop on Energy Data Visualization. 2024: 12-17.

[20] ZHOU X, ZHAO H, CHENG Y, et al. ElecBench: a power dispatch evaluation benchmark for large language models[J/OL]. arXiv:2407.05365, 2024.

[21] ZHANG S, HUANG Q, ZHANG Q, et al. ElecBench: a large language model benchmark in electric power domain[J]. Engineering Applications of Artificial Intelligence, 2025, 162: 112310.

[22] CHENG Y, ZHAO H, ZHOU X, et al. A large language model for advanced power dispatch[J]. Scientific Reports, 2025, 15: 8925.

[23] ZHONG Y, LUO P, YAN Y, et al. PowerGPT: a multimodal foundation model for power inspection[J]. Applied Soft Computing, 2026, 186: 113939.

[24] WANG Y, KORDI Y, MISHRA S, et al. Self-Instruct: aligning language models with self-generated instructions[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. Toronto: Association for Computational Linguistics, 2023: 13484-13508.

[25] XU C, SUN Q, ZHENG K, et al. WizardLM: empowering large pre-trained language models to follow complex instructions[C]//Proceedings of the 12th International Conference on Learning Representations. Vienna: ICLR, 2024.

[26] WEI Y, WANG Z, LIU J, et al. Magicoder: empowering code generation with OSS-Instruct[C]//Proceedings of the 41st International Conference on Machine Learning. PMLR, 2024, 235: 52632-52657.

[27] MUKHERJEE S, MITRA A, JAWAHAR G, et al. Orca: progressive learning from complex explanation traces of GPT-4[J/OL]. arXiv:2306.02707, 2023.

[28] ZHANG H, CHEN J, JIANG F, et al. HuatuoGPT, towards taming language model to be a doctor[C]//Findings of the Association for Computational Linguistics: EMNLP 2023. Singapore: Association for Computational Linguistics, 2023: 10859-10885.

[29] BAO Z, CHEN W, XIAO S, et al. DISC-MedLLM: bridging general large language models and real-world medical consultation[J/OL]. arXiv:2308.14346, 2023.

[30] CHRISTIANO P F, LEIKE J, BROWN T, et al. Deep reinforcement learning from human preferences[C]//Advances in Neural Information Processing Systems. 2017, 30: 4299-4307.

[31] STIENNON N, OUYANG L, WU J, et al. Learning to summarize with human feedback[C]//Advances in Neural Information Processing Systems. 2020, 33: 3008-3021.

[32] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[C]//Advances in Neural Information Processing Systems. 2022, 35: 27730-27744.

[33] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[J/OL]. arXiv:1707.06347, 2017.

[34] SHAO Z, WANG P, ZHU Q, et al. DeepSeekMath: pushing the limits of mathematical reasoning in open language models[J/OL]. arXiv:2402.03300, 2024.

[35] YU Q, ZHANG Z, ZHU R, et al. DAPO: an open-source LLM reinforcement learning system at scale[J/OL]. arXiv:2503.14476, 2025.

[36] KESKAR N S, MCCANN B, VARSHNEY L R, et al. CTRL: a conditional transformer language model for controllable generation[J/OL]. arXiv:1909.05858, 2019.

[37] DATHATHRI S, MADOTTO A, LAN J, et al. Plug and play language models: a simple approach to controlled text generation[C]//Proceedings of the 8th International Conference on Learning Representations. Addis Ababa: ICLR, 2020.

[38] LI X L, LIANG P. Prefix-tuning: optimizing continuous prompts for generation[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2021: 4582-4597.

[39] LESTER B, AL-RFOU R, CONSTANT N. The power of scale for parameter-efficient prompt tuning[C]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. Online: Association for Computational Linguistics, 2021: 3045-3059.

[40] RAFAILOV R, SHARMA A, MITCHELL E, et al. Direct preference optimization: your language model is secretly a reward model[C]//Advances in Neural Information Processing Systems. 2023, 36.

[41] GHESHLAGHI AZAR M, GUO Z D, PIOT B, et al. A general theoretical paradigm to understand learning from human preferences[C]//Proceedings of the 27th International Conference on Artificial Intelligence and Statistics. PMLR, 2024, 238: 4447-4455.

[42] ETHAYARAJH K, XU W, MUENNIGHOFF N, et al. Model alignment as prospect theoretic optimization[C]//Proceedings of the 41st International Conference on Machine Learning. PMLR, 2024, 235: 12634-12651.

[43] MENG Y, XIA M, CHEN D. SimPO: simple preference optimization with a reference-free reward[C]//Advances in Neural Information Processing Systems. 2024, 37: 124198-124235.

[44] BAI Y, KADAVATH S, KUNDU S, et al. Constitutional AI: harmlessness from AI feedback[J/OL]. arXiv:2212.08073, 2022.

[45] WEI A, HAGHTALAB N, STEINHARDT J. Jailbroken: how does LLM safety training fail?[C]//Advances in Neural Information Processing Systems. 2023, 36.

[46] ZOU A, WANG Z, CARLINI N, et al. Universal and transferable adversarial attacks on aligned language models[J/OL]. arXiv:2307.15043, 2023.

[47] QI X, ZENG Y, XIE T, et al. Fine-tuning aligned language models compromises safety, even when users do not intend to![C]//Proceedings of the 12th International Conference on Learning Representations. Vienna: ICLR, 2024.

[48] QI X, PANDA A, LYU K, et al. Safety alignment should be made more than just a few tokens deep[C]//Proceedings of the 13th International Conference on Learning Representations. Singapore: ICLR, 2025.

[49] RÖTTGER P, KIRK H R, VIDGEN B, et al. XSTest: a test suite for identifying exaggerated safety behaviours in large language models[C]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics. Mexico City: Association for Computational Linguistics, 2024: 5377-5400.

[50] CUI J, CHIANG W L, STOICA I, et al. OR-Bench: an over-refusal benchmark for large language models[C]//Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025.

[51] XIE T, QI X, ZENG Y, et al. SORRY-Bench: systematically evaluating large language model safety refusal behaviors[C]//Proceedings of the 13th International Conference on Learning Representations. Singapore: ICLR, 2025.

[52] GU J, YANG Z, DING C, et al. CMR scaling law: predicting critical mixture ratios for continual pre-training of language models[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Miami: Association for Computational Linguistics, 2024: 16143-16162.

[53] ZENG W, XU C, ZHAO Y, et al. Automatic instruction evolving for large language models[C]//Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Miami: Association for Computational Linguistics, 2024: 6998-7018.

[54] LIU W, ZHAO Y, LUO Y, et al. DESIGNER: design-logic-guided multidisciplinary data synthesis for LLM reasoning[C]//Proceedings of the 14th International Conference on Learning Representations. ICLR, 2026.

[55] YANG A, YANG B, ZHANG B, et al. Qwen2.5 technical report[R/OL]. arXiv:2412.15115, 2024.

[56] WENZEK G, LACHAUX M A, CONNEAU A, et al. CCNet: extracting high quality monolingual datasets from web crawl data[C]//Proceedings of the 12th Language Resources and Evaluation Conference. Marseille: European Language Resources Association, 2020: 4003-4012.

[57] LEE K, IPPOLITO D, NYSTROM A, et al. Deduplicating training data makes language models better[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. Dublin: Association for Computational Linguistics, 2022: 8424-8445.

[58] MARION M, ÜSTÜN A, POZZOBON L, et al. When less is more: investigating data pruning for pretraining LLMs at scale[J/OL]. arXiv:2309.04564, 2023.

[59] CHARIKAR M S. Similarity estimation techniques from rounding algorithms[C]//Proceedings of the 34th Annual ACM Symposium on Theory of Computing. New York: ACM, 2002: 380-388.

[60] MANKU G S, JAIN A, DAS SARMA A. Detecting near-duplicates for web crawling[C]//Proceedings of the 16th International Conference on World Wide Web. New York: ACM, 2007: 141-150.

[61] BRODER A Z. On the resemblance and containment of documents[C]//Proceedings of Compression and Complexity of Sequences 1997. Los Alamitos: IEEE Computer Society, 1997: 21-29.

[62] INDYK P, MOTWANI R. Approximate nearest neighbors: towards removing the curse of dimensionality[C]//Proceedings of the 30th Annual ACM Symposium on Theory of Computing. New York: ACM, 1998: 604-613.

[63] JOHNSON J, DOUZE M, JÉGOU H. Billion-scale similarity search with GPUs[J]. IEEE Transactions on Big Data, 2021, 7(3): 535-547.

[64] KIRKPATRICK J, PASCANU R, RABINOWITZ N, et al. Overcoming catastrophic forgetting in neural networks[J]. Proceedings of the National Academy of Sciences, 2017, 114(13): 3521-3526.

[65] ZHENG L, CHIANG W L, SHENG Y, et al. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena[C]//Advances in Neural Information Processing Systems. 2023, 36.

[66] HUANG Y, BAI Y, ZHU Z, et al. C-Eval: a multi-level multi-discipline Chinese evaluation suite for foundation models[C]//Advances in Neural Information Processing Systems. 2023, 36.

[67] HENDRYCKS D, BURNS C, BASART S, et al. Measuring massive multitask language understanding[C]//Proceedings of the 9th International Conference on Learning Representations. ICLR, 2021.

[68] LOSHCHILOV I, HUTTER F. Decoupled weight decay regularization[C]//Proceedings of the 7th International Conference on Learning Representations. ICLR, 2019.

[69] RAJBHANDARI S, RASLEY J, RUWASE O, et al. ZeRO: memory optimizations toward training trillion parameter models[C]//Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis. Piscataway: IEEE, 2020: 1-16.

[70] DEVLIN J, CHANG M W, LEE K, et al. BERT: pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Minneapolis: Association for Computational Linguistics, 2019: 4171-4186.

[71] HUANG Z, XU W, YU K. Bidirectional LSTM-CRF models for sequence tagging[J/OL]. arXiv:1508.01991, 2015.

[72] MINTZ M, BILLS S, SNOW R, et al. Distant supervision for relation extraction without labeled data[C]//Proceedings of the Joint Conference of the 47th Annual Meeting of the ACL and the 4th International Joint Conference on Natural Language Processing. Singapore: Association for Computational Linguistics, 2009: 1003-1011.

[73] RIEDEL S, YAO L, MCCALLUM A. Modeling relations and their mentions without labeled text[C]//Machine Learning and Knowledge Discovery in Databases. Berlin: Springer, 2010: 148-163.

[74] BORDES A, USUNIER N, GARCIA-DURAN A, et al. Translating embeddings for modeling multi-relational data[C]//Advances in Neural Information Processing Systems. 2013, 26: 2787-2795.

[75] LIN C Y. ROUGE: a package for automatic evaluation of summaries[C]//Text Summarization Branches Out. Barcelona: Association for Computational Linguistics, 2004: 74-81.

[76] SHROUT P E, FLEISS J L. Intraclass correlations: uses in assessing rater reliability[J]. Psychological Bulletin, 1979, 86(2): 420-428.

[77] SENNRICH R, HADDOW B, BIRCH A. Neural machine translation of rare words with subword units[C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics. Berlin: Association for Computational Linguistics, 2016: 1715-1725.

[78] KUDO T, RICHARDSON J. SentencePiece: a simple and language independent subword tokenizer and detokenizer for neural text processing[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations. Brussels: Association for Computational Linguistics, 2018: 66-71.

[79] SUNDARARAJAN M, TALY A, YAN Q. Axiomatic attribution for deep networks[C]//Proceedings of the 34th International Conference on Machine Learning. PMLR, 2017, 70: 3319-3328.

[80] WALLACE E, FENG S, KANDPAL N, et al. Universal adversarial triggers for attacking and analyzing NLP[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. Hong Kong: Association for Computational Linguistics, 2019: 2153-2162.

攻读硕士学位期间取得创新性成果

（一）发表的相关论文

[1] 待补充。

（二）申请及已获得的专利

[1] 待补充（无专利时此项可删除）。

哈尔滨工业大学学位论文原创性声明和使用权限

学位论文原创性声明

本人郑重声明：此处所提交的学位论文《基于指令微调与安全对齐的数字电网大语言模型应用研究》，是本人在导师指导下，在哈尔滨工业大学攻读学位期间独立进行研究工作所取得的成果，且学位论文中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本学位论文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。

作者签名：　　日期：　　年　　月　　日

学位论文使用权限

学位论文是研究生在哈尔滨工业大学攻读学位期间完成的成果，知识产权归属哈尔滨工业大学。学位论文的使用权限如下：

（1）学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文，并向国家图书馆报送学位论文；（2）学校可以将学位论文部分或全部内容编入有关数据库进行检索和提供相应阅览服务；（3）研究生毕业后发表与此学位论文研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉学位论文的使用权限，并将遵守有关规定。

作者签名：　　日期：　　年　　月　　日

导师签名：　　日期：　　年　　月　　日

致　谢

衷心感谢导师 许鋆 对本人的精心指导。导师严谨的治学态度和深厚的专业素养使本人受益良多。

感谢哈尔滨工业大学（深圳）智能科学与工程学院的各位老师和同学在论文研究过程中给予的帮助与支持。

感谢家人一直以来的理解与鼓励。