硕士学位论文

（专业学位论文）

基于多模态特征融合的乳腺癌病理完全缓解预测研究

RESEARCH ON PREDICTION OF PATHOLOGIC COMPLETE RESPONSE IN BREAST CANCER BASED ON MULTIMODAL FEATURE FUSION

谭继阳

哈尔滨工业大学

2027 年 1 月

国内图书分类号:　　学校代码：10213
国际图书分类号:　　密级：公开

硕士学位论文

基于多模态特征融合的乳腺癌病理完全缓解预测研究

硕士研究生：谭继阳

导　　师：许鋆教授

申请学位：专业学位硕士

学　　科：控制工程

所在单位：哈尔滨工业大学（深圳）

答辩日期：2027 年 1 月

授予学位单位：哈尔滨工业大学

Classified Index:
U.D.C:

Dissertation for the Master Degree

RESEARCH ON PREDICTION OF PATHOLOGIC COMPLETE RESPONSE IN BREAST CANCER BASED ON MULTIMODAL FEATURE FUSION

Candidate: Tan Jiyang
Supervisor: Professor Xu Jun
Academic Degree Applied for: Master of Engineering
Specialty: Control Engineering
Affiliation: Harbin Institute of Technology, Shenzhen
Date of Defense: January, 2027
Degree-Conferring-Institution: Harbin Institute of Technology

摘 要

在新辅助治疗开始前预测乳腺癌患者能否达到病理完全缓解（pathologic complete response，pCR），有助于评估其治疗反应。基于影像的预测模型往往难以追踪预测依据，临床信息如何与影像征象共同参与预测也有待明确。本文利用治疗前动态对比增强磁共振成像（DCE-MRI）和临床资料构建可解释的 pCR 预测模型，以放射学概念呈现病例级预测依据。

在 I-SPY2 的 949 例病例中，建立基于三通道 DCE-MRI 的三维 ResNet-50 影像基线，结合通道注意力和肿瘤掩码引导的空间注意力。概念瓶颈模型冻结影像主干，将病例特征投影至文本嵌入空间，计算 13 个放射学概念的相似度得分，再由线性分类头预测 pCR。通过概念置零和测试时扰动，分别检验模型对概念的依赖和概念得分的稳定性。进一步比较临床信息直接融合、门控调制及两者联合的效果。在 Duke 队列的 256 例病例中开展探索性外部评价，分别考察 MammaPrint（MP）不可获得时的冻结模型加权预测，以及使用两队列共有临床字段重训模型后的表现。

在 I-SPY2 内部测试中，影像基线和概念瓶颈模型的平均受试者工作特征曲线下面积（AUC）分别为 0.7146 和 0.7079。将每例病例贡献绝对值最大的五个概念得分置零后，AUC 下降 0.041，随机置零五个概念时下降 0.021，表明移除高贡献概念对模型判别表现的影响更大。采用 128 维临床嵌入的联合模型取得最高内部平均 AUC（0.8157）。在固定阈值 0.5 下，该模型较 18 维临床编码的联合模型检出更多 pCR 病例，同时产生更多误报。在 Duke 队列上，冻结模型采用 MP 加权时的 AUC 为 0.6355。使用共有字段重训后，概念与临床直接融合模型的平均 AUC 为 0.6946，在该组配置中最高。

概念瓶颈模型在内部判别表现与影像基线相近的同时，提供了病例级解释，可识别哪些放射学概念推高或压低病例的 pCR 分类得分。融合临床信息改善了内部判别表现，联合模型还可逐病例量化基础概念贡献、门控增量和直接临床贡献。上述 Duke AUC 均低于各自对应的内部结果，跨队列表现需结合可用临床字段和具体预测方案理解。

关键词：乳腺癌；病理完全缓解；动态对比增强磁共振成像；概念瓶颈模型；多模态信息融合

Abstract

We developed an interpretable model to predict pathologic complete response (pCR) in breast cancer from pretreatment dynamic contrast-enhanced magnetic resonance imaging (DCE-MRI) and clinical data.

Using 949 I-SPY2 cases, we built a three-channel 3D ResNet-50 baseline with channel attention and tumor mask-guided spatial attention. The concept bottleneck projected frozen backbone features into a text embedding space and used a linear classifier on similarity scores for 13 radiological concepts. Concept zeroing tested the model's reliance on these concepts, and test-time perturbations assessed score stability. We compared direct clinical fusion, clinical gating, and their combination, then evaluated models on 256 Duke cases. This exploratory external evaluation assessed weighted predictions from the frozen model when MammaPrint (MP) was unavailable, as well as predictions from models retrained on clinical variables shared by the two cohorts.

The imaging baseline and concept bottleneck achieved mean internal areas under the receiver operating characteristic curve (AUCs) of 0.7146 and 0.7079. Zeroing the five concepts with the largest absolute contributions per case reduced AUC by 0.041, versus 0.021 for five randomly selected concepts. The joint model with a 128-dimensional clinical embedding had the highest mean internal AUC (0.8157). At a threshold of 0.5, it detected more pCR cases and produced more false positives than the 18-dimensional joint model. In Duke, AUC was 0.6355 for the frozen model with MammaPrint weighting and 0.6946 for the best model retrained on shared variables, which directly fused concepts and clinical data.

The bottleneck explained individual predictions by showing which concepts increased or decreased the pCR score. The joint model also distinguished baseline concept contributions, clinical gating adjustments, and direct clinical contributions. Duke AUCs were lower than their corresponding internal values.

Keywords: breast cancer, pathologic complete response, dynamic contrast-enhanced MRI, concept bottleneck model, multimodal data fusion

目 录

摘 要 I
Abstract II

第 1 章 绪论 1
1.1 研究背景与意义 1
1.2 国内外研究现状 2
1.2.1 基于 MRI 的 pCR 预测 2
1.2.2 可解释学习与概念瓶颈模型 4
1.2.3 多模态 pCR 预测 5
1.3 本文主要研究内容 7
第 2 章 基于 MRI 的乳腺癌 pCR 预测基线模型研究 9
2.1 引言 9
2.2 数据来源与预处理 9
2.3 乳房与肿瘤区域提取 13
2.4 MRI 基线模型构建 17
2.5 实验结果与分析 20
2.5.1 基线模型比较 21
2.5.2 注意力模块消融 22
2.5.3 输入通道消融 23
2.6 本章小结 24
第 3 章 基于概念瓶颈的乳腺 MRI 可解释 pCR 预测研究 26
3.1 引言 26
3.2 概念瓶颈与解释评价基础 27
3.3 放射学概念与文本嵌入构建 29
3.4 概念瓶颈预测模型 31
3.4.1 影像表征与概念得分 32
3.4.2 线性预测与概念贡献 33
3.4.3 模型训练策略 34
3.5 解释评价方法 35

3.5.1 概念干预与忠实性评价 35
3.5.2 测试时增强与稳定性评价 37
3.6 实验结果与分析 38
3.6.1 预测性能比较 38
3.6.2 解释忠实性分析 39
3.6.3 概念稳定性与覆盖率分析 40
3.6.4 全局与病例级概念分析 41
3.7 本章小结 42
第 4 章 融合临床信息的多模态概念瓶颈 pCR 预测研究 44
4.1 引言 44
4.2 临床变量编码 45
4.3 临床背景与概念关联 47
4.3.1 受体分层与 pCR 分布 47
4.3.2 临床变量与概念得分关联 48
4.4 临床信息融合模型 51
4.4.1 临床直接融合与门控调制 51
4.4.2 门控与临床联合融合 53
4.4.3 预测贡献分解 55
4.5 实验设置 56
4.6 实验结果与分析 57
4.6.1 总体性能与融合增益 57
4.6.2 固定阈值下的错误分析 60
4.7 Duke 队列的探索性外部评价 62
4.7.1 外部队列与输入差异 62
4.7.2 MP 缺失条件下的评价方案 65
4.7.3 外部预测结果 66
4.8 讨论 69
4.9 本章小结 71
结 论 73
参考文献 74
攻读硕士学位期间取得创新性成果 80
哈尔滨工业大学学位论文原创性声明和使用权限 81
致 谢 82

第 1 章 绪论

1.1 研究背景与意义

乳腺癌是全球女性中最常见的恶性肿瘤之一，也是影响女性健康和生存质量的重要公共卫生问题[1]。在这一背景下，新辅助治疗（Neoadjuvant Therapy, NAT）已成为局部晚期乳腺癌及部分高风险早期乳腺癌的重要治疗方式。新辅助治疗能够在术前缩小肿瘤体积、提高手术可切除性，并为后续治疗方案调整提供依据[2-3]。

病理完全缓解（Pathological Complete Response, pCR）是评价新辅助治疗疗效的重要终点之一。大量研究表明，达到 pCR 的患者通常具有更好的长期预后，其无事件生存和总体生存结局也往往更优[2,4]。因此，在治疗前预测患者达到 pCR 的可能性，对于优化治疗决策、提高治疗针对性以及及时调整治疗方案具有重要临床意义[3,5]。

磁共振成像（Magnetic Resonance Imaging, MRI）尤其是动态对比增强磁共振成像（Dynamic Contrast-Enhanced MRI, DCE-MRI），由于具有较高的软组织分辨率，并可通过多时相图像反映病灶的动态强化特征，已广泛应用于乳腺癌的筛查、诊断、分期及疗效评估[3,6]。乳腺 DCE-MRI 能够较为全面地表征肿瘤的形态学表现、内部异质性及强化行为，为治疗反应预测提供重要的影像学依据[6]。本文聚焦新辅助治疗开始前的 pCR 预测，利用基线 MRI 与临床信息，评估患者完成新辅助治疗后达到 pCR 的可能性。以本文采用的 I-SPY2 队列为例，T0 为新辅助治疗开始前的基线检查，T3 则为新辅助治疗完成后、手术前的检查，两者对应不同的影像获取阶段[7]。相较于依赖治疗过程中或治疗完成后影像的疗效评估，本文将预测时点前移至新辅助治疗开始前，旨在探索基线影像表型与临床因素对后续治疗反应的预测价值，为初始治疗方案制定和患者风险分层提供参考[3,5]。

近年来，随着人工智能技术的发展，深度学习在医学影像分析中的应用不断深化。与传统机器学习依赖人工设计特征不同，深度学习方法能够直接从原始图像中自动学习多层次表征，并在分类、检测、分割和预后预测等任务中展现出良好的性能潜力[8-10]。在乳腺癌研究中，基于 MRI 的深度学习方法已逐步应用于病灶检测、组织分割和治疗反应预测等任务，显示出较好的应用前景[3,10]。

因此，利用深度学习构建面向 pCR 的预测模型，已成为乳腺癌疗效评估研究的重要方向。

然而，现有研究仍存在一些不足。一方面，许多方法更关注模型预测性能，而对模型决策依据的解释不足。传统深度学习模型往往属于黑盒模型，其内部表征缺乏明确的医学语义对应，难以满足医学场景对可信性和可解释性的要求[11-12]。另一方面，单纯依赖影像数据往往难以全面刻画患者个体差异，乳腺癌的新辅助治疗反应还与年龄、绝经状态、激素受体（hormone receptor，HR）状态、人表皮生长因子受体 2（human epidermal growth factor receptor 2，HER2）状态及分子分型等临床因素密切相关[5,13]。因此，如何在保证预测性能的同时提升模型可解释性，并进一步融合影像与临床信息，是乳腺癌 pCR 预测研究中值得深入探索的问题。

基于上述背景，本文围绕乳腺癌新辅助治疗前 pCR 预测问题展开研究，旨在构建一套兼顾预测性能与可解释性的建模方法。本文首先建立基于纯 MRI 图像的 pCR 预测基线模型，在此基础上进一步引入概念瓶颈模型，探索面向乳腺 DCE-MRI 的可解释预测方法，随后结合临床结构化数据构建多模态概念瓶颈预测模型，以期为乳腺癌 pCR 预测提供更加可靠和具有临床参考价值的技术支持。

1.2 国内外研究现状

1.2.1 基于 MRI 的 pCR 预测

近年来，基于 MRI 的乳腺癌病理完全缓解预测逐渐成为乳腺影像人工智能研究的重要方向。现有研究主要围绕治疗前或治疗过程中的 MRI 数据展开，其中以 DCE-MRI 应用最为广泛[3,6]。相关方法已由早期依赖人工特征提取的传统机器学习逐步发展到基于深度学习的端到端建模，并在 pCR 预测任务中取得了一定进展。

早期研究多采用传统机器学习或影像组学方法，即先从 MRI 中提取肿瘤的形态学特征、纹理特征、灰度统计特征和强化动力学特征，再结合支持向量机、随机森林或逻辑回归等分类器完成 pCR 预测[3,5]。这类方法在一定程度上证明了 MRI 对治疗反应预测的价值，但其较大程度依赖人工特征设计和感兴趣区域勾画，特征工程过程较为复杂，且不同研究在特征定义、预处理流程和建模方式上差异较大，影响了模型的稳定性与结果可比性[3]。

随着深度学习的发展，研究者开始尝试直接利用 MRI 构建端到端预测模

型。相较于传统机器学习方法，深度学习能够从原始图像中自动学习更具判别能力的高层次特征，减少对人工特征设计的依赖[8-10]。在乳腺癌 pCR 预测任务中，已有研究采用卷积神经网络对 MRI 进行建模，并显示出较好的应用潜力。例如，Huynh 等利用 DCE-MRI 图像提取深度特征，对新辅助治疗反应进行预测，结果表明基于深度特征的模型具有较好的预测能力[14]。Qu 等比较了基于治疗前 MRI、治疗后 MRI 及二者联合的 pCR 预测模型[15]。此外，也有研究基于 MRI 建立深度学习模型，分别评估对 pCR、残余癌负荷及无进展生存的预测表现，进一步拓展了该方向的应用范围[16]。

在此基础上，部分研究进一步考虑多时相或纵向 MRI 信息在 pCR 预测中的作用。需要区分的是，多时相 DCE-MRI 描述同一次检查内对比剂注射前后的动态强化过程，纵向 MRI 则涉及治疗前、治疗中或治疗后等不同检查阶段。在单次检查内，Huynh 等比较了不同增强时相的深度特征，Braman 等利用治疗前动态增强 MRI 预测 HER2 靶向新辅助治疗反应[14,17]。在纵向研究中，El Adoui 等使用治疗前后定量 MRI 进行预测，Janíčková 等进一步建模治疗过程中影像表型的演化轨迹[18-19]。这些研究体现了检查内动态强化信息与治疗过程中影像变化的不同价值。其中，利用治疗中或治疗后检查的纵向方法主要服务于早期反应评估或疗效监测；仅基于治疗前单阶段 MRI 建立预测模型，则面向治疗起始阶段的决策需求，具有独立的研究意义。

总体来看，现有基于 MRI 的乳腺癌 pCR 预测研究已取得一定进展，但仍存在一些不足。首先，许多研究的数据规模相对有限，且多来自单中心或单一来源，模型的泛化能力仍有待进一步验证[3,13]。其次，不同研究在 MRI 输入形式、肿瘤区域获取方式、数据预处理流程、标签定义及评价指标等方面差异较大，使得研究结果之间难以直接比较[3]。再次，部分研究利用治疗中或治疗后的纵向 MRI 信息提升预测性能，其研究重点更偏向于疗效监测或早期反应评估，与仅使用治疗前信息的预测任务存在区别[18-19]。因此，如何在治疗前单次检查条件下建立稳定、有效的 pCR 预测模型，仍是值得进一步研究的问题。本文将同一次治疗前检查内取得的增强前相与早期增强相称为“治疗前双时相”，两相及其构造的减影共同形成模型输入。“治疗前单阶段”限定检查发生在新辅助治疗开始前，不涉及治疗中或治疗后的检查数据。

独立队列的评价还需考虑输入可获得性和数据分布。Huang 等报告的单次扫描深度学习对照模型的受试者工作特征（receiver operating characteristic，ROC）曲线下面积（area under the curve，AUC）从内部的 0.753 降至两个外部中心的 0.643 和 0.613，其纵向主模型则具有更好的外部表现[20]。Gao 等在缺少乳腺 X 线和

治疗中、治疗后 MRI 的 Duke 队列上，评价了使用治疗前 MRI 及影像学、组织病理学、个体和临床特征的模型配置[21]。这些研究提示，外部验证既要报告实际性能，也要交代所验证的模型、可用输入及适配条件。

1.2.2 可解释学习与概念瓶颈模型

在医学影像任务中，除预测性能外，模型的可解释性同样是影响其临床应用的重要因素。对于乳腺癌 pCR 预测这类高风险任务而言，模型不仅需要给出准确的预测结果，还需要提供一定程度的决策依据，以增强其临床可信性和可接受性。然而，现有基于 MRI 的乳腺癌 pCR 预测方法虽然在分类性能方面取得了一定进展，但大多仍属于黑盒建模范式，对模型决策依据和中间表征关注不足，难以形成与临床语义直接对应的中间证据。因此，如何提升模型的可解释性，已成为医学人工智能研究中的重要问题，可解释人工智能（Explainable Artificial Intelligence, XAI）也由此受到广泛关注[11]。

目前，医学影像领域常见的可解释方法大多属于后验解释方法，即在模型完成预测之后，再通过可视化或特征归因方式分析模型的决策依据。典型方法包括显著性图、类激活映射（Class Activation Mapping, CAM）及其扩展方法，以及 Grad-CAM 等热力图可视化技术[22-24]。这类方法通常通过梯度、特征响应或注意力分布，突出模型在输入图像中关注的关键区域，从而为模型输出提供一定的直观解释。由于实现相对简便，并且能够较容易地结合现有深度学习框架，后验解释方法已被广泛应用于医学图像分类、检测和预后预测等任务。

然而，现有后验解释方法仍存在一定局限。总体而言，这类方法更擅长展示模型在图像中的关注区域，但较难进一步揭示模型究竟依据何种中间语义信息完成预测。即使热力图能够在空间上定位到病灶区域，也往往难以明确模型是否主要依赖肿瘤形态、边缘特征、强化模式或周围组织表现作出判断。此外，后验解释结果通常受模型结构和具体实现方式影响，不同方法之间可能存在差异，其稳定性和可重复性仍有待进一步提高。由于这类解释通常发生在模型预测之后，因此在建立清晰、可验证的中间推理路径方面仍存在不足。对于乳腺癌 pCR 预测这类高风险医学任务而言，仅依赖后验可视化解释往往难以充分满足临床对模型透明性和可信性的要求。

为克服传统黑盒模型和后验解释方法的不足，研究者开始关注具有显式中间语义表示的可解释建模方法。概念瓶颈模型（Concept Bottleneck Model, CBM）是其中较具代表性的一类方法。该模型通过在输入与最终预测结果之间显式引入一组具有明确语义的中间概念，使模型先从原始输入中预测概念，再基于概

念完成最终任务判断，从而将传统黑盒模型中的隐式表征转化为可理解的中间语义变量[12]。与后验解释方法相比，概念瓶颈模型的一个重要优势在于其概念层具有显式变量形式，因而可以直接进行概念层干预，从而为解释的可验证性分析提供条件。

近年来，围绕概念瓶颈模型的研究不断扩展。Koh 等系统研究了概念瓶颈模型，通过在输入与输出之间显式引入概念层，建立“输入—概念—预测”的结构化推理路径，并表明该框架能够支持概念层面的干预与误差分析[12]。在此基础上，Yuksekgonul 等进一步提出后验概念瓶颈模型，复用已训练模型的特征表示，并构建基于概念的预测头以提供概念级解释[25]。此外，Oikarinen 等提出无标签概念瓶颈模型，探索在缺乏显式概念标注的条件下构建概念层表示，为弱监督或无监督场景下的概念建模提供了新的思路[26]。这些研究表明，显式概念层不仅有助于提升模型解释性，还能够支持概念层面的干预、修正和反事实分析。

在医学影像领域，Bunnell 等将临床概念引入乳腺超声病灶检测，为概念瓶颈模型的应用提供了实例[27]。概念解释还需要用相应的指标和基准评价[28]。医学影像标注依赖专业知识，获取高质量逐例标注的成本较高[29]。在这一条件下，无标签概念瓶颈为利用预定义概念构建模型提供了可借鉴的方法[26]。

从上述研究可以看出，显式概念表示为医学影像预测提供了可分析的中间接口。在乳腺癌 pCR 预测任务中，现有研究更多集中于提高黑盒模型的分类性能，而在显式概念层建模、概念可干预性及解释可靠性方面的研究仍相对不足。尤其是在乳腺 DCE-MRI 场景下，如何围绕治疗前影像构建具有明确医学语义的概念集合，并进一步建立“影像—概念—预测结果”之间的可解释路径，仍存在较大研究空间。因此，将概念瓶颈模型引入乳腺癌 pCR 预测任务，有望为提升模型解释性以及构建更具临床参考价值的医学影像预测框架提供新的思路。

1.2.3 多模态 pCR 预测

乳腺癌新辅助治疗反应受多种因素共同影响。除影像学表现外，患者年龄、绝经状态、HR 状态、HER2 状态、分子分型及治疗方案等临床信息同样与 pCR 结局密切相关[5]。因此，单纯依赖影像数据往往难以全面刻画患者个体差异，而将 MRI 影像特征与临床结构化信息进行联合建模，逐渐成为乳腺癌 pCR 预测研究的重要方向[13,30]。

现有多模态研究通常以 DCE-MRI 为核心影像模态，并结合临床变量、病理特征乃至多组学信息进行联合建模。其中，较常见的策略是将影像分支与临

床分支分别编码，再在特征层或决策层进行融合。相比单模态模型，这类方法能够同时利用影像中的空间表征信息与临床中的患者背景信息，从而更充分地反映肿瘤异质性和治疗反应差异[13]。Dammu 等联合纵向 MRI、分子亚型和人口学信息，评估了 pCR、残余癌负荷和无进展生存的预测表现，并报告影像与非影像信息联合使用时优于单独使用任一类信息[16]。

随着多模态学习的发展，研究者也开始尝试引入更多类型的数据来源，以增强模型表达能力。除 MRI 与临床结构化数据外，部分工作进一步引入病理图像、分子信息或治疗过程中多时间点影像，构建更复杂的多模态预测框架。例如，Mao 等整合 MRI、病理切片图像及临床信息，建立了全自动多模态预测系统，并在多个测试集上取得了较好的预测效果，显示出多模态联合建模的潜力[31]。此外，Ma 等将纵向 MRI 与临床信息结合用于 pCR 预测，进一步说明了多模态与时间信息联合建模的应用价值[32]。Jing 等联合 I-SPY2 的多时间点 DCE-MRI 与临床信息进行早期 pCR 预测，并对预测不确定性进行量化[33]。

从现有研究来看，多模态乳腺癌 pCR 预测通常通过输入级、特征级或决策级等方式实现影像与临床信息的融合。近年来，特征级融合因能够在中间表征层面建模不同模态之间的关联而受到更多关注；同时，结合注意力机制或 Transformer 的融合方法也逐渐被用于增强跨模态关系表征能力[32,34]。

尽管多模态乳腺癌 pCR 预测研究已经取得一定进展，但现有工作仍存在若干不足。首先，许多研究的数据规模有限，且外部验证和多中心泛化评估仍相对不足，这限制了模型的临床可推广性[13]。其次，多模态数据之间在采集方式、数据分布和语义层次上存在明显差异，如何设计稳定、有效的融合策略仍是关键问题。再次，现有研究虽然证明了多模态融合能够提升预测性能，但对于不同模态的独立贡献、互补机制及其与模型最终决策之间关系的分析仍不充分。特别是在医学场景中，若模型仅输出最终预测结果，而缺乏对影像证据和临床信息如何共同作用的解释，则其临床可信度仍然有限[31,34]。

总体来看，多模态学习为乳腺癌 pCR 预测提供了重要的发展方向。通过将 MRI 影像与临床结构化信息进行联合建模，可以在一定程度上弥补单模态方法的不足，并提升对患者异质性的刻画能力。然而，现有多模态方法大多仍以性能提升为核心目标，与显式可解释建模框架的结合仍较少。因此，在多模态 pCR 预测研究基础上，进一步引入概念瓶颈思想，构建兼顾性能与可解释性的多模态预测模型，具有较强的研究价值。

综上，现有研究为基于 MRI 的乳腺癌 pCR 预测提供了方法基础，但在治疗前输入条件下的预测建模、缺少逐例概念标注时的概念贡献与稳定性评价，

以及临床信息与影像概念的融合方面，仍有进一步研究的空间。围绕上述问题，本文依次开展影像预测基线、概念瓶颈建模与多模态融合研究，具体内容如下。

1.3 本文主要研究内容

本课题以乳腺癌新辅助治疗前的pCR预测为研究对象，旨在利用乳腺DCE-MRI影像与临床结构化信息，构建兼顾预测能力与可解释性的预测模型。针对影像模型的中间表征缺乏明确医学语义、影像与临床信息对预测结果的共同作用难以分析等问题，本文从纯影像预测出发，引入放射学概念作为中间表示，进一步研究临床信息与影像概念的融合方法，并通过分类实验、概念干预及扰动实验评价模型的预测表现与概念表示的作用。本文的主要研究内容如下：

（1）构建基于治疗前乳腺DCE-MRI的pCR预测基线模型。首先建立影像预处理与病灶区域提取流程，利用增强前相、早期增强相及两相减影构建三通道输入，并结合肿瘤掩码引入病灶区域先验。随后建立基于三维卷积神经网络的预测模型，比较输入通道、主干网络及注意力配置对预测性能的影响。通过分类性能评价与消融实验，分析各项配置的作用，为后续概念瓶颈建模提供影像特征提取基础与性能参照。

（2）构建基于概念瓶颈的乳腺MRI可解释pCR预测模型。针对缺少逐例概念标注的条件，结合治疗前DCE-MRI中可观察的放射学征象构建概念集合，并利用生物医学文本编码器生成固定的概念向量。在冻结已训练影像主干的基础上，学习影像特征到文本嵌入空间的投影，通过影像投影与概念向量的相似度形成概念得分，再由线性预测头完成pCR分类，建立“影像—概念—预测结果”的计算路径。通过与纯影像基线的比较，评价引入概念层后的预测表现；进一步将概念得分置零，考察移除相应概念贡献后模型预测的变化，并通过测试时扰动量化同一病例的概念输出波动，结合全局权重和病例贡献展示模型的预测依据。

（3）构建融合临床信息的多模态概念瓶颈pCR预测模型。在单模态模型的基础上，引入患者临床结构化信息，将临床嵌入与高维影像特征拼接作为参照，并在概念层将临床编码与概念得分直接拼接。进一步设计临床门控调制模型，利用临床背景生成与概念逐维对应的门控权重，调整各概念进入预测头时的贡献幅度，并考察同时保留直接临床通路的联合配置。通过内部分类性能比较和固定阈值下的漏报与误报分析，评价不同融合方式的预测表现，并给出分解影像概念、门控和直接临床贡献的方法。最后，利用独立队列开展探索性外部评

价，结合输入分布及临床字段可获得性的差异，讨论模型的跨队列适用范围。

第 2 章 基于 MRI 的乳腺癌 pCR 预测基线模型研究

2.1 引言

治疗前 MRI 尤其是 DCE-MRI 能够提供肿瘤负荷、强化模式及内部异质性等重要信息，是乳腺癌新辅助治疗前 pCR 预测的重要影像基础。第一章已对相关研究现状进行了综述，可以看出，现有基于 MRI 的乳腺癌 pCR 预测方法已经由早期依赖人工特征提取的传统机器学习方法，逐步发展到基于深度学习的端到端建模方法，并在预测性能方面取得了一定进展。然而，现有研究在数据预处理流程、模型输入形式、肿瘤区域利用方式及评价策略等方面并不完全一致，尤其是在治疗前单阶段 MRI 条件下，如何构建稳定、有效的 pCR 预测模型，仍是值得进一步研究的问题。

对于本文的整体研究框架而言，建立基于 MRI 的 pCR 预测基线模型具有基础性作用。治疗前单阶段 MRI 预测更符合临床治疗起始阶段的实际决策需求，能够在不依赖治疗过程中额外影像信息的前提下，对患者后续疗效结局进行早期评估。同时，在进一步引入概念瓶颈模型和多模态融合策略之前，首先建立一个统一、稳定的单模态基线模型，有助于明确治疗前 MRI 本身所能够提供的基本预测能力，并为后续章节的方法改进和性能比较提供参考。

基于上述考虑，本章围绕治疗前乳腺 MRI 数据开展乳腺癌 pCR 预测基线模型研究。首先，对数据来源、样本筛选及影像预处理流程进行说明；其次，介绍基于 nnU-Net 的乳房与肿瘤区域提取，以及患侧影像和肿瘤掩码的构建；在此基础上，构建基于纯 MRI 图像的 pCR 预测模型，并对模型输入形式、网络结构、训练策略和评价指标进行介绍；最后，比较不同主干，并通过注意力与输入通道消融分析基线模型的性能和局限性，为下一章基于概念瓶颈模型的可解释建模研究奠定基础。

2.2 数据来源与预处理

本研究所使用的影像及配套临床数据来源于 The Cancer Imaging Archive（TCIA）平台公开发布的 I-SPY2 Imaging Cohort 1[7,35]。该队列共包含 985 例候选病例，其中 719 例来自 ISPY2 影像集合，266 例来自 ACRIN 6698/I-SPY2 Breast DWI 影像集合。本文通过同一下载入口获取数据，解压下载文件后统一整理，

用于后续病例筛选和建模。

I-SPY2 是一项面向高风险乳腺癌患者的多中心、自适应随机分组 II 期新辅助治疗平台试验，通过在标准治疗基础上评估不同试验药物，探索肿瘤生物学特征与治疗反应之间的关系[36-37]。试验在基线阶段评估 HR、HER2 及 MammaPrint 等生物标志物，并将其用于患者分型和随机分组[37]。公开数据同时包含治疗前影像、肿瘤生物学特征及术后病理结局，为乳腺癌治疗反应预测研究提供了数据基础。

I-SPY2 在新辅助治疗过程中设置四个主要 MRI 检查时间点。T0 为随机分组前的治疗前基线检查；T1 为治疗早期检查，通常在第一阶段治疗开始约 3 周后进行；T2 为治疗中期检查，位于紫杉醇治疗阶段与多柔比星联合环磷酰胺（AC）治疗阶段之间；T3 为完成 4 个周期 AC 治疗后、手术前的检查[7]。上述时间点描述患者治疗过程中的纵向检查安排，增强前相与增强后相则属于单次 DCE-MRI 检查内的动态采集时相。

结合本文的研究目标，本章仅使用治疗前阶段（T0）的 DCE-MRI 开展 pCR 二分类建模。与依赖治疗过程中多时间点影像变化的建模方式相比，仅基于治疗前影像进行预测，更符合临床治疗起始阶段的实际应用需求。对于临床决策而言，在系统治疗开始前对患者后续是否能够获得 pCR 进行早期评估，有助于为治疗方案选择与疗效监测提供参考。因此，基于治疗前单阶段 MRI 构建预测模型，不仅具有明确的临床意义，也适合作为后续可解释建模与多模态建模研究的统一基线。

pCR 是乳腺癌新辅助治疗研究的重要疗效终点，依据治疗完成后的手术标本病理检查确定。I-SPY2 以手术时乳腺及淋巴结无残留浸润性癌作为 pCR 评价依据[36]。乳腺癌研究中常用的 ypT0/is ypN0 定义要求乳腺及区域淋巴结均无残留浸润性癌，同时允许乳腺内存在残留原位癌。其中，前缀 yp 表示新辅助治疗后的病理分期，T0/is 表示乳腺无残留肿瘤或仅残留原位癌，N0 表示区域淋巴结无肿瘤残留[4]。本文采用公开队列提供的 pCR 结局标签，据此构建二分类预测任务。

pCR 同时具有预后评估价值。CTNeoBC 汇总分析纳入 12 项研究、共 11955 例患者，发现达到 pCR 与更好的无事件生存和总生存结局相关，且这种关联的强度随乳腺癌亚型而变化，在三阴性乳腺癌和接受曲妥珠单抗治疗的 HER2 阳性、激素受体阴性患者中更为突出[4]。因此，基于治疗前信息预测 pCR，有助于研究不同患者的治疗反应差异，并为疗效风险分层提供依据。

在样本筛选过程中，本文遵循“影像可用、标签明确、预处理可完成”的基

本原则。首先，仅保留具有可用治疗前 DCE-MRI 影像的病例；其次，要求相应病例能够完成关键时相识别、影像格式转换及后续预处理流程；最后，仅保留具有明确 pCR 标签的样本。对于原始影像缺失、关键增强时相无法稳定识别、图像质量明显异常或标签信息不完整的病例，均予以排除。经筛选后，最终纳入 949 例病例，其中 pCR 阳性病例 309 例，非 pCR 病例 640 例。为避免同一患者信息同时出现在不同数据子集中而引发数据泄露，本文严格按照患者级别划分训练集、验证集和测试集，比例为 8:1:1。在标签构建方面，将 pCR 阳性记为 1，非 pCR 记为 0，从而构建标准的二分类预测任务。

pCR 标签取自病例标签表中的 pCR 字段，通过患者标识与影像病例匹配。核对后，949 例病例的二值标签与建模所用病例记录一致。表 2-1 给出本研究训练、验证和测试三组划分的病例构成。三个子集的患者标识互斥。训练集用于拟合模型，验证集用于模型选择，测试集用于报告选定模型的内部评价结果。第四章另采用 Duke 独立队列开展探索性外部评价，其病例筛选、专门输入处理和临床信息缺失方案统一见第 4.7 节，不并入本章训练、验证或测试划分。

表 2-1 纳入病例及患者级划分的 pCR 标签分布

数据子集	病例数	pCR	非 pCR	pCR 比例
训练集	759	254	505	33.5%
验证集	95	30	65	31.6%
测试集	95	25	70	26.3%
合计	949	309	640	32.6%

三个子集的阳性比例有所不同，测试集中阳性病例占 26.3%。因此，在比较固定阈值下的分类表现时，本章结合敏感度、特异度和 F1 值报告结果，使不同指标对应的分类表现能够分别观察。

原始影像以 DICOM 序列形式存储。由于 DICOM 数据在临床采集与归档过程中通常以序列文件夹形式组织，不同中心在序列命名方式、层级结构及检查组织形式上存在一定差异，因此在进入深度学习建模流程之前，需要首先完成统一的影像格式转换与结构化整理。为便于开展批量预处理和后续三维模型训练，本文首先将原始 DICOM 序列统一转换为 NIfTI 格式，并在病例层面重新组织影像结构。相较于 DICOM 格式，NIfTI 更适合医学影像算法的批量读取与处理，能够有效支持后续的时相拆分、空间重采样、区域分割、裁剪及分类建模等操作。

需要指出的是，I-SPY2 数据中的 DCE-MRI 并非单一静态体数据，而是由多个动态增强时相构成。不同病例在时相数量、组织方式及序列描述上并不完全一致，部分病例还可能同时包含其他 MRI 序列。因此，在完成格式转换后，本文进一步对每例病例的治疗前 MRI 检查进行序列识别与时相解析，从中提取动态增强序列，并对治疗前阶段的动态增强影像进行时相拆分。通过这一过程，可将原始动态增强序列转化为结构明确的多时相三维体数据，从而为后续关键时相选择、区域提取及分类建模奠定基础。

在本研究中，最终用于 pCR 预测模型输入的原始影像来自治疗前 T0 阶段的两个关键采集时相，即增强前相与增强后早期相。选择该输入形式的原因在于，这两个时相能够较稳定地反映病灶在增强前后的信号变化特征，同时又能够在控制输入复杂度的前提下保留主要诊断信息。与直接引入全部动态时相相比，这种处理方式既有助于降低模型输入维度与训练难度，也更适合作为后续不同方法比较时的统一基线。

在完成关键时相提取后，本文进一步对影像进行空间标准化处理。由于多中心 MRI 数据在层厚、层间距、平面分辨率及体素尺寸等方面通常存在差异，若直接使用原始图像进行建模，不同病例之间在空间尺度上的不一致将影响模型训练的稳定性与结果的可比性。因此，本文将病例级影像统一重采样至 $1\times1\times1$ mm^3 的各向同性体素尺寸，以尽可能降低扫描参数差异对后续分析带来的影响。通过该步骤，不同病例在空间分辨率和体素尺度上得到统一，为后续基于区域分割结果的标准化裁剪提供了稳定基础。

在此基础上，本文进一步围绕治疗前 T0 阶段开展病灶相关区域构建。考虑到原始乳腺 MRI 通常同时覆盖双侧乳房，并包含一定范围的无关背景组织，若直接将完整体数据输入分类模型，可能会引入与当前病灶无关的干扰信息，并增加不同病例之间空间组织形式的不一致性。因此，在完成影像标准化后，本文进一步结合自动分割结果，对病灶相关区域进行提取与约束，并据此构建后续分类模型所需的输入数据。经过上述处理，最终获得了面向纯 MRI 基线模型训练的标准化病例级输入。相关区域提取方法将在下一节中详细介绍。

总体而言，本章的数据预处理是一个包含影像标准化、关键时相提取、病灶相关区域构建及固定输入表示生成等步骤的完整处理链。该流程的核心目标在于，在尽可能保留治疗前 MRI 中与疗效预测相关信息的基础上，降低多中心数据在空间结构与输入形式上的差异，为后续 pCR 预测模型提供稳定、规范且具有可重复性的输入基础。

2.3 乳房与肿瘤区域提取

在完成治疗前 MRI 的时相整理与空间标准化后，本文进一步利用自动分割模型开展乳房与肿瘤区域提取，以构建后续分类模型所需的病灶相关输入。具体而言，首先获得乳房区域分割结果和肿瘤区域分割结果；随后在此基础上完成肿瘤掩码清理、患侧判定、单侧乳房提取以及统一输入构建，从而形成更加聚焦且空间组织形式更一致的分类模型输入。

nnU-Net 是一种基于 U-Net 的自配置医学图像分割框架[38]。U-Net 采用编码器与解码器相结合的结构：编码器逐步提取不同尺度的影像特征，解码器逐步恢复空间分辨率，并通过跳跃连接融合编码阶段的细节信息与深层语义信息，从而实现像素级或体素级分类。nnU-Net 在这一结构基础上，将数据预处理、网络配置、训练策略和后处理整合为相互关联的分割流程，重点解决不同医学影像数据集之间配置需求差异较大的问题。

nnU-Net 的主要特点是依据数据集属性配置分割方案。在构建新任务的分割流程时，框架综合考虑影像尺寸、体素间距及可用计算资源等条件，确定重采样方式、输入块大小、网络层级和批大小等配置，并结合验证结果选择模型及后处理方案。由此，分割性能的获得既依赖网络结构，也依赖与数据特征相适应的完整处理流程。本文使用已有的公开训练权重进行分割推理，利用模型输出的乳房与肿瘤掩码，为后续区域清理、患侧判定、影像裁剪及分类网络的空间引导提供依据。两类分割模型分别承担解剖范围定位与病灶范围提取的任务，共同服务于 pCR 预测模型的输入构建。

具体而言，本文使用两套分别训练的 nnU-Net 权重。第一套为 BreastFGT 乳房组织分割权重。该权重说明中的训练来源为荷兰癌症研究所（NKI）的乳房 MRI，其输出区分乳房组织、纤维腺体组织（FGT）和背景。本文利用乳房区域确定解剖范围，为患侧判断和裁剪提供依据。Van Dijk 等的工作介绍了以单序列标注训练多序列乳房 MRI 分割模型的方法[39]。

第二套为 MAMA-MIA 官方项目公开的肿瘤分割权重[40]。该模型用于生成肿瘤候选掩码，供后续掩码清理和病灶空间引导使用。MAMA-MIA 的数据来源包括 I-SPY2 和 Duke。本文在固定预训练分割权重的条件下评价 pCR 分类，分割预训练样本与本文评价病例的重叠范围尚未按病例核对。

首先，基于自动分割模型获得乳房区域掩码。乳房区域掩码能够较稳定地描述当前病例中双侧乳房的大致空间范围，为后续肿瘤掩码清理和患侧判定提供解剖学依据。随后，利用肿瘤分割模型对同一病例影像进行自动分割，得到

初始肿瘤候选区域。由于自动分割结果中可能存在乳房区域外误检、散在小体积伪阳性以及局部边界不连续等问题，本文并未直接将原始肿瘤分割结果用于后续分类，而是在此基础上进一步进行后处理，以提高病灶定位的稳定性和空间合理性。

在肿瘤掩码清理过程中，首先利用乳房区域掩码对肿瘤候选区域施加空间约束，仅保留位于乳房区域内部的肿瘤部分，从而剔除明显不符合解剖位置的乳房外误检。随后，对约束后的肿瘤掩码进行三维连通域分析，并依据连通域体积过滤明显过小的离散区域，以减少散在伪阳性对后续患侧判定和区域裁剪的干扰。通过上述处理，可获得在空间上更加连续、在语义上更加可信的肿瘤区域表示。该步骤的主要目的在于，在尽可能保留真实病灶信息的基础上，去除明显不稳定或不合理的候选区域，提高后续建模输入的一致性。

在获得清理后的肿瘤掩码后，进一步结合乳房区域掩码进行患侧判定。由于原始影像同时包含左右乳房，而当前分类任务主要关注真实病灶所在侧，因此有必要在进入分类模型前去除对侧乳房信息。本文以乳房区域掩码为基础，通过三维连通域将左右乳房分离，并统计清理后肿瘤掩码与左右乳房区域之间的空间重叠关系，据此判定病灶主要位于左侧还是右侧。随后，仅保留病灶所在侧乳房作为后续分析对象。该处理一方面能够减少对侧正常乳房组织对分类模型训练造成的干扰，另一方面也能使不同病例的输入在空间组织形式上更趋一致，从而增强下游模型学习的稳定性。

在完成患侧判定后，本文依据肿瘤与乳房区域的空间分布确定裁剪范围，提取病灶所在侧乳房的影像及对应掩码。在尽量保留病灶主体和必要邻域上下文的前提下，去除对侧乳房及大部分无关背景。该步骤用于确定病例的有效空间范围；最终输入张量的固定尺寸处理在数据加载阶段完成。

为突出病灶的早期强化表现，本文将同一次治疗前检查的增强后早期图像与增强前图像逐体素相减，得到减影图像。增强前图像主要提供基础解剖结构信息，增强后早期图像反映早期强化表现，减影图像则突出两时相之间的信号变化。三者共同构成后续预测模型的三通道影像输入。在完成病例空间范围构建后，数据加载阶段先由原始两相计算减影，再对增强前图像、增强后早期图像及减影图像分别执行 z-score 标准化。各通道使用对应体数据的均值和标准差，因此标准化后的减影一般不等于两个已标准化时相的直接相减。训练、内部测试及后文外部评价均沿用这一处理顺序。

减影计算要求两个时相在体素位置上具有对应关系。若增强前后存在运动，图像边缘附近的信号差异可能同时包含强化变化与位置变化，因此需要保持两

时相空间处理及裁剪范围的一致性。乳房与肿瘤分割结果还决定患侧定位和保留区域，掩码中的误检、漏检或位置偏差均可能影响后续输入构建。

肿瘤掩码在二值化后执行 3 次膨胀。数据加载阶段，在完成三通道标准化后，对影像和膨胀掩码执行一致的中心裁剪或零填充，统一为 $160 \times 160 \times 160$ 个体素，保持影像与掩码在空间上的对应关系。记处理后的膨胀掩码为 M_d，三个影像通道共同乘以 $1 + 5M_d$，即掩码内权重为 6，掩码外为 1。该操作保留区域外上下文，同时提高病灶相关区域的数值权重。完成区域加权后，三通道影像与对齐掩码分别送入分类网络；掩码用于网络内部的空间注意力引导。

从整体流程上看，本节所述区域提取方法并不是孤立的分割步骤，而是与前述影像标准化、关键时相选择及后续输入构建紧密衔接的预处理组成部分。其核心目标在于，借助自动分割模型提供的空间先验，在尽可能保留病灶相关信息的基础上去除无关背景，并通过患侧提取、固定尺寸构建、标准化处理和差分图像构造等步骤，将原始双侧乳腺 MRI 转换为适合三维分类模型学习的标准化输入表示。相较于直接在完整双侧乳腺体数据上进行建模，上述处理能够在一定程度上提高病灶相关信息在输入中的占比，降低不同病例之间的结构差异，并为后续纯 MRI 基线模型的构建提供更加合理的数据基础。

乳房掩码用于限定解剖范围并辅助患侧判定，肿瘤掩码用于确定病灶范围，并为后续区域裁剪与分类网络提供空间先验。两类掩码共同参与标准化输入的构建，整体处理流程如图 2-1 所示。图左侧展示序列整理、时相选择及空间标准化，右侧展示分割、掩码清理、患侧约束与感兴趣区域（region of interest，ROI）裁剪，以及最终输入生成。

图 2-1 将两类标准化操作分开呈现。时相确定与重采样分别统一输入的时间含义和体素尺度；掩码清理与患侧定位确定需要保留的空间范围；裁剪或填充完成后，三个影像通道与掩码处在相同的病例级输入空间，其中第三个影像通道由两个原始时相构造后单独标准化。

图 2-2 展示了同一病例的影像输入与区域提取过程。其中，（a）和（b）分别为增强前图像与增强后早期图像，（c）为两相相减得到的减影图像；（d）在增强后早期图像上叠加乳房与肿瘤掩码，分别以青色和红色标示；（e）以黄色边框标示最终裁剪范围；（f）展示裁剪后的增强后早期图像。该示例直观说明了从双侧乳房影像到病灶所在侧区域的提取过程，其他输入通道及掩码采用一致的空间裁剪。



图 2-1 治疗前乳腺 MRI 预处理与标准化输入构建流程

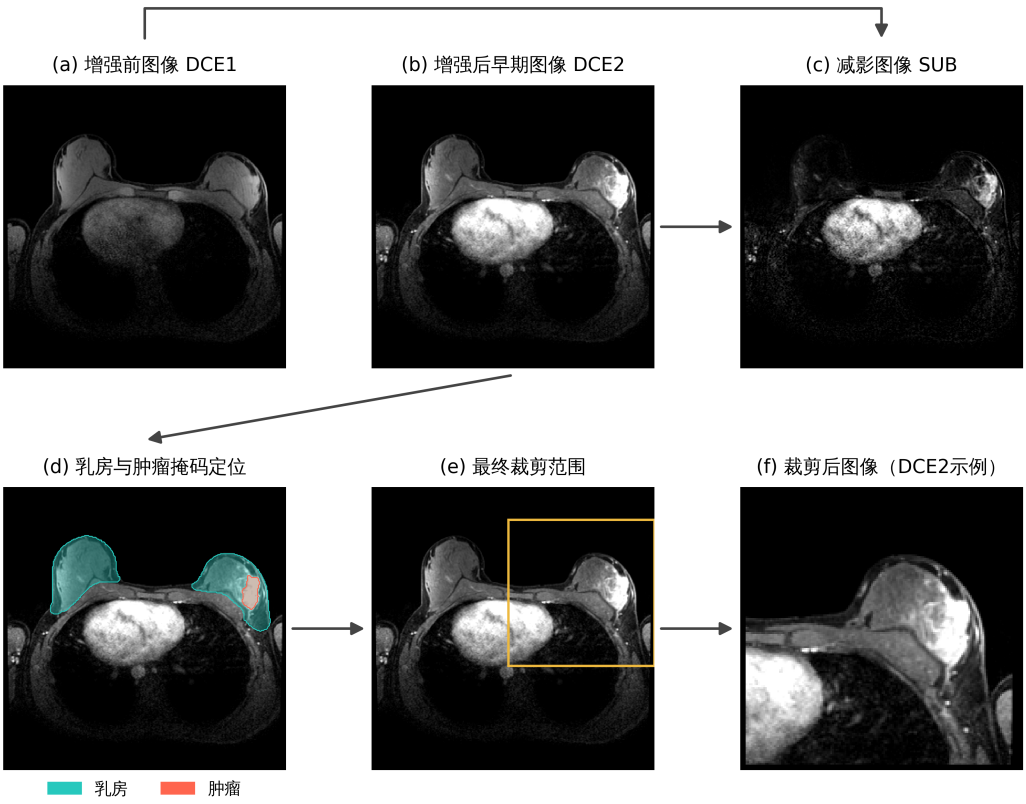


图 2-2 代表性病例的 MRI 预处理与区域提取示例

2.4 MRI 基线模型构建

在完成病灶相关区域提取与统一输入构建后，本文进一步建立基于纯 MRI 图像的 pCR 预测基线模型。考虑到乳腺 MRI 具有明显的三维空间结构特征，且肿瘤表型在不同切片之间具有空间连续性，若仅采用二维切片级模型进行分析，往往难以充分利用病灶在体数据中的上下文信息。因此，本文采用三维卷积神经网络作为基线分类框架，以实现对治疗前乳腺 MRI 体数据的端到端判别学习，从而更充分地挖掘病灶形态、强化模式及其空间分布所蕴含的预测信息。

按照前述预处理流程，本文基线模型将增强前图像、增强后早期图像及减影图像依次堆叠为三通道输入，并保留肿瘤掩码作为空间先验。为明确模型输入的数学表示，记原始两时相图像为 I_{pre} 与 I_{post}，则减影及其标准化结果可写为

$$D = I_{\mathrm{post}} - I_{\mathrm{pre}}, \qquad X_{\mathrm{sub}} = \mathcal{Z}(D) \tag{2-1}$$

其中，$\mathcal{Z}$ 表示各通道独立执行的 z-score 标准化，$X_{\mathrm{pre}} = \mathcal{Z}(I_{\mathrm{pre}})$，$X_{\mathrm{post}} = \mathcal{Z}(I_{\mathrm{post}})$。记中心裁剪或零填充为 $\mathcal{P}$，对齐后的膨胀掩码对应权重 $A = 1 + 5M_d$。各通道先统一空间尺寸，再与 A 逐体素相乘，最终沿通道维堆叠为

$$X = \mathrm{stack}_{\mathrm{ch}}\big(A \odot \mathcal{P}(X_{\mathrm{pre}}),\, A \odot \mathcal{P}(X_{\mathrm{post}}),\, A \odot \mathcal{P}(X_{\mathrm{sub}})\big) \in \mathbb{R}^{3\times160\times160\times160}. \tag{2-2}$$

三个通道及对应肿瘤掩码采用一致的空间处理，使各通道在相同体素位置上保持对应关系。模型以三通道影像提取病例级特征，并在后续特征学习中引入掩码提供的位置约束。

在网络结构设计上，本文采用以 ResNet-50 为主干的三维残差网络构建纯 MRI 预测基线。残差网络（Residual Network，ResNet）由 He 等提出，通过在卷积模块中引入快捷连接，缓解普通网络随深度增加而出现的训练退化问题[41]。其基本思想是将目标映射表示为输入与残差映射之和，使卷积分支学习相对于输入的特征变化。设残差模块的输入为 u，残差分支为 $F(u;\theta)$，则相加后的特征可写为

$$\widetilde{u} = F(u;\theta) + S(u). \tag{2-3}$$

其中，θ 为残差分支的可学习参数，$S(u)$ 为快捷分支。当输入与残差分支输出的维度一致时，采用恒等映射 $S(u) = u$；当通道数或空间尺寸发生变化时，通过投影使两分支维度匹配。相加后的特征再经激活函数传递至后续模块。快捷分支为特征与梯度提供了直接传播路径，有助于深层网络的优化。

原始 ResNet 主要面向二维图像识别，本文采用其三维实现处理 MRI 体数据，将卷积与池化操作扩展至三维空间，以联合提取层内结构和相邻切片之间的空间信息。网络接收前述三通道影像，先通过卷积与池化进行初步特征提取，再经多个残差模块形成层级表示，最后通过全局平均池化获得病例级特征。本文在这一主干上结合肿瘤掩码引导以及通道、空间注意力模块，具体作用将在下文说明。该网络既用于本章的直接 pCR 分类，也为第三章的概念瓶颈模型提供影像特征提取基础。

模型接收三通道影像与独立的肿瘤掩码。前节的区域加权在输入构建阶段增强病灶相关信号，网络中的掩码引导则通过空间注意力调节中间特征的响应。两者分别作用于输入和特征学习阶段，共同提供病灶位置先验。网络内部的具体引导方式结合下文的注意力模块说明。

设经过特征提取网络和全局平均池化后得到的病例级特征表示为 h，则分类层输出可表示为

$$s = f_{\mathrm{cls}}(h) \tag{2-4}$$

其中，f_{cls} 表示全连接分类头，s 为模型输出的分类得分。进一步通过 Sigmoid 函数将分类得分映射为 pCR 阳性概率

$$p = \sigma(s) \tag{2-5}$$

其中，$p \in [0,1]$ 表示输入病例属于 pCR 阳性的预测概率。由此，模型能够实现从三维 MRI 影像输入到病例级 pCR 概率输出的端到端预测。

在基线网络结构的基础上，本文进一步在残差模块内部引入通道注意力（Channel Attention, CA）和空间注意力（Spatial Attention, SA）机制，以增强模型对判别性特征的表征能力。在残差分支与快捷分支相加前，先对残差分支的特征图施加通道注意力。该模块分别对特征图进行全局平均池化和全局最大池化，并通过共享映射生成通道权重，从而提升对关键通道响应的利用程度。随后，引入空间注意力模块对特征图进行空间约束。与仅基于图像特征本身构建空间注意力不同，本文在空间注意力中进一步引入肿瘤掩码信息：将掩码插值到当前特征图对应的空间尺寸后，通过卷积生成空间权重图，并对经过通道重标定的残差特征逐位置加权。加权后的残差特征与快捷分支相加。通过这种方式，模型能够在特征学习过程中更加集中地关注病灶相关区域及其邻近组织，从而提升对肿瘤表型信息的建模能力。

需要说明的是，在本节中引入多通道输入形式以及通道注意力、空间注意

力机制，主要是为了构建一个信息利用更加充分的纯 MRI 基线模型。上述设计是否能够在实验上带来性能改善，将在后续实验部分通过对比分析与消融实验进行进一步验证。

在损失函数设计方面，由于本章任务属于二分类问题，且 pCR 阳性与阴性样本之间存在一定类别不平衡，因此本文采用焦点损失（Focal Loss）与二元交叉熵损失（Binary Cross Entropy, BCE）的加权组合作为模型优化目标。设模型输出得分为 s，经 Sigmoid 函数映射后的预测概率为 $p = \sigma(s)$，真实标签为 $y \in \{0, 1\}$，则二元交叉熵损失定义为

$$\mathcal{L}_{\mathrm{BCE}} = -\left[y \log p + (1 - y) \log(1 - p)\right] \tag{2-6}$$

为了增强模型对难分类样本的关注，进一步引入焦点损失[42]

$$\mathcal{L}_{\mathrm{Focal}} = -\alpha_t (1 - p_t)^{\gamma} \log(p_t) \tag{2-7}$$

其中

$$p_t = yp + (1 - y)(1 - p) \tag{2-8}$$

表示与真实类别对应的预测概率，γ 为聚焦参数，α_t 为类别平衡权重。在本文中，γ 设为 2.0，α_t 根据训练集中正负样本比例动态确定。最终采用如下组合损失进行模型优化

$$\mathcal{L} = 0.5\,\mathcal{L}_{\mathrm{Focal}} + 0.5\,\mathcal{L}_{\mathrm{BCE}} \tag{2-9}$$

采用组合损失的目的在于，在保持二分类概率建模稳定性的基础上，提高模型对类别不平衡情形下难分类样本的关注程度，从而增强整体训练效果。

除损失函数外，本文还在数据采样阶段考虑类别不平衡问题。具体而言，在训练数据加载过程中采用基于类别频率的加权随机采样策略，以提高少数类样本在训练批次中的出现概率。该策略与上述损失函数设计相配合，有助于在模型优化过程中减轻类别分布不均对学习偏置的影响。

在模型训练过程中，本文采用监督学习方式，以经过预处理的三通道 MRI 体数据作为输入，以 pCR 标签作为监督信号，对网络参数进行端到端优化。训练配置方面，模型采用 AdamW 优化器，初始学习率设为 1×10^{-4}，权重衰减系数设为 1×10^{-3}，训练轮数设为 50，Batch Size 设为 16，并启用自动混合精度训练以提高训练效率和显存利用率。训练阶段对输入数据施加随机翻转、仿射变换和高斯噪声等增强操作，以提高模型对空间形变和强度波动的鲁棒性；常规

验证和测试关闭随机增强。第三章另在解释稳定性实验中使用测试时扰动。最终，根据验证集表现选择最优模型，并在预留的内部测试集上评估其预测性能。

在评价指标方面，本文主要采用 AUC 作为模型性能的核心评价指标，同时结合准确率、敏感度（sensitivity，SEN）、特异度（specificity，SPE）和 F1 值对模型分类性能进行综合分析。其中，AUC 能够较好地反映模型在不同分类阈值下的整体判别能力，适合用于不平衡二分类任务的性能评价。全文二分类评价统一采用固定阈值 0.5：预测概率大于或等于 0.5 时判为 pCR，否则判为非 pCR。准确率、敏感度、特异度和 F1 值均依据这一规则计算，AUC 根据连续预测得分计算。

令 TP、FP、TN 和 FN 分别表示真阳性、假阳性、真阴性和假阴性。敏感度和特异度分别记为 SEN 和 SPE，在公式中以 Se 和 Sp 表示。三项分类指标计算如下

$$\mathrm{Se} = \frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}, \quad \mathrm{Sp} = \frac{\mathrm{TN}}{\mathrm{TN} + \mathrm{FP}}, \quad \mathrm{F1} = \frac{2\mathrm{TP}}{2\mathrm{TP} + \mathrm{FP} + \mathrm{FN}}. \tag{2-10}$$

敏感度表示真实 pCR 病例中被检出的比例，特异度表示真实非 pCR 病例中被正确判为阴性的比例。F1 综合阳性病例的检出情况和阳性预测的准确程度。

三通道影像的特征提取、注意力模块和分类路径如图 2-3 所示。局部放大图展示肿瘤掩码参与空间注意力计算的路径。主路径先从三个影像通道提取特征，再经池化和分类层输出病例级预测；局部模块中，通道注意力重标定各特征通道，掩码引导的空间注意力进一步调节特征在不同空间位置的响应。

基于上述模型结构与训练策略，下一节将进一步从整体性能比较和关键设计因素验证两个方面展开实验分析，重点考察所构建的纯 MRI 基线模型相对于其他基线方法的表现，以及三通道输入形式和注意力机制设计对模型预测性能的影响。

2.5 实验结果与分析

本章将配置确定、权重选取和测试评价分开。ResNet-50 主干、联合通道与空间注意力以及三通道输入作为后续章节的 MRI 基线配置，均在查看测试结果前确定。每一配置在训练集上拟合，并依据其验证集表现选择权重；随后在预留的内部测试集上报告性能。下列主干与消融结果用于比较预先定义的配置在测试病例上的表现。分类指标采用固定阈值 0.5。本章性能表中的数值以重复实验的均值 ± 标准差表示，用于同时描述平均预测表现及重复实验的波动。

为验证本文所构建纯 MRI 图像 pCR 预测基线模型的有效性，本节围绕模

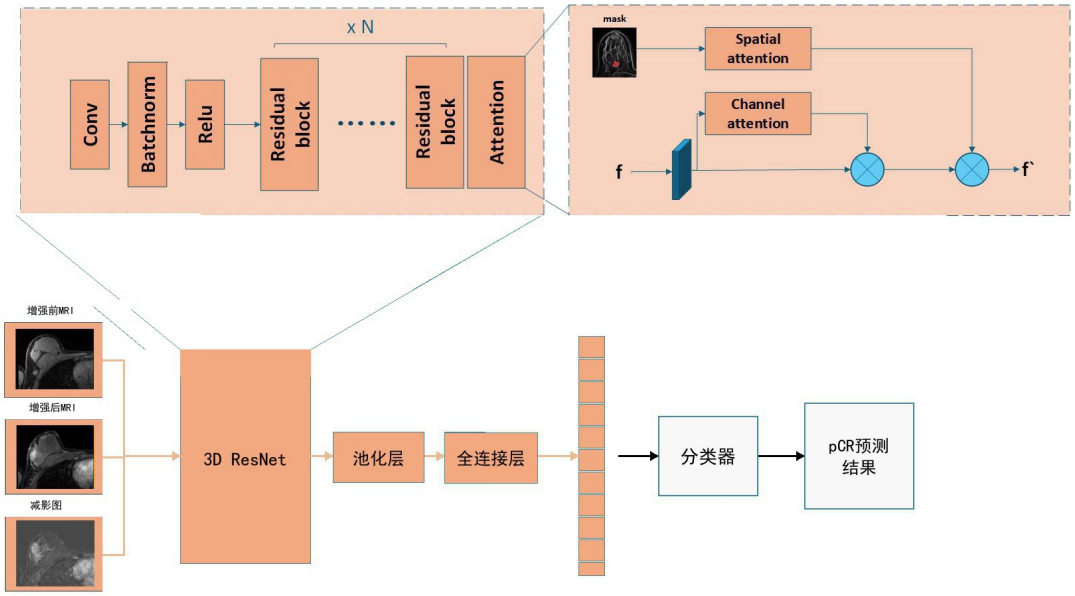


图 2-3 掩码引导的三通道乳腺 MRI 分类网络

型主干结构选择、注意力模块设置以及输入通道组合三个方面开展实验分析。首先，对所采用的三维 ResNet-50 基线模型与若干常用三维分类网络进行比较，以评估其在本研究任务中的适用性；其次，通过注意力模块消融实验分析 CA 与 SA 对模型性能的影响；最后，通过输入通道组合消融实验验证三通道输入策略的合理性。

2.5.1 基线模型比较

为评估本文基线模型所采用主干网络的合理性，本文选取多种常见三维卷积分类模型进行对比实验，包括 ResNet-18、ResNet-34、ResNet-50、SE-ResNet50、SE-ResNet101、DenseNet121 和 DenseNet169。上述模型涵盖残差连接、通道重标定与密集连接三类结构。ResNet-18、ResNet-34 和 ResNet-50 通过快捷连接学习残差映射，其基本原理已在前节介绍；选取不同深度的配置，用于考察网络深度变化对应的预测表现[41]。SE-ResNet50 和 SE-ResNet101 在残差网络中引入压缩与激励（Squeeze-and-Excitation，SE）模块，通过汇总各通道的全局信息并生成通道权重，对特征响应进行自适应重标定，用于考察通道关系建模的作用[43]。DenseNet121 和 DenseNet169 在密集块内将前面各层的特征沿通道维度拼接，促进不同层次特征的复用，为残差网络之外的特征连接方式提供对照[44]。

各模型均在相同数据划分与训练策略下进行训练与测试，以保证结果具有可比性。表 2-2 给出了不同模型在测试集上的性能表现。

由表 2-2 可见，ResNet-50 在所比较配置中取得最高的平均测试 AUC，为

表 2-2 不同基线模型在测试集上的性能比较

模型	AUC	F1	SEN	SPE
ResNet-18	0.68 ± 0.11	0.52 ± 0.15	0.64 ± 0.19	0.71 ± 0.11
ResNet-34	0.70 ± 0.11	0.52 ± 0.13	0.80 ± 0.16	0.54 ± 0.11
ResNet-50	**0.71 ± 0.01**	0.42 ± 0.09	0.44 ± 0.20	**0.78 ± 0.17**
SE-ResNet50	0.66 ± 0.13	0.45 ± 0.14	0.68 ± 0.19	0.51 ± 0.12
SE-ResNet101	0.69 ± 0.12	0.47 ± 0.15	0.56 ± 0.19	0.71 ± 0.10
DenseNet121	0.69 ± 0.12	0.49 ± 0.16	0.56 ± 0.19	0.74 ± 0.10
DenseNet169	0.67 ± 0.12	0.48 ± 0.14	0.60 ± 0.20	0.63 ± 0.11

0.71 ± 0.01。其他模型的平均 AUC 为 0.66–0.70，标准差为 0.11–0.13。ResNet-50 不仅具有较高的平均判别能力，其 AUC 在重复实验中的波动也较小。这表明，在当前数据划分与训练设置下，该配置能够提供相对稳定的病例排序表现，有利于为后续概念瓶颈建模与多模态融合研究建立统一的影像性能参照。

在固定分类阈值 0.5 下，ResNet-50 的平均特异度为 0.78，高于其他模型的 0.51–0.74，体现出较好的非 pCR 病例排除能力。相比之下，ResNet-34 的敏感度达到 0.80，但特异度为 0.54；ResNet-50 的敏感度为 0.44，F1 为 0.42，说明其较高特异度同时伴随较多的阳性漏检。因此，ResNet-50 的优势主要体现在整体排序能力、AUC 的重复实验稳定性及固定阈值下的特异度，其敏感度仍有进一步改善的空间。

综合上述结果，ResNet-50 配置适合作为后续研究的影像基线：较高且波动较小的 AUC 为不同建模方法的比较提供性能参照，较好的特异度则体现了影像信息对非 pCR 病例的判别价值。在这一基线上，后续章节进一步考察概念表示和临床信息融合能否改善预测表现及类别间的识别取舍。表中的 ResNet-50 行对应后续使用的最终 MRI 配置；注意力消融表中的裸 ResNet-50 则用于隔离注意力模块的影响。

2.5.2 注意力模块消融

在确定以 ResNet-50 作为基础主干网络后，本文进一步设计注意力模块消融实验，以分析两类注意力机制对模型性能的影响。具体而言，分别比较不引入注意力模块、仅引入 CA、仅引入 SA 以及同时引入 CA 与 SA 四种设置下模型在测试集上的性能表现，结果如表 2-3 所示。

由表 2-3 可见，单独引入 CA 后，平均 AUC 从 0.6757 变为 0.6728，F1 和敏感度也有所下降，特异度则由 0.6521 略升至 0.6603。单独引入 SA 后，平均 AUC 提升至 0.6904，特异度提高至 0.7274，相比不使用注意力的模型分别增加 1.47 和 7.53 个百分点。这一结果支持在影像特征学习中引入病灶空间引导，以改善

表 2-3 注意力模块消融实验结果

方法	AUC	F1	SEN	SPE
ResNet50	0.6757 ± 0.0463	**0.4408 ± 0.1350**	**0.5982 ± 0.2473**	0.6521 ± 0.1797
ResNet50 + CA	0.6728 ± 0.0427	0.4098 ± 0.1111	0.5366 ± 0.2373	0.6603 ± 0.1959
ResNet50 + SA	0.6904 ± 0.0533	0.4310 ± 0.1171	0.5100 ± 0.2293	0.7274 ± 0.1747
ResNet50 + CA + SA	**0.7146 ± 0.0118**	0.4177 ± 0.0893	0.4429 ± 0.2012	**0.7827 ± 0.1661**

模型的判别表现。

联合使用 CA 和 SA 时，模型取得最高平均 AUC 0.7146 和特异度 0.7827，相比不使用注意力的模型分别增加 3.89 和 13.06 个百分点；相比仅使用 SA 的模型，两项指标仍分别提高 2.42 和 5.53 个百分点。同时，联合配置的 AUC 标准差为 0.0118，低于其他配置的 0.0427–0.0533，表明其排序性能在重复实验中具有较小波动。单独使用 CA 未获得收益，而与 SA 联合后表现更好，提示通道重标定的作用可能与空间引导有关。两类模块分别调整特征通道与空间位置的响应，联合配置的结果与这一设计思路相符。

本文以 AUC 为核心评价指标，因此联合配置在平均 AUC、AUC 重复实验稳定性和特异度上的优势，为保留 CA 与 SA 提供了实验依据。与此同时，其敏感度为 0.4429、F1 为 0.4177，均低于不使用注意力的模型，说明该配置在固定阈值 0.5 下更侧重于非 pCR 病例的正确识别，阳性检出仍有不足。综合整体判别能力与重复实验表现，后续影像基线采用 CA 与 SA 联合配置，并在概念建模及临床融合实验中继续评价其敏感度与特异度的变化。

2.5.3 输入通道消融

除网络结构外，模型输入形式也是影响预测性能的重要因素。为便于表述，本文将增强前图像记为 DCE1，将增强后早期图像记为 DCE2，并将二者的减影结果记为 SUB。为验证三通道输入策略的合理性，本文进一步比较了不同输入通道组合下模型的分类表现。实验分别考察了单通道输入、双通道输入以及三通道联合输入三类设置，结果如表 2-4 所示。

表 2-4 不同输入通道组合的消融实验结果

DCE1	DCE2	SUB	AUC	F1	SEN	SPE
✓	-	-	0.6707 ± 0.0468	0.3978 ± 0.0956	0.4550 ± 0.2152	0.7339 ± 0.1825
-	✓	-	0.6840 ± 0.0289	0.4264 ± 0.0772	0.4912 ± 0.1707	0.7297 ± 0.1474
-	-	✓	0.6586 ± 0.0515	0.4227 ± 0.1117	0.5264 ± 0.2106	0.6880 ± 0.1877
✓	✓	-	0.6567 ± 0.0477	0.3524 ± 0.1095	0.4224 ± 0.2353	0.7160 ± 0.2072
✓	-	✓	0.6609 ± 0.0509	0.3955 ± 0.0895	0.4832 ± 0.2141	0.6920 ± 0.1860
-	✓	✓	0.6698 ± 0.0560	**0.4376 ± 0.1177**	**0.5552 ± 0.2275**	0.6857 ± 0.2006
✓	✓	✓	**0.7146 ± 0.0118**	0.4177 ± 0.0893	0.4429 ± 0.2012	**0.7827 ± 0.1661**

由表 2-4 可见，在单通道设置中，DCE2 的平均 AUC 为 0.6840，高于 DCE1 的 0.6707 和 SUB 的 0.6586，且 AUC 标准差最小，说明增强后早期图像在当前单通道比较中具有较好的判别表现。SUB 单独输入的 AUC 较低，提示显式强化差异本身尚不足以替代原始时相提供的影像信息。

增加输入通道并不必然提高预测性能。三种双通道配置的平均 AUC 均低于单独使用 DCE2，其中 DCE2 与 SUB 的组合取得双通道配置中最高的 AUC 0.6698，同时具有全表最高的 F1 0.4376 和敏感度 0.5552，但特异度为 0.6857。这表明不同输入组合会改变模型在固定阈值下的类别识别取舍，不能仅根据通道数量判断其优劣。

三通道联合输入的平均 AUC 为 0.7146，特异度为 0.7827，均为所有输入配置中的最高值。相较于 AUC 最高的单通道 DCE2，两项指标分别提高 3.06 和 5.30 个百分点；其 AUC 标准差仅为 0.0118，也低于其他输入配置的 0.0289–0.0560。减影由原始两相构造，虽未增加独立的采集信息，但显式呈现了强化差异。三通道配置同时保留原始时相和减影表示，其较高且波动较小的 AUC 支持在当前网络和训练条件下采用这一输入方式。

三通道配置的 F1 和敏感度低于 DCE2 与 SUB 的双通道组合，因此本文采用三通道的主要依据是更好的整体排序表现、较小的 AUC 波动和较高的特异度。结合主干对照与注意力消融结果，后续研究沿用以 ResNet-50 为主干、联合 CA 与 SA、接收 DCE1、DCE2 和 SUB 的 MRI 基线配置。该配置为概念瓶颈建模和临床信息融合提供统一的影像输入及性能参照。

2.6 本章小结

本章围绕基于纯 MRI 图像的乳腺癌 pCR 预测基线模型构建展开研究。首先，对 I-SPY2 临床试验公开数据的来源、样本筛选策略以及治疗前 T0 阶段 DCE-MRI 的预处理流程与输入构建方式进行了说明，明确了本章所采用的数据基础与任务设定。随后，结合乳腺 MRI 原始数据同时包含双侧乳房及无关背景区域的特点，利用公开预训练的 nnU-Net 模型分别获得乳房区域掩码和肿瘤区域掩码，并在此基础上完成肿瘤掩码去杂、患侧判定、单侧乳房提取及统一预处理，从而为后续分类建模提供标准化输入。

在模型构建方面，本章采用三通道 DCE-MRI 影像表示，并结合肿瘤掩码引导的三维残差网络建立纯 MRI 图像 pCR 预测模型。模型在 ResNet-50 主干基础上引入通道注意力与掩码引导空间注意力机制，以增强对病灶相关区域和判

别性特征的表征能力；同时，结合焦点损失、二元交叉熵损失以及加权随机采样策略，对类别不平衡问题进行处理。实验结果表明，治疗前纯 MRI 图像能够为乳腺癌 pCR 预测提供一定有效信息，不同基线模型在该任务上均表现出一定预测能力，其中预先确定的 ResNet-50 配置具有最高平均 AUC 和特异度，但 F1 与敏感度并非同时最高。注意力与输入通道消融结果进一步表明，联合通道和空间注意力、采用三通道输入的配置在各自比较中均取得最高平均 AUC 和特异度，且 AUC 的重复实验波动最小。这些优势为后续沿用该配置提供了依据，其固定阈值下的 F1 和敏感度则需结合具体任务要求共同评价。

总体来看，本章建立了面向治疗前乳腺 MRI 的 pCR 预测基线模型，并完成了从数据预处理、区域提取到分类建模的完整流程，为后续章节研究提供了统一的实验基础。然而，该基线模型整体上仍属于黑盒预测框架，虽然能够实现对 pCR 的一定程度预测，但其内部决策过程缺乏显式的医学语义表达。因此，下一章将在本章研究基础上进一步引入概念瓶颈思想，构建面向乳腺 DCE-MRI 的可解释 pCR 预测模型。

第 3 章 基于概念瓶颈的乳腺 MRI 可解释 pCR 预测研究

3.1 引言

第二章围绕治疗前乳腺 MRI 影像构建了 pCR 预测基线模型，验证了纯影像输入在该任务中的一定预测价值。然而，第二章所建立的模型本质上仍属于端到端黑盒分类框架。尽管通过三通道输入、肿瘤区域先验以及注意力机制能够在一定程度上增强模型对病灶相关区域的关注，但模型内部高维特征与临床可理解影像征象之间仍缺乏明确对应关系，因而难以直接回答“模型究竟依据哪些影像学证据作出判断”这一关键问题。

在第二章确定影像输入与网络配置后，本章需要进一步分析病例级影像特征如何参与 pCR 判断。对于同一预测结果，病灶早期强化强度、强化异质性、边缘表现及背景实质强化等信息可能提供不同方向的支持。因此，本章关注的不仅是模型输出的概率，还包括能否以统一的概念名称组织中间表示、能否分解各概念对当前病例的贡献，以及这些贡献在被移除后如何影响模型预测。

第一章已综述后验解释与概念建模的相关研究。对本章而言，关键是建立能够与预测计算直接衔接的概念接口，使“概念表示—分类结果”之间具有明确的计算关系。热力图能够提供空间关注信息，而本章进一步希望在概念层面对病例进行比较，并通过可重复的操作分析概念与输出之间的联系。基于这一目标，需要在原有影像特征与最终分类之间设置显式中间表示。

本章采用概念瓶颈模型连接影像表征与 pCR 分类。具体研究内容包括三个相互衔接的环节：首先定义适用于当前影像输入的概念集合，为各病例提供一致的概念坐标；随后将原有病例级特征映射为概念得分，并建立可分解的预测头；最后通过概念干预与输入扰动，分别观察模型对概念的依赖及概念输出的一致性。模型结构、训练方式与评价方法围绕这三个环节展开。

然而，将传统概念瓶颈模型直接应用于医学影像场景仍面临现实困难。首先，标准概念瓶颈模型往往依赖实例级概念标注，即需要为每个病例提供逐概念的监督信息，而这类标注在医学影像中成本高、难度大且一致性有限。其次，即使构建了概念层，若概念集合本身与当前任务场景不匹配，或者概念证据缺乏可量化评价方式，则模型解释仍可能停留在表面语义层面。对于本研究所采

用的治疗前双时相乳腺 DCE-MRI 数据而言，并非所有 BI-RADS MRI 描述词都能够在当前输入条件下被稳定观察，因此有必要围绕具体任务约束对概念集合进行针对性构建。

基于上述考虑，本文在第二章纯 MRI 预测基线模型的基础上，引入基于投影的概念瓶颈框架，构建面向治疗前乳腺 DCE-MRI 的可解释 pCR 预测模型。该方法首先利用已训练完成的 3D ResNet 提取病例级影像表征，再将其映射至生物医学文本嵌入空间，通过与预定义放射学概念向量之间的相似度计算得到概念得分，并据此完成最终预测。进一步地，为避免解释仅停留在定性展示层面，本文从解释忠实性（faithfulness）和解释稳定性（reliability）两个维度对概念证据进行量化评价：前者通过概念干预检验概念是否真正参与模型预测，后者通过测试时增强（test-time augmentation，TTA）分析概念证据在轻微扰动下的稳定程度[45-46]。由此，本文不仅关注模型能否输出具有医学语义的概念证据，也进一步关注这些概念证据是否能够被定量分析和验证。

本章先定义适用于治疗前双时相影像的放射学概念及其文本嵌入，再建立概念投影和线性预测头。实验比较 CBM 与 MRI 基线的预测性能，通过概念置零和测试时扰动分别考察决策依赖与概念得分波动，并以全局权重图和病例贡献图展示模型如何使用概念。

3.2 概念瓶颈与解释评价基础

概念瓶颈模型的核心思想是在模型输入与最终预测结果之间显式引入一组具有明确语义的中间概念变量[12]。设输入样本为 x，中间概念表示为 c，最终预测结果为 y，则传统端到端模型通常直接学习从 x 到 y 的映射关系，而概念瓶颈模型则将这一过程分解为两个阶段：首先由模型从输入中提取概念表示 c，再由概念层完成最终任务预测。通过这种结构化设计，模型原本不可解释的高维隐式表示被替换为可与人类知识体系对齐的概念空间，从而使中间推理路径具有更强的可读性和可分析性。

图 3-1 对比了两类模型的基本结构。普通深度学习模型通过隐含特征完成预测，概念瓶颈模型则以具有预定义语义的概念表示作为中间接口，使最终预测建立在概念表示之上，并支持对概念层进行观察与干预。

在自然图像任务中，概念通常可以对应颜色、纹理、材质或部件等属性；而在医学影像场景中，概念则更适合对应影像描述符、放射学术语或病理相关表型。以乳腺 DCE-MRI 为例，病灶早期强化强度、强化异质性、边缘不规则性、

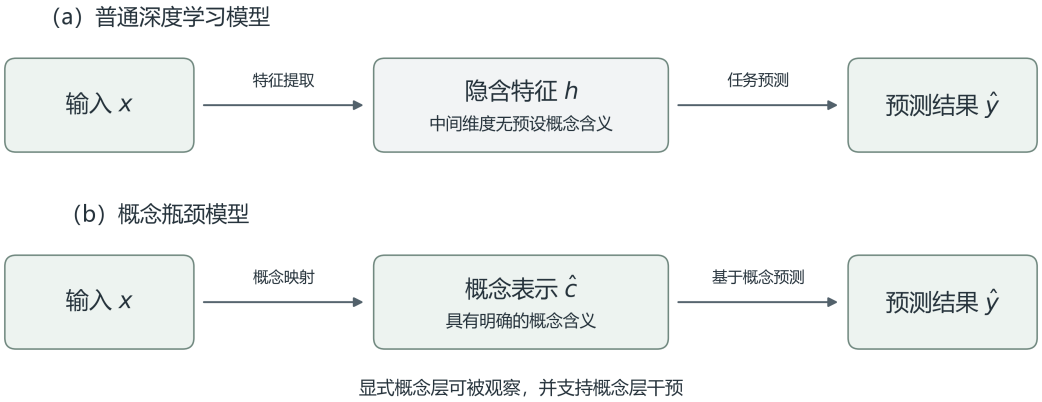


图 3-1 普通深度学习模型与概念瓶颈模型的基本结构对比

内部低强化区域以及背景实质强化程度等，均属于具有明确临床意义的中间语义。这类概念既能够被放射科医生理解，也往往与治疗反应存在一定关联。因此，将这些中间概念引入预测模型，不仅有助于增强模型解释性，也能够使模型的决策依据更接近临床阅读过程。

概念瓶颈模型的实现形式取决于概念信息的获得方式。传统模型利用实例级概念标注训练输入到概念的映射[12]；后验概念瓶颈和无标签概念瓶颈则探索利用既有表示或文本概念构建中间接口[25-26]。这些方法在监督信号和训练过程上有所区别，但都需要明确各概念的定义及其进入预测头的方式。因此，理解具体模型时，应分别考察概念如何确定、病例概念得分如何计算，以及最终任务如何使用这些得分。

在这一结构中，概念层的作用是为中间表示建立固定的语义索引。每个病例都以相同顺序输出一组概念得分，使同一概念在不同病例之间具有可比较的表示位置。任务预测头随后对这些得分进行组合，形成最终输出。概念得分描述病例在相应概念上的模型表示，预测贡献则进一步取决于任务头的参数；两者承担不同作用。这样的分解使得中间证据可以被逐项查看，并为后续病例级分析提供共同的计算接口。

从跨模态表示学习角度看，文本可以为预定义概念提供向量形式的参照。CLIP（Contrastive Language-Image Pre-training）类模型通过图像–文本对比学习构建共享嵌入空间，使两类表示能够在相同维度下进行相似度比较[47]。用于构建概念参照的文本向量可以在后续任务中保持固定，病例相关表示则通过相应映射获得。对于医学术语，文本编码器的预训练领域也会影响概念表达。本章选用生物医学领域的 PMC-CLIP 文本编码器[48]，具体概念文本及固定嵌入的构建过程在第 3.3 节说明，病例级映射与分类过程在第 3.4 节说明。

显式概念层还为解释评价提供了明确的操作对象。在模型参数保持不变时，可以对选定概念的得分实施受控修改，并比较修改前后的预测输出。该操作建立了概念层变化与模型输出变化之间的计算联系，使概念贡献能够结合实际预测进行分析。评价时需要同时明确概念选择规则、修改方式以及观察指标：前两者定义干预操作，后者用于描述模型输出受到的影响。本章的具体干预设计在解释评价方法中展开。

除概念对预测的作用外，还需要分析概念表示在重复推理中的一致性。对同一病例施加轻微输入扰动后，重复计算各概念得分，可以从其波动程度评价输出稳定性。这类评价关注同一病例在不同扰动条件下的表示变化，与前述概念干预关注的决策依赖形成互补。将波动汇总为病例级指标后，还可以按稳定程度对病例排序，比较不同保留范围内的预测表现。这一思路与测试时增强的不确定性分析和选择性预测研究相联系[45-46]。

总体而言，概念瓶颈模型为乳腺 MRI pCR 预测提供了一种兼顾预测性能与解释能力的建模思路，而基于干预和稳定性分析的定量评价则进一步将概念解释从定性展示推进到可量化分析的层面。基于这一理论基础，本章后续内容将围绕概念构建、模型设计及解释评价三个方面展开。

3.3 放射学概念与文本嵌入构建

在概念瓶颈模型中，概念层的定义直接决定了模型解释结果的临床可读性和任务相关性。因此，如何构建一组既具有明确放射学语义、又与治疗前 pCR 预测任务相匹配的概念，是这一方法设计中的关键环节。

这里的概念构建主要遵循两个基本原则。第一，概念应来源于已有临床知识体系，具备明确医学语义，使概念结果能够被放射科医生理解和分析。第二，概念应与当前任务设定保持一致，即仅保留在治疗前双时相 DCE-MRI 及其派生图像中能够观察到的影像表型。换言之，本文并不追求构建一个尽可能庞大的 BI-RADS MRI 词汇全集，而是希望在当前数据条件下筛选出一组既可观察、又对 pCR 预测具有潜在意义的中间概念。

基于上述考虑，本文以第 5 版 BI-RADS（Breast Imaging Reporting and Data System）的 MRI 词汇体系为主要参考。BI-RADS 是乳腺影像判读与报告的标准化术语体系，涵盖病灶形态、边缘表现、强化方式及分布特征等描述维度，能够为乳腺 MRI 征象的规范表达提供统一依据[49-50]。在此基础上，本文整理 BI-RADS MRI 相关描述词，并结合当前任务的影像输入条件构建概念集。具体而

言，概念保留需同时满足三个条件：其一，能够在治疗前双时相 DCE-MRI 及其派生图像中较为稳定地观察；其二，能够与病灶强化、形态、边缘或背景实质强化等放射学征象建立明确对应关系；其三，与当前 pCR 预测任务具有潜在判别价值。经过上述筛选后，最终定义了 $K = 13$ 个面向治疗前双时相 DCE-MRI 的放射学概念，分别为：强早期强化、强化异质性、环形强化、中央低强化区、不规则病灶形态、不规则或毛刺样边缘、非肿块样强化、节段样强化分布、强化范围较大、不连续强化模式、肿瘤边界不清、病灶显著性较低以及明显背景强化。上述概念均能够在增强前相、增强后早期相及减影图像条件下进行描述，因此与本研究的数据输入形式保持一致，其具体内容及含义如表3-1所示。

表 3-1 本章采用的 13 个放射学概念及其含义

序号	概念名称	概念说明
1	强早期强化	描述病灶在增强后早期相中出现较明显强化反应，反映病灶血供与早期对比剂摄取特征。
2	强化异质性	描述病灶内部强化分布不均匀，提示病灶内部结构复杂或成分不一致。
3	环形强化	描述病灶周边强化较明显而中央相对较弱的表现。
4	中央低强化区	描述病灶内部存在相对低强化区域，可与坏死、囊变或内部成分差异相关。
5	不规则病灶形态	描述病灶整体轮廓不规则，偏离圆形或类圆形结构。
6	不规则或毛刺样边缘	描述病灶边界不光滑，存在分叶、毛刺或边缘浸润样表现。
7	非肿块样强化	描述强化区域不呈典型肿块样，而表现为片状、区域性或弥散性强化。
8	节段样强化分布	描述强化沿导管或腺体分布方向呈节段样扩展。
9	强化范围较大	描述病灶强化累及范围相对较广，提示较大的病灶负荷或强化扩展范围。
10	不连续强化模式	描述强化呈斑片状、间断性或局部中断分布。
11	肿瘤边界不清	描述病灶与周围组织分界不清晰，边界识别难度较高。
12	病灶显著性较低	描述病灶在当前图像中的可见性较弱，不易从背景组织中清晰分辨。
13	明显背景强化	描述病灶周围背景实质强化较为显著，可能增加病灶判读难度。

在概念整理过程中，为提高词汇表述的一致性，本文引入大语言模型对初始概念描述进行文本层面的规范化处理，包括概念归纳、表达标准化和重复项去除等。但需要强调的是，大语言模型在该过程中仅用于概念词汇整理，而不参与逐病例概念标注，不生成训练监督信号，也不直接参与模型训练与推理。

其输出仅用于概念文本的规范化表达，而不进入训练标签体系。这样设计的目的，是在尽量保持概念语义清晰和术语一致的同时，避免引入额外的实例级伪监督。

在具体实现上，设预定义概念集合为 $\{t_k\}_{k=1}^{K}$，其中每个 t_k 表示一个放射学概念对应的文本提示。结合前文理论基础部分关于 CLIP 类共享语义空间的讨论，本文采用冻结的 PMC-CLIP 文本编码器对概念提示进行编码[48]。设文本编码器为 $\phi(\cdot)$，则第 k 个概念的嵌入向量可表示为

$$v_k = \frac{\phi(t_k)}{\|\phi(t_k)\|_2}, \quad k = 1, 2, \ldots, K \tag{3-1}$$

其中，$v_k \in \mathbb{R}^{D_t}$ 表示归一化后的概念向量。若同一概念采用多个文本模板，则可先对不同模板对应的嵌入结果求平均，再进行归一化处理。将所有概念向量堆叠后，可得固定概念嵌入矩阵

$$E \in \mathbb{R}^{K \times D_t}, \qquad E_{k,:} = v_k^{\top} \tag{3-2}$$

矩阵 E 汇集了全部预定义概念的文本表示，其每一行对应一个概念，行的顺序与表 3-1 的概念编号一致。该矩阵由概念文本编码得到，对所有病例保持一致，并在后续模型训练中固定。

图 3-2 汇总了从概念文本整理到固定嵌入矩阵构建的过程。图左侧为依据 BI-RADS 词汇和治疗前影像条件进行的概念整理，中间为确定的放射学概念文本，右侧为冻结文本编码器及其输出的概念嵌入矩阵 E。至此，得到后续模型共用的概念名称及文本表示；下一节介绍如何将每个病例的影像特征与这些概念表示关联，并完成 pCR 预测。

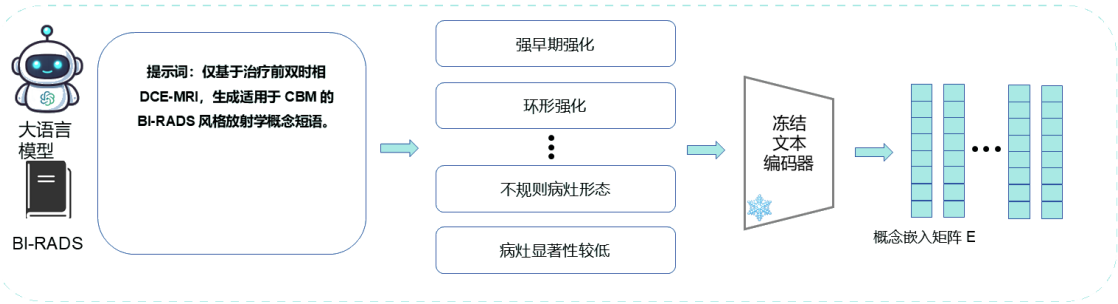


图 3-2 放射学概念生成与文本嵌入构建流程

3.4 概念瓶颈预测模型

上一节完成了放射学概念及其固定文本嵌入的构建，本节进一步介绍如何

利用这些概念表示建立病例级 pCR 预测模型。本文借鉴后验概念瓶颈和无标签概念瓶颈中以文本表示定义概念的思路[25-26]，将影像特征转换为概念得分，并通过线性预测头完成分类。

3.4.1 影像表征与概念得分

本章的影像编码部分直接沿用第二章所建立的纯 MRI 预测基线模型。在输入形式上，仍采用增强前相、增强后早期相和减影图像构成的三通道乳腺 DCE-MRI 作为模型输入，并结合肿瘤 ROI 掩码对病灶区域进行引导；在网络结构上，继续采用第二章中已完成训练的 3D ResNet-50 作为影像特征提取主干。第二章的实验结果表明，该模型能够在当前任务中学习到具有判别性的病例级影像表征，因此本文在此基础上进一步构建概念瓶颈模型，而不重新设计新的影像编码框架。

相关输入定义、掩码融合方式以及主干网络内部结构已在第二章中详细介绍，这里不再重复展开。为便于后续表述，记经过第二章影像编码模块提取得到的病例级影像表征为

$$h \in \mathbb{R}^{D_f} \tag{3-3}$$

其中，D_f 表示影像特征维度。本节中的影像特征、投影结果及概念得分向量均采用列向量表示。

与第二章不同的是，第二章模型在获得病例级影像表征后，直接通过分类头输出 pCR 预测结果；而在本章中，h 不再直接用于黑盒分类，而是作为概念投影模块的输入，进一步映射到预定义放射学概念空间中，以构建“影像—概念—预测结果”的可解释推理路径。

在获得病例级影像表征 h 后，本文进一步引入概念投影模块，将影像特征映射到与放射学概念文本向量一致的语义空间中。这样做的目的在于建立影像表示与预定义概念之间的对应关系，使模型中间层不再停留于不可解释的高维特征表示，而能够以放射学概念的形式进行表达。

结合前文理论基础部分关于 CLIP 类跨模态对齐方法的讨论，本文不重新训练整套图文编码模型，而是在冻结影像特征提取主干和文本编码器的基础上，仅学习一个轻量化线性投影层，用于完成病例级影像表征到概念语义空间的映射[47-48]。设该线性投影矩阵为

$$W_f \in \mathbb{R}^{D_t \times D_f} \tag{3-4}$$

其中，D_f 表示影像特征维度，D_t 表示文本概念嵌入维度。于是，病例级影像表征 h 经投影后可表示为

$$z = W_f h \tag{3-5}$$

为便于后续与概念文本向量进行相似度计算，对投影后的影像表示 z 进行 ℓ_2 归一化，得到

$$\bar{z} = \frac{z}{\|z\|_2} \tag{3-6}$$

另一方面，在第 3.3 节中，本文已利用 PMC-CLIP 文本编码器构建了固定概念嵌入矩阵 $E \in \mathbb{R}^{K \times D_t}$。因此，可通过计算归一化影像向量 $\bar{z}$ 与各概念向量之间的余弦相似度，得到病例的概念得分向量

$$c(X, M) = E\bar{z} \in \mathbb{R}^K \tag{3-7}$$

其中，X 为三通道影像输入，M 为对应的肿瘤掩码。由于 E 的第 k 行为归一化概念向量的转置 $v_k^\top$，第 k 个概念得分为 $c_k = v_k^\top \bar{z}$。两向量均经过 ℓ_2 归一化，因此该内积即为影像投影与概念文本向量的余弦相似度。例如，“环形强化”的概念得分越高，表示该病例的影像投影与“环形强化”文本表示在嵌入空间中越接近。该得分按模型相似度解读，不能直接视为病例存在相应征象的概率。

与直接输出不可解释的高维隐式特征相比，概念得分向量 c 具有更明确的中间语义含义。向量中的每一维均对应一个预定义放射学概念，因此模型中间层可以被表示为一组可阅读、可比较的概念证据。这也为后续解释忠实性和解释稳定性分析提供了直接作用对象。

3.4.2 线性预测与概念贡献

在获得病例级概念得分向量 c 后，仍需进一步建立概念证据与最终 pCR 预测结果之间的对应关系。为保持决策路径的可解释性，本文采用线性概念头完成最终分类。与更复杂的非线性分类器相比，线性结构能够更直接地反映各概念维度对预测结果的作用方向和作用强度，因此更适合用于后续病例级概念贡献分析。若在概念层之后继续引入额外非线性分类模块，则会削弱概念维度与最终预测结果之间的直接对应关系，不利于中间解释路径的分析。

设线性概念头参数为

$$w \in \mathbb{R}^K, \qquad b \in \mathbb{R} \tag{3-8}$$

其中，w 表示各概念维度对应的权重，b 表示偏置项。则模型输出的分类 logit

可表示为

$$\ell = w^{\top} c + b \tag{3-9}$$

进一步地，经过 Sigmoid 函数后，可得到病例属于 pCR 类别的预测概率

$$p(X, M) = \sigma(\ell) \tag{3-10}$$

由上述形式可见，最终预测结果由各概念得分的线性组合决定，因此模型决策路径可以分解到具体概念维度上进行分析。为刻画单个概念对当前病例预测结果的影响，本文进一步定义病例 i 在第 k 个概念上的贡献为

$$a_{i,k} = w_k \, c_{i,k} \tag{3-11}$$

其中，$c_{i,k}$ 表示第 i 个病例在第 k 个概念上的得分，w_k 表示线性概念头中对应的概念权重。

该定义表明，概念贡献由“概念得分”与“概念权重”共同决定。概念得分较高并不必然意味着对预测结果的影响更大，还需结合对应权重的大小与符号判断。若 $a_{i,k}$ 为正，则说明该概念对当前病例的 pCR 预测起正向支持作用；若 $a_{i,k}$ 为负，则该概念项降低 pCR 分类得分；其绝对值越大，则表明该概念对当前预测结果的影响越强。基于这一量化形式，后续可以在病例层面对概念进行排序，识别对预测最重要的高贡献概念，并据此开展解释忠实性分析和概念可视化展示。

与直接输出一个不可分解的分类结果相比，线性概念头使最终预测能够明确回溯到各个放射学概念维度，从而使“模型为何做出当前判断”具备更清晰的语义解释路径。这一设计也是本章概念瓶颈模型区别于第二章纯黑盒分类模型的重要环节。

3.4.3 模型训练策略

概念瓶颈模型的训练采用两阶段策略。第一阶段，训练第二章所述的端到端 3D ResNet-50 基线模型，使其能够从治疗前乳腺 MRI 中学习到有效的病例级影像表征；第二阶段，在冻结已训练完成的影像特征提取主干后，仅训练概念投影层 W_f 和线性概念头参数 (w, b)，使影像表示能够映射到预定义概念空间并完成最终 pCR 分类。

在训练过程中，仍以 pCR 标签作为最终监督信号，使用二分类损失函数对概念投影层和概念头参数进行优化。概念投影由最终任务损失学习，概念文本

嵌入在训练中固定。概念得分的语义对应程度需要结合逐病例的影像征象标注另行评价。

综合上述影像映射、概念预测与模型训练过程，本文构建的概念瓶颈预测框架如图 3-3 所示。模型由冻结的三维 ResNet 提取病例级影像特征，经投影和相似度计算得到概念得分，再由线性预测头输出 pCR 预测结果。图中的雪花表示影像主干保持冻结，所列概念及数值用于示意不同概念对预测的贡献，不作为实验结果报告。

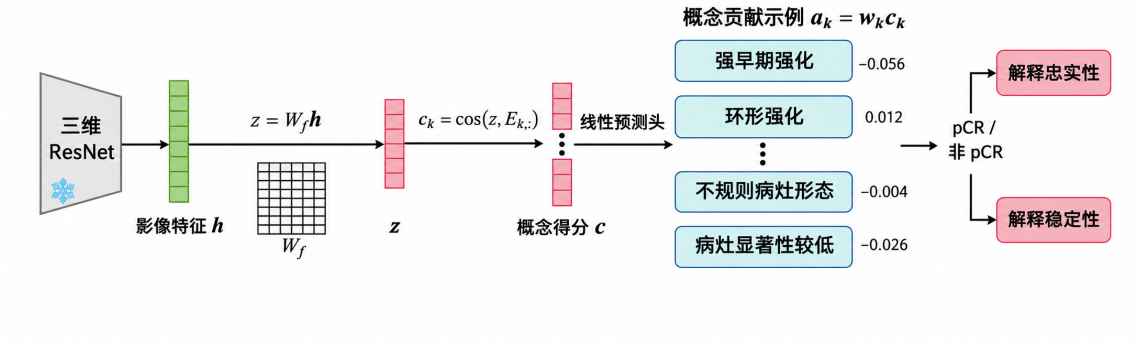


图 3-3 基于概念瓶颈的病例级 MRI 预测与解释评价框架

该框架形成了“影像输入—病例级特征—概念得分—预测结果”的完整路径，并为概念贡献分析提供了显式的中间表示。在此基础上，下一节分别通过概念干预和输入扰动，评价概念对模型决策的作用及概念输出的稳定性，对应图右侧的解释忠实性与解释稳定性两个方向。

3.5 解释评价方法

与传统分类模型主要关注 AUC、准确率等预测指标不同，本文不仅关注模型“能否预测”，还进一步关注模型“给出的概念证据是否真正参与了预测”以及“这些概念证据在轻微扰动条件下是否保持稳定”。因此，在常规分类指标之外，进一步从解释忠实性和解释稳定性两个维度构建概念解释评价体系。

3.5.1 概念干预与忠实性评价

本节通过概念置零实验，比较高贡献概念与随机概念对模型预测的影响。设每次同时置零的概念数量为 m，采用以下两种方式：

（1）高贡献概念干预（top-m）：对每个病例，按概念贡献的绝对值 $|a_{i,k}| = |w_k c_{i,k}|$ 从大到小排序，选取前 m 个概念，将其得分同时置零。这里的 top 表示贡献绝对值排名靠前，排序依据为预测贡献而非概念相似度；正向和负向贡献

均可入选。

（2）随机概念干预（random-m）：对每个病例，从全部 13 个概念中随机选取 m 个不同概念，将其得分同时置零，作为同等干预规模下的对照。这里的 random 表示随机选择概念。

每次比较均对同一组模型权重和同一批病例应用两种干预方式，干预数量及置零操作相同，区别在于概念选择规则。被选概念按病例分别确定，因此不同病例的 top-m 概念可能不同。下面给出置零操作及评价指标的具体定义。

设某一病例的概念得分向量为

$$c = [c_1, c_2, \ldots, c_K]^\top \tag{3-12}$$

其中，K 表示概念总数。设 $S \subseteq \{1, 2, \ldots, K\}$ 为被干预的概念索引集合，则定义置零干预后的概念向量为

$$\tilde{c}_k = \begin{cases} 0, & k \in S \\ c_k, & k \notin S \end{cases} \tag{3-13}$$

将干预后的概念向量 $\tilde{c}$ 代入原线性概念头，即可得到新的 pCR 预测概率 $\tilde{p}$。干预时模型参数、其他概念得分及预测头偏置保持不变，不重新训练模型。由于此处的概念得分为相似度，置零表示在模型计算中移除相应贡献，不等同于判定影像中不存在该征象。

为量化概念干预所引起的变化，本文采用以下三个指标进行评价。

第一，平均预测概率变化幅度：

$$\mathbb{E}[|\Delta p|] = \frac{1}{N} \sum_{i=1}^{N} |\tilde{p}_i - p_i| \tag{3-14}$$

其中，N 表示测试集病例数，p_i 和 $\tilde{p}_i$ 分别表示干预前后第 i 个病例的预测概率。该指标越大，表示干预引起的预测概率变化越大。例如，数值 0.090 表示预测概率平均变化 9.0 个百分点，既包括上升也包括下降。

第二，预测概率变化超过 0.05 的病例比例。设预测概率变化的幅度界限为 $\epsilon = 0.05$，当 $|\tilde{p}_i - p_i| > \epsilon$ 时，认为该病例在干预后出现了超过预设幅度的预测变化。进一步统计整组病例中这类情况所占比例，得到

$$R_{0.05} = \frac{1}{N} \sum_{i=1}^{N} \mathbb{I}\big(|\tilde{p}_i - p_i| > 0.05\big) \tag{3-15}$$

其中，指示函数 $\mathbb{I}$ 在括号内条件成立时取 1，否则取 0。该比例表示预测概率变

化超过 5 个百分点的病例占比，并非分类结果发生翻转的病例比例；分类判定仍统一采用阈值 0.5。

第三，整体判别性能变化：

$$\Delta\mathrm{AUC} = \mathrm{AUC}(\tilde{p}) - \mathrm{AUC}(p) \tag{3-16}$$

两项 AUC 均在相同测试病例及真实标签上计算，分别使用干预后与干预前的连续预测概率。该差值为负表示干预后判别性能下降，为正表示上升。例如，-0.024 表示 AUC 下降 0.024。其变化取决于病例之间的预测排序，不能仅由被置零概念的贡献绝对值推断。

实验分别取 $m = 3$ 和 $m = 5$，即每次同时移除 3 个或 5 个概念的贡献。对每一种规模，分别汇总 top-m 与 random-m 在上述三个指标上的表现，比较其对概率变化幅度、受影响病例比例及测试集排序的影响。该实验评价的是模型内部概念贡献与预测变化的关系。

3.5.2 测试时增强与稳定性评价

除解释忠实性外，本文还关注概念证据在轻微输入扰动下的稳定性。其基本思想是：对于同一病例，若模型在不同轻微扰动条件下得到的概念证据始终较为一致，则说明该病例的概念解释更稳定、更可靠；反之，若概念证据波动较大，则说明该解释更容易受输入变化影响，其概念输出对当前扰动更敏感。这里的测试时增强稳定性分析借鉴了医学影像领域利用 TTA 估计不确定性的思路[45]。

为此，本文在测试阶段对每个病例重复施加轻微测试时增强，包括随机翻转、轻度仿射变化和强度扰动等，并进行 $T = 20$ 次独立推理。设第 t 次推理得到的概念向量为

$$c^{(t)} = [c_1^{(t)}, c_2^{(t)}, \ldots, c_K^{(t)}]^\top, \qquad t = 1, 2, \ldots, T \tag{3-17}$$

则对于第 k 个概念，可计算其在 T 次推理中的标准差

$$\mathrm{Std}_t\left(c_k^{(t)}\right) \tag{3-18}$$

进一步定义病例级概念稳定性指标为

$$U_{\mathrm{mean}} = \frac{1}{K}\sum_{k=1}^{K}\mathrm{Std}_t\left(c_k^{(t)}\right) \tag{3-19}$$

其中，U_{mean} 越小，表示该病例的概念证据在轻微扰动下越稳定；反之，则表示

其概念层输出更容易受输入变化影响。

引入 U_{mean} 的目的并不只是为每个病例分配一个“稳定性分数”，更重要的是探究该指标能否作为实际部署中的质量控制信号。为此，进一步进行覆盖率—性能分析。具体做法为：首先按 U_{mean} 从小到大对测试病例进行排序；然后分别按 50%、70% 和 90% 的目标覆盖率保留病例子集；最后统计模型在各保留子集中的 AUC、F1 值、敏感度和特异度。这一分析方式与基于可靠性进行选择性保留高置信样本的思路相一致[46]。

若较低概念波动对应的保留子集具有较高分类性能，可以将其作为病例筛选的观察结果。该比较不直接度量预测概率的重复推理方差，概念输出稳定、预测稳定和保留子集分类性能应分别解释。

3.6 实验结果与分析

第三章实验所使用的数据来源、病例纳入标准、患者级训练集/验证集/测试集划分方式、影像预处理流程以及常规分类评价指标，整体上均沿用第二章设置，以保证本章方法与第二章纯 MRI 基线模型之间具有良好的可比性。与第二章相比，本章新增的实现内容主要包括：构建由 13 个放射学概念组成的概念集合，采用冻结的 PMC-CLIP 文本编码器生成固定概念嵌入矩阵，并在第二章训练完成的 3D ResNet-50 基础上，通过两阶段训练方式学习概念投影层和线性概念头。

在解释评价方面，本文进一步引入两类新增实验设置。其一，在解释忠实性分析中，分别采用 $m = 3$ 和 $m = 5$ 两种概念干预规模，并设置随机概念干预作为对照；其二，在解释稳定性分析中，对每个测试病例实施 $T = 20$ 次测试时增强推理，并比较 50%、70% 和 90% 三档覆盖率下的子集表现，同时列出常规内部测试的全量参考。基于上述设置，后文将分别从预测性能、解释忠实性和解释稳定性三个方面对本章方法进行分析。

3.6.1 预测性能比较

本节以第二章的 ResNet-50 影像基线为参照，评价引入显式概念层后的预测性能保持情况。比较重点在于：模型能否在保持整体判别能力的同时，将隐含影像特征转化为按放射学概念组织、能够进行贡献分析与干预的中间表示。

由表 3-2 可见，CBM 的平均测试 AUC 为 0.7079，与 ResNet-50 的 0.7146 仅相差 0.0067，两者的 AUC 标准差分别为 0.0105 和 0.0118。这表明，在本次内部

表 3-2 概念瓶颈模型与第二章端到端基线模型在测试集上的性能比较

模型	AUC	F1	敏感度	特异度
ResNet-50	0.7146 ± 0.0118	0.4177 ± 0.0893	0.4429 ± 0.2012	0.7827 ± 0.1661
CBM（本章方法）	0.7079 ± 0.0105	0.4836 ± 0.0120	0.7600 ± 0.1033	0.5071 ± 0.1020

测试中，引入概念瓶颈后，模型仍保持了与端到端影像基线接近的整体判别能力，平均 AUC 的差异较小。固定阈值 0.5 下，CBM 的 F1 从基线的 0.4177 提高至 0.4836，敏感度从 0.4429 提高至 0.7600，表现出更高的阳性检出能力；同时，特异度由 0.7827 降至 0.5071，说明检出更多 pCR 病例也伴随更多误报。

在预测性能接近的基础上，CBM 进一步提供了端到端基线所缺少的显式概念表示。ResNet-50 直接利用高维影像特征输出分类结果，而 CBM 通过预定义概念得分形成预测，并利用线性头将病例的分类得分分解为各概念的贡献。由此，可以查看哪些概念支持或抑制 pCR 预测，并通过修改概念得分观察输出变化，使预测过程具有更清晰的概念级分析路径。

因此，本节结果体现了概念瓶颈建模的主要价值：在平均 AUC 与 ResNet-50 接近的同时，增加可查看、可分解和可干预的中间表示，实现预测能力与概念级解释能力的结合。这一结果为采用 CBM 作为后续多模态建模的基础提供了依据。下文进一步通过概念置零与测试时扰动，分别评价这些概念对预测的作用及其输出稳定性。

3.6.2 解释忠实性分析

本节沿用前述 top-m 高贡献概念干预与 random-m 随机概念干预，分别取 $m = 3$ 和 $m = 5$，比较两种选择方式对预测概率和判别性能的影响，结果如表 3-3 所示。

表 3-3 基于概念干预的解释忠实性评价结果

干预规模 m	概念选择方式	$\mathbb{E}[\lvert\Delta p\rvert]$	$R_{0.05}$	ΔAUC
3	top-3	0.090	0.384	-0.024
	random-3	0.054	0.253	-0.013
5	top-5	0.132	0.512	-0.041
	random-5	0.079	0.347	-0.021

由表 3-3 可见，在两种干预规模下，针对高贡献概念实施干预均比随机概念干预引起更明显的预测变化。以 $m = 3$ 为例，top-3 概念干预对应的平均预

测概率变化幅度为 0.090，高于 random-3 干预的 0.054；预测概率变化超过 0.05 的病例比例分别为 38.4% 和 25.3%；AUC 分别下降 0.024 和 0.013。类似地，在 $m = 5$ 设置下，top-5 概念干预在三个指标上也均表现出更强的影响。

进一步比较 $m = 3$ 和 $m = 5$ 两种设置可见，top-m 干预的平均预测概率变化幅度从 0.090 增至 0.132，预测概率变化超过 0.05 的病例比例从 38.4% 增至 51.2%，AUC 下降幅度从 0.024 增至 0.041。这说明，随着被移除的高贡献概念数量增加，模型预测受到的影响进一步扩大，概念集合对病例级输出与整体判别表现均具有实际作用。

综合两种干预规模的结果，在移除相同数量概念的条件下，高贡献概念干预比随机概念干预引起更大的预测概率变化和 AUC 下降，表明这些高贡献概念对模型预测具有更强的影响。概念贡献排序由此为定位模型依赖的中间证据提供了依据，使病例级决策能够通过具体概念的贡献及其移除效果进行追踪和分析。这体现了概念瓶颈模型在预测结果之外提供可分析、可干预决策路径的价值。

3.6.3 概念稳定性与覆盖率分析

本节从病例级概念输出的稳定性及其质量控制用途两个方面展开分析。对每个测试病例，在保持模型参数固定的条件下进行 $T = 20$ 次测试时增强推理，统计各概念得分的波动，并以平均标准差 U_{mean} 作为病例级稳定性指标。该指标越小，表示同一病例在轻微输入扰动下的概念得分越一致。通过这一评价，可以进一步分析模型在给出概念解释时，哪些病例具有较稳定的概念证据。

测试集中，U_{mean} 的均值与标准差为 $(0.992 \pm 0.494) \times 10^{-3}$，第 10、50 和 90 百分位数分别为 0.505×10^{-3}、0.844×10^{-3} 和 1.607×10^{-3}。上述统计描述了病例间概念波动的差异：中位数低于均值，而第 90 百分位数接近第 10 百分位数的 3.2 倍，说明在概念得分波动较小的病例之外，还存在一部分波动相对较高的病例。稳定性得分因此为区分不同病例的概念输出一致性提供了量化依据。

为进一步考察稳定性指标能否用于预测质量控制，按 U_{mean} 从小到大对病例排序，按 50%、70% 和 90% 的目标覆盖率从低波动到高波动依次保留病例。覆盖率表示参与评价的病例占比，例如 50% 覆盖率对应保留概念输出最稳定的一半病例。各子集的分类阈值均固定为 0.5，筛选依据为概念波动大小，分类规则保持一致。三档筛选子集的结果见表 3-4。表中 100% 行列出表 3-2 的 CBM 全量测试指标，作为参考。

在表 3-4 的三档子集中，50% 覆盖率对应最高的 AUC 和 F1，分别为 0.743

表 3-4 基于概念稳定性筛选的覆盖率与预测性能

覆盖率（%）	AUC	F1	SEN	SPE
50	0.743	0.581	0.600	0.788
70	0.726	0.558	0.600	0.766
90	0.704	0.471	0.522	0.746
100	0.708	0.484	0.760	0.507

和 0.581。覆盖率扩大至 70% 和 90% 时，AUC 分别为 0.726 和 0.704，F1 分别为 0.558 和 0.471。敏感度在 50% 和 70% 覆盖率下均为 0.600，在 90% 时降至 0.522。

三档子集的指标受各自病例构成影响。若要量化按概念波动筛选相对于全量评价的性能变化，需使用同一组逐病例预测计算全量和子集指标。

3.6.4 全局与病例级概念分析

在预测性能、概念干预和稳定性评价的基础上，本节进一步通过全局权重图与病例贡献图展示模型的决策依据。全局分析观察同一预测头对各概念得分的权重分配，用于理解模型总体采用的证据方向；病例分析则结合某一患者的概念得分，计算各概念对该次预测的实际贡献。两类图分别对应模型参数与病例输出，能够从不同层面呈现概念瓶颈预测的计算过程。

图 3-4 展示了解释实验模型的线性概念头权重。正权重表示在其他概念得分保持不变时，提高该概念得分会增加 pCR 分类得分，负权重则对应相反方向。图中肿瘤边界不清、非肿块样强化等概念具有正权重，明显背景强化、强化异质性等概念具有负权重。权重反映模型使用概念得分的方式，而单个病例的实际贡献还取决于该病例的概念得分，因此需要结合乘积 $a_{i,k} = w_k c_{i,k}$ 进一步分析。

图 3-5 展示了一个模型判为非 pCR 的病例。左侧为增强前、早期增强和减影输入，中间为该病例的概念贡献，右侧为分类结果。横轴零点两侧分别呈现支持和抑制 pCR 预测的贡献，使读者能够同时观察不同方向的证据。该病例中，明显背景强化与强化异质性的贡献偏向非 pCR，非肿块样强化的贡献则偏向 pCR。模型将各项贡献与偏置组合后形成最终分类得分，病例图由此把中间概念与输出判定连接起来。

全局权重与病例贡献的排序可以不同，因为后者同时由权重和病例概念得分决定。结合两张图，可以先了解模型对各概念的总体使用方向，再查看这些概念在具体病例中实际产生了多大影响，从而把参数层面的解释与病例层面的

证据分析联系起来。

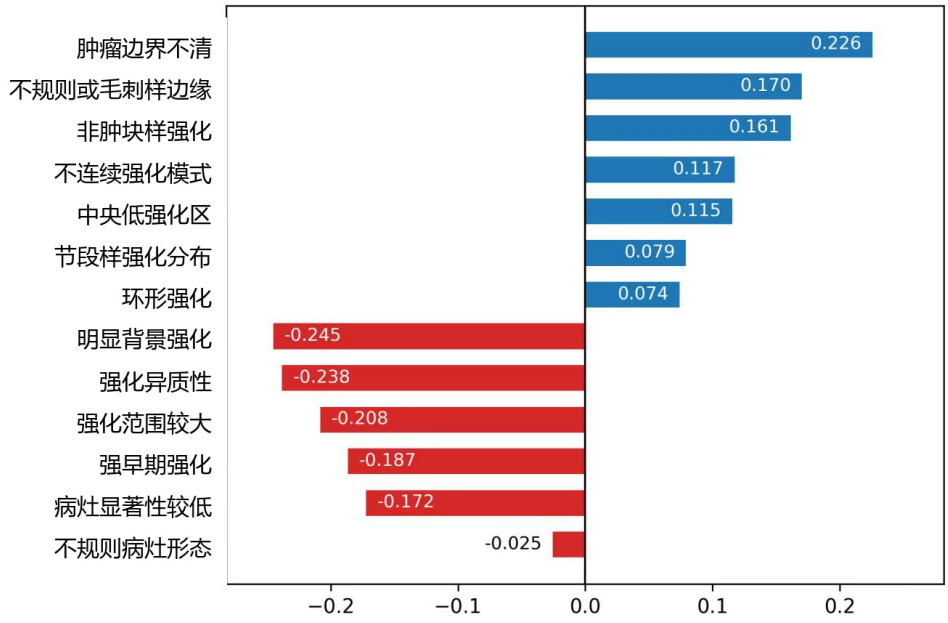


图 3-4 解释实验模型的线性概念头权重

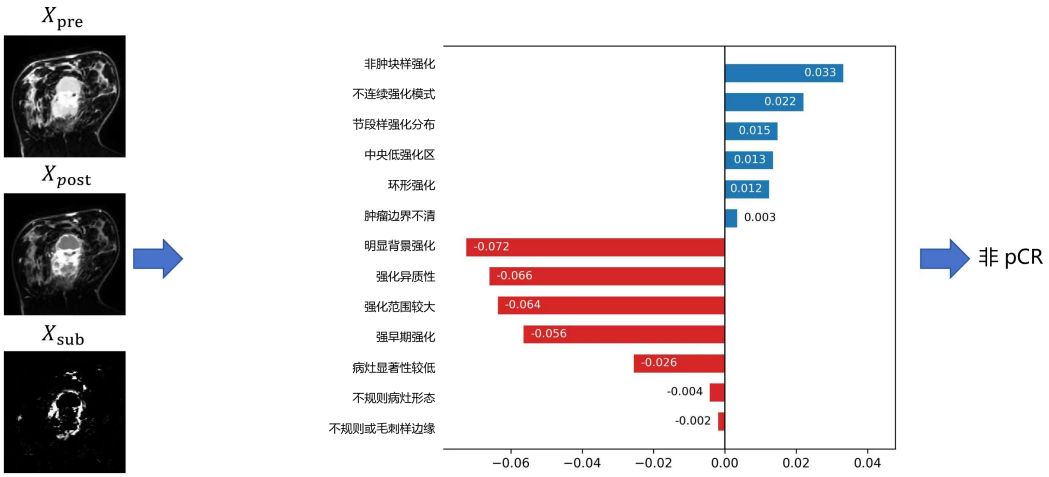


图 3-5 代表性病例的 MRI 输入及概念贡献

3.7 本章小结

本章围绕治疗前乳腺 DCE-MRI 的可解释 pCR 预测问题，构建了基于投影式概念瓶颈的可解释预测模型。首先，在第二章纯 MRI 预测基线模型的基础上，分析了黑盒模型在医学语义表达和解释可验证性方面的不足；随后，面向治疗前双时相 DCE-MRI 场景构建了由 13 个放射学概念组成的概念集合，并利用 PMC-CLIP 文本编码器建立固定概念嵌入空间；在此基础上，通过冻结 3D ResNet 主干、学习影像到文本概念空间的线性投影以及线性概念头，构建了“影

像—概念—预测结果”的可解释推理路径。

在模型评价方面，本章不仅分析了常规分类性能，还进一步从解释忠实性和解释稳定性两个角度建立了概念解释评价体系。实验结果表明，概念瓶颈模型与 MRI 基线的平均 AUC 接近。在固定阈值 0.5 下，CBM 的 F1 和敏感度更高，MRI 基线的特异度更高。进一步的概念干预实验表明，对高贡献概念进行置零所引起的预测概率变化和整体 AUC 下降均明显强于随机概念干预，说明模型给出的概念证据确实参与了最终决策。测试时增强实验量化了同一病例概念得分在输入扰动下的波动。在三档筛选子集中，概念波动最小的 50% 子集具有最高 AUC 与 F1。表中 100% 行提供常规全量测试参考，筛选相对于全量的性能变化仍需用同一组逐病例预测核对。进一步的全局与病例级分析分别展示了线性头的概念权重和具体病例的概念贡献，将模型总体的证据使用方向与单次预测的得分构成联系起来。

总体来看，本章实现了从第二章“能够预测”的纯 MRI 黑盒模型，到“既能预测又能给出可测试概念证据”的可解释模型的关键推进。通过显式构建概念层并建立相应的验证机制，本章不仅提升了模型结果的可读性，也为后续进一步引入临床结构化信息开展多模态概念调制建模提供了基础。

第 4 章 融合临床信息的多模态概念瓶颈 pCR 预测研究

4.1 引言

第二章建立了治疗前乳腺 DCE-MRI 的 pCR 预测基线，第三章进一步将影像表征映射到固定的放射学概念空间，形成“影像–概念–预测”的计算路径。在这一基础上，本章研究临床结构化信息如何与影像概念共同参与预测。影像侧提供病灶形态、强化模式等中间表征，临床侧提供受体状态、分子风险和患者背景。两类信息的来源和表达形式不同，融合模型需要同时回答信息如何接入、如何影响最终得分，以及不同接入方式对应怎样的预测表现。

本章比较临床信息参与概念瓶颈预测的两种方式。在直接融合模型中，影像概念得分与临床变量拼接后送入线性预测头。预测头分别计算影像概念和临床变量的贡献，再将两部分相加。以“环形强化”为例，若两名患者的这一概念得分相同，则该概念在同一个直接融合模型中的贡献也相同，临床变量通过单独的加性项影响预测总分。在门控模型中，选定的临床变量用于为每个概念生成一个缩放系数，再将调整后的概念得分送入预测头。即使两名患者的原始概念得分相同，临床背景不同也可能使模型赋予“环形强化”不同大小的贡献。

本章将上述问题组织为三个递进层次。首先，在单模态模型的基础上引入临床直接融合，观察临床信息能否补充影像特征或概念表示。其次，构建临床门控调制模型，使所选临床变量仅通过概念重标定参与预测，以研究受临床背景约束的概念通路。最后，在门控之外增加一条直接参与预测的临床分支，并比较该分支的两种输入形式。一种直接使用编码后的 18 维临床向量，另一种通过含 ReLU 激活的网络将同一临床向量转换为 128 维特征。两种配置都由门控调整影像概念的贡献，并将临床分支的得分加到预测总分中。

在 I-SPY2 训练集中，本章先按 HR 和 HER2 状态分组，比较各组的 pCR 比例，再考察临床变量与影像概念得分的探索性关联，分别为直接融合和门控设计提供参考。内部测试比较八种配置的重复实验汇总，并在固定阈值 0.5 下重点分析两种联合模型的漏报与误报。模型部分还给出在 logit 尺度上分解预测得分的方法，以区分基础概念贡献、门控增量和直接临床贡献。

外部评价先说明 Duke 队列的影像输入分布和可用临床字段，再考察

MammaPrint 70 基因表达分层（MP）不可获得时的两种方案。第一种方案冻结完整模型的一组权重，对 MP 两种取值的预测进行概率加权，并在 I-SPY2 设置配对遮蔽对照。第二种方案在 I-SPY2 上仅使用两队列共有字段重新训练，再分别在 I-SPY2 测试集和 Duke 队列评价，以考察当前输入条件下的跨队列表现。

4.2 临床变量编码

本章沿用第二、三章的 I-SPY2 治疗前 T0 阶段 DCE-MRI 队列、pCR 标签及患者级数据划分。949 例病例中，训练集 759 例、验证集 95 例、测试集 95 例。相应 pCR 例数分别为 254、30 和 25。原始临床信息取自 TCIA 随 I-SPY2 Imaging Cohort 1 公开发布的配套临床数据表[7]。本文按患者编号将临床记录与影像、掩码及 pCR 标签对应，同一患者的全部数据归入同一数据子集。

临床向量由筛查年龄、HR 状态、HER2 状态、MP、族裔、种族和绝经状态等字段构成。年龄来自原始 Age_at_Screening 字段，单位为岁，在临床向量中保留数值形式。HR 和 HER2 均沿用原始二值状态，0 表示阴性，1 表示阳性；MP 保留原始临床表中的 0/1 编码。种族采用多标签二值编码（multi-hot），绝经状态采用互斥类别的 one-hot 编码。各维度的取值与解释见表 4-1，每例病例最终对应 $v \in \mathbb{R}^{18}$。

在临床输入的时间含义上，年龄对应筛查阶段的患者背景，HR、HER2 和 MammaPrint 则属于 I-SPY2 试验在基线阶段评估、用于患者分型和随机分组的生物标志物[7,37]。这些变量描述患者背景及治疗前肿瘤特征，术后获得的 pCR 字段提供模型训练与评价所用的结局标签。

年龄缺失时，使用纳入队列中非缺失年龄的全局中位数 49 岁进行填补；另设 age_was_imputed，填补时取 1，原始年龄可用时取 0。这样既保留年龄数值输入，也单独标识该数值是否来源于填补。当前 949 例病例中有 3 例采用该年龄填补方式。MP 在本队列中没有缺失；其在 Duke 外部队列不可获得时的处理另见第 4.7 节，不将 MP 的 0 编码解释为缺失。分类字段的缺失按其各自编码处理，不统一使用年龄中位数规则：种族缺失或无法归入已定义类别时使用未知类别，绝经状态缺失或未识别时使用 meno_unknown。

编码后的维度与临床字段数量并不相同。例如，绝经状态由多个互斥类别表示，每个类别占用一个维度，缺失或未知状态也有相应编码。这样的处理使类别取值具有固定输入位置，避免直接把类别编号当作连续数值使用。模型中的“18 维临床向量”始终指这套统一编码，而非 18 项彼此独立的临床检查。

表 4-1 本章采用的临床结构化变量

类别	变量名称	说明
连续变量	age	筛查年龄，单位为岁；缺失填补为 49。
肿瘤生物学信息	HR	激素受体状态：0 为阴性，1 为阳性。
肿瘤生物学信息	HER2	HER2 状态：0 为阴性，1 为阳性。
肿瘤生物学信息	MP	MammaPrint 分层，保留原始 0/1 编码。
族裔信息	ethnicity_bin	族裔字段的二值数值输入，取值为 0/1。
种族信息	race_white	1 表示包含白人类别，0 表示不包含。
种族信息	race_black	1 表示包含黑人类别，0 表示不包含。
种族信息	race_asian	1 表示包含亚洲人类别，0 表示不包含。
种族信息	race_pacific_islander	1 表示包含夏威夷原住民或太平洋岛民类别。
种族信息	race_native_american	1 表示包含美洲印第安人或阿拉斯加原住民类别。
种族信息	race_unknown	1 表示种族未知，0 表示已有类别信息。
绝经状态	meno_pre	1 为绝经前，0 为其他类别。
绝经状态	meno_peri	1 为围绝经期，0 为其他类别。
绝经状态	meno_post	1 为绝经后，0 为其他类别。
绝经状态	meno_na_gt50	1 为原记录的上述类别不适用且年龄大于 50 岁。
绝经状态	meno_na_lt50	1 为原记录的上述类别不适用且年龄小于 50 岁。
绝经状态	meno_unknown	1 为缺失或未知，0 为已归入其他类别。
缺失指示	age_was_imputed	1 为年龄经过填补，0 为原始年龄可用。

种族各维度分别表示是否包含对应类别。对于原始记录中的混合种族，多个维度可同时取 1，因此不将这六维解释为互斥的 one-hot 向量。夏威夷原住民与太平洋岛民归入同一编码，美洲印第安人与阿拉斯加原住民归入同一编码；未归入的维度取 0。未知类别用于表达缺失或未识别的种族记录，与已有明确类别的病例区分。

绝经状态的三个主要类别沿用原始记录的条件。绝经前对应距末次月经不足 6 个月、无双侧卵巢切除史且未接受雌激素替代治疗；围绝经期对应距末次月经 6–12 个月、无双侧卵巢切除史且未接受雌激素替代治疗；绝经后对应已有双侧卵巢切除史，或距末次月经超过 12 个月且无既往子宫切除史。这些条件用于解释临床表已有分类，本文按原字段归类，不根据其他变量重新诊断绝经状态。

此外，原记录包含“上述类别不适用且年龄大于 50 岁”和“上述类别不适用且年龄小于 50 岁”两类，分别映射为 meno_na_gt50 与 meno_na_lt50。它们表示原始临床类别不适用，不能等同于绝经状态缺失后按年龄进行的推断。实际缺失或未识别的记录映射为 meno_unknown。六个绝经状态维度采用 one-hot 表示：对应类别取 1，其余取 0。

完成临床变量编码后，下一节分别考察临床背景与 pCR 结局分布、影像概念得分之间的关系，为后续设计临床信息的接入方式提供参考。

4.3 临床背景与概念关联

I-SPY2 研究团队开展的多特征 MRI 研究联合分析了功能性肿瘤体积、病灶最长径、球形度及对侧背景实质强化，并观察到模型预测表现随 HR/HER2 亚型而变化[51]。这一结果提示，在研究影像表型与治疗反应的关系时，有必要同时考虑肿瘤生物学背景。本节分析临床变量与影像概念得分的关联，后续通过不同融合配置比较临床信息直接参与预测和调节概念贡献时的表现。

4.3.1 受体分层与 pCR 分布

临床背景可能直接携带结局相关信息，也可能与影像中间表示有关，两者需要分别观察。首先按 HR、HER2 二值状态对 759 例训练病例分组，表 4-2 给出各组病例数与观察 pCR 比例。HR 阴性、HER2 阳性组的比例为 63.8%，HR 阳性、HER2 阴性组为 17.4%，其余两组约为 39% 至 40%。这些比例说明本队列不同受体组合的结局分布不同，为保留临床信息的直接预测通路提供了数据层面的动机。

表 4-2 按 HR 和 HER2 状态分层的 pCR 分布

HR 状态	HER2 状态	病例数	pCR 例数	pCR 比例
阴性	阴性	282	113	40.1%
阴性	阳性	69	44	63.8%
阳性	阴性	287	50	17.4%
阳性	阳性	121	47	38.8%
合计		759	254	33.5%

HR 阴性、HER2 阳性组有 44 例达到 pCR，少于 HR 阳性、HER2 阴性组的 50 例。但前一组总人数较少，因此组内 pCR 比例反而更高，分别为 44/69（63.8%）和 50/287（17.4%）。这两组的 HR 和 HER2 状态同时不同，实际接受的治疗方案也可能不同，因此这里以受体组合为单位描述本队列的 pCR 分布。后续在同一测试集上比较影像模型与加入临床信息的模型，评价临床信息能否为影像预测提供补充。

4.3.2 临床变量与概念得分关联

本节沿用上一小节的病例。利用第三章的概念瓶颈模型，为每例病例的MRI计算 13 个放射学概念的得分，再按病例编号将这些得分与该患者的临床记录匹配。得分越高，表示该病例的影像投影在模型空间中越接近对应的概念文本向量。下文先用同一统计量比较各临床指标与概念得分的关联程度，再分析不同临床类别之间的得分差异。

为在同一尺度上比较各候选指标，本文利用已有的病例级概念得分和临床记录补充计算 Spearman 秩相关系数。对年龄及每个可比较的二值编码，分别计算该指标与 13 个概念得分的相关系数。

$$\rho_{jk} = \mathrm{corr}_{\mathrm{Spearman}}(v_j, c_k). \tag{4-1}$$

其中，v_j 表示第 j 个临床指标，c_k 表示第 k 个概念的得分。系数为正表示年龄较大或编码为 1 的病例倾向于得分较高，负值表示相反趋势。绝对值越接近 1，排序关联越强。对每个临床指标，将其 13 个相关系数先取绝对值再求平均，以概括该指标与整组概念得分的关联程度。

图 4-1 汇总年龄和 16 个二值编码的秩相关系数，概念编号见表 3-1。色块显示各概念的相关系数，最右列显示 13 项绝对相关系数的均值，各行据此由高到低排列。族裔编码只有一个取值，无法计算相关系数。

以第 7 列“非肿块样强化”为例，HR 的相关系数为 +0.109，表示阳性组病例倾向于得分较高。年龄的相关系数为 −0.055，表示年龄较大的病例倾向于得分略低。比较各指标与整组概念的关联时，读取图的最右列。HR、MP 和绝经后编码的平均绝对相关系数分别为 0.1087、0.0858 和 0.0820，位于前三，年龄和 HER2 分别为 0.0540 和 0.0334。整体相关程度较弱，排序用于观察本队列内的相对差异。

图 4-1 的秩相关结果用于比较候选指标的关联强弱。为了具体说明较靠前指标对应的得分差异，下面再看二值编码为 1 和 0 的两组病例。组间均值差定义为

$$\Delta_{jk} = \mathrm{E}(c_k \mid v_j = 1) - \mathrm{E}(c_k \mid v_j = 0). \tag{4-2}$$

均值差为正表示编码为 1 的组平均得分更高，负值表示该组平均得分更低。本文采用 Mann–Whitney U 检验比较两组病例按概念得分排序后的位置。原始 p 值用于辅助判断这种排序差异的统计证据。

图 4-2 分别展示 HR、MP 和绝经后编码的一个比较实例。柱高表示组均值，

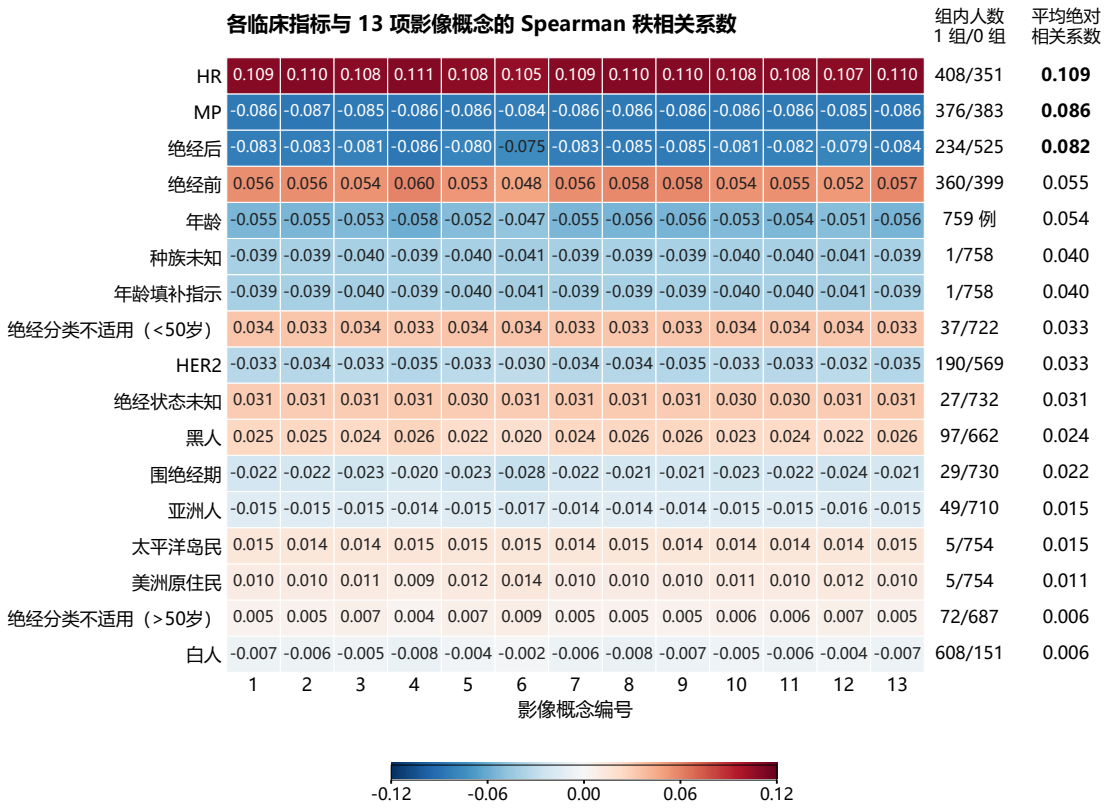


图 4-1 临床指标与影像概念得分的秩相关比较

误差线表示组内标准差，标注的 p 值由 Mann–Whitney U 检验得到。

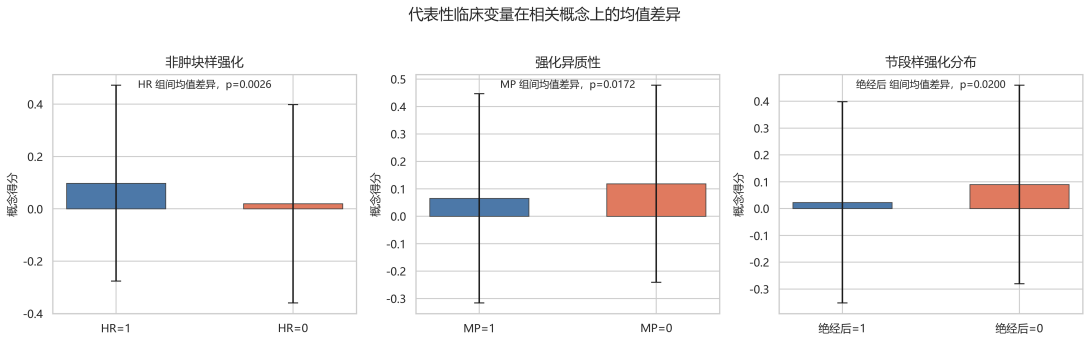


图 4-2 代表性临床分组的概念均值比较

HR=1 组在“非肿块样强化”概念上的平均得分较高；MP=1 组在“强化异质性”上的平均得分较低；绝经后编码为 1 的组在“节段样强化分布”上的平均得分也较低。标准差描述组内个体差异，不是均值估计的置信区间（confidence interval，CI）。图中的三个组合用于具体展示得分变化，不能代替全部变量与概念的检验结果。

同时进行多项检验时，偶然出现较小原始 p 值的机会也会增加。本文对年龄的 Spearman 检验和二值编码的 Mann–Whitney U 检验共 221 项结果统一进行

Benjamini–Hochberg 校正。表 4-3 列出图 4-2 中三个代表性组合的样本量、均值差、原始 p 值和校正 q 值。

表 4-3 代表性临床变量与模型概念得分的探索性关联

临床变量	模型概念	n_1/n_0	均值差	原始 p	校正 q
HR	非肿块样强化	408/351	+0.0783	0.0026	0.0586
MP	强化异质性	376/383	−0.0528	0.0172	0.1496
绝经后编码	节段样强化分布	234/525	−0.0662	0.0200	0.1496

以 HR 与“非肿块样强化”为例，该项的原始 p 值为 0.0026，即假设两组得分分布相同，出现与本次一样明显或更明显的排序差异的概率约为 0.26%。对所有变量与概念组合进行多重比较校正后，该项的 q 值为 0.0586。本次校正后各项检验均未达到 $q < 0.05$，因此将这些组间差异作为探索性观察。尤其是绝经后编码为 0 的组包含其他多种状态，不能将其全部解释为绝经前人群。这样的统计界定保留了图表对于模型设计的启发作用，也使关联结论与实际检验范围一致。

受体分层显示不同临床背景下的 pCR 比例存在差异，为临床信息直接参与预测提供了依据。概念关联分析进一步引出了门控设计的问题。以“非肿块样强化”为例，HR 阳性组的平均概念得分较高，因此相同的得分在两组各自的分布中可能处于不同的相对位置。本章据此考察，在影像概念得分相同的情况下，允许模型根据患者的临床背景调整该概念的贡献幅度，能否改善 pCR 预测。

本章采用 HR、MP 和绝经状态作为固定门控组合。补充比较表明，HR、MP 和绝经后编码与整组影像概念的排序关联在候选指标中相对靠前，为考察这一组合提供了依据。HR 和 MP 分别提供受体状态和分子风险信息，绝经后编码的结果支持将绝经背景纳入考察。建模时保留完整的绝经状态编码，使门控网络可以区分绝经前、围绝经期、绝经后等类别。组间检验及校正结果用于辅助解读这些关联，门控的预测表现由后续模型实验评价。

从同一病例的完整临床向量 v 中提取 HR 和 MP 的两个二值编码，以及绝经状态的六个编码维度，组成 8 维门控输入 v_g。模型通过 v_g 生成用于调整各概念贡献的系数。完整的 18 维向量 v 用于临床单模态模型，以及影像特征融合、概念直接融合和两类联合融合模型中的直接临床分支。

HER2、年龄、种族和族裔等字段均保留在完整临床向量中。仅门控模型使用选定的 8 维临床输入，联合模型同时使用门控输入与完整临床向量。

4.4 临床信息融合模型

上一节确定了临床信息的两种输入形式，即完整的 18 维临床向量 v 和用于生成门控的 8 维临床子集 v_g。本节在第三章的概念瓶颈模型上比较两种使用方式。完整临床向量可为 pCR 预测提供一项直接得分，门控输入则用于调节各影像概念的贡献。联合模型同时使用这两条通路。

各概念模型沿用第三章定义的 13 个放射学概念。记治疗前 MRI 及对应肿瘤掩码为影像侧输入 x，影像编码器得到病例表征 $h = f_{\text{img}}(x)$。概念模型将 h 投影到文本嵌入空间，再与第三章的固定概念向量 e_k 计算余弦相似度。

$$z = \frac{W_f h}{\|W_f h\|_2}, \qquad c_k = z^\top \frac{e_k}{\|e_k\|_2}, \quad k = 1, \ldots, 13. \tag{4-3}$$

其中，z 为归一化后的影像投影，c_k 为第 k 个概念的相似度得分。本文沿用无需逐例概念标注的建模思路[25-26]，各配置使用相同的概念名称和固定文本向量，并在各自的融合结构下学习投影及预测参数。

为比较引入临床信息前后的预测表现，本章保留第二章的影像基线（ResNet）和第三章的概念瓶颈基线（CBM）。前者由影像表征 h 直接预测，后者通过线性头将概念得分 c 转为分类得分 $s = b + w^\top c$，再经 Sigmoid 函数得到概率 $p = \sigma(s)$。此外，临床单模态基线（Clinical）使用完整临床向量，通过多层感知机（multilayer perceptron，MLP）完成预测。影像特征与临床特征融合基线（ResNet + Clinical-128）沿用前期 ResNet 与临床信息融合实验中表现最好的 128 维临床嵌入配置。该模型将完整的 18 维临床向量编码为 128 维特征，再与 2048 维影像表征拼接后送入非线性预测头，作为本章的影像特征层融合对照。概念层的 Clinical-18 配置则将 18 维临床编码直接接入预测头，以便逐项解释原始临床变量的贡献。

在这些对照的基础上，下文依次介绍临床直接融合、门控调制和两者的联合模型，最后说明如何分解单例病例的预测得分。

4.4.1 临床直接融合与门控调制

概念与临床直接融合模型（CBM + Clinical-18）将 13 维概念得分 c 与 18 维临床向量 v 拼接后送入线性预测头，其分类得分和预测概率分别为

$$s_C = b_C + w_C^\top c + \beta_C^\top v, \qquad p_C = \sigma(s_C). \tag{4-4}$$

这里预测头接收 31 维拼接表示，w_C 和 β_C 分别对应概念与原始临床变量。固定

模型参数后，临床变量通过加性项改变得分，而概念项的系数不随临床输入变化。对于 one-hot 维度，临床项还可按实际编码分组汇总，便于检查特定病例的得分来源。

直接融合的优势是保留临床信息的独立预测机会。例如，某个变量可能与结局有关，却不必与某一概念得分存在明显单变量关联。该变量仍可通过直接通路发挥作用。其约束在于最终线性形式没有显式包含临床与概念的乘积项，因而不能仅靠这一加性头表达患者背景对某一概念系数的条件改变。这一结构特点引出下一步门控设计。

临床门控调制模型（CBM + Gate）利用选定的临床变量调节各影像概念的贡献。门控输入 $v_g \in \mathbb{R}^8$ 经过层归一化、全连接层、ReLU、dropout、第二个全连接层和 Sigmoid，生成 13 维门控向量。调制网络中间层为 64 维，概念重标定和输出为

$$r = \psi(v_g), \quad r_k \in (0,1), \qquad c' = c \odot (\mathbf{1} + r), \qquad s_G = b_G + w_G^{\top} c'. \tag{4-5}$$

临床向量不再与 c' 拼接，最终预测头仍只接收 13 维概念表示。临床输入在该模型中只通过 $v_g \to r \to c' \to s_G$ 影响预测，因此能够在结构上保持概念通路作为最终决策的接口。

这一设计与条件特征调制思想相联系。FiLM 根据条件信息对特征执行逐维仿射变换[52]；本章采用其中乘性条件调节的思路，在概念层使用有界残差缩放，没有增加条件平移项。保留 c 的残差形式使每个概念维度始终对应原来的文本锚点，不因临床输入变化而混合成新的概念维度。

必须结合实现理解门控的数学含义。由于 $1 + r_k \in (1,2)$，它不是将概念乘以一个 0 到 1 的抑制系数，也不能直接把某个概念的贡献符号反转。对同一训练模型，概念有效系数为

$$\widetilde{w}_k(v_g) = w_{G,k}[1 + r_k(v_g)]. \tag{4-6}$$

不同临床背景可以得到不同的贡献幅度。若 $w_{G,k}c_k > 0$，较大门控强化正向支持；若 $w_{G,k}c_k < 0$，则强化负向支持。门控值大不等于 pCR 概率高，必须同时考虑概念得分和预测头权重。

在保持模型参数不变时，临床背景从 v_g 改为 $\bar{v}_g$，且固定原始概念向量，得分变化可写为

$$\Delta s_G = \sum_{k=1}^{13} w_{G,k}c_k\{r_k(\bar{v}_g) - r_k(v_g)\}. \tag{4-7}$$

该式说明临床背景的作用由现有概念贡献承载：若某维概念贡献接近零，即使该门控变化较大，对总得分的影响也可能很小。这是模型计算关系的推导，不把改变临床编码解释为真实临床干预。

仅门控提供了有约束的融合形式，但也限制了临床信息的使用方式。某些独立临床信息若不能通过所选概念及其调制表达，就不会形成额外的加性预测项。因此，门控的优势在于显式建模条件交互和保留概念接口，而不是理论上保证高于直接融合。由此进一步考虑同时保留直接通路。

4.4.2 门控与临床联合融合

门控与原始临床变量联合融合模型（CBM + Gate + Clinical-18）在门控调制的基础上，将完整的 18 维临床向量 v 与调制后的概念得分拼接。预测头将两条通路的贡献相加，得到分类得分

$$s_{GR} = b_{GR} + w_{GR}^{\top}[c \odot (\mathbf{1} + \psi(v_g))] + \beta_{GR}^{\top} v. \tag{4-8}$$

预测头接收 $[c', v]$，共 31 维。HR、MP 和绝经状态既可通过门控影响概念项，也可作为完整临床向量的一部分提供直接贡献；其余临床变量通过直接通路参与。两条路径承担不同计算功能，不将其合并解释为同一种作用。

与仅门控相比，这一配置恢复了完整临床信息的独立表达；与 CBM + Clinical-18 相比，它又使概念系数依赖患者背景。由于最终头对拼接输入仍为线性形式，可以分别列出每个概念项和每个原始临床项。然而，从全部原始输入到结果的映射包含门控非线性及乘积，因此不能将整个模型称为纯线性模型。

原始临床通路的权重具有明确的编码对应关系，但变量量纲不同。例如年龄与二值状态的数值尺度不同，不能仅按系数绝对值比较临床重要性。病例级解释应结合实际取值计算贡献，并说明 one-hot 组的编码含义。

门控与临床嵌入联合融合模型（CBM + Gate + Clinical-128）沿用相同的门控变量。在直接临床分支中，先用含 ReLU 激活的网络对 18 维临床向量进行非线性变换，得到 128 维临床特征。其特征生成与预测过程为

$$h_c = \phi_G(v) \in \mathbb{R}^{128}, \qquad s_{GE} = b_{GE} + w_{GE}^{\top} c' + u_{GE}^{\top} h_c. \tag{4-9}$$

ϕ_G 对完整 18 维临床向量执行层归一化、$18 \to 128$ 全连接映射、ReLU 与 dropout，再通过 $128 \to 128$ 全连接和 ReLU 输出。拼接后的预测头输入为 141 维，最终仍输出一个二分类得分。

联合模型的临床嵌入输出维度设为 128，与前期 ResNet 融合基线的临床特

征宽度一致。CBM + Clinical-18 与 CBM + Gate + Clinical-18 使用完整的 18 维原始编码，便于逐项分解临床变量的直接贡献。

嵌入分支允许临床变量在进入最终头之前组合形成非线性表示，能够表达原始线性分支之外的临床组合模式。相应地，128 个潜在维度通常不再逐一对应 HR、年龄或某个绝经类别。解释时应将 $u_{GE}^{\top}\phi_G(v)$ 作为临床直接分支总贡献，与概念项和门控增量区分，不能把某个嵌入维度直接冠以原始变量名称。

这三类门控配置形成从受约束概念通路，到保留原始独立证据，再到非线性临床表达的递进关系。它们具有不同表示能力和解释粒度。结构更复杂意味着可表达关系增加，也意味着更多参数和不同的优化条件，因此性能排序应由实测结果确定。

图 4-3 展示三种概念融合方式中各向量的流向。直接融合把概念与临床向量拼接后送入预测头。仅门控先根据临床子集生成缩放系数，再将调制后的概念送入预测头。联合融合在调制后的概念之外，还接入完整临床向量或其嵌入表示。

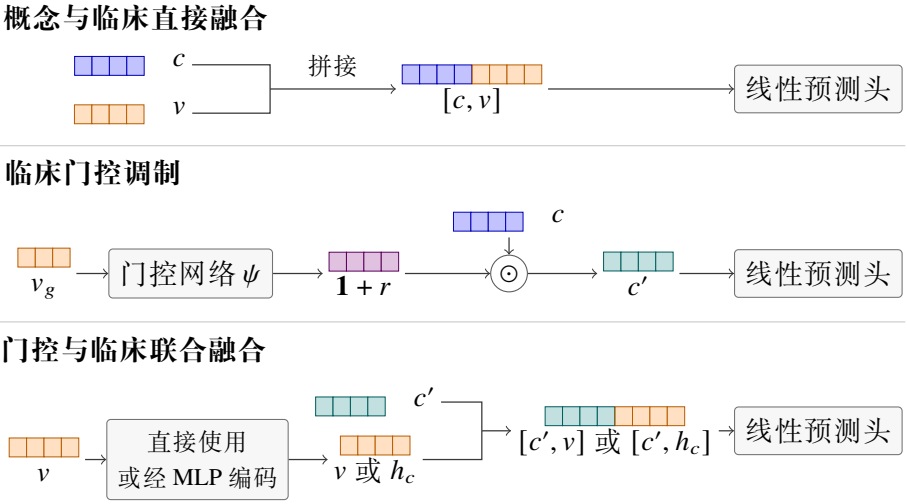


图 4-3 概念模型的直接融合、门控调制与联合融合路径

表 4-4 汇总本章使用的八种配置，便于对照临床信息的接入位置和预测头接收的表示。表中所列维度均为最终预测头的输入维度。各模型输出一个 pCR 分类得分，并经 Sigmoid 函数转换为预测概率。

表 4-4 模型命名、临床信息路径与预测表示

模型	临床信息接入方式	预测表示及输入维度
ResNet	无临床通路	影像表征 h，2048 维
Clinical	仅完整临床向量	临床多层感知机表征
ResNet + Clinical-128	完整临床向量编码后直接融合	$[h, \phi_R(v)]$，2048 + 128 = 2176 维
CBM	无临床通路	概念 c，13 维
CBM + Clinical-18	原始临床变量直接融合	$[c, v]$，13 + 18 = 31 维
CBM + Gate	临床子集仅生成门控	调制概念 c'，13 维
CBM + Gate + Clinical-18	门控与原始临床联合融合	$[c', v]$，13 + 18 = 31 维
CBM + Gate + Clinical-128	门控与临床嵌入联合融合	$[c', \phi_G(v)]$，13 + 128 = 141 维

4.4.3 预测贡献分解

为统一解释 CBM + Gate、CBM + Gate + Clinical-18 和 CBM + Gate + Clinical-128，记直接临床贡献为 $d(v)$。仅门控有 $d(v) = 0$，原始联合配置有 $d(v) = \beta^\top v$，嵌入联合配置有 $d(v) = u^\top \phi_G(v)$。对每个已训练模型分别使用其自身参数，可写出

$$s = b + \sum_{k=1}^{13} w_k c_k + \sum_{k=1}^{13} w_k c_k r_k + d(v). \tag{4-10}$$

式中，b 为截距，w_k 为线性预测头的第 k 个概念权重，c_k 为该概念的原始得分，r_k 为门控网络输出的对应调节量。第二项是各概念的基础贡献之和，第三项是门控带来的贡献增量之和，$d(v)$ 为临床分支的直接贡献。第 k 个概念的总贡献为 $a_k = w_k c_k (1 + r_k)$，门控增量为 $m_k = w_k c_k r_k$。它们均位于 logit 尺度。Sigmoid 为非线性函数，不能将各项分别转换成概率后相加，也不能将一个正向 logit 贡献直接描述为固定增加若干个百分点的 pCR 概率。

贡献分解具有明确的复核条件：截距、基础概念项、门控增量与临床项之和必须重构该病例的模型 logit，再经 Sigmoid 还原其预测概率。只有来自同一权重、同一次病例评估的中间输出才能用于这一计算。这一条件用于核对分解得到的各项贡献之和与实际预测得分是否一致。

此外，模型内分解与跨模型性能比较不同。前者在固定模型内追踪一例预测的组成；后者比较各自训练后的整体表现，投影、门控和头权重均可能变化。某个模型内的门控增量较大，不代表去掉门控并重新训练后性能必然下降同样幅度。因此，性能比较用于评价不同模型配置，预测得分分解用于说明各通路

在同一模型中的计算作用。

4.5 实验设置

本章使用与前两章对应的患者级训练、验证和测试病例。所有影像配置均采用增强前相、增强后早期相和减影图组成的三通道输入，并沿用肿瘤掩码和预处理流程。所有概念模型使用相同的 13 个概念名称及固定文本嵌入，以保证比较围绕同一概念接口展开。临床变量按表 4-1 编码，门控变量按本章定义提取，不根据测试病例重新选择。

表 4-4 的八种配置对应三个比较问题。首先，保留 ResNet、CBM 和 Clinical 作为对照，分别考察影像特征、影像概念和临床信息单独预测时的表现。再将 ResNet + Clinical-128 与 ResNet 比较，观察临床特征与高维影像特征直接拼接后的表现，为概念层融合提供参照。

其次，在概念层以 CBM 为共同基线，比较 CBM + Clinical-18 和 CBM + Gate。前者检验完整临床向量通过直接分支能否补充概念证据，后者考察所选临床变量仅通过调节概念贡献参与预测时的表现。

最后，引入 CBM + Gate + Clinical-18 和 CBM + Gate + Clinical-128，考察在门控基础上增加直接临床分支后，预测表现如何变化。两种联合配置采用相同的门控变量，直接分支分别使用 18 维原始编码和 128 维临床嵌入，用于比较两种临床表示方式。

内部性能表汇总各配置已有的重复实验结果，报告均值和样本标准差。两种联合配置的错误分析采用各自五次运行的汇总。每次训练以验证集 AUC 选择保存的模型参数，再评价对应的内部测试表现。验证选择与测试报告承担不同职责：前者决定训练轮次对应的权重，后者描述选定模型在预留病例上的性能。正文中的结构递进用于组织研究问题，不表示以测试集逐次选择模型超参数。

设同一配置有 n 次运行，各次运行的指标为 M_i，汇总方式为

$$\overline{M} = \frac{1}{n}\sum_{i=1}^{n} M_i, \qquad \mathrm{SD}(M) = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(M_i - \overline{M})^2}. \tag{4-11}$$

标准差描述重复训练结果的离散程度，不等同于置信区间。不同指标的标准差分别计算，不能将各指标的均值组合后直接恢复某一次运行的混淆矩阵，也不能由两个模型的标准差直接推导其差值显著性。

主要指标为 AUC、F1、敏感度和特异度。AUC 使用连续预测概率，反映阳

性与阴性病例的排序能力；其余分类指标均采用固定阈值 0.5。模型输出概率达到 0.5 时判为 pCR，否则判为非 pCR。本章的分类指标、漏报和误报均按这一规则计算。

敏感度、特异度和 F1 按式 (2-10) 计算。测试集含 25 例 pCR 和 70 例非 pCR，后续结合敏感度和特异度分别分析阳性漏报与阴性误报。

后续比较各配置的总体性能及重复运行波动，再结合固定阈值下的漏报和误报分析两类病例的识别表现。

4.6 实验结果与分析

4.6.1 总体性能与融合增益

表 4-5 汇总各配置的内部测试结果，数值为已有重复运行的均值 ± 样本标准差。除 AUC 外，分类指标均按固定阈值 0.5 计算。粗体表示各列最高均值。模型结构和预测头输入维度见表 4-4。

表 4-5 不同配置在 I-SPY2 内部测试集上的性能比较

模型	AUC	F1	敏感度	特异度
ResNet	0.7146 ± 0.0118	0.4177 ± 0.0893	0.4429 ± 0.2012	**0.7827 ± 0.1661**
Clinical	0.6982 ± 0.0185	0.4708 ± 0.0657	0.8560 ± 0.2165	0.3457 ± 0.3320
ResNet + Clinical-128	0.7273 ± 0.0085	0.4859 ± 0.1164	0.5450 ± 0.1749	0.7786 ± 0.0913
CBM	0.7079 ± 0.0105	0.4836 ± 0.0120	0.7600 ± 0.1033	0.5071 ± 0.1020
CBM + Clinical-18	0.7898 ± 0.0225	0.5537 ± 0.0501	0.7840 ± 0.1846	0.6086 ± 0.2516
CBM + Gate	0.7954 ± 0.0281	0.5583 ± 0.0116	0.6800 ± 0.2227	0.7333 ± 0.1886
CBM + Gate + Clinical-18	0.8015 ± 0.0204	0.5946 ± 0.0322	0.7600 ± 0.0938	0.7143 ± 0.0857
CBM + Gate + Clinical-128	**0.8157 ± 0.0123**	**0.5954 ± 0.0228**	**0.9280 ± 0.0335**	0.5743 ± 0.0433

在本研究比较的配置中，CBM + Gate + Clinical-128 的平均 AUC、F1 和敏感度最高，分别为 0.8157、0.5954 和 0.9280。ResNet 的平均特异度最高，为 0.7827。CBM + Gate + Clinical-18 的 AUC 为 0.8015，F1 为 0.5946；其 F1 与 CBM + Gate + Clinical-128 接近，但敏感度较低、特异度较高。仅门控 CBM + Gate 的 AUC 为 0.7954，高于 CBM 和 CBM + Clinical-18 的对应均值，而低于两类联合配置。

下文进一步比较各融合路径相对基线的增益，以及固定阈值下敏感度与特异度的变化。

为描述配置间的指标差异，使用报告均值计算 $\Delta M = M(B) - M(A)$。表 4-6 的差值由主结果表保留四位小数的均值计算，单位为百分点。每行对应两套分别训练的配置，差值用于描述预测表现的变化。

表 4-6 递进配置间测试指标均值的变化

基准配置	目标配置	AUC	F1	敏感度	特异度
ResNet	ResNet + Clinical-128	+1.27	+6.82	+10.21	−0.41
CBM	CBM + Clinical-18	+8.19	+7.01	+2.40	+10.15
CBM	CBM + Gate	+8.75	+7.47	−8.00	+22.62
CBM + Clinical-18	CBM + Gate	+0.56	+0.46	−10.40	+12.47
CBM + Clinical-18	CBM + Gate + Clinical-18	+1.17	+4.09	−2.40	+10.57
CBM + Gate	CBM + Gate + Clinical-18	+0.61	+3.63	+8.00	−1.90
CBM + Gate + Clinical-18	CBM + Gate + Clinical-128	+1.42	+0.08	+16.80	−14.00

首先，临床直接融合在两种影像表示上均获得更高平均 AUC。ResNet + Clinical-128 相对 ResNet 增加 1.27 个百分点，CBM + Clinical-18 相对 CBM 增加 8.19 个百分点。ResNet + Clinical-128 的主要变化包括敏感度提高和特异度基本保持；CBM + Clinical-18 的敏感度与特异度均提高。两条比较的初始表示、头结构与训练条件不同，因此不能仅由增幅大小认定概念表示在所有融合设置下都优于高维影像特征。

其次，仅门控相对概念基线的 AUC 增加 8.75 个百分点，特异度增加 22.62 个百分点，敏感度减少 8.00 个百分点。这表明临床信息不经直接拼接，也可以通过调制概念形成不同的排序与判定表现。与此同时，它并非各指标全面提高，门控配置将原 CBM 较高敏感度、较低特异度的工作点调整为更高特异度和较低敏感度的结果。

CBM + Gate 与 CBM + Clinical-18 的平均 AUC 分别为 0.7954 与 0.7898，差 0.56 个百分点；F1 差 0.46 个百分点。两者更明显的差异发生在固定阈值指标：CBM + Gate 敏感度较低 10.40 个百分点，特异度较高 12.47 个百分点。该比较说明两种临床接入方式对应不同的错误取舍，但 CBM + Gate 使用门控子集、CBM + Clinical-18 使用完整向量，不能将全部差异只解释为乘性调制与加性拼接的区别。

在联合配置中，CBM + Gate + Clinical-18 相对 CBM + Clinical-18 的平均 AUC 和 F1 分别增加 1.17 和 4.09 个百分点。两者均保留完整原始临床通路，CBM + Gate + Clinical-18 进一步加入概念门控，观察结果与引入条件交互的设计方向一致。由于各自重新学习参数，比较描述的是加入这一结构后的整体训练结果，而非同一组固定参数上的简单加减。

CBM + Gate + Clinical-18 相对仅门控 CBM + Gate 又提高平均 AUC 0.61 个百分点、F1 3.63 个百分点，同时提高敏感度 8.00 个百分点。保留完整临床向量的直接作用，使模型有机会利用门控子集之外的信息，以及不依赖概念乘积表达

的临床贡献。结果与这一信息保留动机相符，但不能据此逐项确定是哪一个临床变量造成变化。

最后，CBM + Gate + Clinical-128 相对 CBM + Gate + Clinical-18 的平均 AUC 增加 1.42 个百分点，而 F1 仅增加 0.08 个百分点。临床嵌入配置的敏感度增加 16.80 个百分点、特异度下降 14.00 个百分点。这说明使用非线性临床表示后，预测能力和工作点共同发生变化；其优势主要体现为更高平均 AUC 和更高阳性检出，不能概括为在所有类别上更准确。

重复实验的波动可结合表 4-5 中的样本标准差一并比较。CBM + Gate + Clinical-128 的 AUC 标准差为 0.0123，低于 CBM + Clinical-18 的 0.0225、CBM + Gate 的 0.0281 和 CBM + Gate + Clinical-18 的 0.0204。在本次概念融合配置中，它同时具有最高平均 AUC 和较小的 AUC 波动。不过，ResNet + Clinical-128 的 AUC 标准差为 0.0085，更小的波动不等同于更高预测能力：其平均 AUC 为 0.7273。因此，应共同考虑均值与离散程度，不只按标准差排列模型。

仅门控的 F1 标准差为 0.0116，但敏感度和特异度标准差分别为 0.2227 与 0.1886。较小的 F1 波动不能据此解释为两类病例识别均稳定。不同运行中，阳性检出与误报可以发生反向变化，F1 对 TP、FP 和 FN 的汇总可能掩盖这种变化。该结果说明，评价受约束概念通路时，仍需要保留类别分项指标。

Clinical 也呈现类似的指标差异：AUC 标准差为 0.0185，而特异度标准差达到 0.3320。这种现象反映总体排序与固定阈值判定具有不同敏感性。保持分数排序的单调变换可不改变 AUC，但会使部分概率越过固定阈值，从而改变敏感度和特异度。这里用这一数学性质解释为何需要多指标评价，不据汇总数据断言某一次训练必然发生了特定分数变换。

已有验证汇总中，CBM + Clinical-18、CBM + Gate + Clinical-18 和 CBM + Gate + Clinical-128 的平均验证 AUC 分别为 0.7208、0.7282 和 0.7341，与这三种配置的平均测试 AUC 排序一致。另一方面，ResNet + Clinical-128 的验证 AUC 为 0.6526，低于 ResNet 的 0.6587，但其平均测试 AUC 较高。验证集与测试集病例不同，各自数值同时受病例组成和模型分数分布影响；本文按验证结果选择权重，按内部测试结果报告选定配置。

综合表 4-6，概念基线上最明显的平均 AUC 增益出现在首次引入临床信息时。直接融合与仅门控分别提高 8.19 和 8.75 个百分点，说明两条路径都能补充影像概念。保留门控的同时加入完整临床分支，仍可进一步提高平均 AUC 和 F1。两种联合配置中，CBM + Gate + Clinical-128 的平均 AUC 和敏感度最高，因此作为总体判别与阳性检出方面的重点配置。CBM + Gate + Clinical-18 的 F1 与

之接近，特异度更高，并保留了逐项解释原始临床编码贡献的条件。因此，下文选取这两种联合配置，具体比较高阳性检出与低阴性误报之间的取舍。

4.6.2 固定阈值下的错误分析

本节采用平衡准确率（balanced accuracy，BA）对阳性和阴性病例的识别表现赋予相同权重[53]。在二分类中，BA 等于敏感度与特异度的算术平均值

$$\mathrm{BA} = \frac{\mathrm{Se} + \mathrm{Sp}}{2}. \tag{4-12}$$

由于该运算对两项指标为线性，可由同一配置重复运行的平均敏感度和平均特异度得到平均 BA。表 4-7 同时列出每 100 例真实阳性的漏报量 $100(1 - \mathrm{Se})$ 和每 100 例真实阴性的误报量 $100(1 - \mathrm{Sp})$。这些数值是类条件错误比例的归一化表示，并非测试集中实际存在的小数患者。

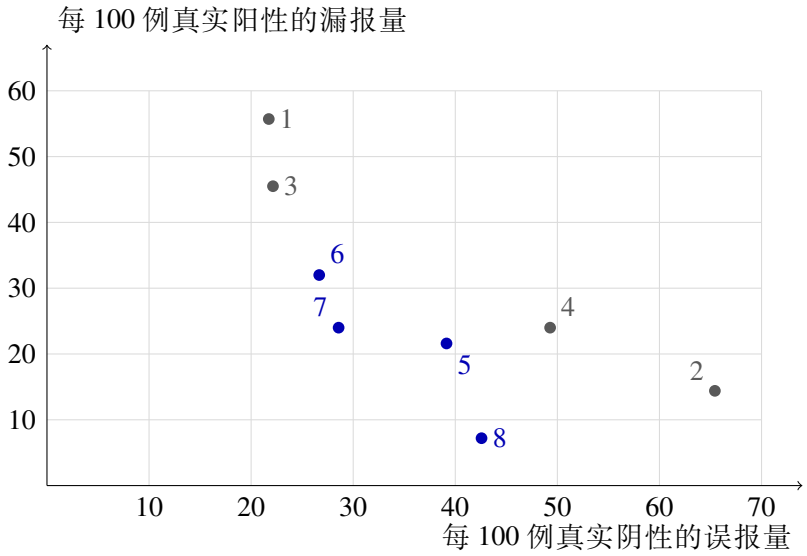
表 4-7 固定阈值 0.5 下的平衡准确率与归一化错误量

配置	平衡准确率	每百例阳性漏报	每百例阴性误报
ResNet	0.6128	55.71	21.73
Clinical	0.6009	14.40	65.43
ResNet + Clinical-128	0.6618	45.50	22.14
CBM	0.6336	24.00	49.29
CBM + Clinical-18	0.6963	21.60	39.14
CBM + Gate	0.7067	32.00	26.67
CBM + Gate + Clinical-18	0.7372	24.00	28.57
CBM + Gate + Clinical-128	0.7512	7.20	42.57

Clinical 的平均敏感度为 0.8560，但较低特异度使 BA 约为 0.6009，低于主要融合配置。这说明高阳性检出并不能单独说明整体判别均衡。CBM + Gate 的 BA 为 0.7067，高于 CBM + Clinical-18 的 0.6963；CBM + Gate + Clinical-18 和 CBM + Gate + Clinical-128 分别为 0.7372 和 0.7512，在两类识别等权时取得更高汇总值。

CBM + Gate + Clinical-128 与 CBM + Gate + Clinical-18 的 BA 相差 1.40 个百分点，明显小于二者敏感度和特异度的单项差距。原因是 CBM + Gate + Clinical-128 减少漏报的同时增加误报，两种变化在等权平均中部分抵消。它们的 F1 也仅相差 0.0008，因此相近 F1 不能被解释为相同的错误结构。图 4-4 进一步展示这种取舍。

图中越靠左表示阴性误报越少，越靠下表示阳性漏报越少。CBM + Gate + Clinical-128 位于较低但较靠右的位置，CBM + Gate + Clinical-18 位于其左上方，体现前者偏向减少漏报、后者偏向减少误报。CBM + Gate 相比 CBM + Clinical-18



1：ResNet；2：Clinical；3：ResNet + Clinical-128；4：CBM；5：CBM + Clinical-18；6：CBM + Gate；7：CBM + Gate + Clinical-18；8：CBM + Gate + Clinical-128。

图 4-4 八种配置在固定阈值下的归一化误报与漏报

也向左上方移动。点的位置来自平均类条件错误率，不能相加后直接作为全体病例的错误率，因为两个坐标使用不同分母。

图 4-4 的横、纵坐标分别以阴性和阳性病例为分母。若要计算所有病例中的错误比例，需按两类病例的实际占比加权。记阳性比例为 π，则总体错误率为

$$R_{\mathrm{err}} = \pi(1 - \mathrm{Se}) + (1 - \pi)(1 - \mathrm{Sp}). \tag{4-13}$$

在本测试集中，25 例为 pCR、70 例为非 pCR，因此式 (4-13) 对阳性漏报和阴性误报分别赋予 25/95 和 70/95 的权重。代入表 4-5 中五次运行的平均敏感度和特异度，128 维和 18 维联合配置的总体错误率分别约为 33.26% 和 27.37%。在本测试集的类别构成下，128 维配置增加的误报多于减少的漏报。

在固定阈值 0.5 下，128 维联合配置更有利于检出 pCR，并在两类病例等权评价时取得较高的 BA。18 维联合配置的阴性误报更少，在本测试集的实际类别构成下，总体错误率也更低。上述比较基于 I-SPY2 的完整临床输入。

为展示模型对单个病例的预测过程，图 4-5 给出了 CBM + Gate + Clinical-128 在 I-SPY2 内部测试集中正确检出的一例 pCR 病例，并按式 (4-10) 分解其预测得分。

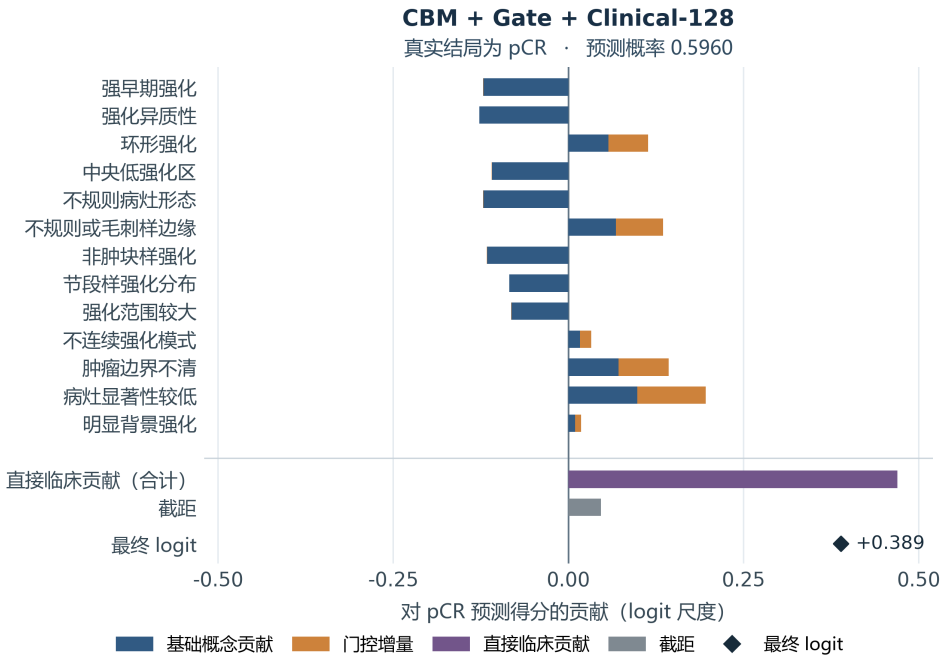


图 4-5 CBM + Gate + Clinical-128 对一例正确检出的 pCR 病例的预测贡献分解

该病例的基础概念贡献合计为 −0.4412，门控净增量为 +0.3142。其中，门控放大了环形强化、肿瘤边界不清等概念项在该次预测中的正向贡献。直接临床贡献为 +0.4693，计入截距 +0.0463 后，最终 logit 为 +0.3886，对应 pCR 预测概率 0.5960，高于判定阈值 0.5。下一节转向 Duke 队列，考察部分临床信息不可获得时的预测表现。

4.7 Duke 队列的探索性外部评价

前文在 I-SPY2 临床输入完整的条件下比较了各模型的预测性能。转至 Duke 队列后，MP 不可获得，病例构成和影像采集条件也有所不同。本节先介绍 Duke 队列及两队列在影像分布和可用临床字段上的差异，再说明 MP 不可获得时的评价方案。预测结果分别回答两个问题：原模型在缺少 MP 时采用加权预测的表现如何，以及在训练阶段仅使用共有字段时，融合模型能否在 Duke 队列区分 pCR 与非 pCR。外部评价报告 AUC、固定阈值分类指标及患者抽样区间[54]。

4.7.1 外部队列与输入差异

Duke-Breast-Cancer-MRI 由 TCIA 公开，包含 2000–2014 年收集的 922 例浸润性乳腺癌患者的术前 DCE-MRI 及相关临床记录[55-56]。本研究按治疗前影像、pCR 标签、区域掩码和临床信息的患者级对应关系使用其中 256 例，包含 pCR

64 例、非 pCR 192 例，阳性比例为 25.0%。

表 4-8 内部开发队列与 Duke 外部评价队列的病例构成

队列或子集	病例数	pCR	非 pCR	用途
I-SPY2 训练集	759	254	505	参数拟合及 MP 参考分布估计
I-SPY2 验证集	95	30	65	模型权重选择
I-SPY2 测试集	95	25	70	内部评价与 MP 遮蔽配对分析
Duke 外部队列	256	64	192	冻结模型外部推理

Duke 输入为治疗前检查内的增强前相与所选增强后相。实验文件中的 T1 为本次输入版本标识，不表示使用治疗后的 MRI。Duke 病例未用于拟合本研究的 pCR 预测网络，标签沿用已有临床表中的 pCR 二值记录，并与推理输出按患者编号核对。来源队列与外部队列的病例组成和治疗背景不同，评价时分别统计，不将外部病例并入 I-SPY2 的训练、验证或测试划分。

两队列预处理后影像的体素间距均为 $1\times1\times1\,\mathrm{mm}^3$。Duke 队列从每例原始 DCE-MRI 序列中整理出增强前相和所选增强后相，并在标准化前用增强后相逐体素减去增强前相，得到减影图。增强前相、增强后相和减影图共同构成三通道影像输入。病灶掩码沿用第二章的处理流程，由 nnU-Net 自动分割获得。将清理后的肿瘤掩码二值化并膨胀 3 次，得到后续用于区域加权的膨胀掩码。

加载数据时，先对三个影像通道分别进行 z-score 标准化，再对三通道影像和膨胀掩码采用相同的中心裁剪或零填充操作，将尺寸统一为 $160\times160\times160$ 个体素。记尺寸统一后的膨胀掩码为 M_d，三个影像通道均乘以 $1+5M_d$，并将对齐后的掩码送入分类网络，用于特征提取阶段的空间引导。外部推理关闭随机增强，使用 FP32 计算。Duke 的 3 例空掩码病例保留在性能评价中，掩码内统计仅使用非空病例。

统一体素尺度、输入尺寸和强度标准化方式后，两队列的影像输入仍可能存在分布差异。本文对 949 例 I-SPY2 和 256 例 Duke 的影像进行患者级统计。图 4-6 以原始减影强度标准差描述标准化前的强度离散程度，以归一化后全图减影的第 99 百分位数（P99）比较高值端信号。模型还利用病灶掩码进行区域加权和特征引导，因此进一步比较膨胀掩码内的减影 P99 和掩码体积占比，分别描述病灶相关区域的高值端信号与空间覆盖。

归一化指标均在 ROI 加权前计算。图中（a）、（c）和（d）的纵轴采用对数刻度。两队列各有 3 例空掩码，（c）和（d）仅纳入掩码非空的病例，I-SPY2 和 Duke 分别为 946 例和 253 例。箱体表示四分位距，箱内横线表示中位数。须线延伸至距箱体边缘 1.5 倍四分位距以内的最远观测值，超出该范围的观测值以

散点表示。

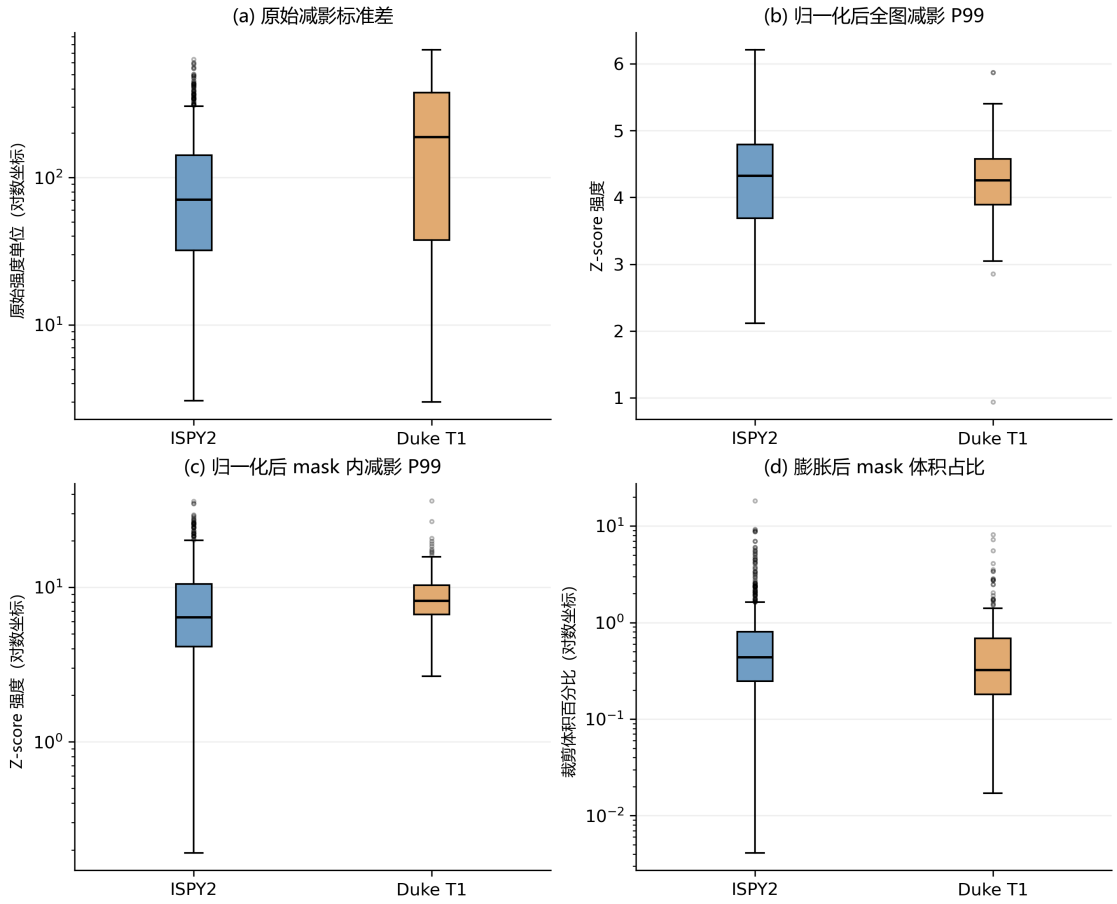


图 4-6 I-SPY2 与 Duke 的患者级影像输入分布

按 I-SPY2 和 Duke 的顺序，原始减影强度标准差的中位数分别为 70.64 和 188.11。经 z-score 标准化后，两队列全图 P99 的中位数较为接近，分别为 4.33 和 4.26，而掩码内 P99 分别为 6.37 和 8.13，在非空掩码病例中，掩码体积占比的中位数分别为 0.438% 和 0.323%。在全图高值端指标接近的情况下，两队列在模型重点利用的病灶相关区域内仍存在信号强度与覆盖范围的差异。

采集设备、增强时相、病灶形态及区域提取均可能影响上述统计量。影像分布统计纳入 I-SPY2 全队列，用于描述输入条件。下文的预测性能比较使用预留的 I-SPY2 测试集和 Duke 队列。

Duke 队列的临床表分别记录了病理活检报告中的雌激素受体（ER）和孕激素受体（PR）状态[56]。本文沿用原始记录中的阴阳性判定，将两项受体状态合并为模型的 HR 输入。ER 或 PR 至少一项阳性时记为 HR 阳性（编码为 1），两项均为阴性时记为 HR 阴性（编码为 0）。其他临床变量中，年龄由去标识化天数换算为岁，HER2、种族和绝经状态按现有病例清单映射；256 例均未触发年

龄填补。

在 Duke 队列上进行预测前，本文统一核对了两队列共有临床变量的编码和输入顺序。例如，同一族裔类别在两队列中采用相同的编码。HR、HER2 等共有变量按核对后的编码直接输入模型。

Duke 不提供与 MP 对应的 MammaPrint 分层，因而需要为冻结模型定义该变量不可获得时的输入规则。MP 的 0 和 1 是原始数据类别，均不是缺失标记；I-SPY2 的 949 例 MP 均无缺失，训练集中 0、1 分别为 383、376 例。

4.7.2 MP 缺失条件下的评价方案

外部数据缺少预测变量时，可根据变量的可获得性选择相应的处理策略[57-58]。针对 Duke 队列缺少 MP 的情况，本文采用两种方案开展外部评价。冻结完整模型的 MP 加权方案沿用已经训练好的模型，分别按 MP 为 0 和为 1 进行预测，再按 I-SPY2 训练集中的 MP 类别比例对两次预测的概率加权。共有字段重训方案则从 I-SPY2 的临床输入中去掉 MP，重新训练模型，再到 Duke 队列上评价。加权方案保留完整模型的全部权重及 18 维临床输入、8 维门控输入。记影像和其余可用临床信息为 x，两次预测的概率分别为

$$p_0 = f_\theta(x, \mathrm{MP} = 0), \qquad p_1 = f_\theta(x, \mathrm{MP} = 1), \tag{4-14}$$

并由 I-SPY2 训练集参考比例形成概率加权：

$$q = \frac{376}{759} = 0.495389, \qquad \widetilde{p} = (1 - q)p_0 + qp_1. \tag{4-15}$$

对同一病例，两次预测使用相同的影像和其他临床变量。第一次将门控分支和直接临床分支中的 MP 都设为 0，得到 p_0。第二次将两条分支中的 MP 都设为 1，得到 p_1。两次预测完成后，分别按 I-SPY2 训练集中 MP 为 0 和为 1 的病例比例 $1 - q$ 和 q 对两项概率加权，得到该病例最终的 pCR 预测概率 $\widetilde{p}$。所有 Duke 病例共用这组加权比例，模型每次接收的 MP 仍是 0 或 1。

完整模型的外部评价采用 CBM + Gate + Clinical-128 一次训练所得的权重。内部 MP 遮蔽对照与 Duke 外部推理均使用这组固定权重。在 I-SPY2 验证集上复核模型输出后，本文以测试集为内部对照，比较同一批病例使用真实 MP 与遮蔽 MP 后加权的预测结果。该对照固定患者、权重、影像和其他临床字段，考察的是这套遮蔽与加权程序。共有字段实验则在 I-SPY2 中去除 MP 后重新训练，原始临床输入为 17 维，门控输入为 HR 与绝经编码共 7 维，再冻结各自权重用于 Duke。

全部分类指标统一采用固定阈值 0.5，AUC 使用连续概率。区间采用 10000 次患者级分层 bootstrap，分别在阳性和阴性病例内有放回抽样，以 2.5% 与 97.5% 分位数构成 95% 区间。内部 AUC 差值使用同一轮患者抽样，以保留配对关系。区间描述既定模型下的患者抽样不确定性；五种子样本标准差描述重复训练的离散程度，两者分别报告。

表 4-9 对比 I-SPY2 内部基准和两种 Duke 外部评价方案。表中的门控维数适用于含门控分支的模型。两种外部方案均可使用 Clinical-128 配置，其中 128 指临床特征的维数。完整模型从 18 维临床输入生成该特征，共有字段模型则从去掉 MP 后的 17 维临床输入生成该特征。

表 4-9 I-SPY2 内部基准与两种 Duke 外部评价方案

评价条件	临床输入	训练与预测方式	结果汇总
I-SPY2 内部基准	临床输入 18 维 门控输入 8 维 均含 MP	在 I-SPY2 训练，在内部测试时使用实际 MP	重复运行的均值和标准差
Duke 完整模型	临床输入 18 维 门控输入 8 维 均含 MP	沿用原模型的固定权重，分别设 MP 为 0 和 1 预测，再加权	一次运行的结果及置信区间
Duke 共有字段模型	临床输入 17 维 门控输入 7 维 均去掉 MP	在 I-SPY2 去掉 MP 后重新训练，再用各次训练所得权重预测	五次运行的均值和标准差

对完整模型，先在 I-SPY2 测试集内固定病例和模型权重，仅改变 MP 的输入方式，以考察从实际 MP 改为加权预测后性能如何变化。随后用同一组权重及同一加权规则比较 I-SPY2 与 Duke 的预测表现。对于共有字段方案，每次重训所得的同一组权重也分别用于两个队列。这样，两种方案各自的跨队列比较均采用一致的预测规则。

4.7.3 外部预测结果

在冻结完整模型的 MP 加权方案中，I-SPY2 内部遮蔽对照与 Duke 外部评价使用同一次训练得到的 CBM + Gate + Clinical-128 权重。图 4-7 给出相应的 ROC 曲线。左图在同一批 I-SPY2 测试病例中比较实际 MP 与遮蔽后加权两种条件，右图报告 Duke 的加权结果。跨队列比较以左图中的加权曲线为内部参照，使两队列采用相同的 MP 处理规则。

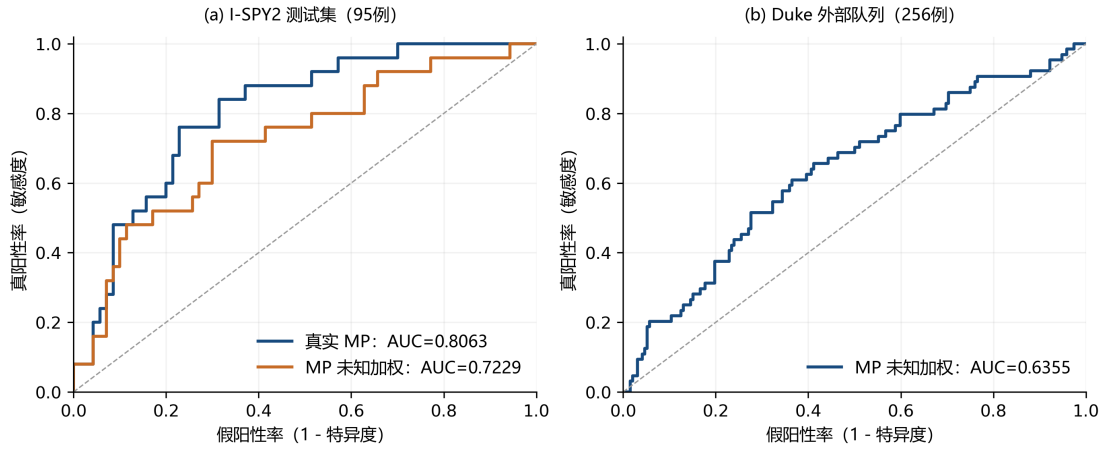


图 4-7 完整模型在 I-SPY2 与 Duke 队列上的 ROC 曲线

由图 4-7 左图可见，在同一批 I-SPY2 测试病例中，使用实际记录的 MP 时，AUC 为 0.8063（95% CI：0.7069–0.8914）。遮蔽 MP 并加权后，AUC 降至 0.7229（95% CI：0.5977–0.8337），配对降幅为 0.0834（95% CI：0.0080–0.1657）。右图显示，采用相同加权规则时，Duke 队列的 AUC 为 0.6355（95% CI：0.5545–0.7123），比 I-SPY2 测试集的加权 AUC 低 0.0874。

上述跨队列 AUC 差距是在模型权重和 MP 加权规则相同的条件下观察到的。图 4-6 显示，两队列标准化后的全图减影 P99 中位数接近。模型利用膨胀掩码对病灶及其周围区域加权，并用掩码引导特征提取，因此还需比较掩码覆盖范围和区域内的影像信号。与 I-SPY2 相比，Duke 的掩码体积占比中位数更低，意味着被加权的体素占比中位数更低。与此同时，Duke 的掩码内减影 P99 中位数更高，表明被加权区域的减影高值端更强。两队列的全图指标虽然接近，模型重点利用的病灶相关区域仍有差异。图中的统计量描述的是队列间的输入分布，尚无法判断这些影像差异对 AUC 差距的贡献。病例构成与治疗背景也可能影响跨队列表现。

表 4-10 给出 95 例测试病例在固定阈值 0.5 下的配对判定。25 例阳性中，5 例由检出转为漏报，1 例由漏报转为检出。70 例阴性中，11 例由正确排除转为误报，9 例由误报转为正确排除。共 26 例改变分类，净变化为少检出 4 例、增加误报 2 例。加权后，准确率从 0.6947 降至 0.6316，F1 从 0.6027 降至 0.5070。

同样采用固定阈值 0.5 时，Duke 队列的准确率、F1、敏感度和特异度分别为 0.5273、0.4319、0.7188 和 0.4635。64 例阳性中检出 46 例，漏报 18 例。192 例阴性中正确排除 89 例，误报 103 例。

表 4-10 内部测试病例在 MP 遮蔽前后的配对判定

真实结局	真实 MP 时判定	加权后阳性	加权后阴性	合计
pCR	阳性	17	5	22
pCR	阴性	1	2	3
非 pCR	阳性	17	9	26
非 pCR	阴性	11	33	44

在共有字段重训方案中，本文从 I-SPY2 的临床输入中去掉 MP，对四种配置各重新训练五次。每次训练所得的模型分别在 I-SPY2 测试集和 Duke 队列上评价。表 4-11 并列给出两队列 AUC 的均值 ± 样本标准差，末列为内部 AUC 均值减去外部 AUC 均值。

表 4-11 共有字段模型在 I-SPY2 测试集与 Duke 队列上的 AUC

配置	I-SPY2 测试	Duke	内部减外部
Clinical（17 维输入）	0.6030 ± 0.0270	0.6551 ± 0.0322	−0.0521
CBM + Clinical-17	0.7815 ± 0.0199	0.6946 ± 0.0235	+0.0869
CBM + Gate + Clinical-17	0.7385 ± 0.0299	0.6576 ± 0.0078	+0.0809
CBM + Gate + Clinical-128	0.7067 ± 0.0252	0.6323 ± 0.0157	+0.0745

对照表 4-5 中含 MP 的对应配置，去掉 MP 并重新训练后，四种配置在同一 I-SPY2 测试集上的平均 AUC 均有所下降。其中，CBM + Gate + Clinical-128 的平均 AUC 从 0.8157 降至 0.7067，降幅最大。直接融合原始临床变量的配置降幅最小，平均 AUC 从 0.7898 降至 0.7815。这些差值反映输入字段变化与模型重新拟合的共同影响。前述内部配对结果则反映权重固定时改变 MP 输入方式的影响。

在共有字段模型中，CBM + Clinical-17 在 I-SPY2 测试集和 Duke 队列均取得最高平均 AUC，分别为 0.7815 和 0.6946。CBM + Gate + Clinical-17 在两队列的平均 AUC 分别为 0.7385 和 0.6576。仅使用临床变量的 Clinical 模型在 Duke 上的平均 AUC 高于内部测试值，三个包含影像概念的配置则均有所下降。

三个融合配置均利用影像概念进行预测，因而其跨队列比较还涉及图 4-6所示的掩码内强度和覆盖范围差异。在使用原始临床变量的两种配置中，直接融合与门控联合融合的平均 AUC 在 Duke 分别降低 0.0869 和 0.0809，直接融合在两个队列的平均 AUC 均更高。现有输入分布统计尚无法确定影像差异对跨队列 AUC 降幅的贡献。

表 4-12 补充报告同一批共有字段模型在 Duke 上以 0.5 为固定阈值的分类结果，数值为五次运行的均值 ± 样本标准差。

在固定阈值 0.5 下，CBM + Gate + Clinical-17 在 Duke 上的平均 F1 最高，为

表 4-12 共有字段模型在 Duke 上的固定阈值分类结果

配置	准确率	F1	敏感度	特异度
Clinical	0.5312 ± 0.2566	0.2601 ± 0.2415	0.5375 ± 0.5026	0.5292 ± 0.4977
CBM + Clinical-17	0.5375 ± 0.0484	0.4559 ± 0.0212	0.7719 ± 0.0210	0.4594 ± 0.0694
CBM + Gate + Clinical-17	0.6047 ± 0.0588	0.4780 ± 0.0161	0.7250 ± 0.1130	0.5646 ± 0.1142
CBM + Gate + Clinical-128	0.5867 ± 0.0878	0.4395 ± 0.0190	0.6438 ± 0.1056	0.5677 ± 0.1505

0.4780。与 CBM + Clinical-17 相比，其平均敏感度较低（0.7250），平均特异度较高（0.5646），表明两种配置在固定阈值下对阳性和阴性病例的识别表现各有侧重。Clinical 的 AUC 标准差为 0.0322，但敏感度和特异度的标准差均接近 0.5，说明该模型在固定阈值下的分类表现随重复训练变化较大。

在 Duke 队列缺少 MP 的条件下，两种方案均保留了一定的 pCR 判别能力。冻结完整模型并采用 MP 加权时，Duke AUC 为 0.6355，较相同权重和加权规则下的 I-SPY2 测试 AUC 低 0.0874。采用共有字段重训后，Duke 平均 AUC 最高的 CBM + Clinical-17 达到 0.6946，较该配置的内部平均 AUC 低 0.0869。这些结果为影像概念与临床信息融合模型的跨队列泛化提供了初步证据，同时显示判别能力在由 I-SPY2 转至 Duke 时有所减弱。本节结论适用于所评价的外部队列与输入条件，模型在其他独立队列上的判别表现和概率校准仍需进一步评价[54]。

4.8 讨论

本研究结果应结合 I-SPY2 的入组人群及治疗设计理解。I-SPY2 面向高风险乳腺癌患者，本文使用的公开影像队列包含不同试验治疗组和对照组[7,36-37]。患者的 pCR 结局同时受到肿瘤特征及实际接受治疗的影响，因此内部测试反映模型在当前混合治疗队列中的预测表现。Duke 外部评价考察固定分割预处理条件下 pCR 分类模型的跨队列表现。第二章所述的分割权重训练样本可能与评价病例重叠，相关范围仍待按病例核对。

直接融合使完整临床向量通过单独的加性项参与预测，门控根据临床背景调节概念贡献，联合配置同时保留两条通路。在 I-SPY2 内部测试中，CBM + Clinical-18、CBM + Gate、CBM + Gate + Clinical-18 和 CBM + Gate + Clinical-128 的平均 AUC 分别为 0.7898、0.7954、0.8015 和 0.8157，均高于概念基线 0.7079。

CBM + Gate 由 HR、MP 和绝经状态生成门控系数，预测头只接收 13 维调制后的概念得分。与 CBM 相比，该配置在内部测试中取得更高的平均 AUC 和特异度，但敏感度较低。与 CBM + Clinical-18 比较时，两种配置的临床输入范围和接入方式均有差异，性能差值反映的是各自训练后的整体表现。

两类联合模型采用相同的门控变量，直接分支分别使用 18 维临床编码和由该编码生成的 128 维临床嵌入。CBM + Gate + Clinical-18 保留了直接临床贡献与原始变量的对应关系。CBM + Gate + Clinical-128 在 I-SPY2 内部测试的八种配置中取得最高平均 AUC、F1 和敏感度。该比较同时涉及临床表示、网络结构和重新拟合后的模型参数。

ResNet + Clinical-128 与 CBM + Gate + Clinical-128 都从 18 维临床编码生成 128 维特征，分别与影像表征及调制后的概念得分拼接。两种模型最终预测头的输入分别为 2176 维和 141 维，具体表示见表 4-4。

训练集中的 HR/HER2 分层显示不同受体组合的 pCR 比例有差异。临床变量与概念得分的秩相关总体较弱，多重检验校正后各项均未达到 $q < 0.05$。这些探索性结果为考察临床信息直接参与预测和条件调制提供了设计参考，模型的预测效果由内部测试结果评价。

CBM + Clinical-18 的预测得分可分为截距、概念项和直接临床项。CBM + Gate 可分为截距、基础概念贡献和门控增量。CBM + Gate + Clinical-18 可进一步按原始临床变量汇总直接贡献，CBM + Gate + Clinical-128 的直接临床贡献按嵌入分支整体计算。

概念的基础贡献由概念得分和预测头权重共同决定。门控按 $1 + r_k$ 缩放该项，因此同一概念的贡献幅度可以随患者临床背景而变化，并保持基础贡献的符号。

固定阈值下的误报和漏报分析描述的是模型在测试集上的平均表现。病例级得分分解则使用同一模型、同一次推理的中间输出，按式 (4-10) 复原单例预测的 logit。两种分析分别说明测试集的错误分布与单例预测得分的组成。

在 I-SPY2 内部测试的固定阈值 0.5 下，CBM + Gate + Clinical-128 相比 CBM + Gate + Clinical-18 的敏感度高 16.80 个百分点，特异度低 14.00 个百分点。两者分别偏向减少阳性漏报与阴性误报。

为说明这一取舍与类别构成的关系，令阳性比例为 π，漏报与误报权重分别为 C_{FN}、C_{FP}。以主表的平均类条件错误率代入，CBM + Gate + Clinical-128 相对 CBM + Gate + Clinical-18 的加权错误差为

$$\Delta R = -0.1680\pi C_{\mathrm{FN}} + 0.1400(1-\pi)C_{\mathrm{FP}}. \tag{4-16}$$

前一项对应减少漏报，后一项对应增加误报。如果两类权重相同，则在 $\pi = 0.1400/(0.1680 + 0.1400) \approx 0.455$ 时两项抵消。该临界比例仅用于说明类别构成对加权错误差的影响。

本研究的 I-SPY2 测试集阳性比例为 25/95 ≈ 0.263。在这一病例构成下，CBM + Gate + Clinical-128 的 BA 较高，而 CBM + Gate + Clinical-18 的总体错误率较低。BA 对两类病例的识别表现赋予相同权重，总体错误率则按两类病例的实际占比加权。

上述计算以类条件错误率保持适用为前提，描述本文内部测试工作点。临床应用还取决于任务目标与实际病例构成，本文不将假设错误权重下的数值直接扩展为临床效益。这里的临床意义主要体现在：明确不同模型如何分配漏报与误报，以及临床信息通过何种路径参与预测。

本章在外部加权方案中采用内部平均 AUC 最高的 CBM + Gate + Clinical-128，并固定一次训练所得的权重。共有字段方案则比较去除 MP 后分别在 I-SPY2 重训的四种配置。

已有研究同样强调外部评价需要结合输入和任务设定解释。Huang 等的单次扫描对照模型在内部和两个外部中心的 AUC 分别为 0.753、0.643 和 0.613，其纵向主模型则采用不同信息条件[20]。Wei 等的联合模型在其内部测试队列 Center 2 和外部测试队列 Duke 上的 AUC 分别为 0.916 和 0.830，所用队列规模、病灶表示及临床输入与本文不同[59]。这些数值用于说明研究条件，不作为本文模型的直接性能对照或合格界限。

外部测试的结论应对应实际可用的输入。Gao 等的融合模型使用了乳腺 X 线影像。Duke 队列可用的影像限于治疗前 MRI，因此该研究在 Duke 上评价的是结合治疗前 MRI 与影像学、组织病理学、个体和临床特征的模型配置[21]。Riley 等也指出，外部数据缺少预测变量时，可根据实际使用条件评价相应的缺失处理规则[54]。本研究在 Duke 上分别评价原模型采用 MP 加权时的表现，以及融合框架使用共有字段重训后的表现，两者对应不同的临床输入条件。

完整模型的外部加权结果对应一次训练所得的固定权重，其患者 bootstrap 区间描述该权重和参考比例下的抽样不确定性。共有字段方案报告每种配置五次重训的均值和样本标准差。该方案中，CBM + Clinical-17 的 Duke 平均 AUC 最高，CBM + Gate + Clinical-17 在固定阈值 0.5 下的 Duke 平均 F1 最高。两种方案为当前输入条件下的跨队列判别表现提供了初步证据，概率校准和临床效益仍需在独立队列中评价[54]。

4.9 本章小结

本章在影像预测与概念瓶颈框架中引入临床结构化信息。完整临床输入采

用统一的 18 维编码，门控输入由 HR、MP 和绝经状态组成，共 8 维。训练集受体分层与概念得分的探索性关联为融合设计提供参考。本章考察了概念直接融合 CBM + Clinical-18、仅门控 CBM + Gate、门控与原始临床联合融合 CBM + Gate + Clinical-18，以及门控与临床嵌入联合融合 CBM + Gate + Clinical-128。

在 I-SPY2 内部测试中，表中结果以各配置的重复运行汇总呈现。CBM + Clinical-18 和 CBM + Gate 的平均 AUC 分别为 0.7898 和 0.7954，均高于 CBM 的 0.7079。CBM + Gate 的预测头接收 13 维调制概念。CBM + Gate + Clinical-18 在此基础上接入完整的 18 维临床编码，平均 AUC 为 0.8015。CBM + Gate + Clinical-128 接入 128 维临床嵌入，在八种内部测试配置中取得最高平均 AUC 0.8157、F1 0.5954 和敏感度 0.9280。

比较两种联合配置，在固定阈值 0.5 下，CBM + Gate + Clinical-128 的漏报比例较低，CBM + Gate + Clinical-18 的误报比例较低。前者的平衡准确率较高，后者在本测试集的实际类别构成下总体错误率较低。本章同时给出了在 logit 尺度上分解基础概念贡献、门控增量和直接临床贡献的方法。

在 I-SPY2 内部配对对照中，固定完整模型权重，遮蔽实际 MP 并加权预测后，测试 AUC 从 0.8063 降至 0.7229，配对降幅为 0.0834（95% CI 为 0.0080–0.1657）。Duke 在相同权重和加权规则下的 AUC 为 0.6355（95% CI 为 0.5545–0.7123）。在去除 MP 后各重训五次的共有字段配置中，CBM + Clinical-17 在 I-SPY2 测试集与 Duke 队列均取得最高平均 AUC，分别为 0.7815 和 0.6946。固定阈值 0.5 下，CBM + Gate + Clinical-17 的 Duke 平均 F1 最高，为 0.4780。

两队列标准化后的全图减影 P99 中位数接近，掩码内 P99 和掩码体积占比仍有差异。两种方案在 Duke 上均保留一定的 pCR 判别能力，但冻结完整模型的加权 AUC 和共有字段中最高的平均 AUC 均低于各自对应的内部结果。这为当前影像与临床输入条件下的跨队列泛化提供了初步证据。

结　论

本文利用乳腺癌患者治疗前的 DCE-MRI 和临床资料构建可解释的 pCR 预测框架，并分析放射学概念与临床信息如何共同形成病例级预测。主要结论如下。

（1）建立了三通道 DCE-MRI 影像基线。模型以增强前相、早期增强相和减影为输入，采用结合通道注意力与肿瘤掩码引导空间注意力的三维 ResNet-50 提取病例特征并预测 pCR。I-SPY2 内部测试的平均 AUC 为 0.7146。在阈值 0.5 下，平均特异度为 0.7827，平均敏感度为 0.4429，pCR 病例检出仍有局限。

（2）构建了基于投影的概念瓶颈模型。模型冻结三维 ResNet-50 影像主干，将病例特征线性投影至 PMC-CLIP 文本嵌入空间，再以其与 13 个放射学概念的余弦相似度作为线性分类头的输入。分类得分由截距和各概念的加权贡献组成，可逐病例识别哪些概念推高或压低 pCR 分类得分。内部平均 AUC 为 0.7079，与影像基线接近。逐病例置零贡献绝对值最大的五个概念得分后，AUC 下降 0.041，较随机置零五个概念的 0.021 降幅更大，体现了模型对高贡献概念的依赖。测试时扰动量化了轻微输入变化下的概念得分波动。

（3）临床信息通过直接融合和门控调制补充影像概念，两种接入方式均可改善当前队列中的判别表现。直接融合和仅门控配置的内部平均 AUC 分别为 0.7898 和 0.7954。采用 128 维临床嵌入的联合模型取得最高内部平均 AUC（0.8157），在固定阈值下较采用 18 维临床编码的联合模型漏报较少、误报较多。联合模型保留了病例级可解释性，可以分别量化基础概念贡献、门控增量和直接临床贡献，说明影像与临床信息如何共同形成该病例的预测。

（4）两种外部评价方案在 Duke 队列上的判别表现均低于相应的内部结果。MP 不可获得时，固定完整模型权重并采用 MP 加权，AUC 由 I-SPY2 内部测试的 0.7229 降至 Duke 的 0.6355。使用共有临床字段重训后，直接融合概念与临床变量的模型在两队列上均取得该组配置中最高的平均 AUC，分别为 0.7815 和 0.6946。跨队列结果需结合临床字段的可获得性和相应预测方案理解。

后续可通过逐病例阅片标注检验概念得分与实际影像征象的对应关系，并在分割预训练病例与评价病例互斥的外部队列中进一步评价判别能力、概率校准和临床净获益。

参考文献

[1] SUNG H, FERLAY J, SIEGEL R L, et al. Global cancer statistics 2020: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries [J]. CA: A Cancer Journal for Clinicians, 2021, 71 (3): 209-249.

[2] SPRING L M, FELL G, ARFE A, et al. Pathologic Complete Response After Neoadjuvant Chemotherapy and Impact on Breast Cancer Recurrence and Survival: A Comprehensive Meta-analysis [J]. Clinical Cancer Research, 2020, 26 (12): 2838-2848.

[3] O'DONNELL J P M, GASIOR S A, DAVEY M G, et al. The Accuracy of Breast MRI Radiomic Methodologies in Predicting Pathological Complete Response to Neoadjuvant Chemotherapy: A Systematic Review and Network Meta-analysis [J]. European Journal of Radiology, 2022, 157: 110561.

[4] CORTAZAR P, ZHANG L, UNTCH M, et al. Pathological Complete Response and Long-term Clinical Benefit in Breast Cancer: The CTNeoBC Pooled Analysis [J]. The Lancet, 2014, 384 (9938): 164-172.

[5] ALAMOODI M. Factors Affecting Pathological Complete Response in Locally Advanced Breast Cancer Cases Receiving Neoadjuvant Therapy: A Comprehensive Literature Review [J]. European Journal of Breast Health, 2024, 20 (1): 8-14.

[6] MANN R M, CHO N, MOY L. Breast MRI: State of the Art [J]. Radiology, 2019, 292 (3): 520-536.

[7] LI W, NEWITT D C, GIBBS J, et al. I-SPY 2 Breast Dynamic Contrast Enhanced MRI Trial (ISPY2) (Version 1) [DS/OL]. The Cancer Imaging Archive, 2022.

[8] LECUN Y, BENGIO Y, HINTON G. Deep Learning [J]. Nature, 2015, 521 (7553): 436-444.

[9] YAMASHITA R, NISHIO M, DO R K G, et al. Convolutional Neural Networks: An Overview and Application in Radiology [J]. Insights into Imaging, 2018, 9 (4): 611-629.

[10] DEBELEE T G, SCHWENKER F, IBENTHAL A, et al. Survey of Deep Learning in Breast Cancer Image Analysis [J]. Evolving Systems, 2020, 11 (1): 143-163.

[11] RUDIN C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead [J]. Nature Machine Intelligence, 2019, 1 (5): 206-215.

[12] KOH P W, NGUYEN T, TANG Y S, et al. Concept bottleneck models [C] // Proceedings of Machine Learning Research, Vol 119: Proceedings of the 37th International Conference on Machine Learning, [S.l.]: PMLR, 2020: 5338-5348.

[13] KRASNIQI E, FILOMENO L, ARCURI T, et al. Multimodal Deep Learning for Predicting Neoadjuvant Treatment Outcomes in Breast Cancer: A Systematic Review [J]. Biology Direct, 2025, 20 (1): 72.

[14] HUYNH B Q, ANTROPOVA N, GIGER M L. Comparison of breast DCE-MRI contrast time points for predicting response to neoadjuvant chemotherapy using deep convolutional neural network features with transfer learning [C] // Proceedings of SPIE, Vol 10134: Medical Imaging 2017: Computer-Aided Diagnosis, Bellingham, WA: SPIE, 2017: 101340U.

[15] QU Y-H, ZHU H-T, CAO K, et al. Prediction of pathological complete response to neoadjuvant chemotherapy in breast cancer using a deep learning (DL) method [J]. Thoracic Cancer, 2020, 11 (3): 651-658.

[16] DAMMU H, REN T, DUONG T Q. Deep learning prediction of pathological complete response, residual cancer burden, and progression-free survival in breast cancer patients [J]. PLOS ONE, 2023, 18 (1): e0280148.

[17] BRAMAN N, EL ADOUI M, VULCHI M, et al. Deep learning-based prediction of response to HER2-targeted neoadjuvant chemotherapy from pre-treatment dynamic breast MRI: a multi-institutional validation study [PP/OL]. arXiv preprint arXiv:2001.08570, 2020.

[18] EL ADOUI M, DRISIS S, BENJELLOUN M. Multi-input Deep Learning Architecture for Predicting Breast Tumor Response to Chemotherapy Using Quantitative MR Images [J]. International Journal of Computer Assisted Radiology and Surgery, 2020, 15 (9): 1491-1500.

[19] JANÍČKOVÁ I, TAN Y Y, HELBICH T H, et al. Temporal Representation Learning of Phenotype Trajectories for pCR Prediction in Breast Cancer [C] // Medical Image Computing and Computer Assisted Intervention – MICCAI 2025, Cham: Springer Nature Switzerland, 2026: 606-615.

[20] HUANG X, XU Z, ZHAO Y, et al. Longitudinal MRI-based deep learning model for predicting pathological complete response in breast cancer: a multicenter, retrospective cohort study [J]. npj Precision Oncology, 2026, 10: 57.

[21] GAO Y, VENTURA-DIAZ S, WANG X, et al. An explainable longitudinal multi-modal fusion model for predicting neoadjuvant therapy response in women with breast cancer [J]. Nature Communications, 2024, 15: 9613.

[22] SIMONYAN K, VEDALDI A, ZISSERMAN A. Deep Inside Convolutional Networks: Visualising Image Classification Models and Saliency Maps [C] // Workshop Proceedings of the 2nd International Conference on Learning Representations, Banff, AB, Canada, 2014.

[23] ZHOU B, KHOSLA A, LAPEDRIZA A, et al. Learning Deep Features for Discriminative Localization [C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Los Alamitos, CA: IEEE Computer Society, 2016: 2921-2929.

[24] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization [C] // Proceedings of the IEEE International Conference on Computer Vision, Los Alamitos, CA: IEEE Computer Society, 2017: 618-626.

[25] YÜKSEKGÖNÜL M, WANG M, ZOU J. Post-hoc Concept Bottleneck Models [C] // The Eleventh International Conference on Learning Representations, [S.l.]: OpenReview, 2023.

[26] OIKARINEN T, DAS S, NGUYEN L M, et al. Label-free Concept Bottleneck Models [C] // The Eleventh International Conference on Learning Representations, [S.l.]: OpenReview, 2023.

[27] BUNNELL A, GLASER Y, VALDEZ D, et al. Learning a Clinically-Relevant Concept Bottleneck for Lesion Detection in Breast Ultrasound [C] // Lecture Notes in Computer Science, Vol 15003: Medical Image Computing and Computer Assisted Intervention – MICCAI 2024, Cham: Springer Nature Switzerland, 2024: 650-659.

[28] AYSEL H I, CAI X, PRUGEL-BENNETT A. Concept-Based Explainable Artificial Intelligence: Metrics and Benchmarks [PP/OL]. arXiv preprint arXiv:2501.19271, 2025.

[29] JIN C, GUO Z, LIN Y, et al. Learning with less supervision: A survey of label-efficient learning for medical image analysis [J]. Medical Image Analysis, 2026, 111: 104062.

[30] KHAN N, ADAM R, HUANG P, et al. Deep Learning Prediction of Pathologic Complete Response in Breast Cancer Using MRI and Other Clinical Data: A Systematic Review [J]. Tomography, 2022, 8 (6): 2784-2795.

[31] MAO N，DAI Y，ZHOU H，et al. A Multimodal and Fully Automated System for Prediction of Pathological Complete Response to Neoadjuvant Chemotherapy in Breast Cancer [J]. Science Advances，2025，11（18）：eadr1576.

[32] MA D，CAO J，CHENG H，et al. Longitudinal MRI-Clinical Multimodal Fusion for pCR Prediction in Breast Cancer [C] // Medical Image Computing and Computer Assisted Intervention – MICCAI 2025，Cham：Springer Nature Switzerland，2026：323-332.

[33] JING B，WANG K，SCHMITZ E，et al. Prediction of Pathological Complete Response to Chemotherapy for Breast Cancer Using Deep Neural Network with Uncertainty Quantification [J]. Medical Physics，2024，51（12）：9385-9393.

[34] NISHIZAWA T，MALDJIAN T，JIAO Z，et al. Attention-based multimodal deep learning for interpretable and generalizable prediction of pathological complete response in breast cancer [J]. Journal of Translational Medicine，2025，23：774.

[35] NEWITT D C，PARTRIDGE S C，ZHANG Z，et al. ACRIN 6698/I-SPY2 Breast DWI [DS/OL]. The Cancer Imaging Archive，2021.

[36] RUGO H S，OLOPADE O I，DEMICHELE A，et al. Adaptive Randomization of Veliparib–Carboplatin Treatment in Breast Cancer [J]. New England Journal of Medicine，2016，375（1）：23-34.

[37] PARK J W，LIU M C，YEE D，et al. Adaptive Randomization of Neratinib in Early Breast Cancer [J]. New England Journal of Medicine，2016，375（1）：11-22.

[38] ISENSEE F，JAEGER P F，KOHL S A A，et al. nnU-Net: A Self-configuring Method for Deep Learning-based Biomedical Image Segmentation [J]. Nature Methods，2021，18（2）：203-211.

[39] van DIJK J M，HAN L，BALKENENDE L，et al. One for All: UNET Training on Single-Sequence Masks for Multi-sequence Breast MRI Segmentation [C] // Artificial Intelligence and Imaging for Diagnostic and Treatment Challenges in Breast Care，Cham：Springer Nature Switzerland，2025：32-41.

[40] GARRUCHO L，KUSHIBAR K，REIDEL C-A，et al. A large-scale multicenter breast cancer DCE-MRI benchmark dataset with expert segmentations [J]. Scientific Data，2025，12：453.

[41] HE K，ZHANG X，REN S，et al. Deep Residual Learning for Image Recognition [C] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition，Los Alamitos，CA：IEEE Computer Society，2016：770-778.

[42] LIN T-Y, GOYAL P, GIRSHICK R, et al. Focal Loss for Dense Object Detection [C] //Proceedings of the IEEE International Conference on Computer Vision, Los Alamitos, CA: IEEE Computer Society, 2017: 2980-2988.

[43] HU J, SHEN L, SUN G. Squeeze-and-Excitation Networks [C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Los Alamitos, CA: IEEE Computer Society, 2018: 7132-7141.

[44] HUANG G, LIU Z, van der MAATEN L, et al. Densely Connected Convolutional Networks [C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Los Alamitos, CA: IEEE Computer Society, 2017: 4700-4708.

[45] WANG G, LI W, AERTSEN M, et al. Aleatoric Uncertainty Estimation With Test-Time Augmentation for Medical Image Segmentation With Convolutional Neural Networks [J]. Neurocomputing, 2019, 335: 34-45.

[46] GEIFMAN Y, EL-YANIV R. Selective Classification for Deep Neural Networks [C] //Advances in Neural Information Processing Systems: Vol 30, Red Hook, NY: Curran Associates, 2017: 4878-4887.

[47] RADFORD A, KIM J W, HALLACY C, et al. Learning Transferable Visual Models From Natural Language Supervision [C] //Proceedings of Machine Learning Research, Vol 139: Proceedings of the 38th International Conference on Machine Learning, [S.l.]: PMLR, 2021: 8748-8763.

[48] LIN W, ZHAO Z, ZHANG X, et al. PMC-CLIP: Contrastive Language-Image Pre-training Using Biomedical Documents [C] //Medical Image Computing and Computer Assisted Intervention – MICCAI 2023, Cham: Springer Nature Switzerland, 2023: 525-536.

[49] D'ORSI C J, SICKLES E A, MENDELSON E B, et al. ACR BI-RADS Atlas: Breast Imaging Reporting and Data System [M]. 5th ed. Reston, VA: American College of Radiology, 2013.

[50] SPAK D A, PLAXCO J, SANTIAGO L, et al. BI-RADS fifth edition: A summary of changes [J]. Diagnostic and Interventional Imaging, 2017, 98(3): 179-190.

[51] LI W, NEWITT D C, GIBBS J, et al. Predicting Breast Cancer Response to Neoadjuvant Treatment Using Multi-feature MRI: Results from the I-SPY 2 TRIAL [J]. npj Breast Cancer, 2020, 6: 63.

[52] PEREZ E, STRUB F, de VRIES H, et al. FiLM: Visual Reasoning with a General Conditioning Layer [C] //Proceedings of the AAAI Conference on Artificial Intelligence: Vol 32, Palo Alto, CA: AAAI Press, 2018: 3942-3951.

[53] BRODERSEN K H, ONG C S, STEPHAN K E, et al. The Balanced Accuracy and Its Posterior Distribution [C] //2010 20th International Conference on Pattern Recognition, [S.l.]: IEEE, 2010: 3121-3124.

[54] RILEY R D, ARCHER L, SNELL K I E, et al. Evaluation of clinical prediction models (part 2): how to undertake an external validation study [J]. BMJ, 2024, 384: e074820.

[55] SAHA A, HAROWICZ M R, GRIMM L J, et al. A machine learning approach to radiogenomics of breast cancer: a study of 922 subjects and 529 DCE-MRI features [J]. British Journal of Cancer, 2018, 119 (4): 508-516.

[56] SAHA A, HAROWICZ M R, GRIMM L J, et al. Dynamic contrast-enhanced magnetic resonance images of breast cancer patients with tumor locations [DS/OL]. The Cancer Imaging Archive, 2021.

[57] HELD U, KESSELS A, GARCÍA-AYMERICH J, et al. Methods for Handling Missing Variables in Risk Prediction Models [J]. American Journal of Epidemiology, 2016, 184 (7): 545-551.

[58] HOOGLAND J, van BARREVELD M, DEBRAY T P A, et al. Handling missing predictor values when validating and applying a prediction model to new patients [J]. Statistics in Medicine, 2020, 39 (25): 3591-3607.

[59] WEI M, SHU Z, LYU M, et al. Integrating MRI radiomics and deep learning for predicting pathologic complete response to neoadjuvant chemotherapy in breast cancer: a multicenter study [J]. BMC Medical Imaging, 2026, 26: 505.

攻读硕士学位期间取得创新性成果

（一）发表的学术论文

[1] Tan J, Liang X, Hu X, et al. Testable concept bottlenecks for pretreatment pCR prediction in breast DCE-MRI: faithfulness and reliability[C] // Medical Image Computing and Computer Assisted Intervention – MICCAI 2026, Part V. Cham: Springer, 2027: 523–532.

哈尔滨工业大学学位论文原创性声明和使用权限

学位论文原创性声明

本人郑重声明：此处所提交的学位论文《基于多模态特征融合的乳腺癌病理完全缓解预测研究》，是本人在导师指导下，在哈尔滨工业大学攻读学位期间独立进行研究工作所取得的成果，且学位论文中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本学位论文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。

作者签名：　　日期：　　年　　月　　日

学位论文使用权限

学位论文是研究生在哈尔滨工业大学攻读学位期间完成的成果，知识产权归属哈尔滨工业大学。学位论文的使用权限如下：

（1）学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文，并向国家图书馆报送学位论文；（2）学校可以将学位论文部分或全部内容编入有关数据库进行检索和提供相应阅览服务；（3）研究生毕业后发表与此学位论文研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉学位论文的使用权限，并将遵守有关规定。

作者签名：　　日期：　　年　　月　　日

导师签名：　　日期：　　年　　月　　日

致　谢

待补充致谢正文。